Seminarios de Bioestadística



Seminario 3 | Herramientas para visualizar distribuciones

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2026/2027

Outline

Visualizaciones

- Histogramas
- Curvas acumulativas
- QQ-plots

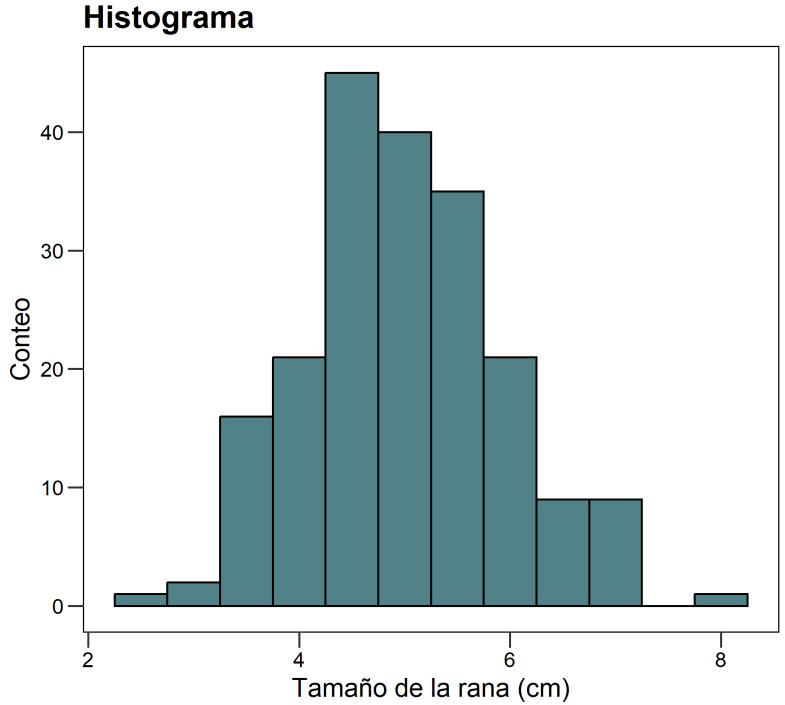
Herramientas para comparar distribuciones visualmente

Normalmente, tenemos datos y queremos encontrar la distribución “adecuada” para ellos. Eso significa que queremos hallar una distribución que modele los datos de manera apropiada. El flujo de trabajo debería ser algo así:

1. Ajusta tus datos a una distribución que consideres plausible. Veremos cómo hacer esto en R. El ajuste te dará los mejores parámetros para esa distribución, dados tus datos.
2. Compara visualmente la distribución teórica con tus datos. La teórica, en este caso, es el ajuste que acabas de obtener. En la visualización, un buen ajuste no muestra desviaciones sistemáticas de los puntos de datos respecto a la teórica.
3. Haz lo mismo con otras distribuciones plausibles.
4. Decide cuál ajuste te parece el mejor.

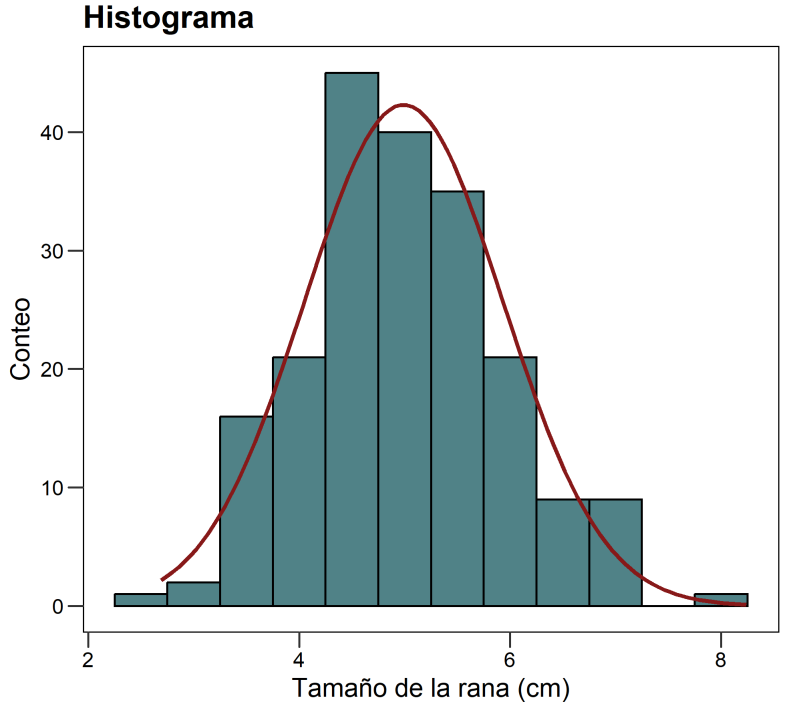
Herramientas para comparar distribuciones visualmente

- Histograma. Cuando se dispone de una muestra suficientemente grande, el histograma permite aproximar la forma de la distribución de probabilidad subyacente.



Herramientas para comparar distribuciones visualmente

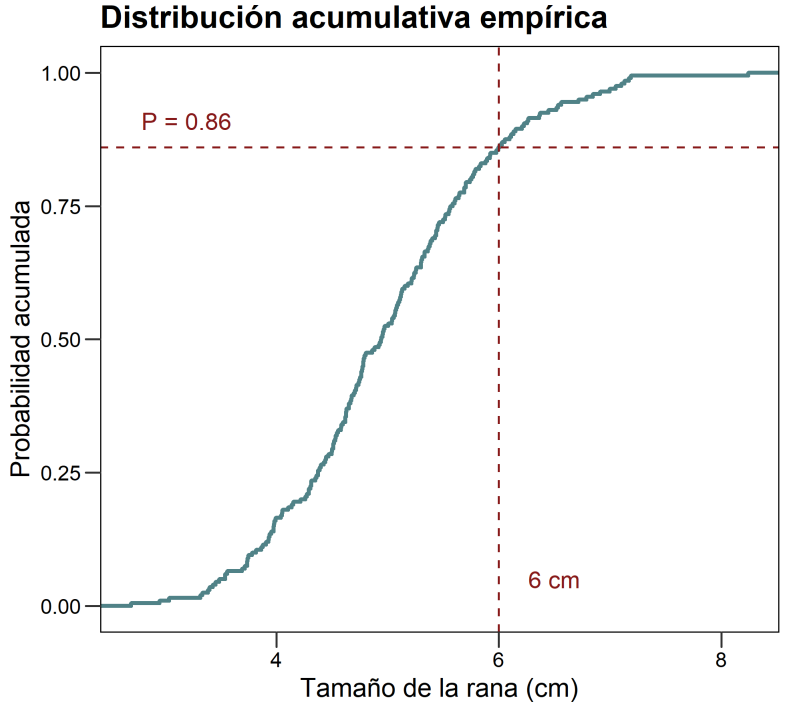
- Histograma. Cuando se dispone de una muestra suficientemente grande, el histograma permite aproximar la forma de la distribución de probabilidad subyacente.



- Podríamos mirar si sigue una distribución normal (*gaussiana*)
- El problema es que muchas distribuciones tienen forma de campana sin ser normales
- Una solución es mirar la distribución acumulativa

Herramientas para comparar distribuciones visualmente

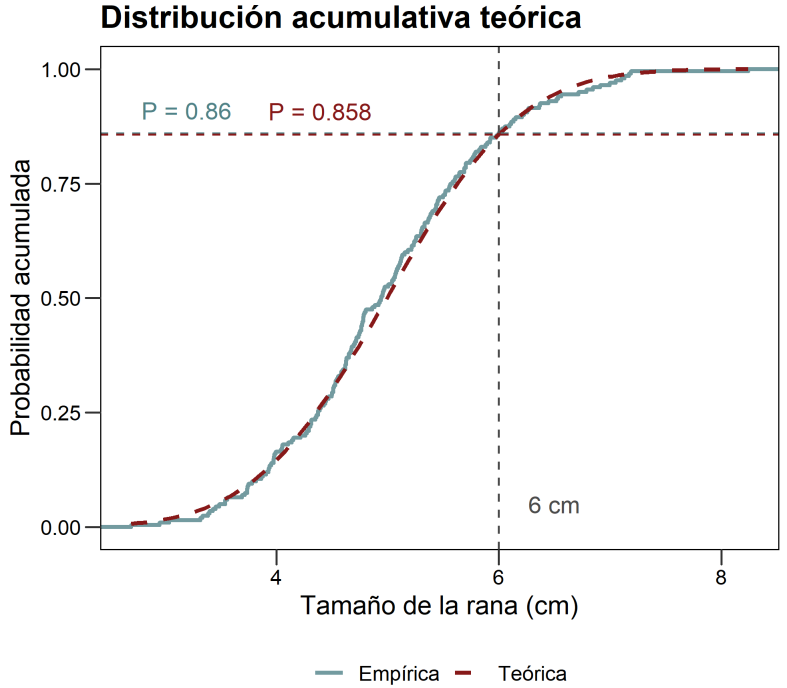
- Distribución acumulativa empírica. Para cada valor, indica la probabilidad de que una observación sea menor o igual a ese valor.



- La distribución empírica se calcula a partir de los datos y muestra pequeños "saltos" en cada observación.

Herramientas para comparar distribuciones visualmente

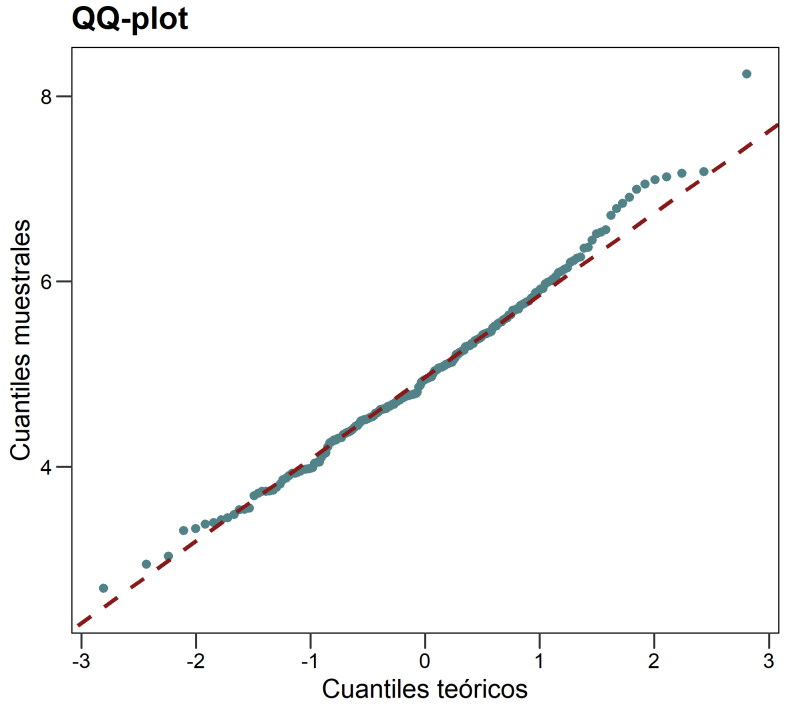
- Distribución acumulativa teórica: Para cada valor, muestra la probabilidad esperada de que una observación sea menor o igual a ese valor.



- La curva roja es la probabilidad acumulada que tendríamos si los datos fueran perfectamente normales, con la media y la desviación estándar que hemos medido en la muestra. Si los datos azules se separan de ella de forma sistemática, la normal no es un buen modelo.
- Al usar este tipo de gráficos para comparar distribuciones, es más fácil identificar desviaciones respecto a lo esperado.

Herramientas para comparar distribuciones visualmente

- QQ-plot: gráfico que compara los cuantiles de un conjunto de datos observados con los cuantiles de una distribución teórica. Sirve para evaluar visualmente si los datos siguen una distribución específica. Por defecto, asume la distribución normal estándar.

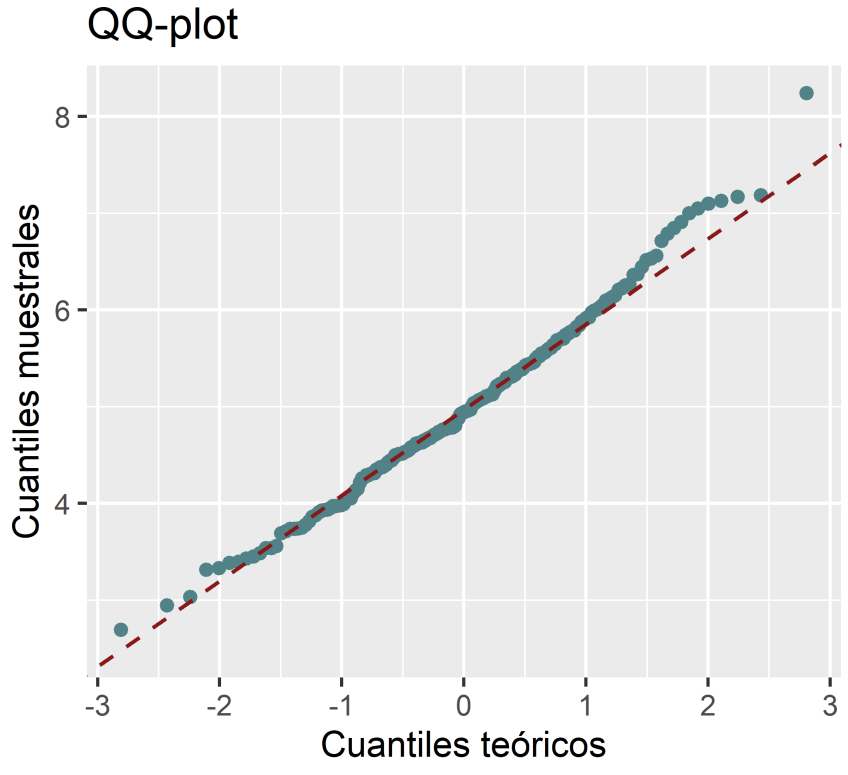


- El cuantil 25 indica el valor k por debajo del cual se encuentra el 25% de los datos.
- Cuando la distribución teórica y los datos muestreados son similares, los puntos del QQ-plot se alinean sobre la línea de referencia.
- Con la normal estándar como referencia, la ordenada en el origen de la recta es μ y la pendiente es σ: solo importa que los puntos sigan una recta.

QQ-plot: comprobar si unos datos siguen una distribución normal

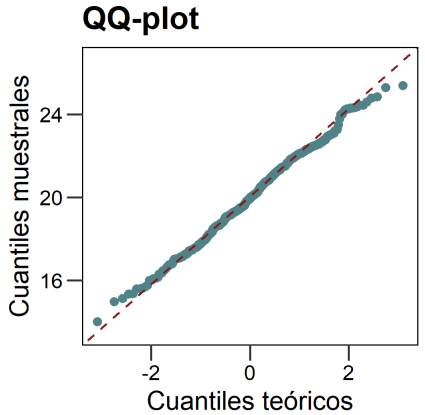
```r
# Simular datos
set.seed(123)
n <- 200
mean_size <- 5
sd_size <- 1
frog_size <- rnorm(n,
                   mean = mean_size,
                   sd = sd_size)
data <- data.frame(frog_size = frog_size)

# Crear QQ-plot
ggplot(data, aes(sample = frog_size)) +
  stat_qq(distribution = qnorm, color = "cadetl
  stat_qq_line(distribution = qnorm,
               dparams = list(mean = 0, sd = 1
               color = "firebrick4",
               linetype = "dashed", size = 1) +
  labs(
    title = "QQ-plot",
    x = "Cuantiles teóricos",
    y = "Cuantiles muestrales"
  )
```



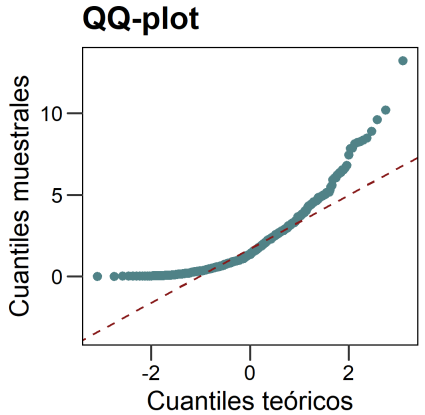
QQ-plot: comprobar si unos datos siguen una distribución normal

```r
set.seed(10)
vector_normal <- rnorm(n = 500,
                       mean = 20, sd = 2)
```



- Datos distribuidos de manera normal

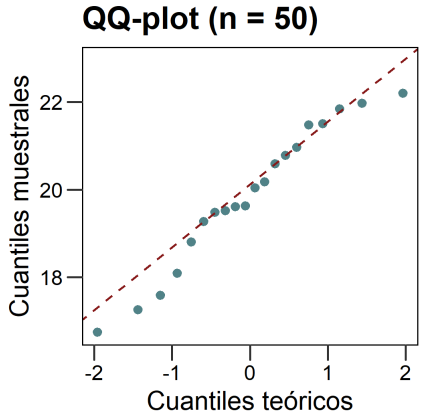
```r
set.seed(10)
vector_exp <- rexp(n = 500,
                   rate = 0.5)
```



- Datos no distribuidos de manera normal

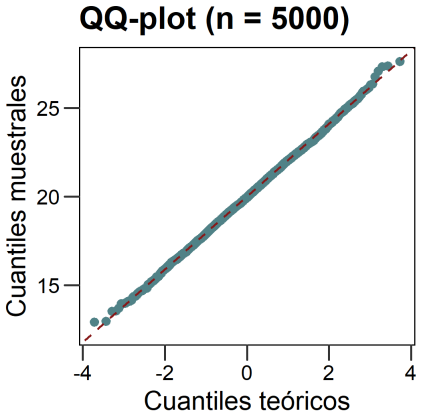
QQ-plot: comprobar si unos datos siguen una distribución normal

```
set.seed(10)
vector_normal <- rnorm(n = 20,
                       mean = 20, sd = 2)
```



- Desviaciones aparentes de la normalidad pueden ser debidas a un tamaño de muestra muy pequeño.

```
set.seed(10)
vector_normal_5000 <- rnorm(n = 5000,
                            mean = 20, sd = 2)
```



- A tamaños más grandes, apenas hay desviaciones.

Resumen

Muestreo y distribuciones

- En estadística, los experimentos se consideran como procesos de muestreo. Muestrear significa “extraer eventos” de una población de interés. Si los eventos se extraen de manera aleatoria e independiente, los resultados tienen más probabilidades de representar adecuadamente la realidad.
- Una distribución de probabilidad asigna probabilidades a los posibles resultados (en distribuciones continuas: a intervalos de resultados).
- Las distribuciones discretas dan probabilidades para resultados discretos, por ejemplo, conteos. En las distribuciones continuas, a cada valor se le asigna una densidad, y las probabilidades se calculan integrando la densidad en el intervalo de interés.

Distribuciones comunes en datos biológicos

- La distribución binomial modela el número de éxitos en una serie de ensayos.
- La distribución de Poisson se utiliza a menudo para modelar datos de conteo. Supone que los conteos ocurren sobre un volumen o periodo de tiempo fijo. Aproxima a la binomial cuando n es grande y p es pequeña.
- La distribución gaussiana o normal modela mediciones repetidas de lo mismo y es una distribución continua.

Vídeo resumen



The Binomial, Poisson and Normal Distributions: summary of their relationships

Maths Doctor





Ver en

Contacto

Marta Coronado Zamora	David Castellano
marta.coronado@uab.cat	david.castellano@uab.cat
@geneticament.bsky.social	@castellanoed.bsky.social
Universitat Autònoma de Barcelona	University of Arizona

Créditos

Adaptado de: CSDA tutorial - Probability distributions (EMBL, Sarah Kaspar, PhD)

Dr. Hafid Laayouni por compartir sus materiales