Bootstrap y test de permutación

Bioestadística

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2026/2027



Outline

- ¿Qué es **remuestrear**?
- ¿Por qué necesitamos **remuestrear**?
- Dos métodos:
  - *Bootstrap*
  - Test de permutación

De las fórmulas a la simulación

En los temas anteriores calculamos la incertidumbre con fórmulas:

- Error estándar: $SE = \frac{s}{\sqrt{n}}$
- IC: $\bar{x} \pm z \times SE$
- p-valor: estandarizamos, $z = \frac{\bar{x} - \mu_0}{SE}$, y miramos el área bajo la normal

Todo esto depende de conocer la distribución muestral del estadístico (normal o t), algo que solo tenemos para unos pocos estadísticos y bajo ciertos supuestos.

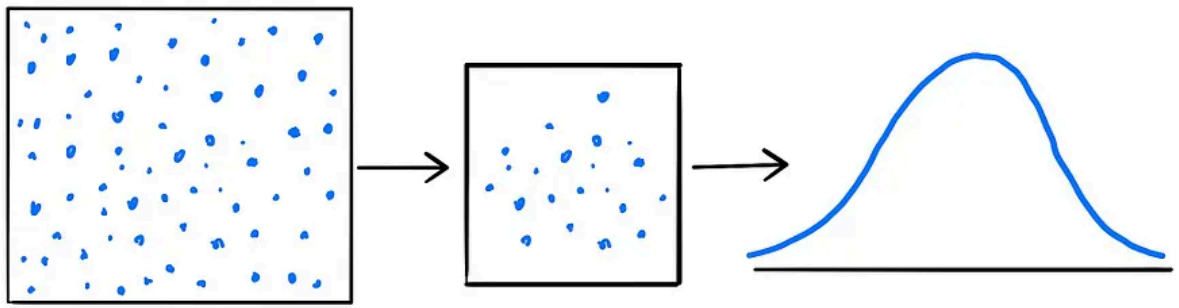
¿Y si el estadístico es la mediana o un cociente, los datos no son normales o la muestra es pequeña?

> Idea: en lugar de deducir la distribución muestral con matemáticas, la simulamos con el ordenador remuestreando los datos.

- *Bootstrap* → error estándar e IC, sin fórmula
- Test de permutación → p-valor, sin fórmula

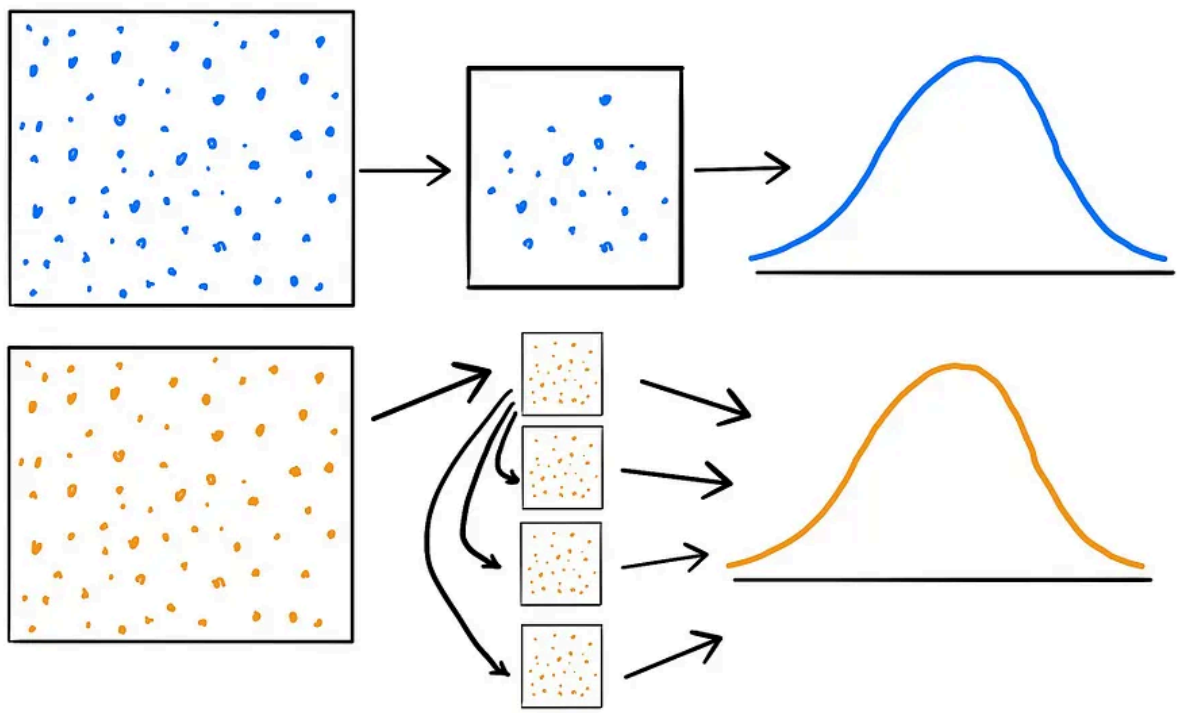
Muestra y muestreo

- Una **muestra** es un subconjunto de la población
- El **muestreo** es la selección de un subconjunto de unidades dentro de una población para estimar las características de toda la población



Remuestreo (*resampling*)

- Remuestreo consiste en muestrear una muestra
- La muestra original se considera como la población
- Remuestrear es un método no-paramétrico - no asume que los datos siguen una distribución concreta (como la normal)



Métodos paramétricos vs. no paramétricos

- Un método **paramétrico** asume que los datos siguen una distribución concreta, descrita por unos pocos **parámetros**

Ejemplos:

- Distribución de Poisson: un único parámetro, λ (media de ocurrencias por unidad de tiempo)
- Distribución normal: dos parámetros, μ (media) y σ (desviación estándar)

- Si la distribución asumida es correcta → estimaciones fiables, intervalos de confianza válidos, tests de hipótesis correctos
- Si la distribución asumida **no** es correcta → conclusiones potencialmente engañosas, intervalos de confianza inválidos

- Los métodos **no paramétricos** (o *distribution-free*), como el remuestreo, no dependen de que una distribución concreta sea la correcta

¿Por qué es útil el remuestreo?

- Para algunos estadísticos (como la media) existen fórmulas clásicas que nos dan su error estándar o su intervalo de confianza

- Pero, ¿y si el estadístico que nos interesa no tiene una fórmula conocida? (por ejemplo, la mediana)

Otras limitaciones:

- Los datos no siguen una distribución normal
- La muestra es pequeña (el test de permutación funciona bien con pocos datos; el *bootstrap* necesita muestras razonablemente grandes)
- Conseguir más datos es caro, lento o directamente imposible (secuenciar más genomas, más pacientes, ...)

- El remuestreo nos permite estimar la variabilidad de cualquier estadístico, sea cual sea su fórmula, sin asumir una distribución concreta, simplemente recalculándolo muchas veces sobre variaciones de nuestra propia muestra

Supuestos del remuestreo

- Los estadísticos muestrales son aproximaciones lo bastante buenas al estadístico poblacional como para que podamos remuestrear la muestra en lugar de la población, y aun así estimar bien los errores estándar
    - Ejemplo con la media: al remuestrear repetidamente nuestra muestra, obtenemos muchas medias distintas; asumimos que la variabilidad entre esas medias (su desviación estándar) se parece a la que tendríamos si pudiéramos repetir el muestreo directamente sobre la población real

Métodos de remuestreo

Bootstrapping

- Se utiliza para estimar la precisión de los estadísticos muestrales extrayendo aleatoriamente, con reemplazamiento, de la muestra original

Test de permutación

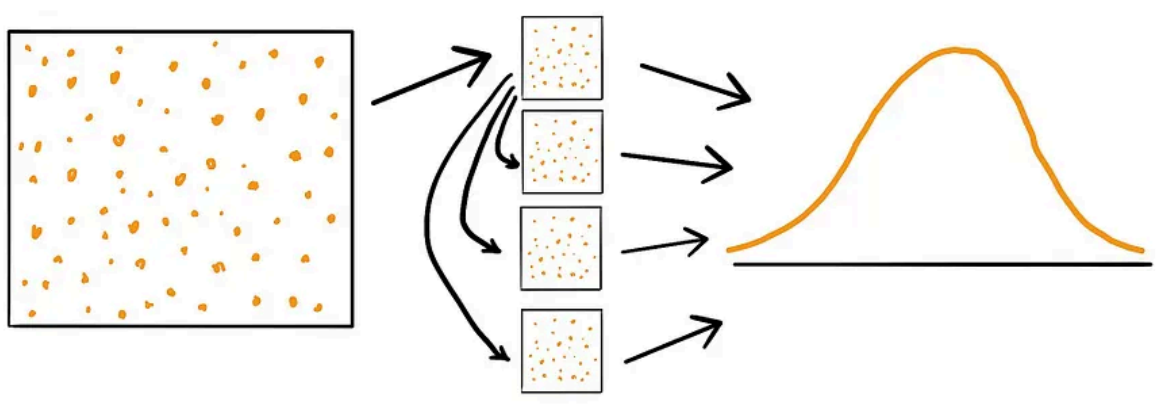
- Un test de hipótesis no paramétrico

Bootstrapping

Efron & Tibshirani (1993): Libro clásico que popularizó el método.

- Idea central: Remuestrear con reemplazo para estimar la distribución de un estadístico y obtener intervalos de confianza, sesgo y varianza.

> Muy flexible; necesita muestras representativas y mejor con *n* grande; impulsado por computación y, más tarde, por big data.

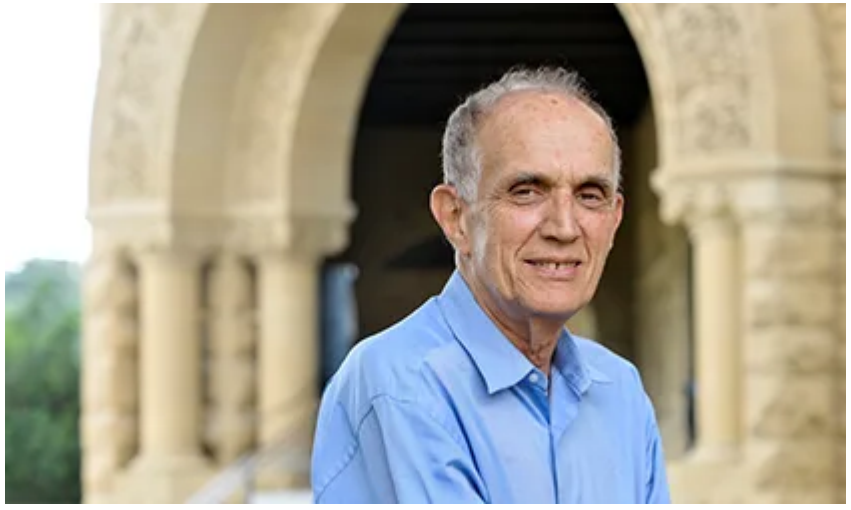


Bootstrapping

La idea de Efron:

> Hacer inferencia estadística usando solo la muestra disponible, tratándola como si fuera la población.

- Esto revolucionó la estadística computacional.
- Antes del bootstrap, los estadísticos estaban limitados por las matemáticas.
- Después del bootstrap, estaban limitados solo por la computación.
- El *bootstrap* se convirtió en una de las herramientas clave de la estadística moderna y del big data.



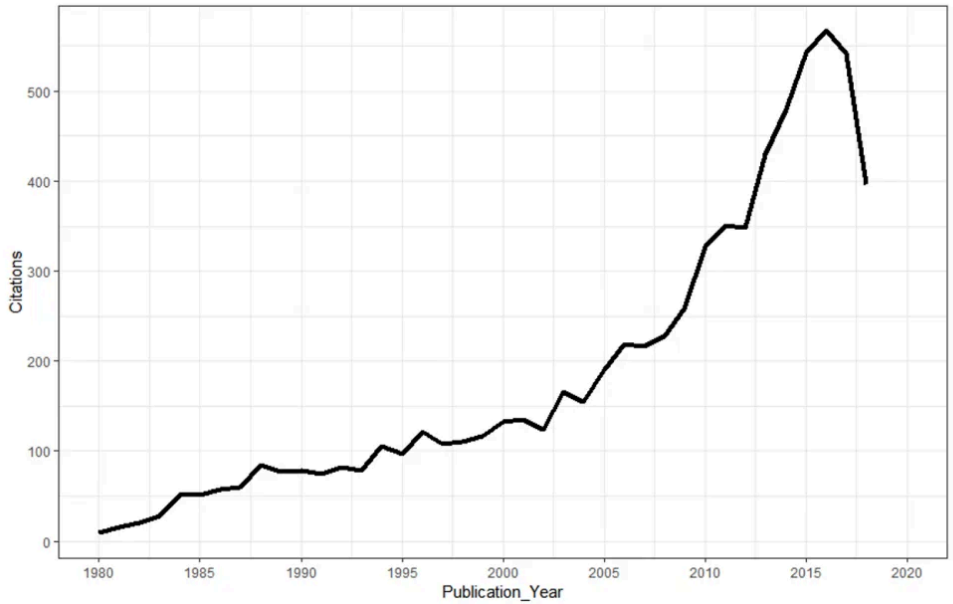
Bradley Efron - International Prize in Statistics (el "Nobel" de la estadística), anunciado en 2018 y entregado en 2019, por la creación del método *bootstrap*: *a method that "transformed science's ability to use and understand data and helped usher in the era of data analysis through computing"*

Bootstrapping

La idea de Efron:

> Hacer inferencia estadística usando solo la muestra disponible, tratándola como si fuera la población.

- Esto revolucionó la estadística computacional.
- Antes del bootstrap, los estadísticos estaban limitados por las matemáticas.
- Después del bootstrap, estaban limitados solo por la computación.
- El *bootstrap* se convirtió en una de las herramienta clave de la estadística moderna y del big data.



Número de citas del paper de Efron de 1979, por año (a fecha de septiembre 2026: 30,245 citas)

Bootstrapping

¿Qué significa “bootstrap” coloquialmente?

> *“To pull oneself up by one’s own bootstraps.”*

Literalmente:

> “levantarse tirando de los cordones de tus propios zapatos.”

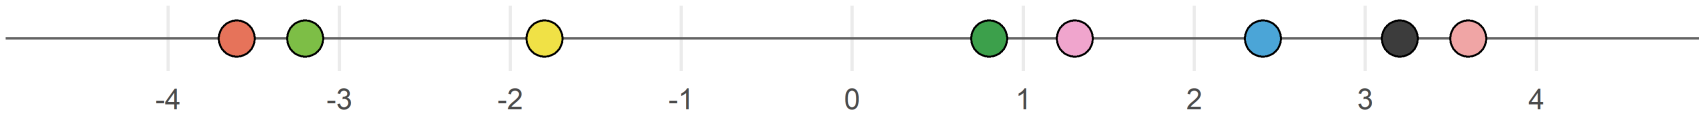
- La idea es hacer algo sin ayuda externa, usando solo lo que ya tienes. Efron usó el término porque su método hace **estadística remuestreando únicamente la muestra disponible, sin más información que los propios datos.**
- Es decir: los datos “se levantan solos”, reconstruyendo su propia variabilidad.

Bootstrapping

- Imagina que hemos desarrollado un nuevo medicamento para tratar una enfermedad



- Damos el medicamento a 8 personas diferentes para tratar esa enfermedad:



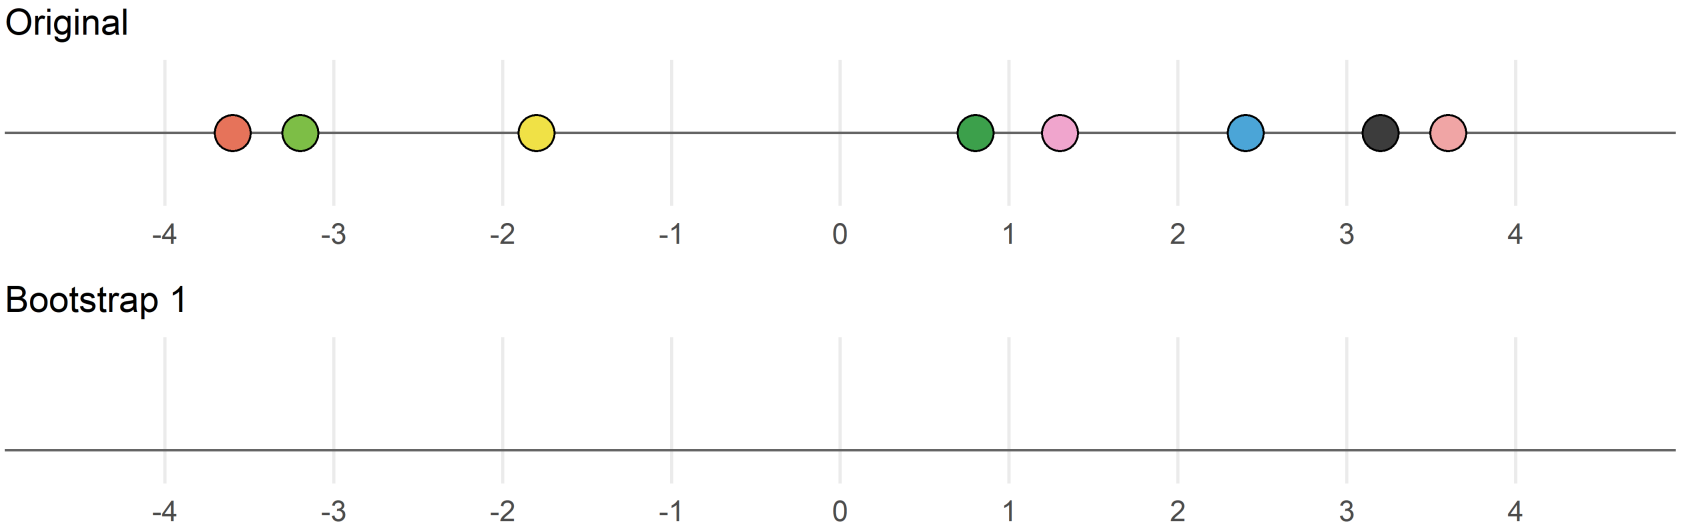
- La media de la respuesta al fármaco es 0.338

- ¿Hace algo el fármaco? Quizás el incremento de 0.338 es por cosas que no podemos controlar... **¿podemos hacer algo?**

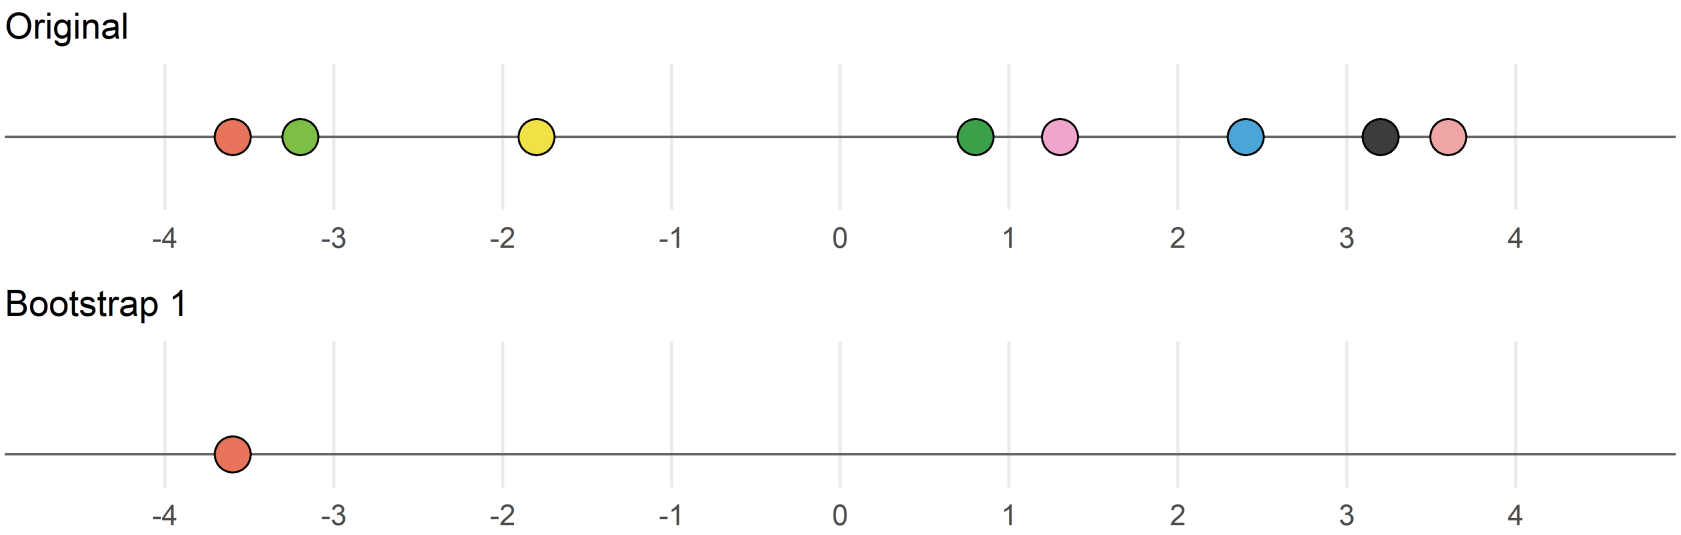
Sí, repetir el experimento (💸 , ⌛)

- O utilizar *bootstrapping!*

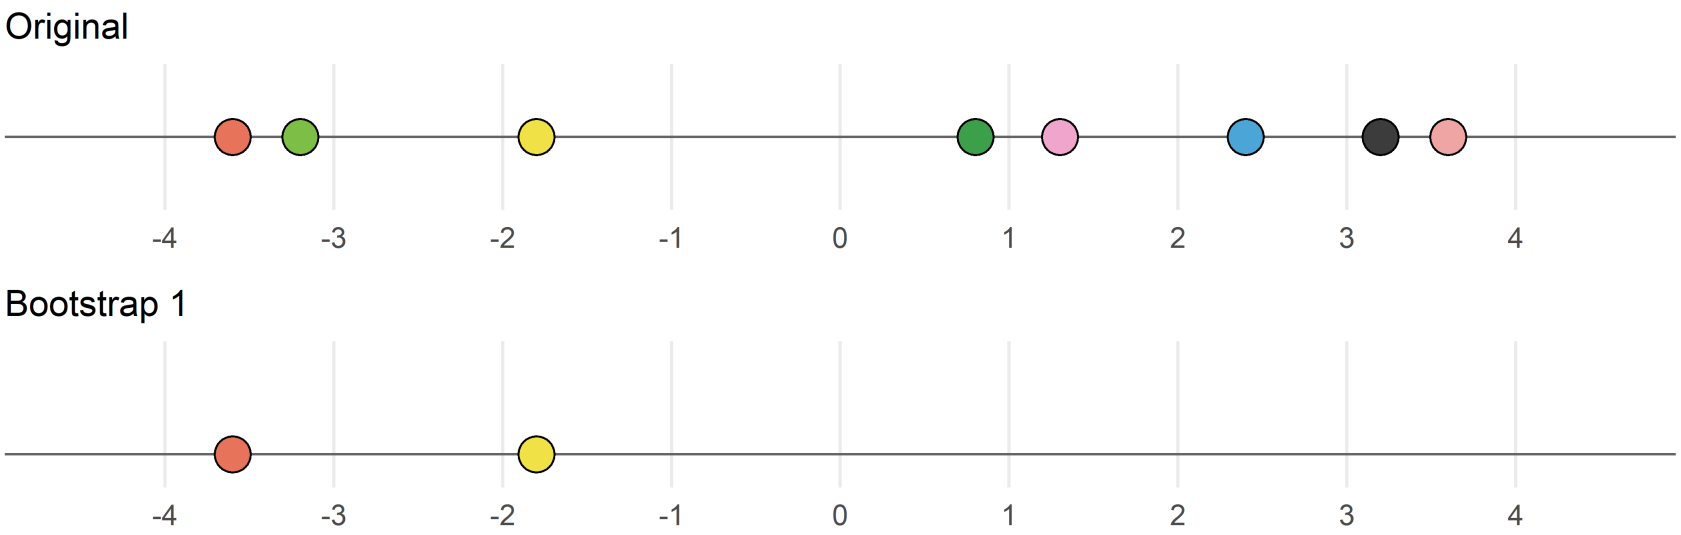
Bootstrapping



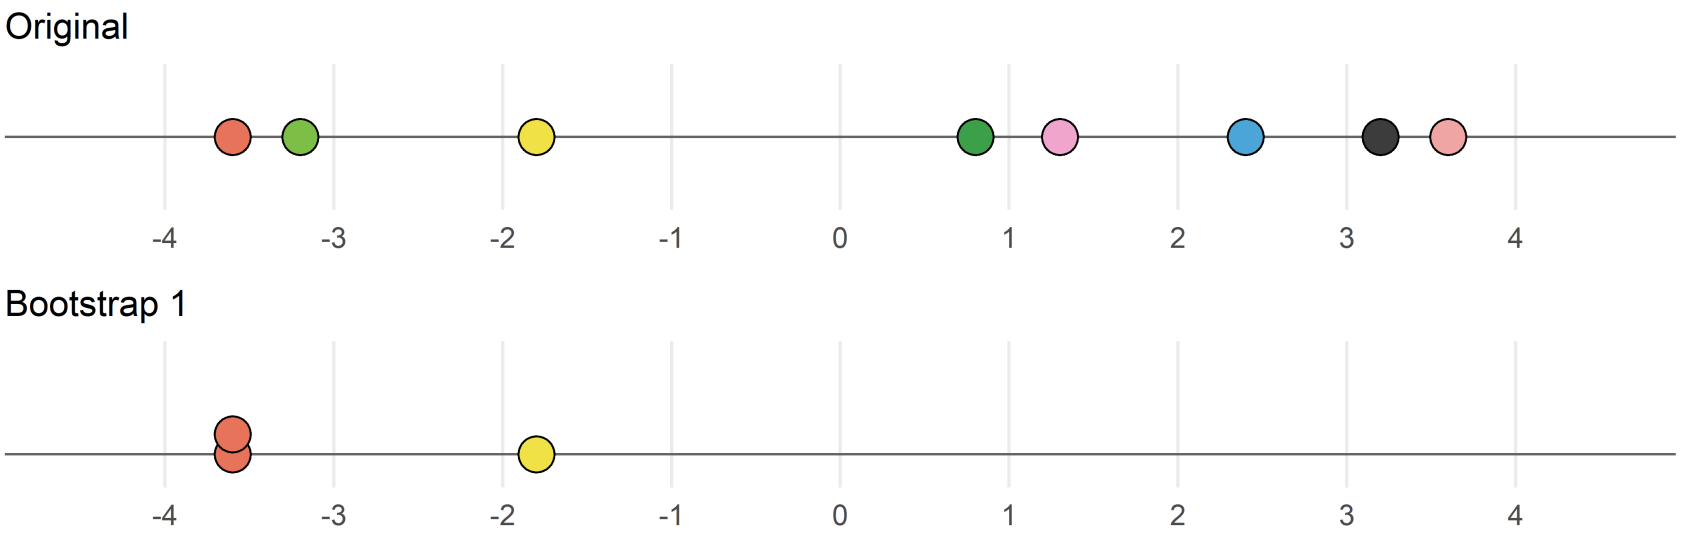
Bootstrapping



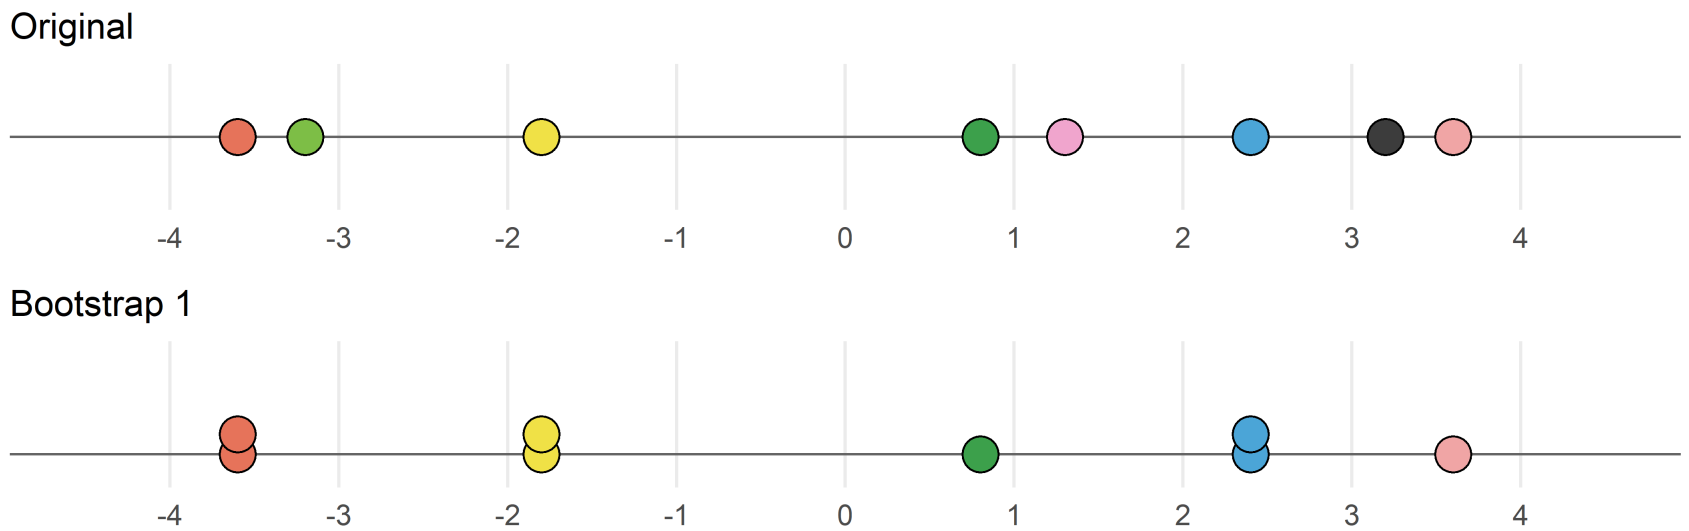
Bootstrapping



Bootstrapping



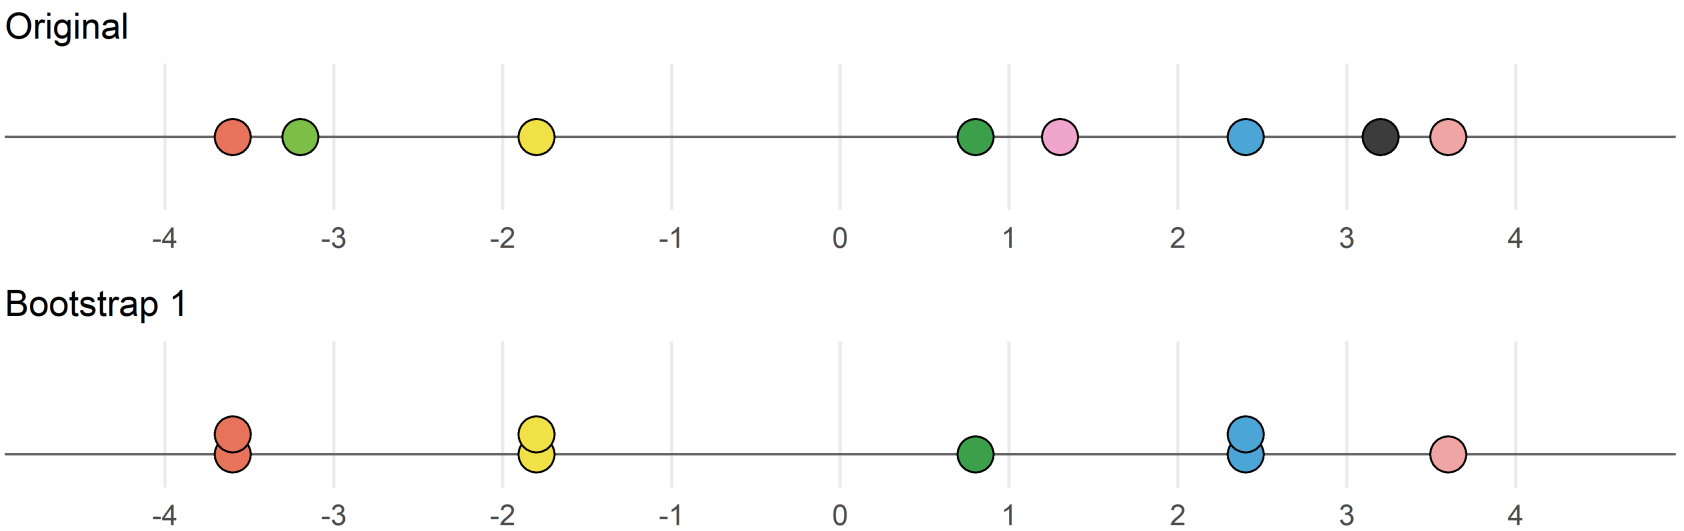
Bootstrapping



- Escogemos 8 valores (el tamaño de la muestra original)
- Cada vez escogemos entre los 8 valores originales
- Puede haber datos repetidos (muestreo con reemplazamiento, *sampling with replacement*)

> Este nuevo conjunto de datos, creado con muestreo con reemplazamiento, se llama "muestra *bootstrap*"

Bootstrapping

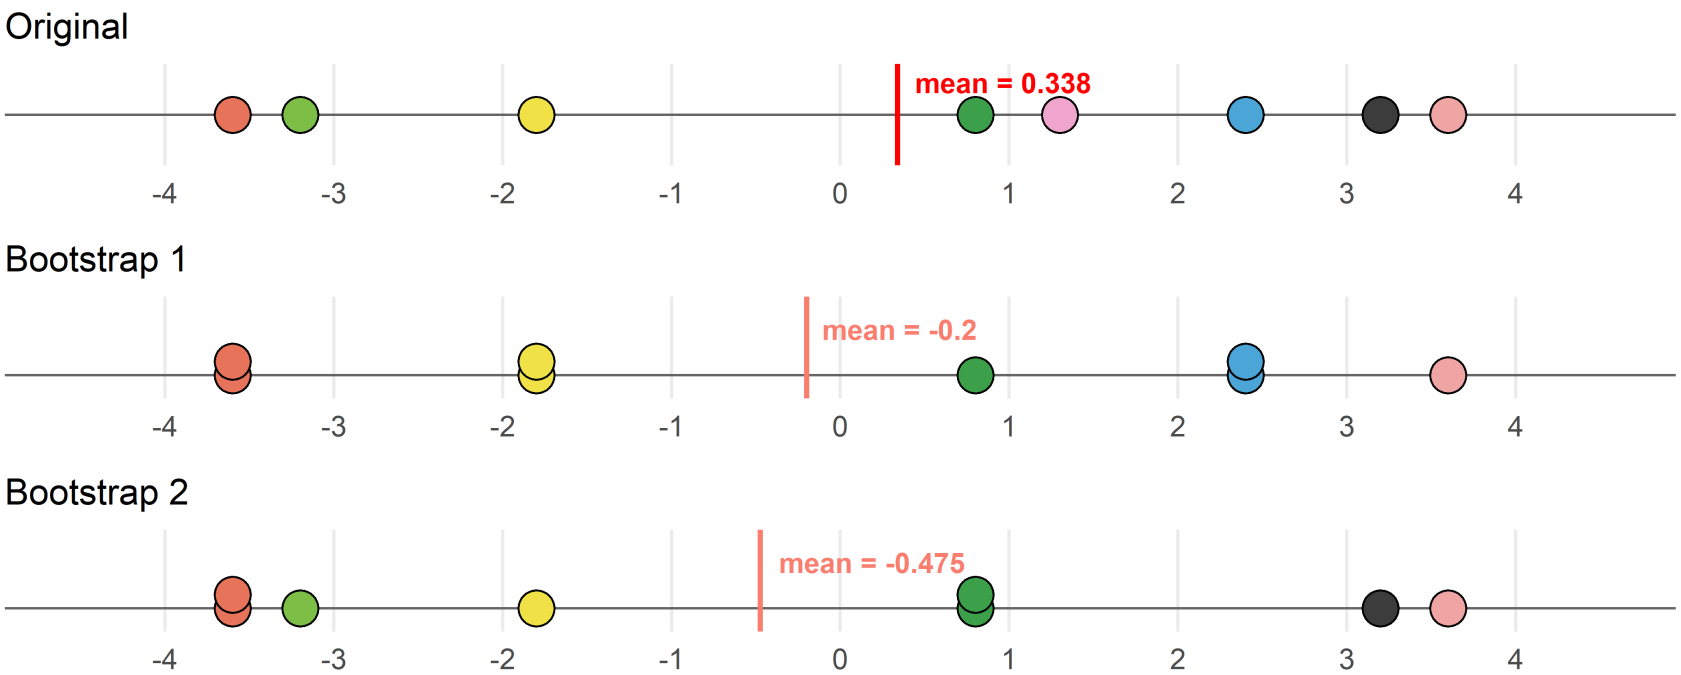


- La media de la muestra *bootstrap 1* es -0.2
- Repetimos el proceso

Bootstrapping



Bootstrapping



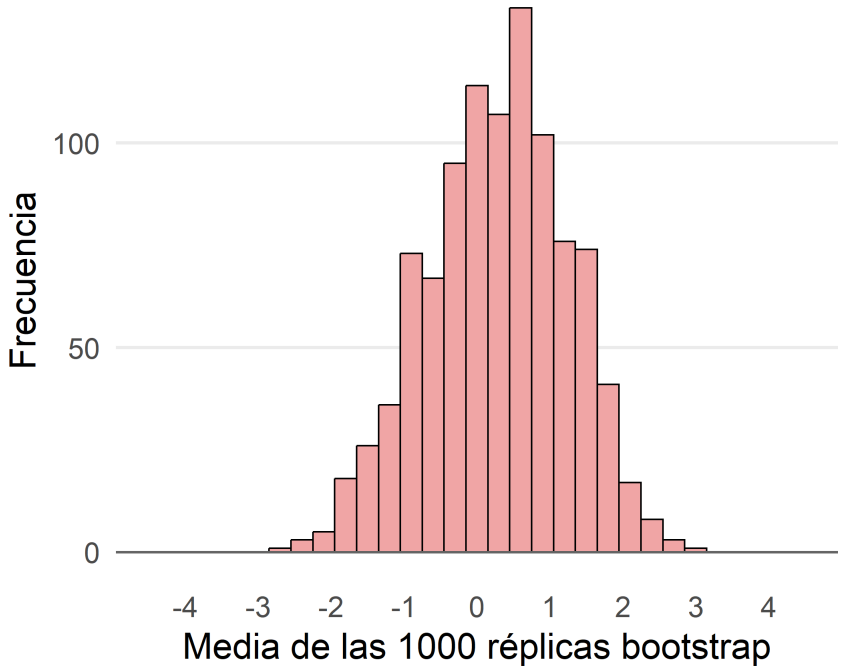
Bootstrapping consiste en 3 pasos:

1. Crear una muestra bootstrap
2. Calcular algún estadístico (media, mediana, sd, etc.)
3. Guardar ese valor

Lo repetimos 1,000 veces.

Bootstrapping

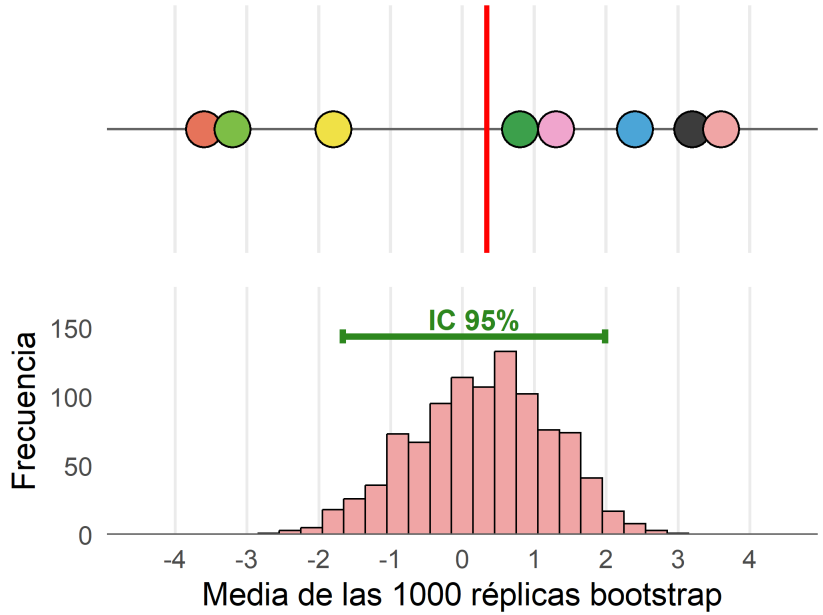
- El histograma nos informa de cómo podría cambiar la media si repitiésemos el experimento muchas veces.



- Si queremos saber el error estándar de la media de nuestro experimento original, podemos calcularlo como la desviación estándar de la distribución *bootstrap*: 0.96, muy parecido al de la fórmula clásica, $s/\sqrt{n}$ = 1.01

Bootstrapping

- El histograma nos informa de cómo podría cambiar la media si repitiésemos el experimento muchas veces.



- Como el IC contiene el 0, no podemos rechazar la hipótesis de que el fármaco no esté haciendo nada.

Bootstrapping

- Podemos aplicarlo a cualquier estadístico para crear un histograma de lo que pasaría si repitiésemos el experimento muchas veces
- Esa información nos sirve para calcular el error estándar o el intervalo de confianza, sin necesidad de conocer una fórmula analítica
- Independientemente del estadístico, el *bootstrap* nos permite verlo en el contexto de una distribución, que podemos usar para interpretar los resultados
- Las distribuciones *bootstrap* aproximan la dispersión, el sesgo y la forma de la distribución muestral real
- El *bootstrap* no sirve para obtener mejores estimaciones del parámetro: las distribuciones *bootstrap* están centradas en el estadístico calculado a partir de la muestra original, no en el valor poblacional desconocido
- Es útil para cuantificar el comportamiento de una estimación, su error estándar, su asimetría (*skewness*) o su sesgo, o para calcular intervalos de confianza

¿Cuántas remuestras se necesitan?

- Con 1.000 remuestras suele bastar para estimar un error estándar
- Para IC por percentiles y p-valores se recomienda al menos 10.000, y más cuando la precisión importa
- Aumentar el número de remuestras (m) no aumenta la información contenida en los datos, esa depende del tamaño de la muestra original (n), que se mantiene fijo en cada remuestra. Más remuestras solo dan una mejor estimación de la distribución muestral, no más información nueva

Test de permutación

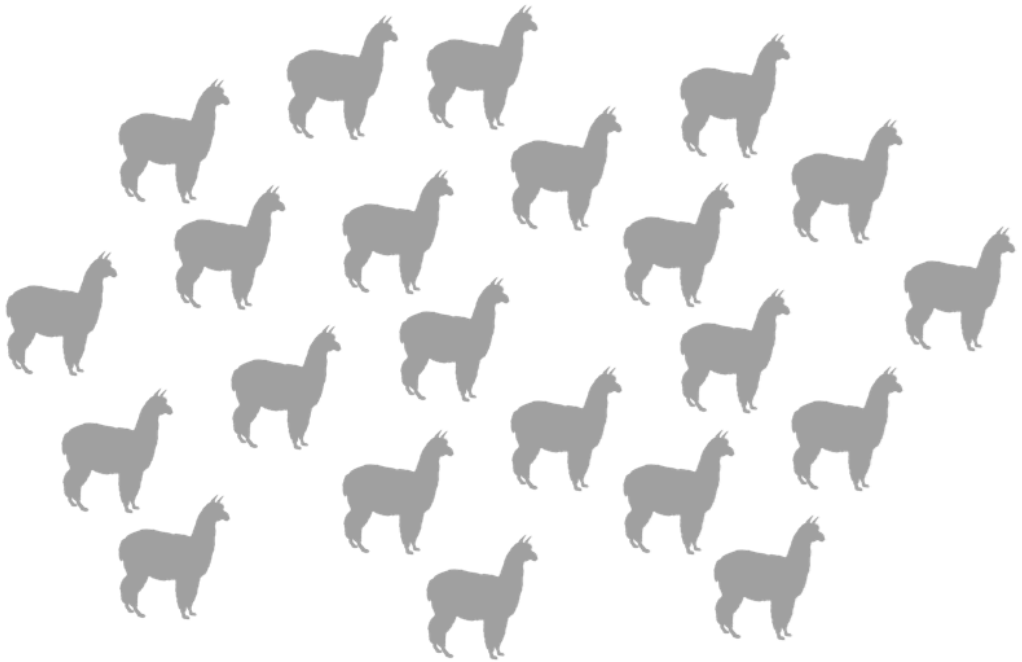
- Un test de hipótesis no paramétrico
- Se basa en remuestrear los datos originales asumiendo la hipótesis nula
- A partir de los datos remuestreados se puede concluir **cuán probable es obtener un estadístico tan extremo como el observado** si la hipótesis nula fuera cierta

Test de permutación

- Intervienen dos o más muestras
- Hipótesis nula: las dos muestras provienen de la misma distribución

Ejemplo

- Queremos saber si un champú incrementa la calidad de la lana de nuestras alpacas



Test de permutación

$$H_0 : \mu_{tratamiento} = \mu_{control}$$

- El champú no incrementa la calidad de la lana

$$H_A : \mu_{tratamiento} > \mu_{control}$$

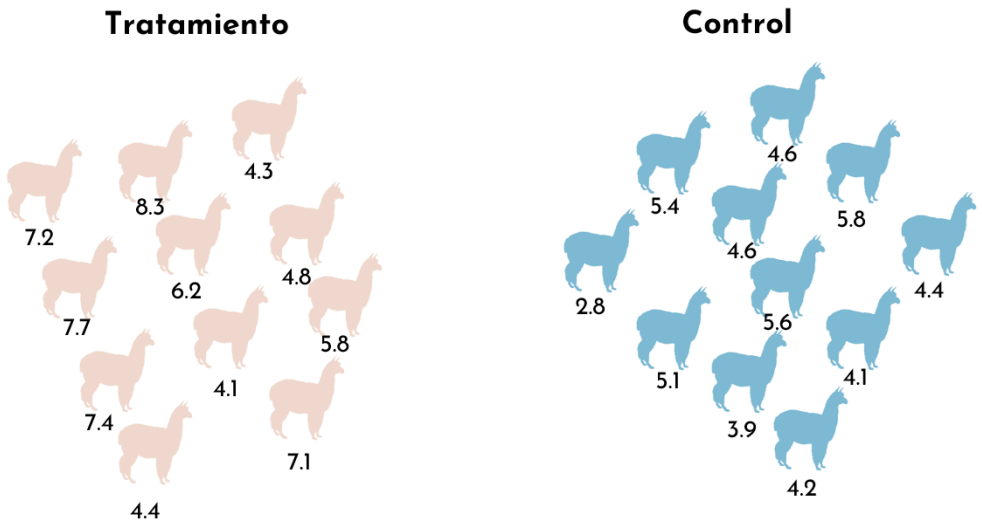
- El champú incrementa la calidad de la lana

Test de permutación

Paso 2: estadístico de prueba

- Para determinar si el champú es o no efectivo, necesitamos una manera de cuantificar la diferencia entre nuestras hipótesis nula y alternativa: prueba estadística
- Podemos utilizar la diferencia de medias de la respuesta entre los dos champús:

$$\text{estadístico de prueba} = \bar{x}_{tratamiento} - \bar{x}_{control} = 6.118 - 4.591 = 1.527$$

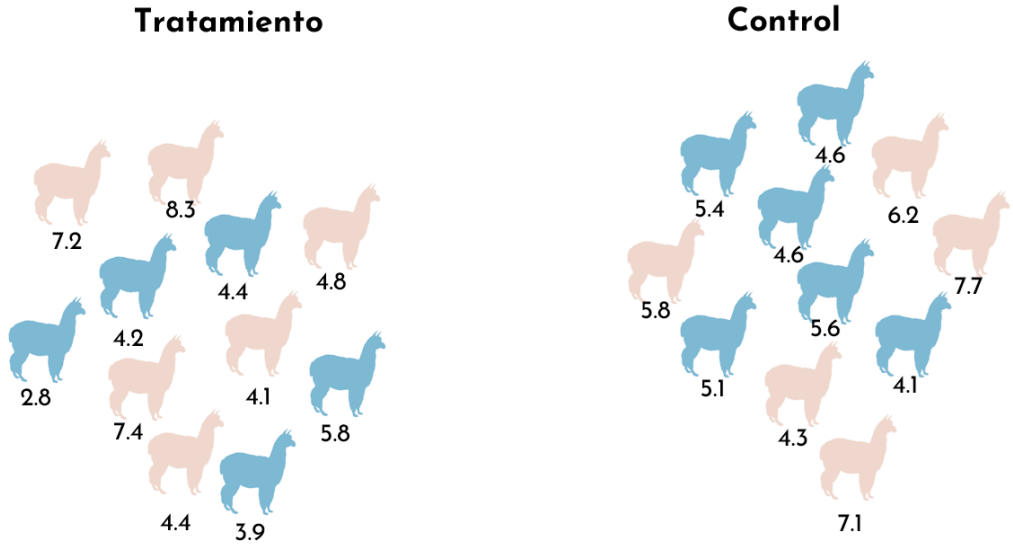


Test de permutación

Paso 3: permutación

- Permutamos (*shuffle*) las asignaciones (etiquetas) de las alpacas, y re-calculamos el valor estadístico (diferencia de medias)
- Hacemos esto porque analizamos los resultados del experimento relativos a la hipótesis nula, que dice que el nuevo champú no tiene ningún beneficio sobre la calidad de la lana
- Si el nuevo champú no mejora la calidad de la lana, permutar las etiquetas y recalcular los valores no tendría impacto: obtendríamos valores similares en los dos grupos

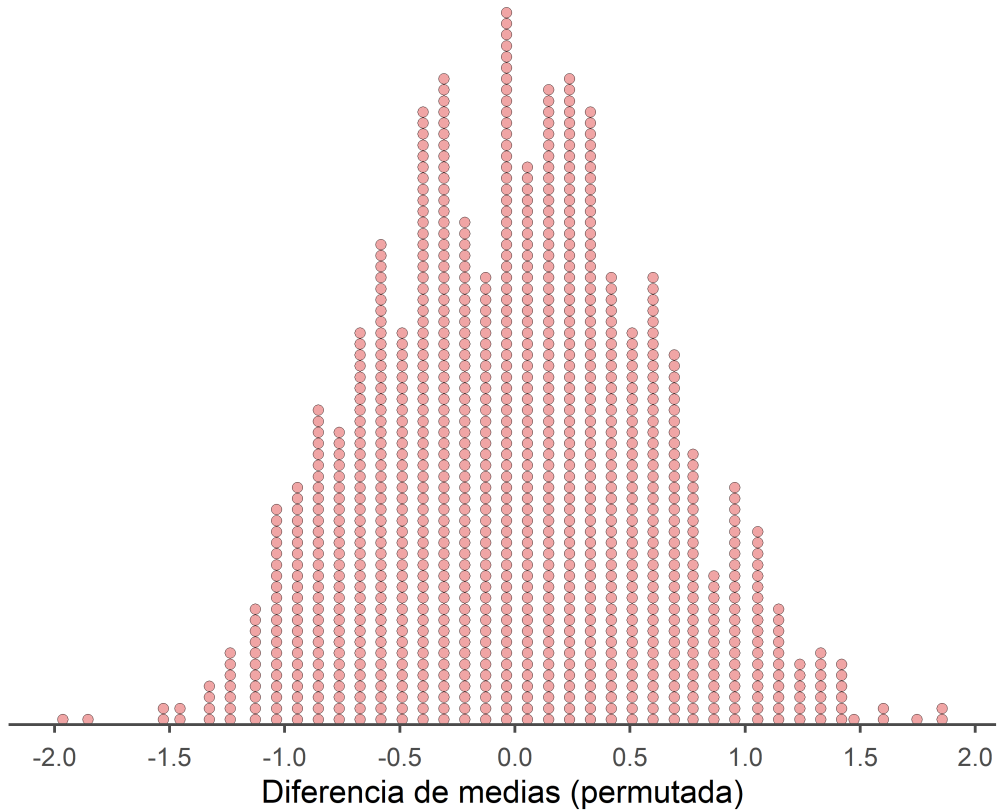
$$\text{prueba estadística} = \bar{x}_{tratamiento} - \bar{x}_{control} = 5.209 - 5.5 = -0.291$$



Test de permutación

Paso 3: permutación

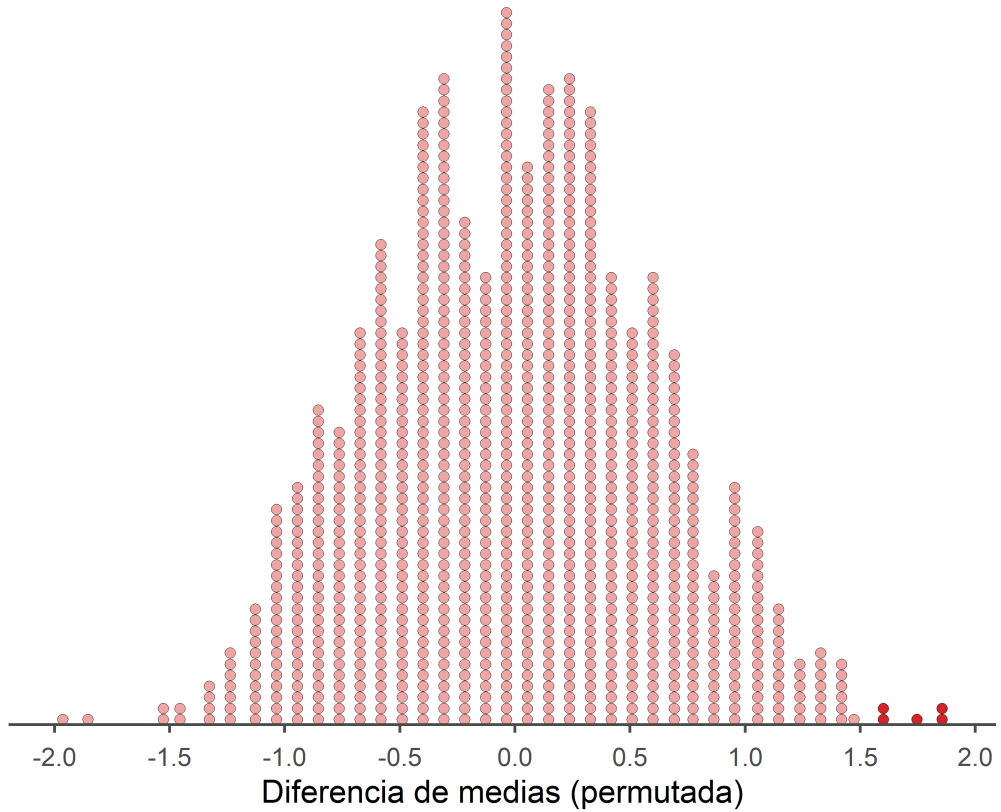
- El proceso se repite, permutando los datos una y otra vez, y recalculando el estadístico (diferencia de medias) en cada iteración
- Tras un número suficiente de permutaciones (1.000-10.000), obtenemos la distribución aproximada del estadístico bajo la hipótesis nula
- Esta distribución nos permite calcular la probabilidad de obtener distintos valores de diferencia de medias, asumiendo que el nuevo champú no mejora la calidad de la lana
- Viendo dónde cae nuestro estadístico observado dentro de esta distribución, obtenemos la pieza final del test: el p-valor.



Test de permutación

Paso 4: p-valor

- El p-valor es la probabilidad de obtener **un estadístico igual o más extremo que el observado**, asumiendo que la hipótesis nula es cierta
- Comparamos el p-valor con un nivel de significación (que debería fijarse a priori; usaremos el 5%). Si el p-valor es menor o igual que ese nivel, rechazamos la hipótesis nula: el resultado se considera estadísticamente significativo
- Un p-valor bajo indica que, si la hipótesis nula fuera cierta, sería poco probable obtener la diferencia en la calidad de la lana que observamos; un p-valor alto indica que ese resultado no sería sorprendente si la hipótesis nula fuera cierta



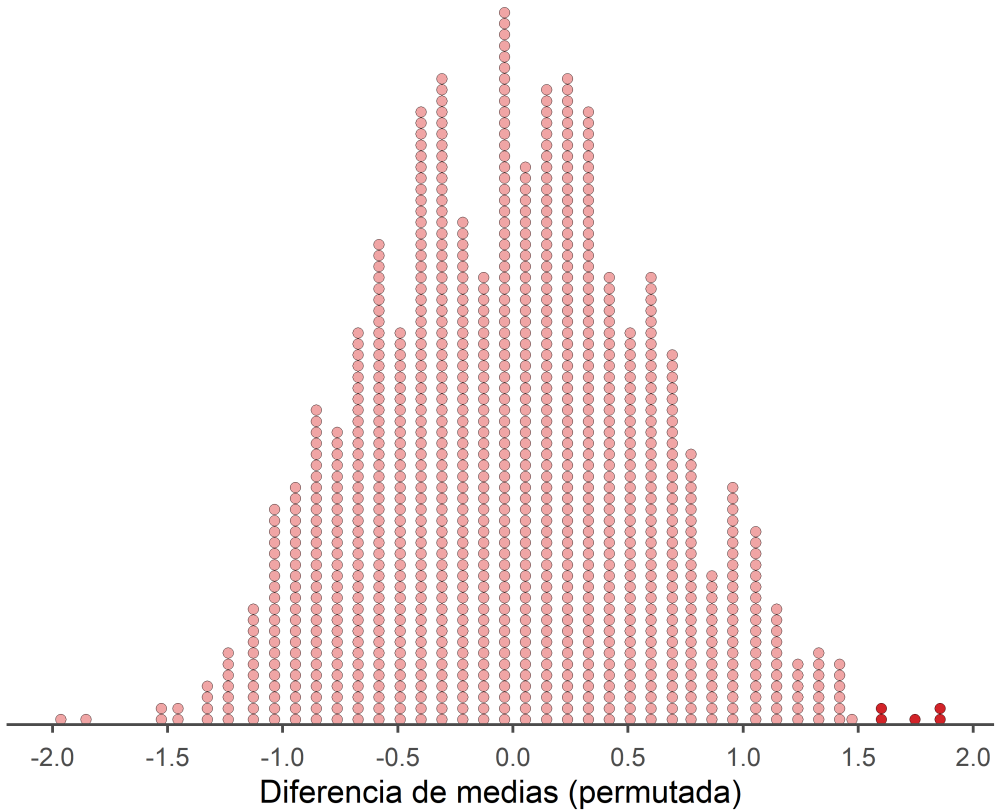
Test de permutación

Paso 4: p-valor

- Para calcular el p-valor, simplemente contamos el número de estadísticos igual o más extremos que nuestro estadístico inicial, y dividimos ese número por el total de estadísticos calculados.

$$\text{p-valor} = \frac{5}{1000} = 0.005$$

- Si realmente fuera cierto que el nuevo champú no mejora la calidad de la lana, obtener la diferencia inicial que observamos ocurriría con una probabilidad de solo el 0.5%
- Esa es una probabilidad muy baja. Con nuestro nivel de significación del 5%, rechazamos la hipótesis nula y tenemos evidencia a favor de la alternativa: el nuevo champú sí parece mejorar la calidad de la lana.



Test de permutación

Resumen: el algoritmo en cuatro pasos

1. Determinar y calcular el estadístico de prueba inicial
2. Construir la distribución aproximada del estadístico
3. Distribución nula por permutació
4. Calcular el p-valor

Supuestos

- Intercambiabilidad (*exchangeability*) de las observaciones bajo la hipótesis nula
  - Un supuesto más débil que asumir que los puntos muestrales son independientes e idénticamente distribuidos
  - Permutar significa intercambiar las etiquetas de los puntos de datos, o cambiar el orden de un conjunto de valores

¿Qué problema resuelve el test de permutación?

- **Para qué sirve:** contrastar hipótesis sin necesidad de asumir una distribución concreta
- **Pregunta que responde:** ¿mi efecto observado es real, o podría haber aparecido por azar?

Ventajas

- No requiere normalidad
- Funciona con muestras pequeñas
- Válido para cualquier estadístico
- Permite hipótesis complejas (permutaciones restringidas, manteniendo bloques, familias, pedigrí, estructura genética...)

Limitaciones

- Requiere intercambiabilidad bajo la hipótesis nula
- No siempre es fácil o posible permutar (series temporales, autocorrelación espacial)
- En diseños complejos, requiere permutaciones condicionadas (no siempre trivial)
- Coste computacional elevado si *n* es grande
- No da estimaciones de parámetros, solo p-valores (a diferencia del *bootstrap*)

Test de permutación

P-valor de dos colas

- Si la hipótesis hubiera sido más general —que el champú tiene algún efecto sobre la calidad de la lana, sin importar la dirección:

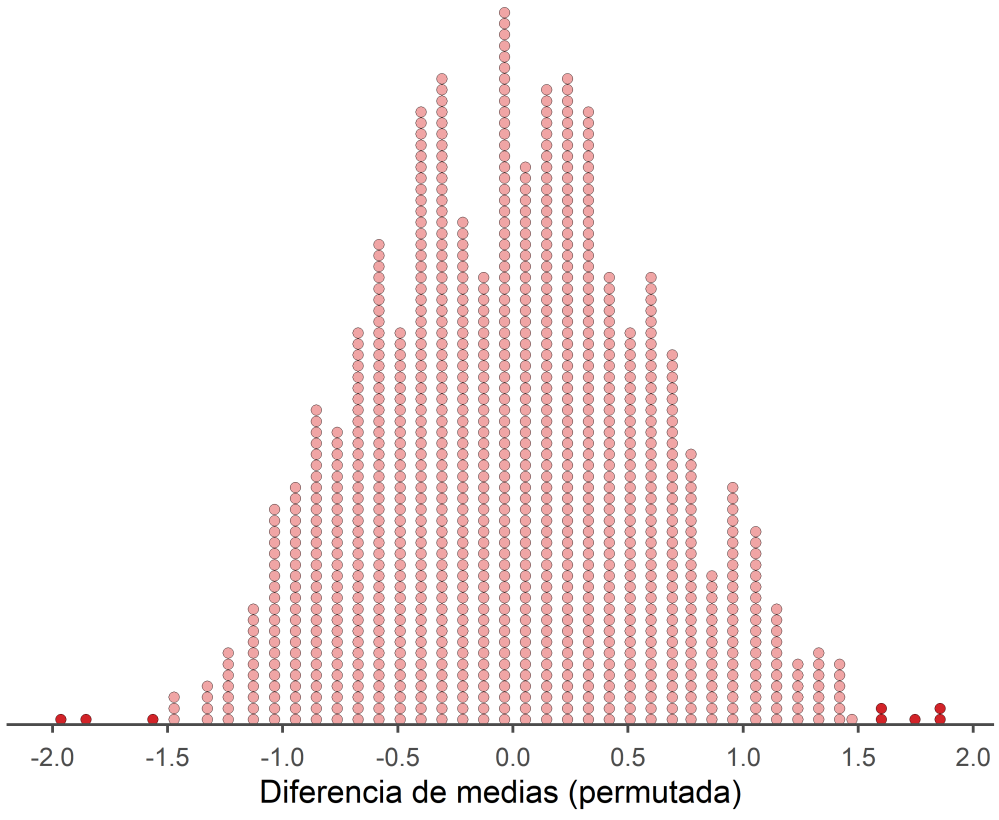
$$H_0 : \mu_{tratamiento} = \mu_{control}$$

$$H_A : \mu_{tratamiento} \neq \mu_{control}$$

- sería una prueba de dos colas: nos interesarían tanto las diferencias muy positivas (el champú mejora mucho) como las muy negativas (el champú empeora mucho la lana)
- Por eso el p-valor se calcula usando el valor absoluto del estadístico:

$$p\text{-valor} = \frac{\#\{|\text{diff}_{perm}| \geq |\text{diff}_{obs}|\}}{n_{perm}}$$

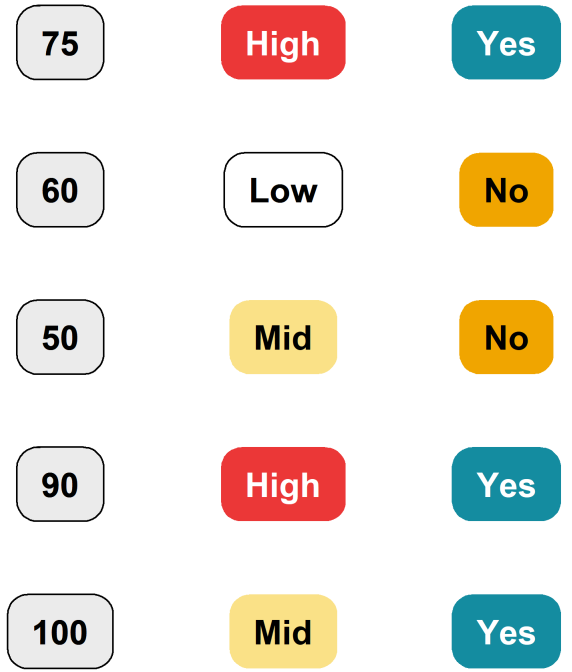
- Al contar extremos en ambas direcciones, el p-valor de dos colas suele ser aproximadamente el doble (en este caso, p-valor = 0.008)



Ejemplo: ¿por qué importa qué permutamos?

Pregunta: ¿las clases de repaso afectan al rendimiento universitario, controlando por la renta familiar?

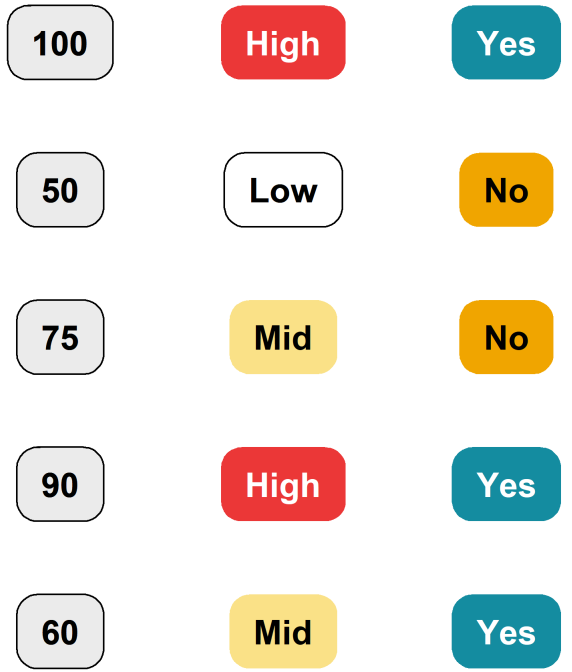
- Bajo H_0: las clases de repaso no están relacionadas con el rendimiento (una vez controlada la renta)
- **Problema:** si permutamos las puntuaciones de rendimiento, rompemos también su relación con la renta
- La renta es un factor de confusión real — su asociación con el rendimiento no debería destruirse al permutar
- Permutar la variable de resultado invalida la prueba sin darnos cuenta, porque destruye una característica real de los datos, no solo la relación que queremos testar



Datos originales

Ejemplo: ¿por qué importa qué permutamos?

- Esta permutación NO es válida porque NO mantenemos la relación original entre el rendimiento y la renta.



Permutación NO válida (se mezcla el rendimiento entre todos)

Solución: estratificación (bloques de intercambiabilidad)

- Si la renta se puede categorizar en niveles discretos (bajo, medio, alto), la estratificación es una alternativa sencilla

Paso 1: Estratificar los datos

- Agrupar las observaciones en estratos (bloques) según su nivel de renta

Paso 2: Permutar dentro de cada estrato

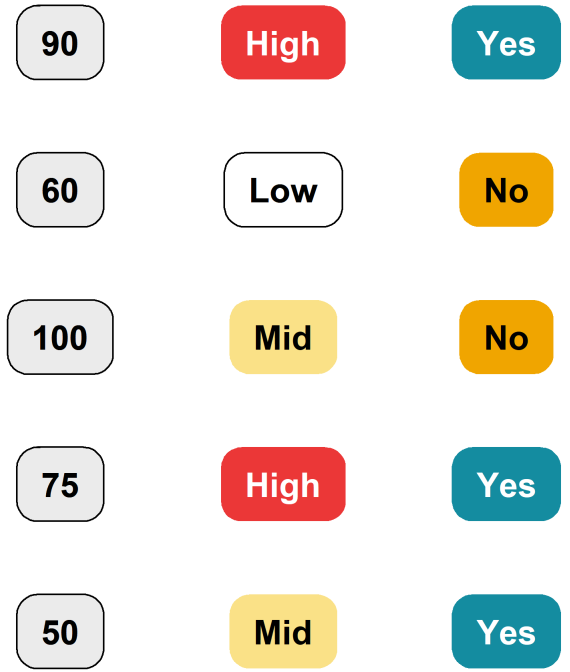
- Permutar el rendimiento (o, de forma equivalente, las etiquetas de clases de repaso) solo entre individuos del mismo estrato de renta

Paso 3: Calcular y repetir

- Calcular el estadístico de prueba con los datos permutados, y repetir el proceso miles de veces para construir la distribución nula
- Esto preserva la asociación general entre renta y rendimiento, ya que solo se intercambian individuos dentro del mismo nivel de renta

Solución: estratificación (bloques de intercambiabilidad)

- Esta permutación es válida porque mantenemos la relación original entre el rendimiento y la renta.



Permutación válida (dentro de cada nivel de renta)

Ejemplo con expresión génica en embriones de *Drosophila*

Mapping Selection within *Drosophila melanogaster* Embryo's Anatomy

Irepan Salvador-Martínez,[†,‡,1] Marta Coronado-Zamora,[‡,2] David Castellano,[‡,3] Antonio Barbadilla,[*,2] and Isaac Salazar-Ciudad[*,1,2]

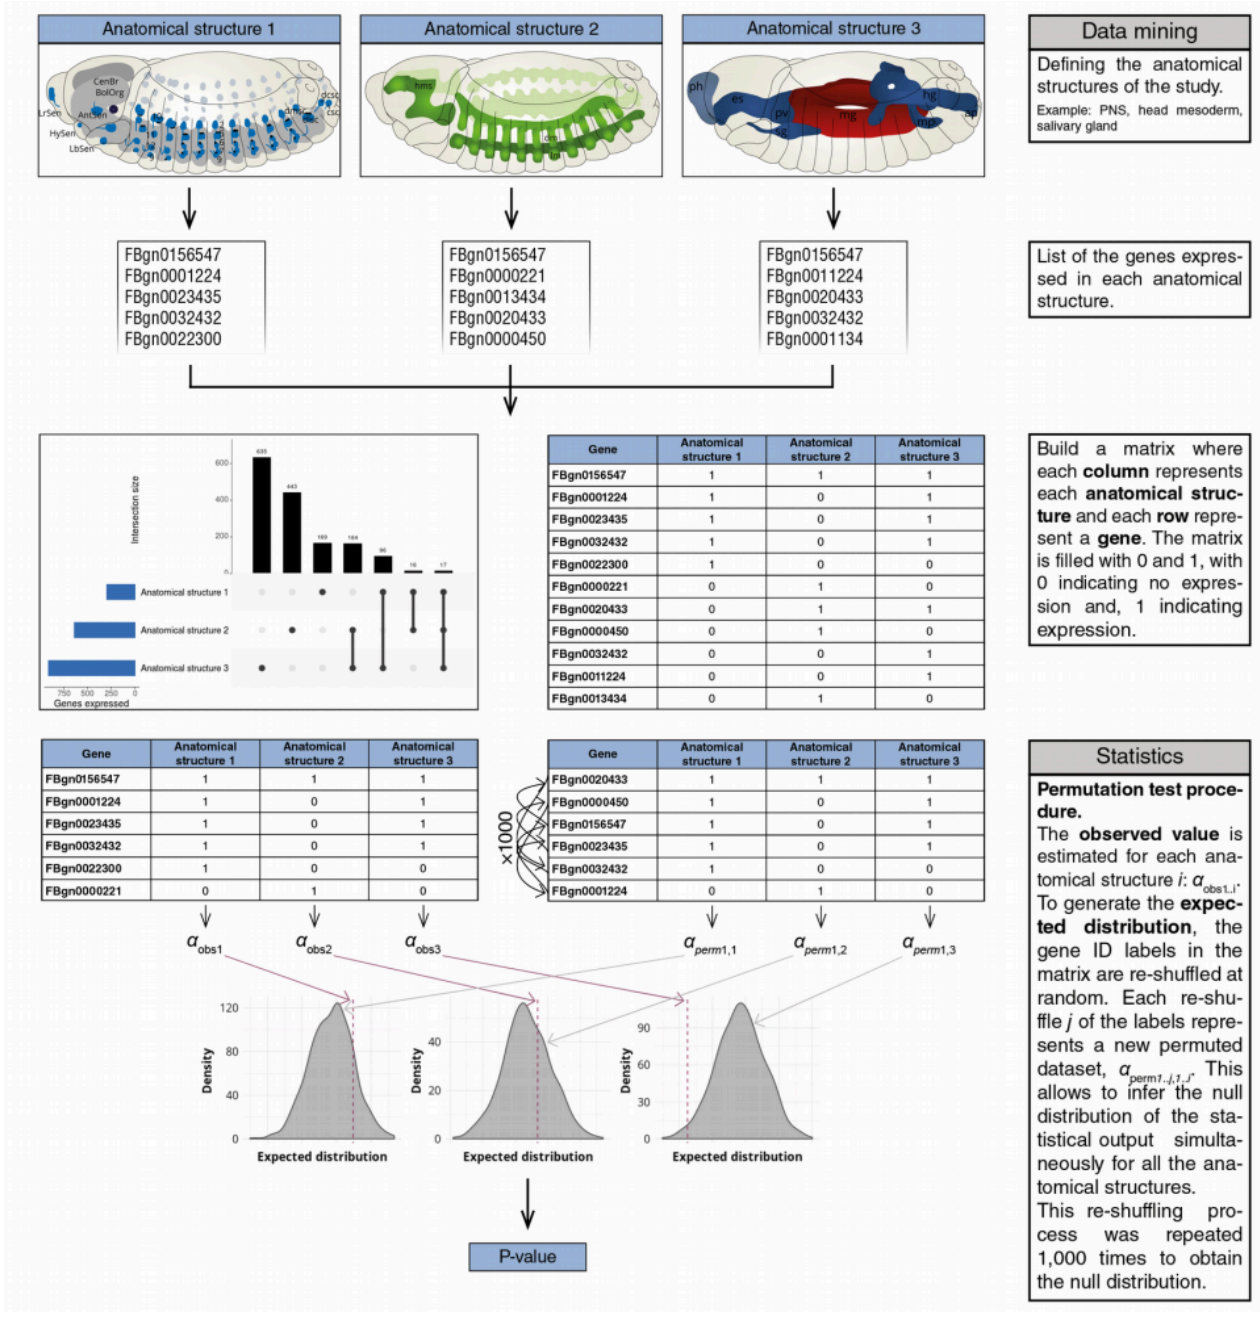
[1]Evo-devo Helsinki Community, Centre of Excellence in Experimental and Computational Developmental Biology, Institute of Biotechnology, University of Helsinki, Helsinki, Finland

[2]Departament de Genètica i de Microbiologia, Genomics, Bioinformatics and Evolution, Departament de Genètica i Microbiologia, Universitat Autònoma de Barcelona, Cerdanyola del Vallès, Spain

[3]Bioinformatics Research Centre, Aarhus University, Aarhus, Denmark

[†]Present address: Department of Genetics, Evolution and Environment, University College London, London, United Kingdom

[‡]Co-first authors


Anatomical structure 1
Anatomical structure 2
Anatomical structure 3
FBgn0156547
FBgn0001224
FBgn0023435
FBgn0032432
FBgn0022300
FBgn0156547
FBgn0000221
FBgn0013434
FBgn0020433
FBgn0000450
FBgn0156547
FBgn0011224
FBgn0020433
FBgn0032432
FBgn0001134
Intersection size
Anatomical structure 1
Anatomical structure 2
Anatomical structure 3
Genes expressed
Gene | Anatomical structure 1 | Anatomical structure 2 | Anatomical structure 3
FBgn0156547 | 1 | 1 | 1
FBgn0001224 | 1 | 0 | 1
FBgn0023435 | 1 | 0 | 1
FBgn0032432 | 1 | 0 | 1
FBgn0022300 | 1 | 0 | 0
FBgn0000221 | 0 | 1 | 0
FBgn0020433 | 0 | 1 | 1
FBgn0000450 | 0 | 1 | 0
FBgn0032432 | 0 | 0 | 1
FBgn0011224 | 0 | 0 | 1
FBgn0013434 | 0 | 1 | 0
Gene | Anatomical structure 1 | Anatomical structure 2 | Anatomical structure 3
FBgn0156547 | 1 | 1 | 1
FBgn0001224 | 1 | 0 | 1
FBgn0023435 | 1 | 0 | 1
FBgn0032432 | 1 | 0 | 1
FBgn0022300 | 1 | 0 | 0
FBgn0000221 | 0 | 1 | 0
×1000
Gene | Anatomical structure 1 | Anatomical structure 2 | Anatomical structure 3
FBgn0020433 | 1 | 1 | 1
FBgn0000450 | 1 | 0 | 1
FBgn0156547 | 1 | 0 | 1
FBgn0023435 | 1 | 0 | 1
FBgn0032432 | 1 | 0 | 0
FBgn0001224 | 0 | 1 | 0
α_{obs1}
α_{obs2}
α_{obs3}
$\alpha_{perm1,1}$
$\alpha_{perm1,2}$
$\alpha_{perm1,3}$
Density
Expected distribution
P-value
Data mining
Defining the anatomical structures of the study.
Example: PNS, head mesoderm, salivary gland
List of the genes expressed in each anatomical structure.
Build a matrix where each column represents each anatomical structure and each row represent a gene. The matrix is filled with 0 and 1, with 0 indicating no expression and, 1 indicating expression.
Statistics
Permutation test procedure.
The observed value is estimated for each anatomical structure i: $\alpha_{obs1..i}$.
To generate the expected distribution, the gene ID labels in the matrix are re-shuffled at random. Each re-shuffle j of the labels represents a new permuted dataset, $\alpha_{perm1..j,1..i}$. This allows to infer the null distribution of the statistical output simultaneously for all the anatomical structures.
This re-shuffling process was repeated 1,000 times to obtain the null distribution.

Bootstrap vs test de permutación

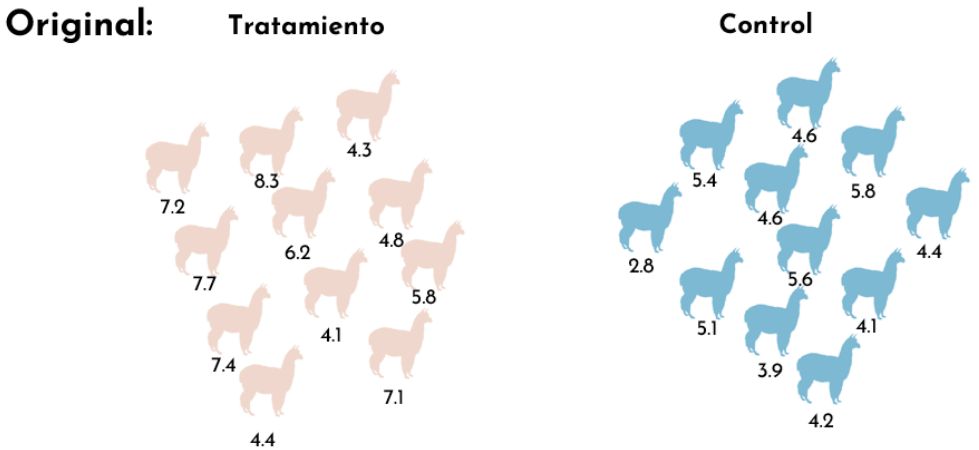
	Bootstrap	Test de permutación
Uso	Estimar la precisión de estadísticos muestrales	Un test de hipótesis no paramétrico
Supuestos	Muestra representativa y observaciones independientes (sin distribución concreta)	Intercambiabilidad bajo la hipótesis nula
Resultado	Error estándar, sesgo, IC	p-valor
Reemplazamiento	Con reemplazamiento	Sin reemplazamiento

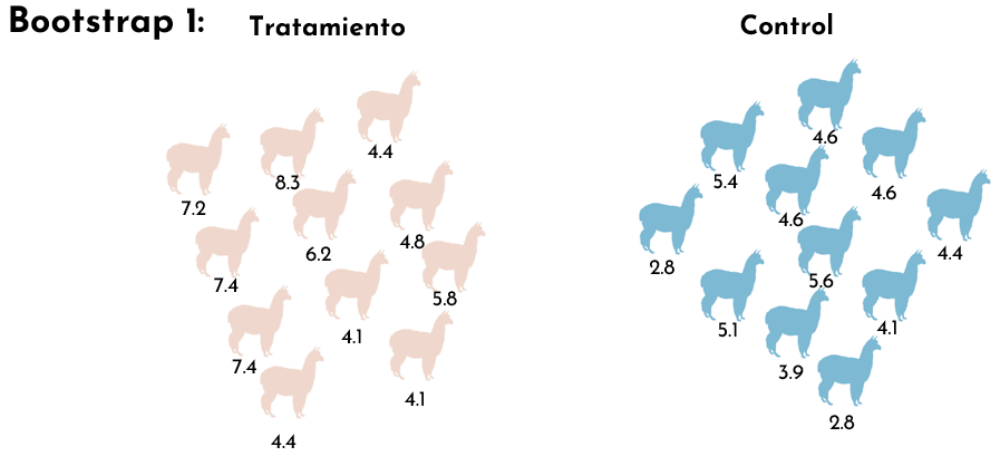
¿Podemos utilizar el *bootstrap* como prueba estadística? Vamos a verlo con la prueba de las alpacas.

Bootstrap

- Nuestro estadístico de interés es la diferencia de las medias

> Atención!
> - No reetiqueta
> - No mezcla datos entre condiciones
> - Por tanto, no simula la hipótesis nula de igualdad entre grupos





Bootstrap

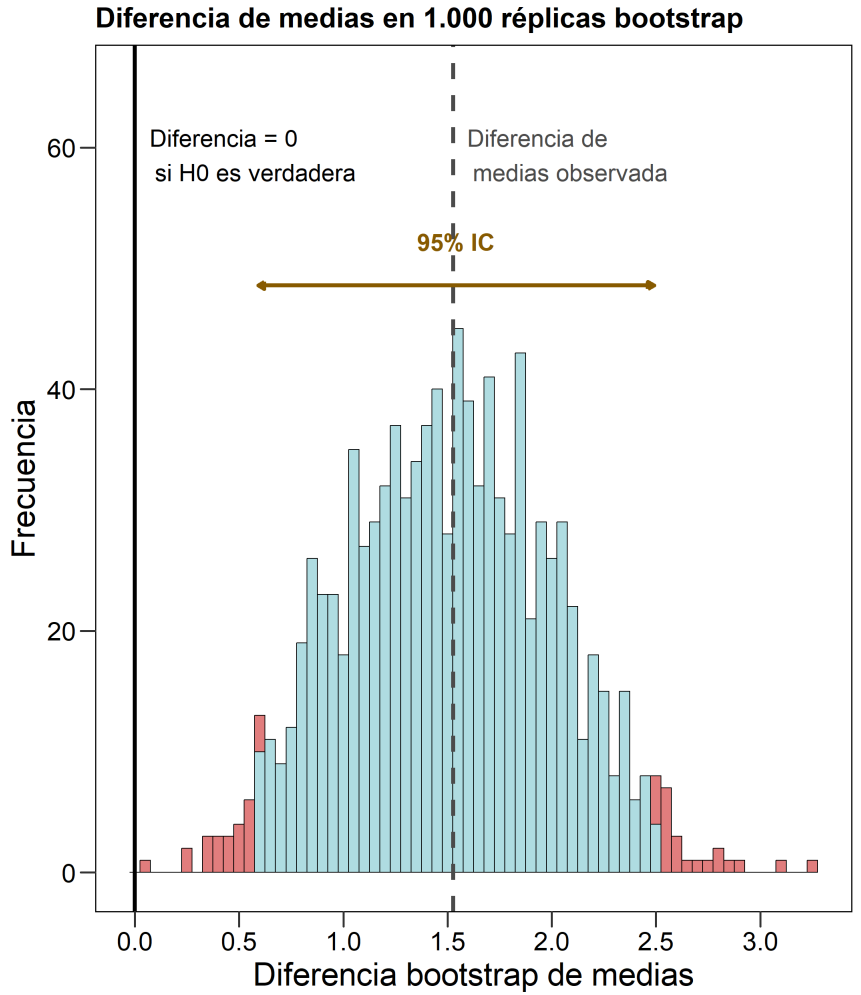
Diferencia de medias (tratamiento − control) en 1000 réplicas con reemplazamiento.

1. Con el IC

- El IC bootstrap del 95% son los percentiles 2.5% y 97.5% de las réplicas (zona azul; en rojo, lo que queda fuera).
- El IC no contiene el 0: rechazamos H_0 al 5% (dos colas).

2. Con el p-valor

- Una cola (H_A: tratamiento > control): proporción de réplicas con diferencia ≤ 0.
- En nuestro caso, 0 de 1000 réplicas son ≤ 0. Si sale 0, se escribe $p < 0.001$ (nunca $p = 0$).
- Dos colas: el doble de ese valor.



Bootstrap vs. test de permutación: el p-valor

> **Test de permutación:** "p = probabilidad de obtener un valor del estadístico tan extremo **como el observado**, si los grupos fueran idénticos (H_0 exacta)"
>
> **Bootstrap:** "p = proporción de réplicas *bootstrap* que caen **del lado de H_0** (cruzan el 0); refleja la variabilidad de los datos observados"

- Ambos p-valores se interpretan como evidencia contra H_0, pero miden cosas ligeramente distintas
- El *bootstrap* da un extra: además del p-valor, permite conocer la variabilidad/incertidumbre de nuestro estadístico (el intervalo de confianza)

Con fórmula *vs.* con remuestreo

	Con fórmula	Con remuestreo
Error estándar	$s/\sqrt{n}$	desviación estándar de las medias *bootstrap*
IC 95%	$\bar{x} \pm 1.96 \times SE$	percentiles 2.5% y 97.5% de la distribución *bootstrap*
p-valor	área bajo la normal (o t) más allá de z	proporción de permutaciones con un estadístico igual o más extremo

- Como vimos con los IC: **si el IC del 95% no contiene el valor de H_0, rechazamos H_0 al 5%** (dos colas). El *bootstrap* de las alpacas lo cumple.
- En el próximo tema veremos el **t-test**, que aproxima la distribución nula con una fórmula.

Contacto

Marta Coronado Zamora	David Castellano
marta.coronado@uab.cat	david.castellano@uab.cat
@geneticament.bsky.social	@castellanoed.bsky.social
Universitat Autònoma de Barcelona	University of Arizona