ANOVA

Bioestadística

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2026/2027



Outline

ANOVA

- Ejemplo
- ¿Qué es un ANOVA? ¿Por qué no hacer t-tests a pares?
- ANOVA de una vía: cálculo, supuestos, R, *post hoc* y alternativas
- ANOVA de dos vías: interacción, R^2 y efecto lote
- Versión no paramétrica

Ejemplo

It is thought that stress may increase susceptibility to illness through suppression of the immune system. In an experiment to investigate this theory, 48 rats were randomly allocated to four treatment groups: no stress, mild stress, moderate stress, and high stress. The stress conditions involved various amounts of restraint and electric shock. The concentration of lymphocytes (cells/ml $\times 10^{-6}$) in the peripheral blood was measured for each rat.

Perform an appropriate statistical analysis of this experiment.

- ¿H_0 y H_A?
- ¿Variable respuesta?
- ¿Grupos?

Ejemplo

*It is thought that **stress may increase susceptibility to illness** through suppression of the immune system. In an experiment to investigate this theory, 48 rats were randomly allocated to **four treatment groups**: no stress, mild stress, moderate stress, and high stress. The stress conditions involved various amounts of restraint and electric shock. The **concentration of lymphocytes** (cells/ml × 10^{-6}) in the peripheral blood was measured for each rat.*

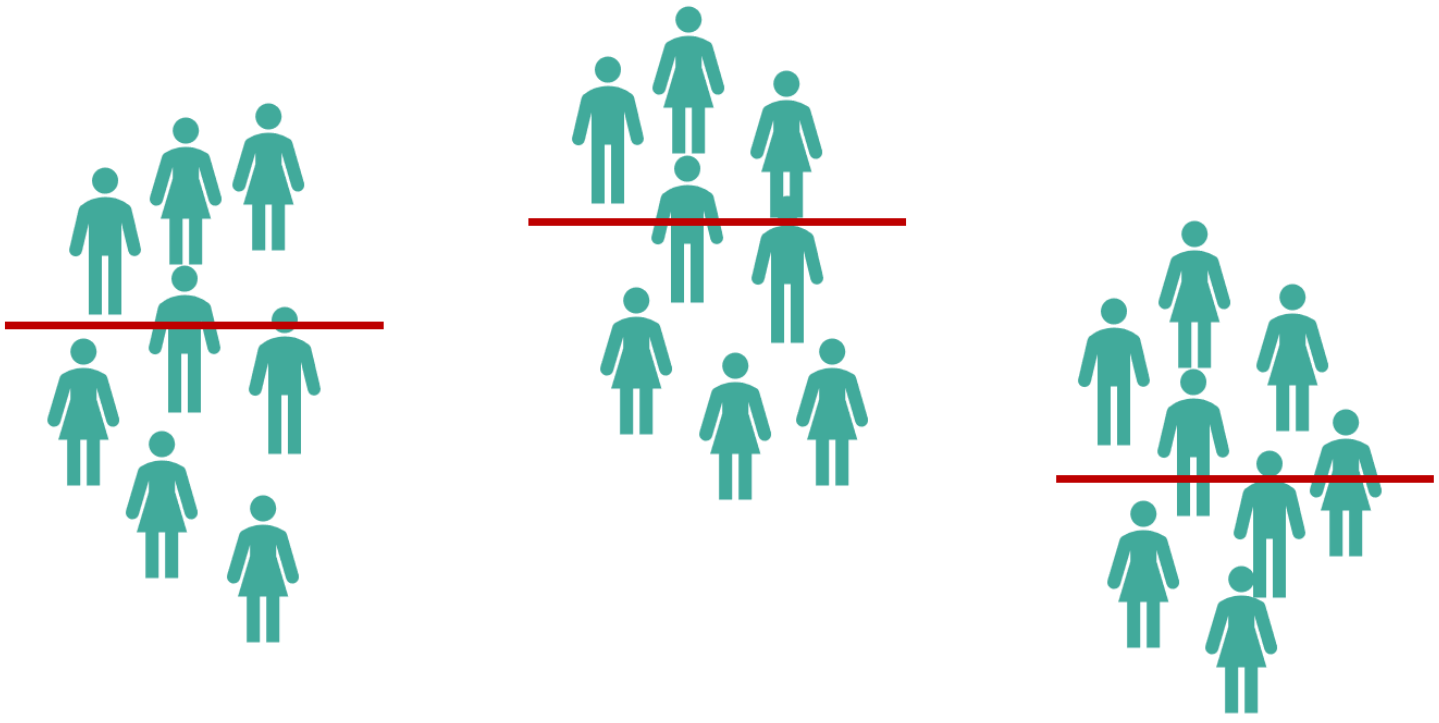
Perform an appropriate statistical analysis of this experiment.

- ¿Por qué no podemos hacer t-tests a pares? (no stress *vs.* mild stress, no stress *vs.* moderate stress, ...)
  - Realizar tests múltiples con los mismos datos incrementa el error tipo I

> Análisis de la varianza (*Analysis of variance*, ANOVA), utiliza una sola prueba de hipótesis para comparar varios grupos (normalmente >2; con 2 grupos es equivalente a un t-test)

ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o **más**



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o **más**



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o **más**



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las medias de tres grupos o más



T-test

ANOVA de una vía

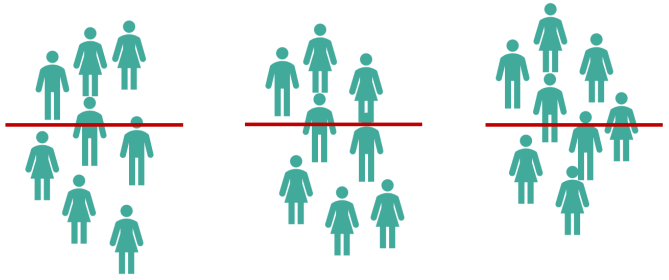
- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o **más**



Hipótesis en ANOVA de una vía

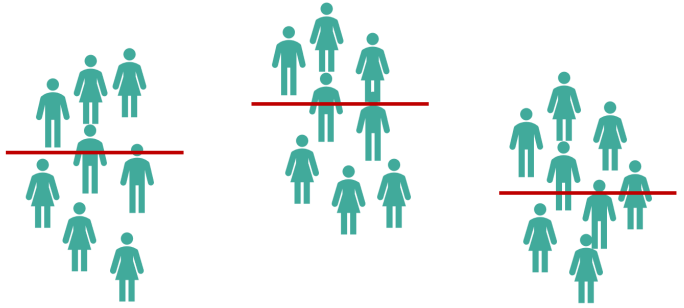
- Hipótesis nula: las medias de todos los grupos k son iguales

$$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k$$



- Hipótesis alternativa: las medias de los grupos no son iguales.

$$H_A : \text{Al menos una } \mu_i \text{ es diferente}$$



Supuestos del ANOVA de una vía

1. Nivel de medición
2. Independencia
3. Normalidad
4. Homogeneidad

Supuestos del ANOVA de una vía

1. Nivel de medición

Variable **independiente** → **Categórica**

Ejemplos:

- Grupo de tratamiento
- Tipo de fertilizante
- ...

Variable **dependiente** → **Continua**

Ejemplos:

- Concentración en sangre
- Crecimiento planta
- ...

Supuestos del ANOVA de una vía

1. Nivel de medición
2. Independencia
    - Los valores medidos en un grupo no deben ser influenciados por las medidas de otro grupo
    - Individuos o unidades experimentales diferentes

Supuestos del ANOVA de una vía

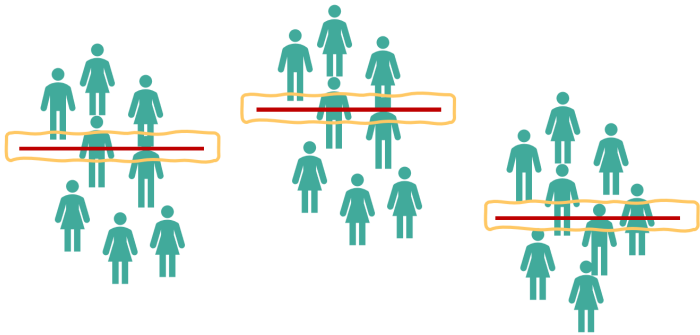
1. Nivel de medición
2. Independencia
3. Normalidad
    - Los datos han de seguir una distribución normal → especialmente si hay pocos datos
    - Si no se cumple la normalidad, podemos usar el test "Kruskal-Wallis"

Supuestos del ANOVA de una vía

1. Nivel de medición
2. Independencia
3. Normalidad
4. Homogeneidad
    - La varianza en cada grupo debería ser parecida entre grupos
    - Si no se cumple la homogeneidad de varianzas, podemos usar el test "Welch-ANOVA"

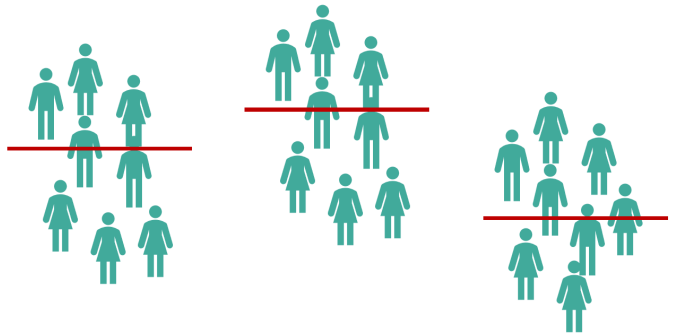
Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



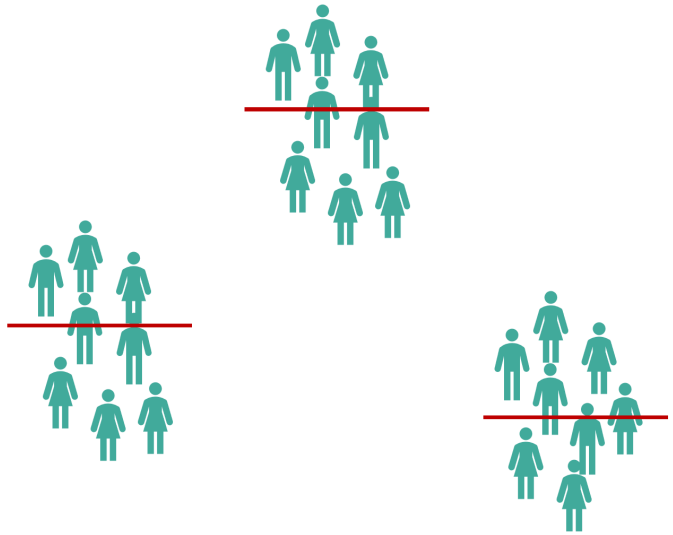
Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



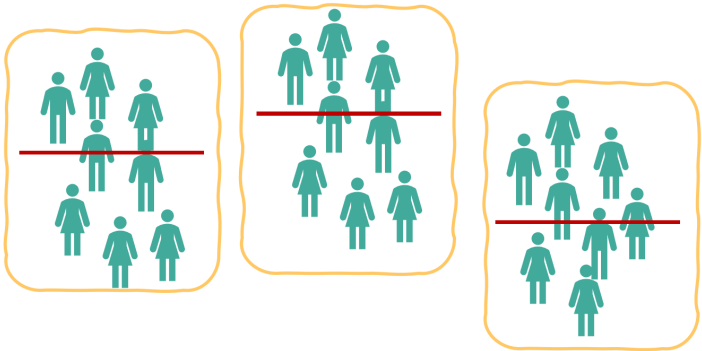
Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



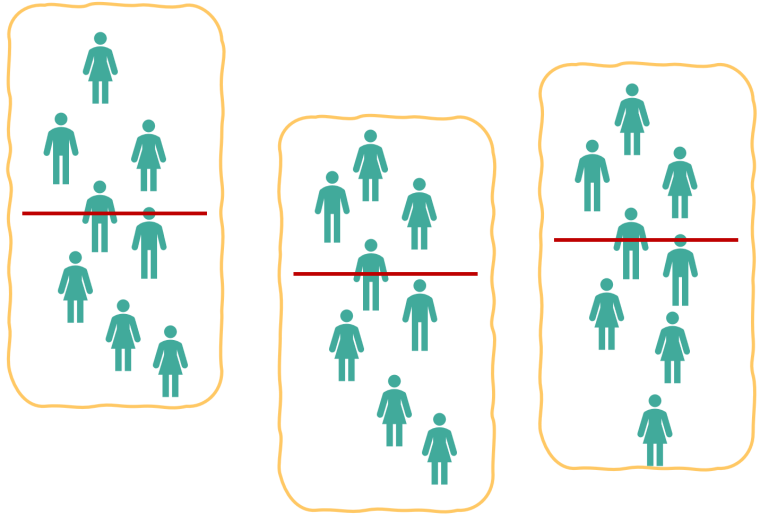
Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



Cómo funciona un ANOVA de una vía

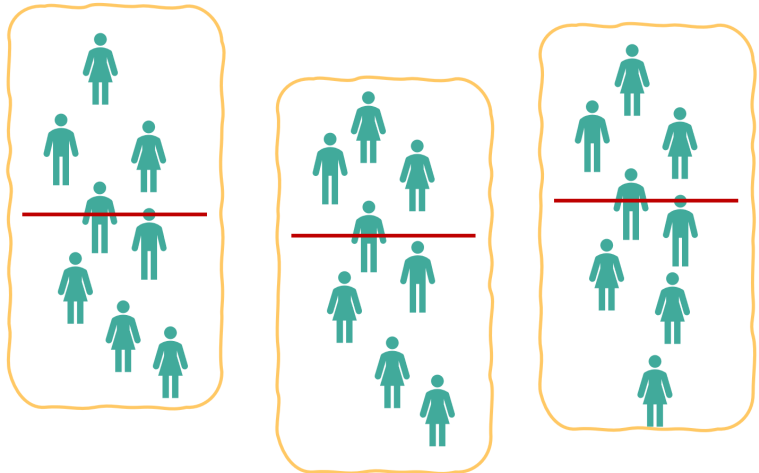
Estadístico F

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}} = F$$

Cómo funciona un ANOVA de una vía

Estadístico F

$$\frac{\text{Varianza ENTRE grupos} \downarrow}{\text{Varianza DENTRO de grupos} \uparrow} = F \downarrow$$

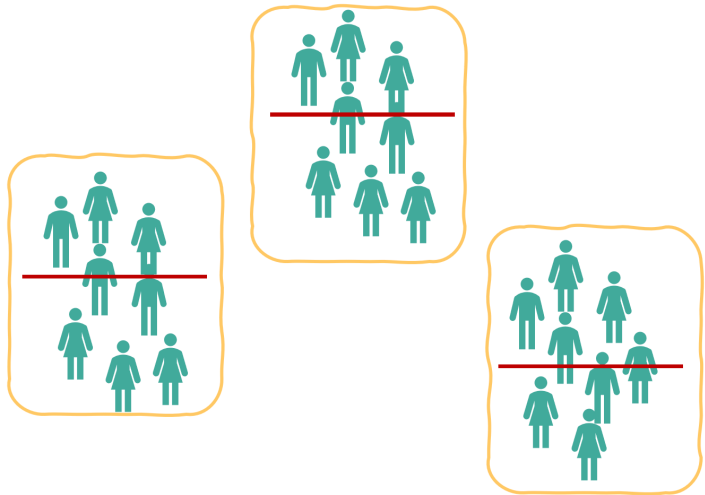


> Muy probable que las diferencias que veamos sean debidas al azar

Cómo funciona un ANOVA de una vía

Estadístico F

$$\frac{\text{Varianza ENTRE grupos} \uparrow}{\text{Varianza DENTRO de grupos} \downarrow} = F \uparrow$$



> Poco probable que las diferencias que veamos sean debidas al azar
>
> Para comprobar nuestra hipótesis y responder si hay o no diferencias significativas, necesitamos calcular el p-valor.

Cómo funciona un ANOVA de una vía

Estadístico F: pasos para calcularlo:

Paso 1: Calcular la media conjunta de todos los grupos

$$G = \frac{\sum x}{N}$$

Paso 2: Calcular la media de cada grupo (g) individual

$$M_i = \frac{\sum^{grupo} x}{n_g}$$

Paso 3: Suma de cuadrados ENTRE grupos (SSB):

$$SS_{entre} = \sum^{grupos} n_i (M_i - G)^2$$

Paso 4: Suma de cuadrados DENTRO de los grupos (SSW):

$$SS_{dentro} = \sum^{grupos} \sum^{grupo} (x_{mi} - M_i)^2$$

Cómo funciona un ANOVA de una vía

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6

Media de todos los datos

$$G = \frac{\sum x}{N}$$

$$G = \frac{3 + 2 + \ldots 3 + 10}{24} = 5.333$$

Cómo funciona un ANOVA de una vía

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6

Media de cada grupo

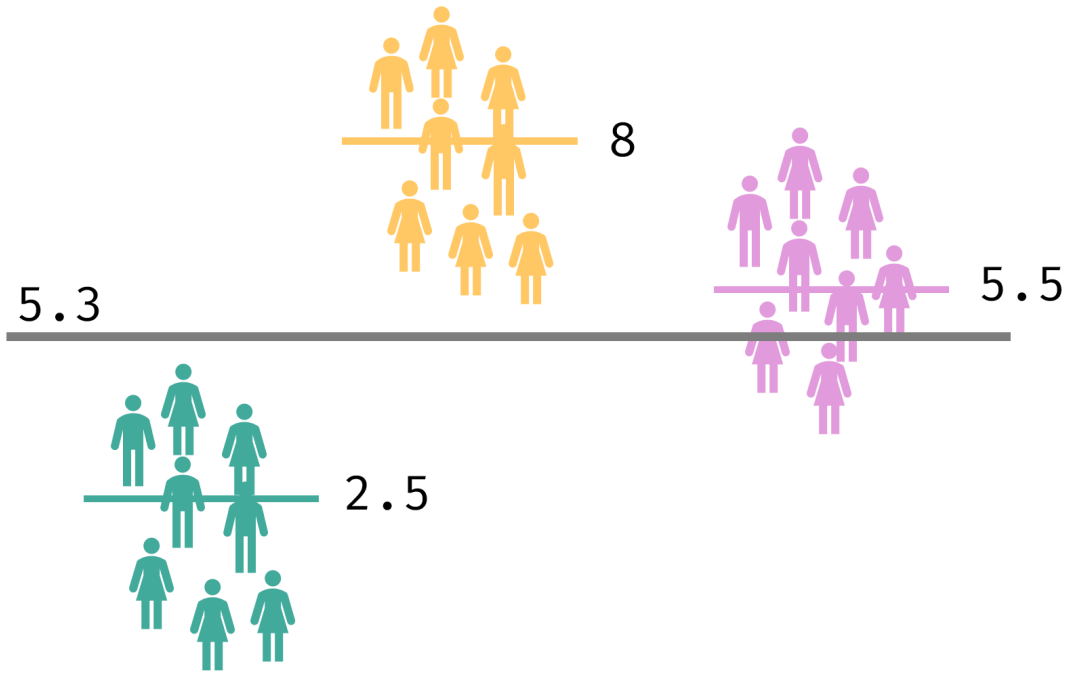
$$M_i = \frac{\sum^{grupo} x}{n_g}$$

$$M_1 = \frac{3 + 2 + \ldots + 4 + 3}{8} = 2.5$$

$$M_2 = \frac{10 + 9 + \ldots + 6 + 7}{8} = 8$$

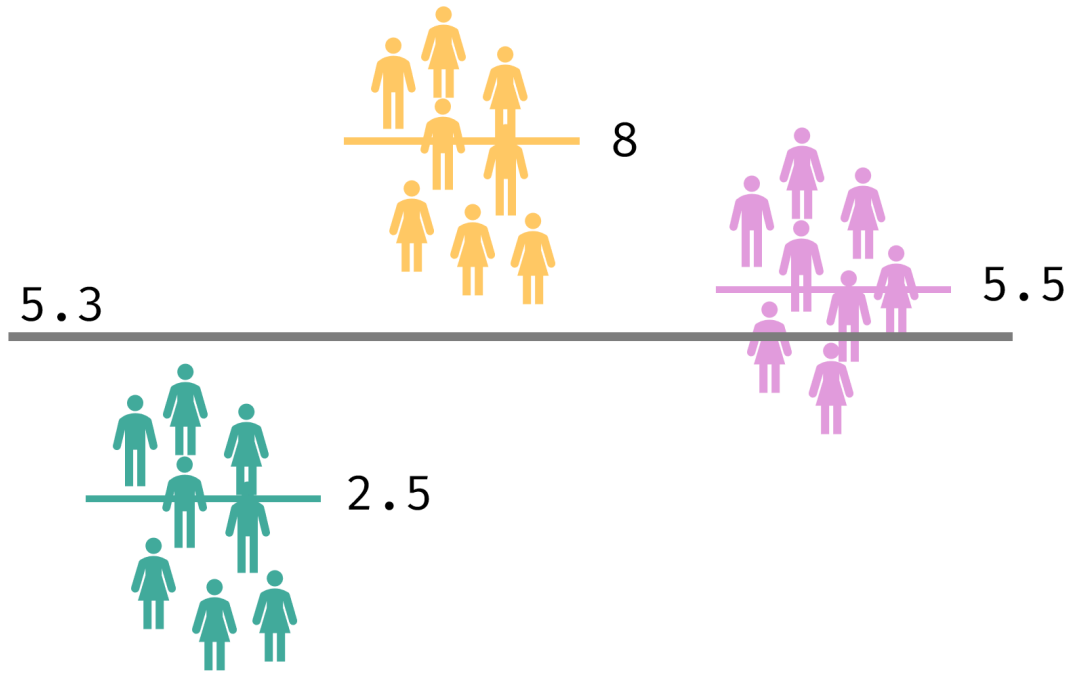
$$M_3 = \frac{7 + 6 + \ldots + 3 + 6}{8} = 5.5$$

Cómo funciona un ANOVA de una vía



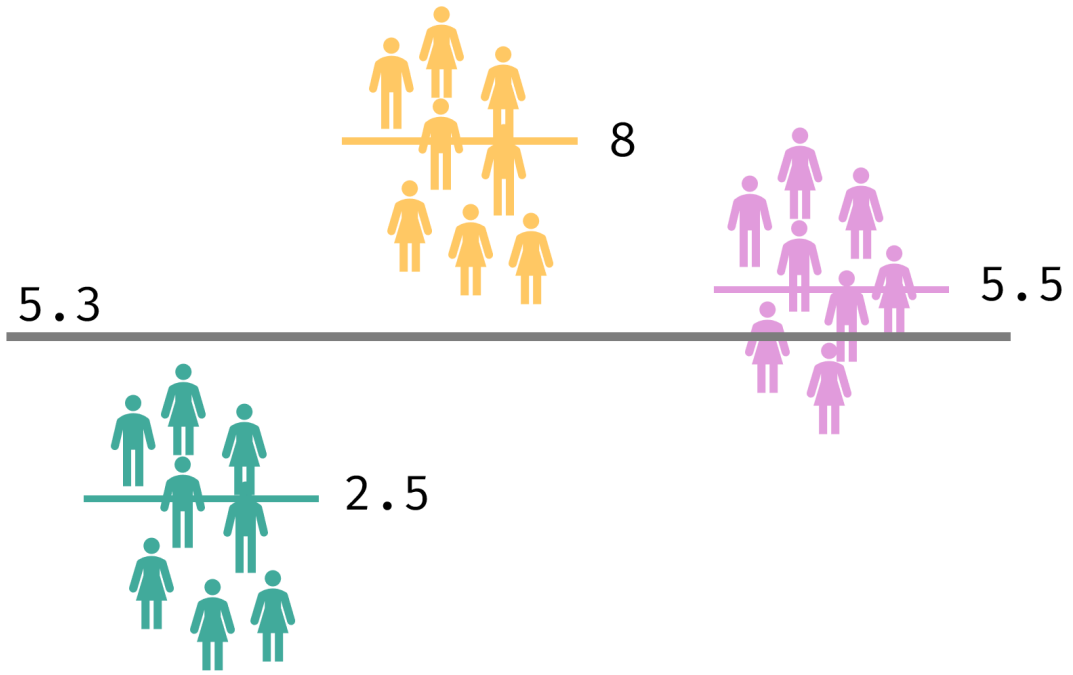
$$SS_{entre} = \sum^{grupos} n_i(M_i - G)^2$$

Cómo funciona un ANOVA de una vía



$$SS_{entre} = 8 \times ((2.5 - 5.3)^2 + (8 - 5.3)^2 + (5.5 - 5.3)^2) = 121.3$$

Cómo funciona un ANOVA de una vía



$$SS_{dentro} = \sum^{grupos} \sum^{grupo} (x_{mi} - M_i)^2$$

Cómo funciona un ANOVA de una vía

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6
2.5	**8**	**5.5**

$$
\begin{aligned}
SS_{\text{dentro}} &= \sum^{grupos}\sum^{grupo}(x_{mi} - M_i)^2 \\
&= (3 - 2.5)^2 + (2 - 2.5)^2 + \dots \\
&+ (10 - 8)^2 + (9 - 8)^2 + \dots \\
&+ (7 - 5.5)^2 + (6 - 5.5)^2 + \dots = 36
\end{aligned}
$$

Cómo funciona un ANOVA de una vía

Media total y por grupo: G, M_1, M_2, M_3
Suma de los cuadrados entre y dentro de grupos: SSB, SSW

Cómo funciona un ANOVA de una vía

Estadístico F: pasos para calcularlo:

Paso 1: Calcular la media conjunta de todos los grupos

$$G = \frac{\sum x}{N}$$

Paso 2: Calcular la media de cada grupo (g) individual

$$M_i = \frac{\sum^{grupo} x}{n_g}$$

Paso 3: Suma de cuadrados ENTRE grupos (SSB):

$$SS_{entre} = \sum^{grupos} n_i (M_i - G)^2$$

Paso 4: Suma de cuadrados DENTRO de los grupos (SSW):

$$SS_{dentro} = \sum^{grupos} \sum^{grupo} (x_{mi} - M_i)^2$$

Paso 5: Media de los cuadrados entre

$$`MS_{entre} = \frac{SSB}{gl_e}`$$

gl_{entre}: número de grupos - 1

Paso 6: Media de los cuadrados dentro

$$MS_{dentro} = \frac{SSW}{gl_d}$$

gl_{dentro}: número de observaciones - número de grupos

Cómo funciona un ANOVA de una vía

Media de los cuadrados entre:

$$`MS_{entre} = \frac{SSB}{gl_e} = \frac{121.3}{2} = 60.67`$$

gl_{entre}: número de grupos - 1 = 3-1 = 2
Media de los cuadrados dentro:

$$MS_{dentro} = \frac{SSW}{gl_d} = \frac{36}{21} = 1.71$$

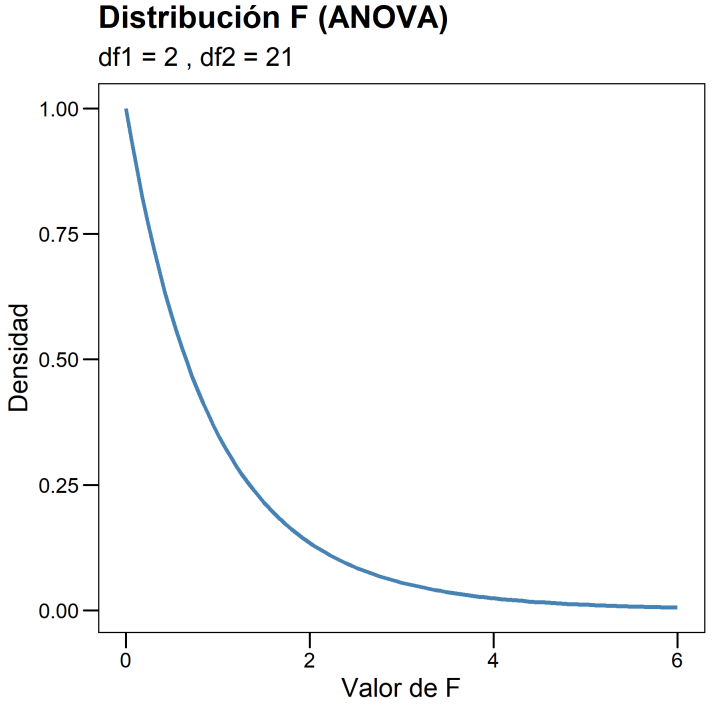
gl_{dentro}: número de observaciones totales - número de grupos = 24 - 3 = 21

Cómo funciona un ANOVA de una vía

Cálculo del estadístico F:

$$`F = \frac{MS_{entre}}{MS_{dentro}}`$$

$$`F = \frac{MS_{entre}}{MS_{dentro}} = \frac{60.67}{1.71} = 35.39`$$



Propiedades:

- El valor de F siempre es positivo
- Generalmente se utiliza una α de 0.05 y una hipótesis unilateral (en el ANOVA para comparar medias de grupos)

Tabla de la distribución F ($\alpha = 0.05$)

Valores críticos de la distribución F (cola superior, α = 0.05)

	gl1 = 1	gl1 = 2	gl1 = 3	gl1 = 4	gl1 = 5	gl1 = 6	gl1 = 7	gl1 = 8	gl1 = 9	gl1 = 10	gl1 = 11	gl1 = 12	gl1 = 13	gl1 = 14	gl1 = 15
gl2 = 1	161.4476	199.5000	215.7073	224.5832	230.1619	233.9860	236.7684	238.8827	240.5433	241.8817	242.9835	243.9060	244.6898	245.3640	245.9499
gl2 = 2	18.5128	19.0000	19.1643	19.2468	19.2964	19.3295	19.3532	19.3710	19.3848	19.3959	19.4050	19.4125	19.4189	19.4244	19.4291
gl2 = 3	10.1280	9.5521	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123	8.7855	8.7633	8.7446	8.7287	8.7149	8.7029
gl2 = 4	7.7086	6.9443	6.5914	6.3882	6.2561	6.1631	6.0942	6.0410	5.9988	5.9644	5.9358	5.9117	5.8911	5.8733	5.8578
gl2 = 5	6.6079	5.7861	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725	4.7351	4.7040	4.6777	4.6552	4.6358	4.6188
gl2 = 6	5.9874	5.1433	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.0990	4.0600	4.0274	3.9999	3.9764	3.9559	3.9381
gl2 = 7	5.5914	4.7374	4.3468	4.1203	3.9715	3.8660	3.7870	3.7257	3.6767	3.6365	3.6030	3.5747	3.5503	3.5292	3.5107
gl2 = 8	5.3177	4.4590	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881	3.3472	3.3130	3.2839	3.2590	3.2374	3.2184
gl2 = 9	5.1174	4.2565	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789	3.1373	3.1025	3.0729	3.0475	3.0255	3.0061
gl2 = 10	4.9646	4.1028	3.7083	3.4780	3.3258	3.2172	3.1355	3.0717	3.0204	2.9782	2.9430	2.9130	2.8872	2.8647	2.8450
gl2 = 11	4.8443	3.9823	3.5874	3.3567	3.2039	3.0946	3.0123	2.9480	2.8962	2.8536	2.8179	2.7876	2.7614	2.7386	2.7186
gl2 = 12	4.7472	3.8853	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964	2.7534	2.7173	2.6866	2.6602	2.6371	2.6169
gl2 = 13	4.6672	3.8056	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144	2.6710	2.6347	2.6037	2.5769	2.5536	2.5331
gl2 = 14	4.6001	3.7389	3.3439	3.1122	2.9582	2.8477	2.7642	2.6987	2.6458	2.6022	2.5655	2.5342	2.5073	2.4837	2.4630
gl2 = 15	4.5431	3.6823	3.2874	3.0556	2.9013	2.7905	2.7066	2.6408	2.5876	2.5437	2.5068	2.4753	2.4481	2.4244	2.4034
gl2 = 16	4.4940	3.6337	3.2389	3.0069	2.8524	2.7413	2.6572	2.5911	2.5377	2.4935	2.4564	2.4247	2.3973	2.3733	2.3522
gl2 = 17	4.4513	3.5915	3.1968	2.9647	2.8100	2.6987	2.6143	2.5480	2.4943	2.4499	2.4126	2.3807	2.3531	2.3290	2.3077
gl2 = 18	4.4139	3.5546	3.1599	2.9277	2.7729	2.6613	2.5767	2.5102	2.4563	2.4117	2.3742	2.3421	2.3143	2.2900	2.2686
gl2 = 19	4.3807	3.5219	3.1274	2.8951	2.7401	2.6283	2.5435	2.4768	2.4227	2.3779	2.3402	2.3080	2.2800	2.2556	2.2341
gl2 = 20	4.3512	3.4928	3.0984	2.8661	2.7109	2.5990	2.5140	2.4471	2.3928	2.3479	2.3100	2.2776	2.2495	2.2250	2.2033
gl2 = 21	4.3248	3.4668	3.0725	2.8401	2.6848	2.5727	2.4876	2.4205	2.3660	2.3210	2.2829	2.2504	2.2222	2.1975	2.1757

Decisión: ¿rechazamos H_0?

- Grados de libertad: numerador = 2, denominador = 21
- En la tabla: $F_{crit}(2, 21) = 3.47$
- $F_{obs} = 35.39 > 3.47 \rightarrow$ rechazamos H_0

> Conclusión: al menos una de las medias de los tres grupos es diferente. Para saber cuál, necesitaremos un test *post hoc*.

Tabla del ANOVA (cálculo a mano)

Todos los resultados del ejemplo se resumen en la tabla del ANOVA:

Fuente de variación	SS	gl	MS	F	p-valor
Entre grupos	121.33	2	60.67	35.39	1.9×10^{-7}
Dentro (residuos)	36	21	1.71		
Total	157.33	23			

- $SS_{total} = SS_{entre} + SS_{dentro} = 121.33 + 36 = 157.33$
- $gl_{total} = gl_{entre} + gl_{dentro} = 2 + 21 = 23 = N - 1$

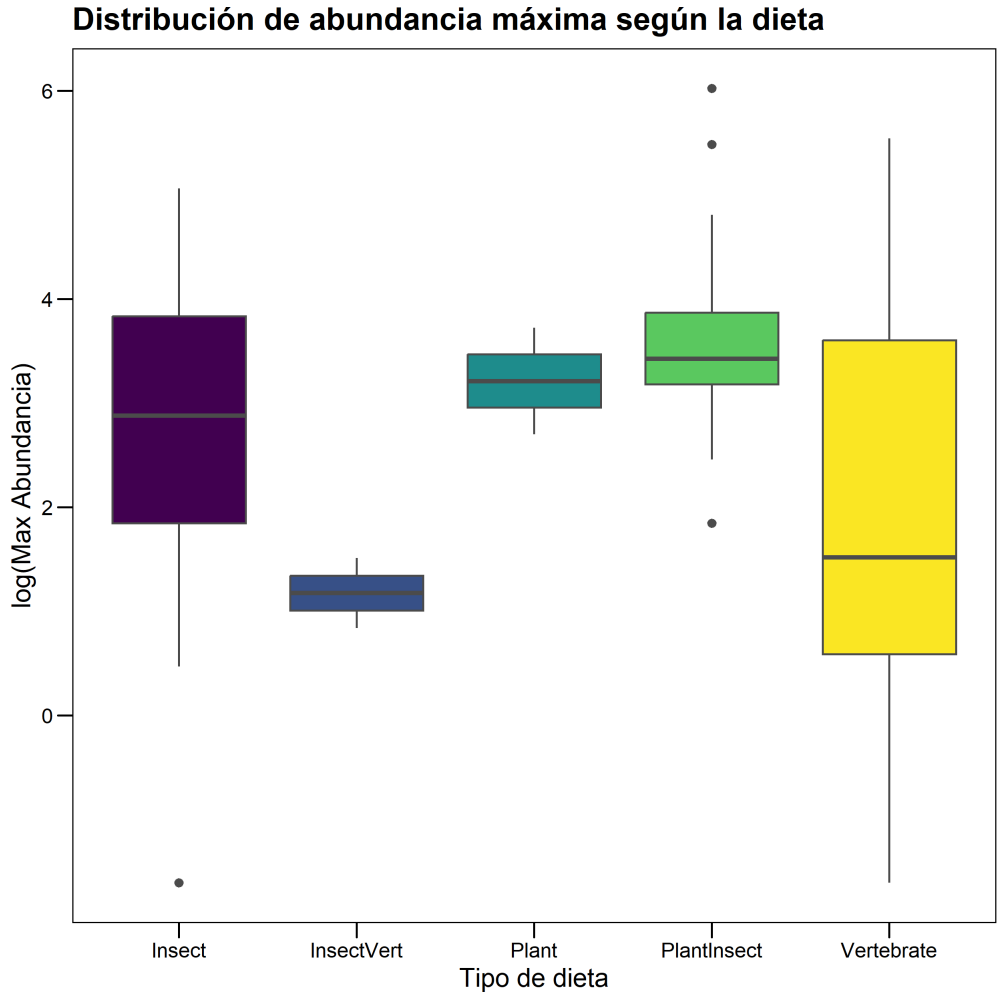
ANOVA en R

Estamos interesados en comprobar si la abundancia de aves depende de la dieta. Total: n = 54 aves.

Family	MaxAbund	AvgAbund	Mass	Diet	Passerine	Aquatic
Hawks&Eagles&Kites	2.9855437	0.6740216	716.018936	Vertebrate	0	0
Long-tailed tits	37.8000000	4.0404300	5.300000	Insect	1	0
Larks	241.4000000	23.1054000	35.777088	PlantInsect	1	0
Kingfishers	4.4000000	0.5949060	119.371716	Vertebrate	0	0
Auks& Puffins	4.5325048	2.9632718	315.495519	InsectVert	0	1
Ducks& Geese	23.6936352	2.7416729	1144.290035	PlantInsect	0	1
Anhingas	24.6000000	1.8423100	1250.000000	Vertebrate	0	1

Visualizar los datos en R

```
ggplot(bird, aes(x = Diet,
                 y = log(MaxAbund),
                 fill=Diet)) +
  geom_boxplot() +
  labs(
    x = "Tipo de dieta",
    y = "log(Max. abundancia)",
    title = "Distribución de abundancia máxima
  ) +
  ggthemes::theme_base(base_size = 14) +
  theme(plot.background = element_rect(colour =
  theme(
    plot.title = element_text(face = "bold", hj
    axis.text.x = element_text(angle = 45, hjus
  )
```



Verificar los supuestos del ANOVA

> Primero, hacemos el ANOVA solo para poder obtener los **residuos** y verificar los supuestos
> ¡Los supuestos del ANOVA se aplican sobre los **residuos**, no sobre los datos originales!

- Los residuos representan el error que comete el modelo al predecir cada observación.
- En el ANOVA, son las diferencias entre los valores observados y las medias de los grupos

Fuente de variación	Suma de cuadrados (SS)	Grados de libertad (gl)	Media cuadrática (MS)	Estadístico F
Factor (variabilidad entre grupos)	$SS_{entre} = \sum_{i=1}^{g} n_i (M_i - G)^2$	$gl_{entre} = g - 1$	$MS_{entre} = \frac{SS_{entre}}{gl_{entre}}$	$F = \frac{MS_{entre}}{MS_{dentro}}$
Residuos (variabilidad dentro de los grupos)	$SS_{dentro} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - M_i)^2$	$gl_{dentro} = N - g$	$MS_{dentro} = \frac{SS_{dentro}}{gl_{dentro}}$	
Total	$SS_{total} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - G)^2$	$gl_{total} = N - 1$		

Donde:

- G = media global (media conjunta de todos los grupos)
- M_i = media del grupo *i*
- n_i = tamaño del grupo *i*
- g = número de grupos
- N = número total de observaciones

Verificar los supuestos del ANOVA

MS_{entre}: es una estimación de la variabilidad entre las poblaciones. Se suele conocer como "varianza explicada" por el factor que define las poblaciones.

- Nos dice cuánta diferencia hay entre los grupos, y por tanto refleja el efecto del tratamiento o del factor que estamos estudiando.

MS_{dentro}: es una estimación conjunta de la varianza residual dentro de cada población. Esta varianza se supone que es la misma para todos los grupos.

- Es una medida del “ruido” o la variabilidad natural que hay dentro de cada grupo.
- Nos dice cuánto varían los valores entre sí dentro de los grupos, sin tener en cuenta las diferencias entre grupos.

Así, cuando calculamos el estadístico F, estamos viendo si las diferencias entre grupos son mayores que el ruido interno esperado por azar.

Verificar los supuestos en R

- Normalidad de los residuos: los residuos del modelo deben seguir una distribución normal.
  - El test de Shapiro-Wilk permite contrastar si los residuos son normales.

Las hipótesis son:

$$H_0 : \text{los residuos siguen una distribución normal}$$

$$H_A : \text{los residuos no siguen una distribución normal}$$

- Homoscedasticidad: debe comprobarse que las varianzas de los grupos son iguales (o al menos que no existen diferencias significativas entre ellas).
  - Aplicamos el Test de Levene.

Las hipótesis son:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_p^2$$

$$H_A : \text{existe al menos un par } (i, j) \text{ tal que } \sigma_i^2 \neq \sigma_j^2$$

ANOVA en R

La función aov() permite realizar el ANOVA:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
aov1
```

```
Call:
   aov(formula = log(MaxAbund) ~ Diet, data = bird)

Terms:
                     Diet Residuals
Sum of Squares   27.07079 116.91775
Deg. of Freedom         4        49

Residual standard error: 1.544693
Estimated effects may be unbalanced
```

ANOVA en R

La función `aov()` permite realizar el ANOVA:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
aov1
```

- `log(MaxAbund)` → es la variable dependiente (la que queremos comparar entre grupos). Logaritmo para normalizar.
- `Diet` → es la variable independiente o factor (los grupos que queremos comparar, por ejemplo diferentes tipos de dieta).
- `data = bird` → indica que los datos se encuentran en el `dataframe bird`.

El operador `~` se lee como “en función de”, es decir: “queremos analizar la abundancia máxima en función de la dieta”.

Normalidad de residuos

Aplicamos el test de Shapiro sobre los residuos, accesibles con la función `resid()`.

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
head(resid(aov1), 20)
```

```
          1           2           3           4           5           6           7           8 
-0.85625404  0.97537067  1.85713458 -0.46843137  0.33589637 -0.46411427  1.25271053  1.12666011 -2.1869348
         17          18          19          20 
-0.51210580 -1.16693290 -0.06183505 -1.22816339 
```

- Cada valor es una observación de la tabla (54 en total)
- El residuo se calcula como la resta del valor observado menos el valor predicho por el modelo (es decir, la media del grupo al que pertenece dicho valor)
- Los residuos reflejan cuánto se desvía cada observación de la media de su grupo, es decir, la parte que el modelo no explica.

Normalidad de residuos

Aplicamos el test de Shapiro sobre los residuos, accesibles con la función `resid()`.

```
shapiro.test(resid(aov1))
```

```
    Shapiro-Wilk normality test

data:  resid(aov1)
W = 0.97995, p-value = 0.4982
```

- Si p-valor > 0.05, no se rechaza H_0: no hay evidencia suficiente para afirmar que los residuos no son normales, por lo que asumimos que se cumple el supuesto de normalidad.

Homogeneidad de varianzas

Para verificar si los residuos del ANOVA tienen varianzas similares entre los grupos (supuesto de homogeneidad de varianzas), aplicamos el test de Levene:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
```

```
library(car)
leveneTest(aov1)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value  Pr(>F)
group  4  2.3493 0.06717 .
      49
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Si p-valor > 0.05 → no se rechaza H_0: no hay evidencia de que las varianzas difieran entre grupos, por lo que asumimos homogeneidad de varianzas.

ANOVA en R

En R, el ANOVA se puede ejecutar directamente con la función aov():

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
summary(aov1)
```

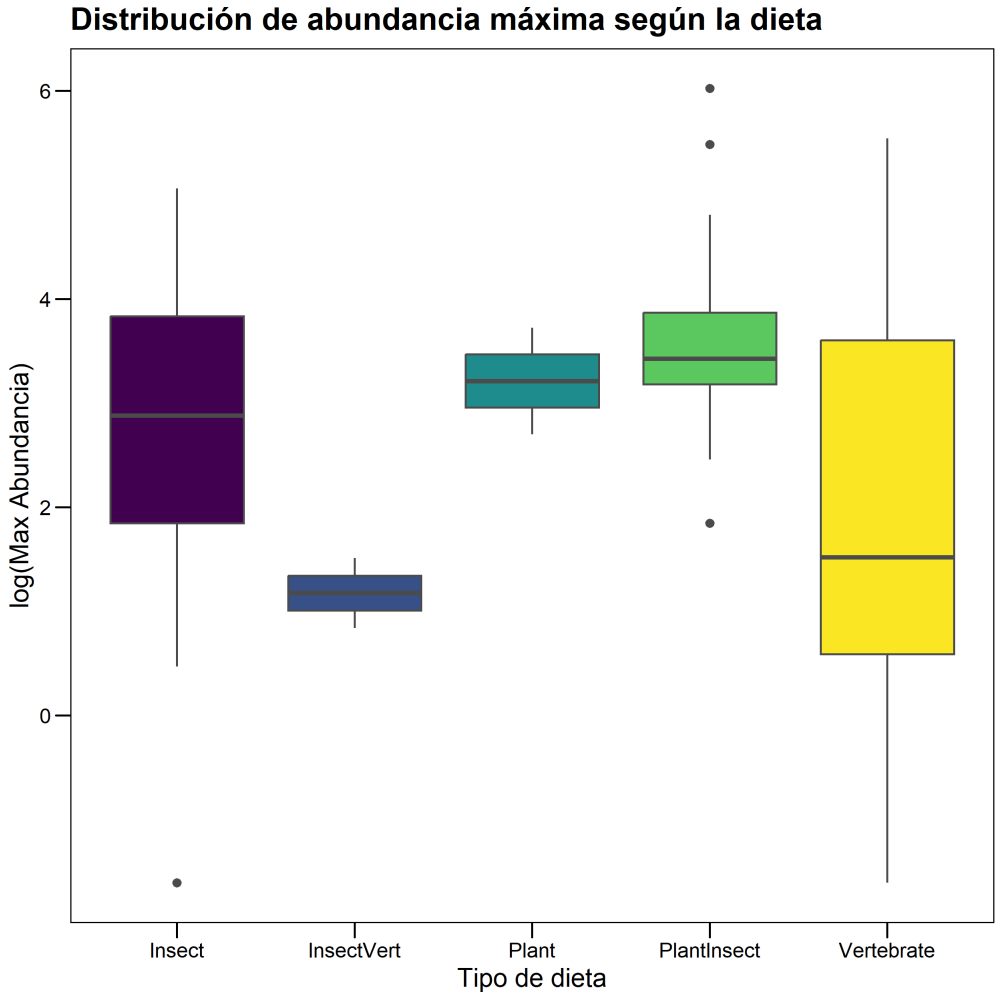
```
            Df Sum Sq Mean Sq F value Pr(>F)
Diet         4  27.07   6.768   2.836 0.0341 *
Residuals   49 116.92   2.386
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretación del ANOVA

```
            Df Sum Sq Mean Sq F value Pr(>F)
Diet         4  27.07   6.768   2.836 0.0341 *
Residuals   49 116.92   2.386
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- `Df` (grados de libertad): número de niveles del factor − 1 ($g - 1$) para el factor, y número total de observaciones − número de grupos ($N - g$) para los residuos.
- `Sum Sq` (suma de cuadrados): cantidad de variación explicada por el factor y por los residuos
- `Mean Sq` (media de cuadrados): varianza estimada por cada componente.
- `F value`: estadístico F, que compara la variabilidad entre grupos con la variabilidad dentro de los grupos.
- `Pr(>F)`: valor p, que indica si las diferencias entre las medias de los grupos son estadísticamente significativas. Se proporciona el valor numérico y un código de significación (asteriscos).

Interpretación del ANOVA



Test complementario: test de Tukey

- ANOVA solo indica si existe una diferencia significativa entre grupos, no cuál es diferente.
- Para identificar qué grupos difieren entre sí, se realizan tests post-hoc que comparan los niveles del factor dos a dos.
- Test típico es el Tukey's HSD (*Honestly Significant Difference*):
  - Compara todas las parejas de medias de los grupos tras un ANOVA
  - Garantiza que el nivel global de significación se mantenga, controlando el error tipo I (falsos positivos) cuando se hacen múltiples comparaciones.

Test complementario: test de Tukey

La función `TukeyHSD` aplica el test de Tukey:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
TukeyHSD(aov1)
```

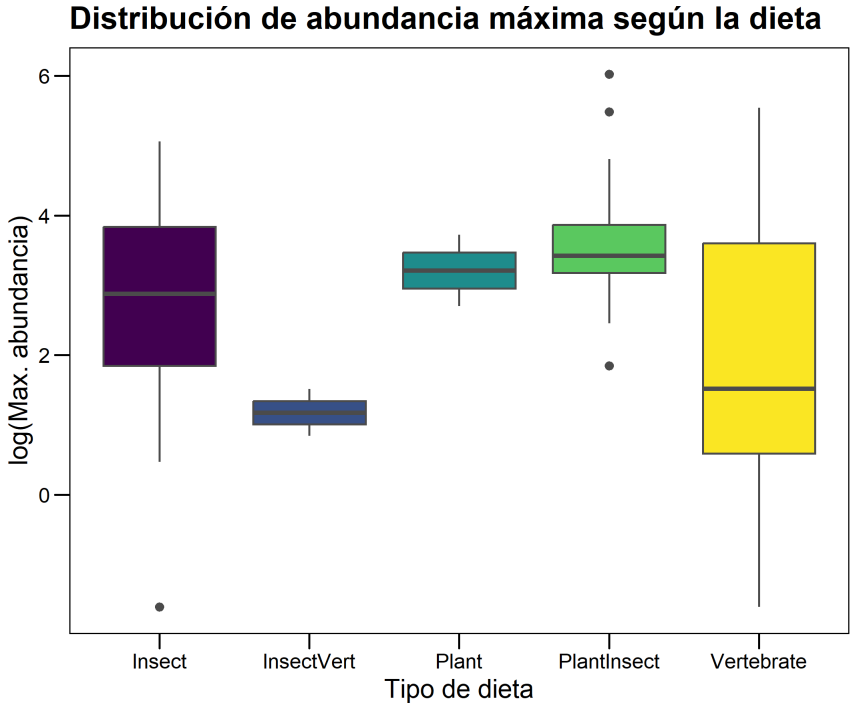
Resultados del test de Tukey para el factor Diet

	diff	lwr	upr	p adj
Vertebrate-PlantInsect	-1.6793	-3.3096	-0.0490	0.0405
PlantInsect-InsectVert	2.4539	-0.8066	5.7145	0.2236
PlantInsect-Insect	0.9724	-0.4489	2.3936	0.3118
Plant-InsectVert	2.0365	-2.3380	6.4110	0.6812
InsectVert-Insect	-1.4816	-4.7258	1.7626	0.6965
Vertebrate-Insect	-0.7069	-2.3042	0.8904	0.7204
Vertebrate-Plant	-1.2618	-4.6029	2.0792	0.8211

- Aplica el test post-hoc de Tukey (HSD), que compara todas las posibles parejas de grupos de `Diet` para determinar qué grupos son significativamente diferentes entre sí.

Test complementario: test de Tukey

- Las comparaciones con un p-valor ajustado (corregido) < 0.05, son las significativas
- En este caso, la única diferencia significativa en la abundancia ocurre entre las dietas `PlantInsect` y `Vertebrate`.



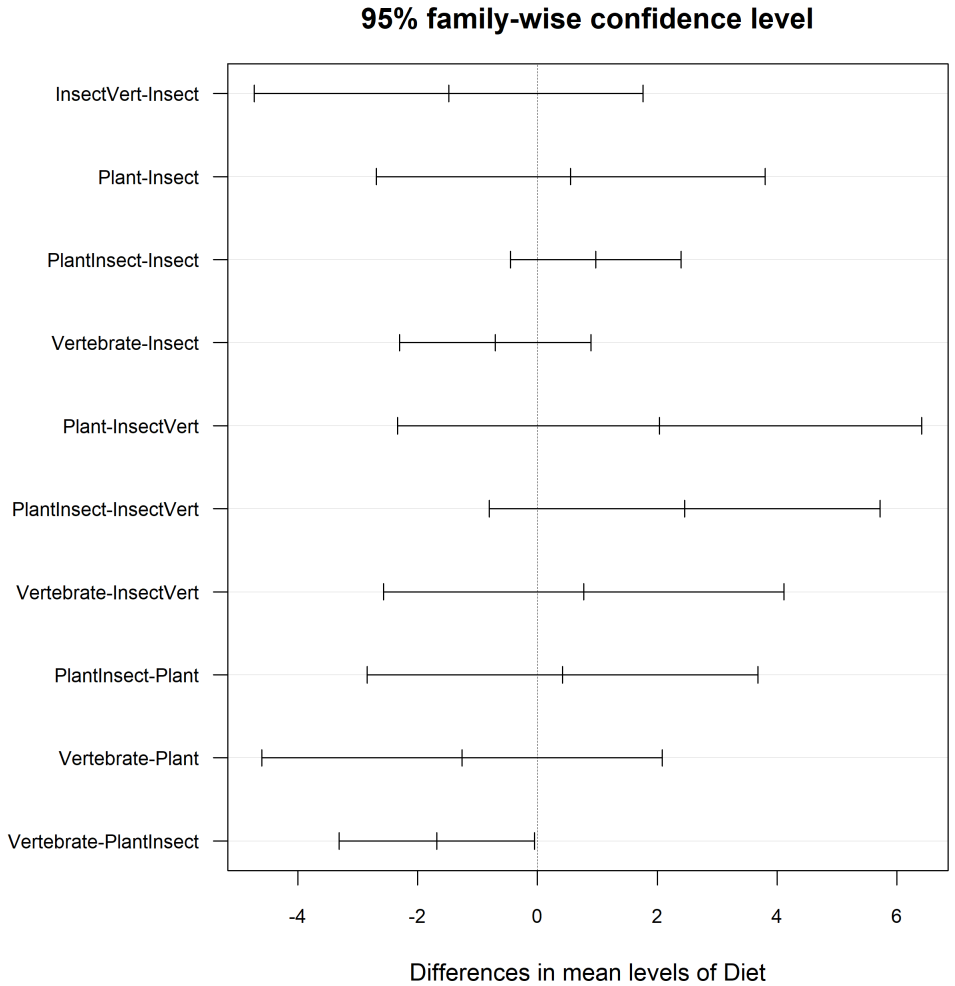
Test complementario: test de Tukey

- El test de Tukey HSD está diseñado para comparar todas las medias entre sí sin inflar el error tipo I (el riesgo de falsos positivos): FWER - *family-wise error rate*
- El error familiar (FWER) es la probabilidad de cometer al menos un error tipo I en el conjunto de comparaciones.

Visualizar el resultado del test de Tukey

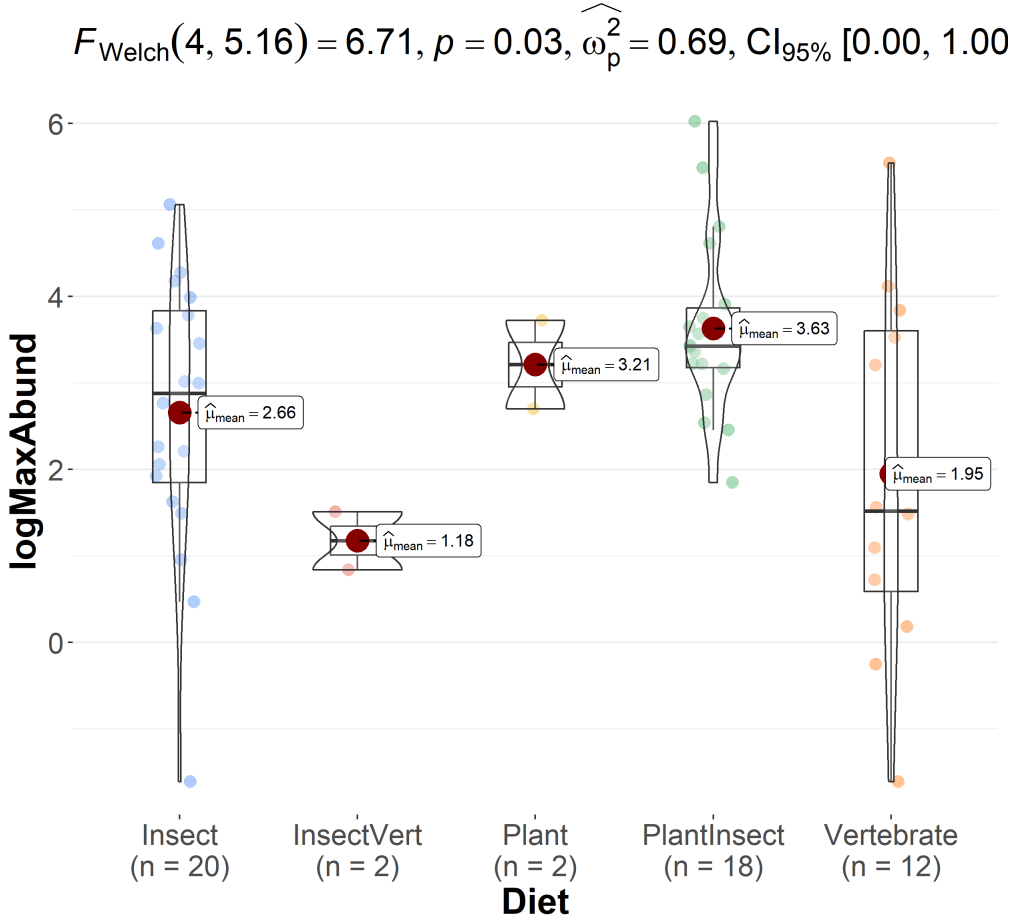
```
tuk <- TukeyHSD(aov1)
plot(tuk, las = 1)
```

- Las líneas horizontales son el intervalo de confianza (IC) al 95% de la diferencia de medias, ajustado por el método de Tukey.
- La línea vertical discontinua en 0 marca el punto donde no hay diferencia (diferencia = 0).
  - Si el intervalo cruza el 0, la diferencia no es significativa (no puedes descartar que sean iguales).
  - Si el intervalo no toca el 0, la diferencia sí es significativa.



Visualizar el resultado del ANOVA

Figura creada con el paquete `ggstatsplot`.



Alternativas al ANOVA

Si no se cumplen los supuestos del ANOVA (normalidad o homogeneidad de varianzas), existen dos estrategias principales:

Transformación de los datos

- Aplicar logaritmo (`y_transf <- log(y)`): datos sesgados
- Inversa (`y_transf <- 1/y`): datos con asimetría positiva muy fuerte
- ...

Test no paramétrico: Kruskal-Wallis

Si ninguna transformación funciona, usar un test no paramétrico:

```
kruskal.test(y ~ grupo, data = datos)
```

- No requiere normalidad ni homogeneidad de varianzas
- Compara los rangos (las distribuciones) de los grupos en lugar de las medias; si las distribuciones tienen una forma similar, se interpreta como una comparación de medianas

Welch-ANOVA: varianzas distintas

Si se cumple la normalidad pero no la homogeneidad de varianzas:

```
oneway.test(log(MaxAbund) ~ Diet, data = bird, var.equal = FALSE)
```

```
    One-way analysis of means (not assuming equal variances)

data:  log(MaxAbund) and Diet
F = 6.7109, num df = 4.0000, denom df = 5.1568, p-value = 0.02858
```

- No asume varianzas iguales: corrige los grados de libertad del denominador (por eso no son enteros).
- *Post hoc* adecuado: Games-Howell (tampoco asume varianzas iguales).

```
# install.packages("rstatix")
library(rstatix)
games_howell_test(bird, logMaxAbund ~ Diet)
```

Kruskal-Wallis y *post hoc* de Dunn

```
kruskal.test(MaxAbund ~ Diet, data = bird)
```

```
    Kruskal-Wallis rank sum test

data:  MaxAbund by Diet
Kruskal-Wallis chi-squared = 8.6127, df = 4, p-value = 0.07154
```

- Si Kruskal-Wallis es significativo, el *post hoc* adecuado es el test de Dunn, con corrección de p-valores por comparaciones múltiples:

```
library(rstatix)
dunn_test(bird, MaxAbund ~ Diet, p.adjust.method = "holm")
```

> Aquí Kruskal-Wallis no es significativo (p = 0.07) y el ANOVA sobre `log(MaxAbund)` sí lo es (p = 0.03): si se cumplen los supuestos, el ANOVA tiene más potencia.

Resumen: ¿qué test uso?

1. Visualizar los datos (boxplot por grupo)
2. Ajustar el modelo con `aov()` y comprobar los supuestos sobre los residuos (Shapiro-Wilk, QQ-plot, Levene)
3. Elegir el test global; si es significativo → test *post hoc*
4. Cuantificar el tamaño del efecto: $R^2 = \eta^2$ en el ANOVA; en Kruskal-Wallis, η^2_H con `kruskal_effsize()` (`rstatix`)

Situación	Test global	Test *post hoc*
Normalidad ✓ y homogeneidad ✓	ANOVA: `aov()`	Tukey HSD: `TukeyHSD()`
Normalidad ✓, homogeneidad ✗	Welch-ANOVA: `oneway.test()`	Games-Howell
Normalidad ✗ (incluso tras transformar)	Kruskal-Wallis: `kruskal.test()`	Dunn (con corrección de p-valores)
Normalidad ✗ y homogeneidad ✗	Transformar + Welch-ANOVA, o test de permutación	Games-Howell (sobre los datos transformados)

ANOVA, t-test y modelo lineal

Con 2 grupos, el ANOVA y el t-test (con varianzas iguales) son equivalentes: $F = t^2$

```
dos <- droplevels(subset(bird,
          Diet %in% c("Insect", "Vertebrate")))
t_res <- t.test(log(MaxAbund) ~ Diet,
                data = dos, var.equal = TRUE)
t_res$statistic^2
```

```
       t
1.153278
```

```
summary(aov(log(MaxAbund) ~ Diet, data = dos))
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
Diet         1   3.75   3.748   1.153  0.291
Residuals   30  97.49   3.250
```

El ANOVA es un modelo lineal: `aov()` usa internamente `lm()`

```
anova(lm(log(MaxAbund) ~ Diet, data = bird))
```

```
Analysis of Variance Table

Response: log(MaxAbund)
          Df  Sum Sq Mean Sq F value Pr(>F)
Diet       4  27.071  6.7677  2.8363 0.0341 *
Residuals 49 116.918  2.3861
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.'
```

- `lm()` ajusta el modelo y `anova()` construye su tabla ANOVA: es la misma tabla que `summary(aov1)`
- Por eso, más adelante, usamos `summary(lm())` para obtener el R^2

Actividad de ANOVA

Una investigadora desea conocer la efectividad de varios suplementos alimenticios (*feed*) sobre la tasa de crecimiento (*weight*) de los pollos. Los datos están disponibles en la tabla `chickwts` de `R` y se muestran a continuación. Usa ANOVA para examinar la efectividad de los suplementos alimenticios. Ejercicio tomado de: Biostatistics with R. Shahbaba (2012). Springer.

Pesos de pollos por tipo de alimentación

horsebean	linseed	soybean	sunflower	meatmeal	casein
179	309	243	423	325	368
160	229	230	340	257	390
136	181	248	392	303	379
227	141	327	339	315	260
217	260	329	341	380	404
168	203	250	226	153	318
108	148	193	320	263	352
124	169	271	295	242	359
143	213	316	334	206	216
140	257	267	322	344	222
	244	199	297	258	283
	271	171	318		332
		158			
		248			

Primer paso: comprobar supuestos del ANOVA

```
aov1 <- aov(weight ~ feed, data = chickwts)

library(car)
leveneTest(aov1)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  5  0.7493 0.5896
      65
```

```
shapiro.test(residuals(aov1))
```

```

    Shapiro-Wilk normality test

data:  residuals(aov1)
W = 0.98616, p-value = 0.6272
```

Interpretación de los supuestos y del ANOVA

- Levene: p = 0.59 > 0.05 → no hay evidencia de que las varianzas difieran → asumimos homogeneidad
- Shapiro-Wilk (residuos): p = 0.63 > 0.05 → no hay evidencia de falta de normalidad

> Se cumplen los supuestos → podemos aplicar el ANOVA

```
summary(aov1)
```

```
            Df Sum Sq Mean Sq F value   Pr(>F)
feed         5 231129   46226   15.37 5.94e-10 ***
Residuals   65 195556    3009
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- gl: 6 tipos de suplemento − 1 = 5; 71 pollos − 6 grupos = 65
- $F_{obs} = 15.37 > F_{crit}(5, 65) = 2.36 \rightarrow$ rechazamos H_0 (p = 5.9 × 10^{-10}): el peso medio depende del suplemento alimenticio

Calculadora de la F crítica de Fisher

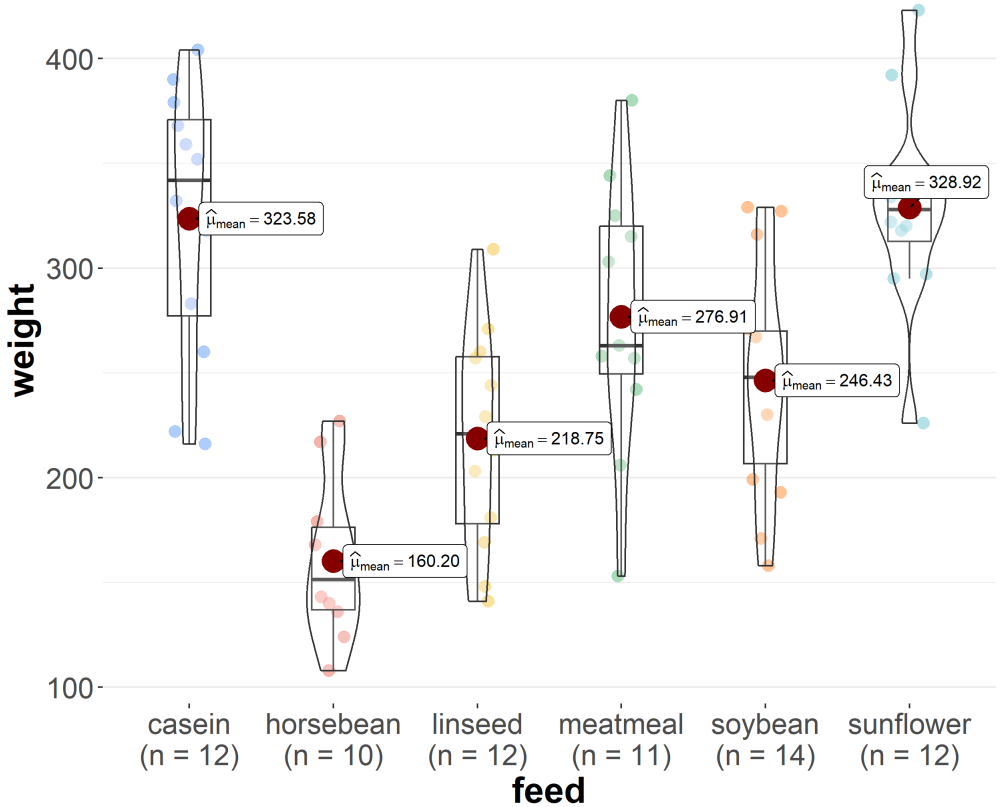
- Podemos utilizar calculadoras online como: https://www.danielsoper.com/statcalc/calculator.aspx?id=4 para obtener rápidamente la F crítica.
- Podemos utilizar la tabla:

Valores críticos de la distribución F (cola superior, α = 0.05)

	gl1 = 1	gl1 = 2	gl1 = 3	gl1 = 4	gl1 = 5	gl1 = 6	gl1 = 7	gl1 = 8	gl1 = 9	gl1 = 10	gl1 = 11	gl1 = 12	gl1 = 13	gl1 = 14	gl1 = 15
gl2 = 55	4.0162	3.1650	2.7725	2.5397	2.3828	2.2687	2.1813	2.1119	2.0552	2.0078	1.9675	1.9329	1.9026	1.8760	1.8523
gl2 = 56	4.0130	3.1619	2.7694	2.5366	2.3797	2.2656	2.1782	2.1087	2.0519	2.0045	1.9643	1.9295	1.8993	1.8726	1.8489
gl2 = 57	4.0099	3.1588	2.7664	2.5336	2.3767	2.2625	2.1751	2.1056	2.0488	2.0014	1.9611	1.9263	1.8960	1.8693	1.8456
gl2 = 58	4.0069	3.1559	2.7636	2.5307	2.3738	2.2596	2.1721	2.1026	2.0458	1.9983	1.9580	1.9233	1.8929	1.8662	1.8424
gl2 = 59	4.0040	3.1531	2.7608	2.5279	2.3710	2.2568	2.1693	2.0997	2.0429	1.9954	1.9551	1.9203	1.8899	1.8632	1.8394
gl2 = 60	4.0012	3.1504	2.7581	2.5252	2.3683	2.2541	2.1665	2.0970	2.0401	1.9926	1.9522	1.9174	1.8870	1.8602	1.8364
gl2 = 61	3.9985	3.1478	2.7555	2.5226	2.3657	2.2514	2.1639	2.0943	2.0374	1.9899	1.9495	1.9146	1.8842	1.8574	1.8336
gl2 = 62	3.9959	3.1453	2.7530	2.5201	2.3631	2.2489	2.1613	2.0917	2.0348	1.9872	1.9468	1.9119	1.8815	1.8547	1.8308
gl2 = 63	3.9934	3.1428	2.7505	2.5177	2.3607	2.2464	2.1588	2.0892	2.0322	1.9847	1.9442	1.9093	1.8789	1.8520	1.8282
gl2 = 64	3.9909	3.1404	2.7482	2.5153	2.3583	2.2440	2.1564	2.0868	2.0298	1.9822	1.9417	1.9068	1.8763	1.8495	1.8256
gl2 = 65	3.9886	3.1381	2.7459	2.5130	2.3560	2.2417	2.1541	2.0844	2.0274	1.9798	1.9393	1.9044	1.8739	1.8470	1.8231
gl2 = 66	3.9863	3.1359	2.7437	2.5108	2.3538	2.2395	2.1518	2.0821	2.0251	1.9775	1.9370	1.9020	1.8715	1.8446	1.8207
gl2 = 67	3.9840	3.1338	2.7416	2.5087	2.3517	2.2373	2.1497	2.0799	2.0229	1.9752	1.9347	1.8997	1.8692	1.8423	1.8183
gl2 = 68	3.9819	3.1317	2.7395	2.5066	2.3496	2.2352	2.1475	2.0778	2.0207	1.9730	1.9325	1.8975	1.8669	1.8400	1.8160
gl2 = 69	3.9798	3.1296	2.7375	2.5046	2.3475	2.2332	2.1455	2.0757	2.0186	1.9709	1.9304	1.8953	1.8648	1.8378	1.8138
gl2 = 70	3.9778	3.1277	2.7355	2.5027	2.3456	2.2312	2.1435	2.0737	2.0166	1.9689	1.9283	1.8932	1.8627	1.8357	1.8117

Resultado del ANOVA

$F_{Welch}(5, 29.95) = 19.66$, $p = 1.18e\text{-}08$, $\widehat{\omega_p^2} = 0.72$, $CI_{95\%}$ [0



Resultado del test de Tukey

Resultados del test de Tukey

	diff	lwr	upr	p adj
linseed-horsebean	58.5500	-10.4135	127.5135	0.1413
soybean-horsebean	86.2286	19.5417	152.9155	0.0042
meatmeal-horsebean	116.7091	46.3351	187.0831	0.0001
casein-horsebean	163.3833	94.4198	232.3469	0.0000
sunflower-horsebean	168.7167	99.7531	237.6802	0.0000
soybean-linseed	27.6786	-35.6837	91.0409	0.7933
meatmeal-linseed	58.1591	-9.0729	125.3911	0.1277
casein-linseed	104.8333	39.0792	170.5875	0.0002
sunflower-linseed	110.1667	44.4125	175.9208	0.0001

Conclusiones de la actividad

- 8 de las 15 comparaciones por pares son significativas (p ajustado < 0.05)
- casein (323.6 g) y sunflower (328.9 g) dan los pesos medios más altos y no difieren entre sí
- horsebean (160.2 g) da el peso más bajo: es significativamente menor que casein, sunflower, meatmeal y soybean
- linseed (218.8 g) y soybean (246.4 g) son significativamente menores que casein y sunflower
- meatmeal (276.9 g) ocupa una posición intermedia: solo difiere de horsebean

> Conclusión: el tipo de suplemento afecta al crecimiento de los pollos; los más efectivos son casein y sunflower, y el menos efectivo, horsebean.

La F crítica y p-valor en R

- F crítico: valor umbral que define si rechazamos la hipótesis nula H_0 al nivel de significación α.

```
alpha <- 0.05       # nivel de significación
df1 <- 5            # gl del numerador (número de grupos - 1 = 6 suplementos - 1)
df2 <- 65           # gl del denominador (total muestras - número de grupos = 71 - 6)

F_critical <- qf(1 - alpha, df1, df2, lower.tail = TRUE)
F_critical
```

```
[1] 2.356028
```

La función qf devuelve el valor de F que corresponde al 5% de probabilidad de error tipo I (cola superior) dados esos grados de libertad.

> Si $F_{obs} > F_{crit}$ rechazamos H_0

La F crítica y p-valor en R

- P-valor: probabilidad de obtener un valor de F igual o mayor que el observado, F_{obs}.

```
df1 <- 5
df2 <- 65
F_obs <- 15.36  # F del ANOVA de chickwts

p_value <- pf(F_obs, df1, df2, lower.tail = FALSE)
p_value
```

```
[1] 5.967948e-10
```

La función `pf` calcula directamente esta probabilidad.

> Si $p\text{-valor} < \alpha \rightarrow$ el ANOVA es significativo.
> ¡`lower.tail=FALSE` porque ANOVA siempre mira la cola superior!

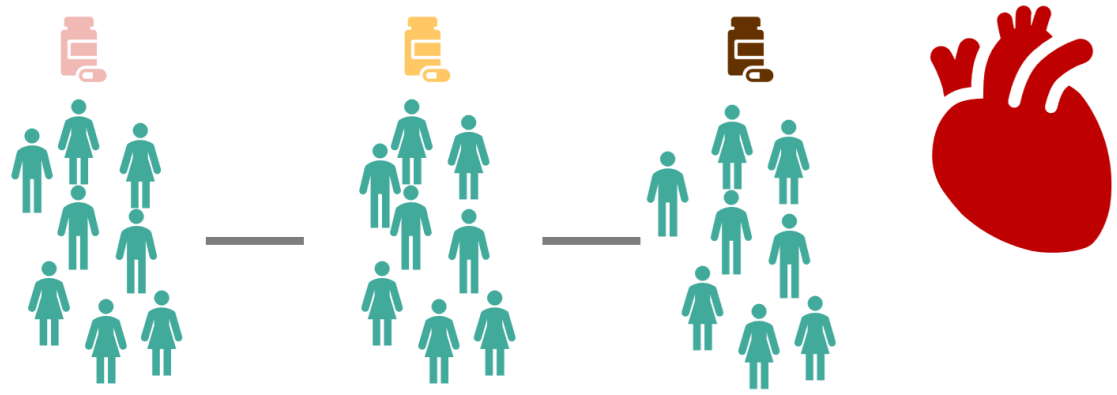
ANOVA de DOS VÍAS

ANOVA de dos vías

- Método estadístico para probar el efecto de **dos variables categóricas** sobre una **variable continua**.
  - Las **variables categóricas** son las **variables independientes**
  - La **variable continua** es la **variable respuesta**
- Es una extensión del ANOVA de una vía

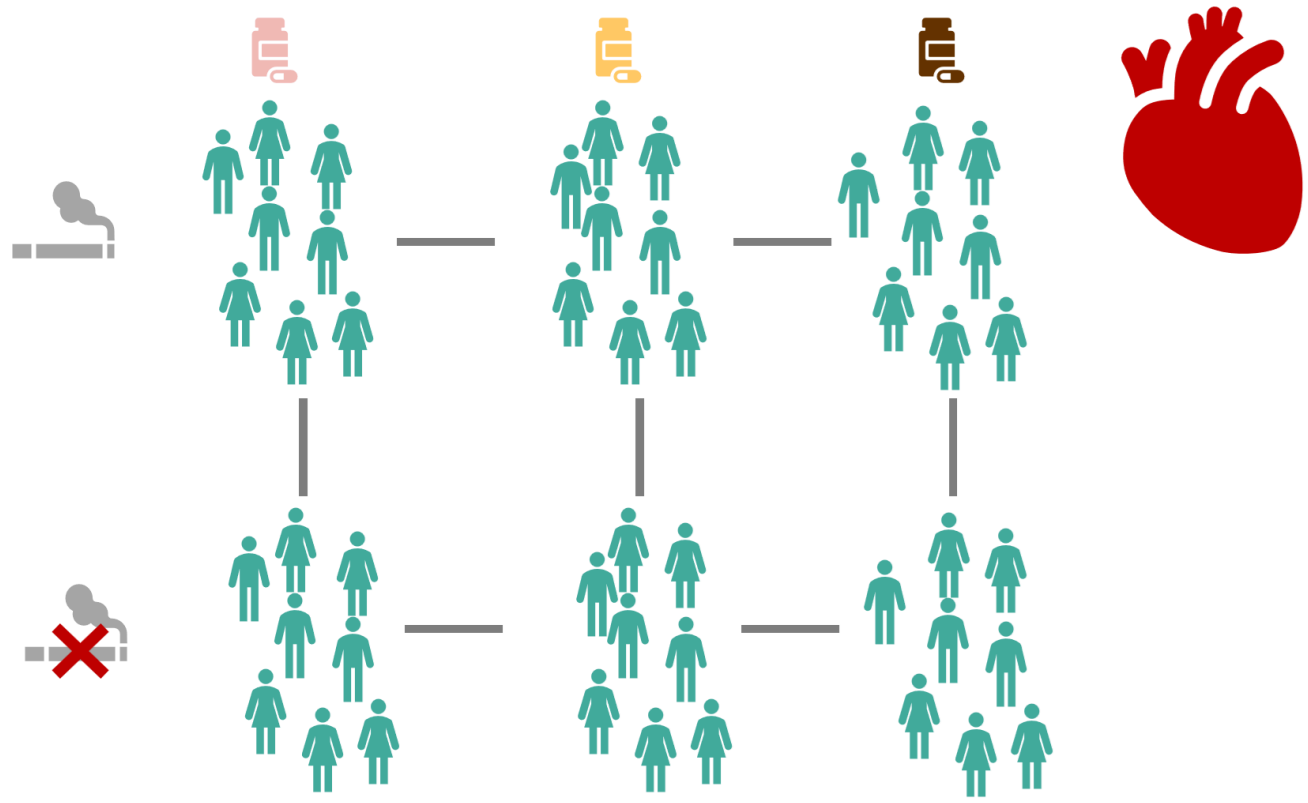
¿Cuándo usamos el ANOVA de dos vías?

- Usamos un ANOVA de dos vías cuando queremos evaluar el efecto de dos factores independientes sobre una variable dependiente.



¿Cuándo usamos el ANOVA de dos vías?

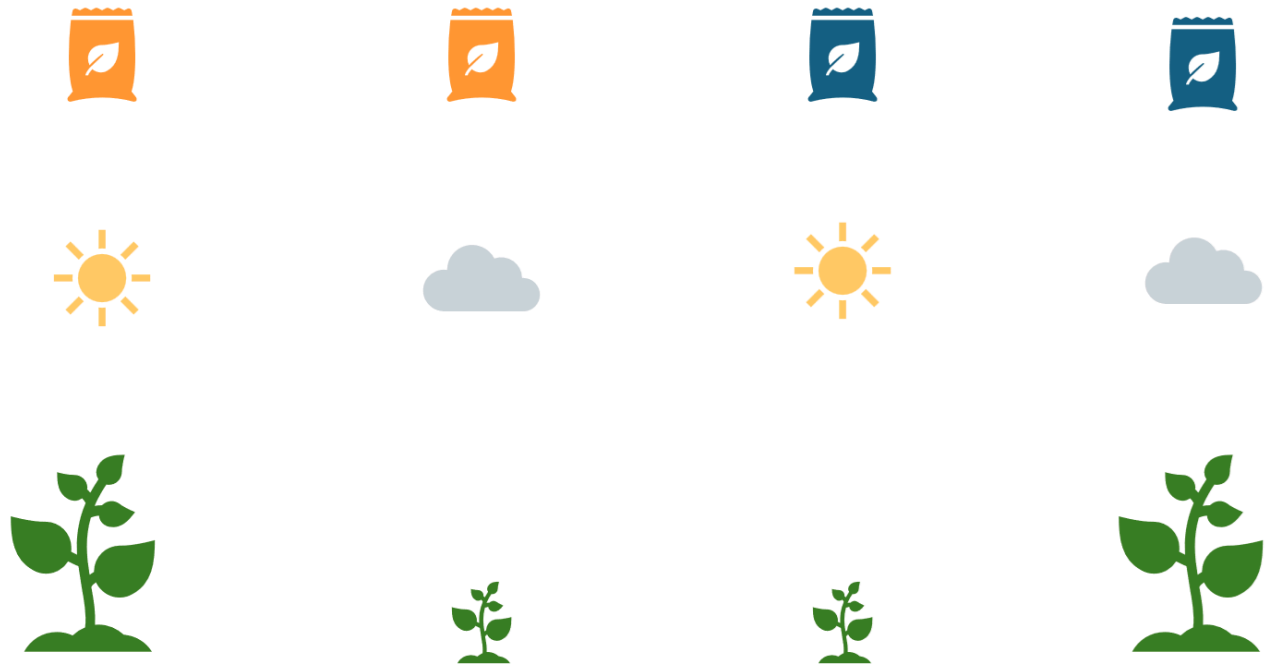
- Usamos un ANOVA de dos vías cuando queremos evaluar el efecto de dos factores independientes sobre una variable dependiente.



Ejemplo de ANOVA de dos vías

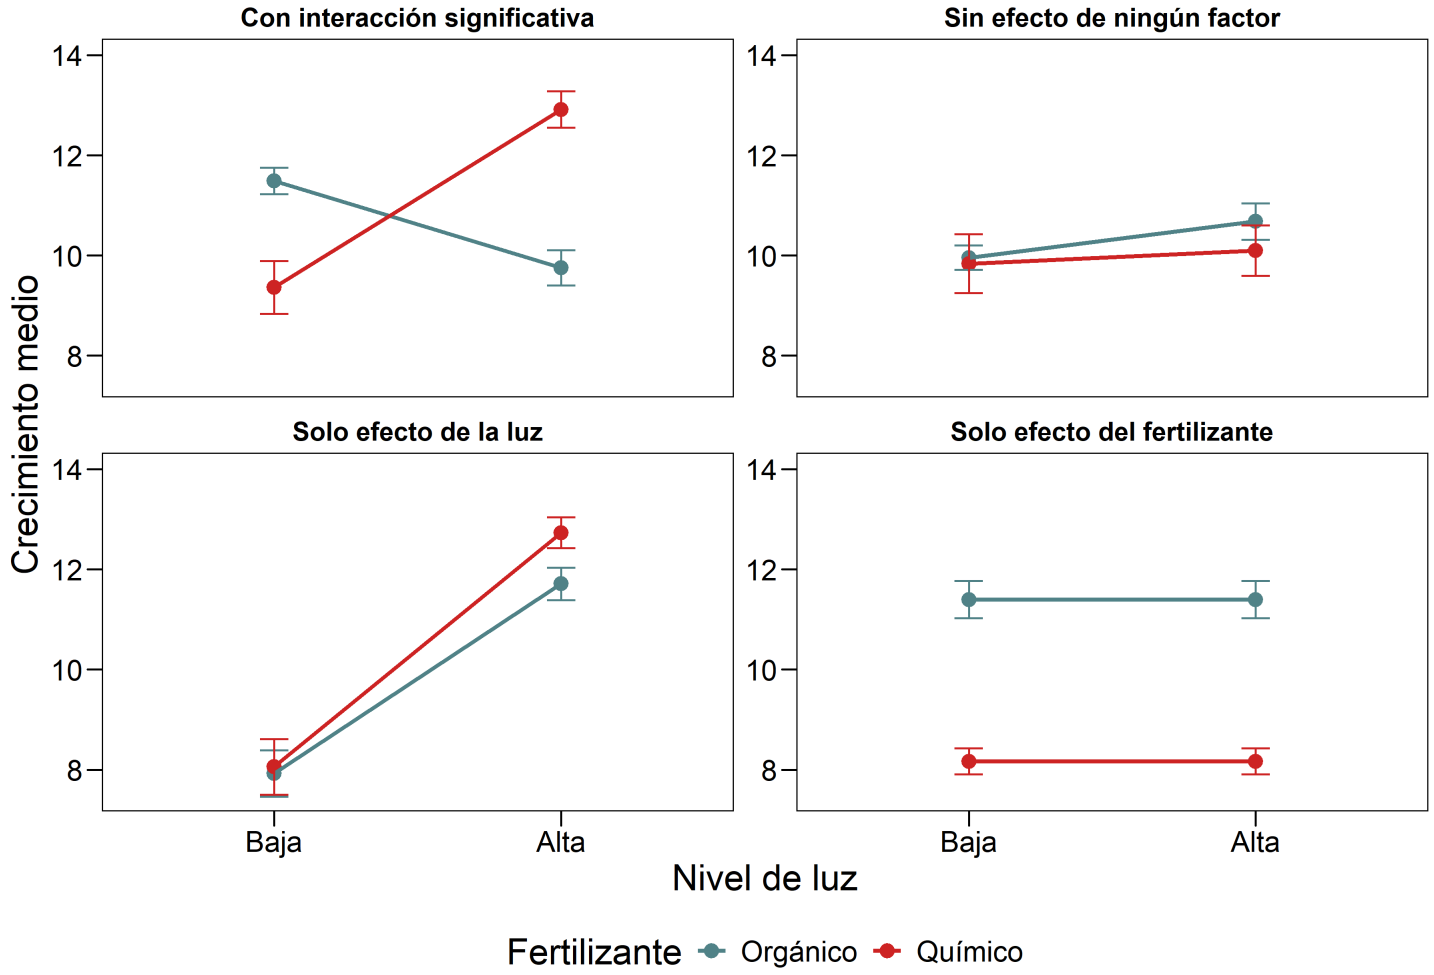
- Variable dependiente: crecimiento de una planta
- Factor 1: tipo de fertilizante (orgánico vs. químico)
- Factor 2: cantidad de luz (alta vs. baja)

¿El fertilizante y/o la luz afectan al crecimiento? ¿Depende el efecto del fertilizante del nivel de luz?



¿Qué afirmaciones podemos hacer con un ANOVA de dos vías?

Posibles escenarios de un ANOVA: efectos principales e interacción



¿Qué afirmaciones podemos hacer con un ANOVA de dos vías?

1. ¿El factor 1 tiene un efecto en la variable dependiente?
2. ¿El factor 2 tiene un efecto en la variable dependiente?
3. ¿Hay interacción entre los dos factores?

Hipótesis del ANOVA de dos vías

Hay 3 hipótesis nulas:

1. No hay diferencia significativa entre los grupos del primer factor.
2. No hay diferencia significativa entre los grupos del segundo factor.
3. Un factor no influye en el efecto del otro factor (no hay interacción).

Hay 3 hipótesis alternativas

1. Hay diferencias significativas entre los grupos del primer factor.
2. Hay diferencias significativas entre los grupos del segundo factor.
3. Un factor influye en el efecto del otro factor (sí hay interacción).

- No tienen que cumplirse (ni rechazarse) las tres hipótesis simultáneamente.

Requisitos del ANOVA

1. Normalidad
   - Los residuos deben seguir una distribución normal.
   - Se puede comprobar mediante:
     - Gráfico QQ-plot
     - Test de Shapiro–Wilk
2. Homogeneidad de varianzas
   - Los grupos deben tener varianzas similares.
   - Se verifica con el test de Levene.
3. Independencia
   - Las observaciones deben ser independientes entre sí.
   - Las medidas de un grupo no deben influir en las de otro.
4. Nivel de medida adecuado
   - La variable dependiente debe estar en una escala métrica (cuantitativa).
   - Los factores deben ser categóricos (niveles o grupos definidos).

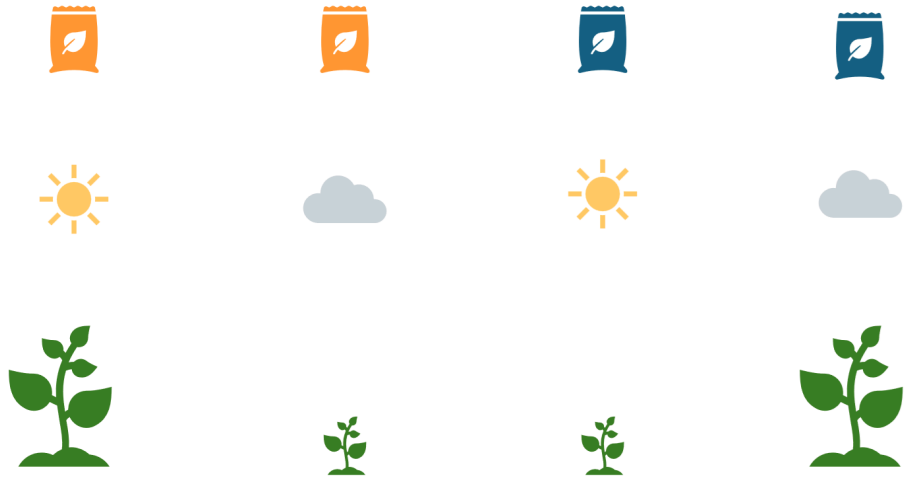
¿Cómo se calcula el ANOVA de dos vías?

> Queremos saber si el tipo de fertilizante (químico u orgánico) y las condiciones de luz (alta o baja) tienen un efecto sobre el crecimiento de las plantas.

Fertilizante	Luz	Crecimiento
Orgánico	Baja	7.305293
Químico	Baja	7.792083
Orgánico	Alta	11.957130
Químico	Alta	13.368602
Orgánico	Baja	9.207962
Químico	Baja	6.876891
Orgánico	Alta	10.451247

Preguntas posibles

1. ¿El tipo de fertilizante (orgánico o químico) influye en el crecimiento de las plantas?
2. ¿Las condiciones de luz (alta o baja) afectan al crecimiento de las plantas?
3. ¿Existe una interacción entre la luz y el tipo de fertilizante que modifique el crecimiento de las plantas?



¿Qué hace el análisis de varianza?

En un análisis de ANOVA de dos vías, la varianza total (suma de cuadrados totales, SS_{total}) de la variable dependiente se descompone en:

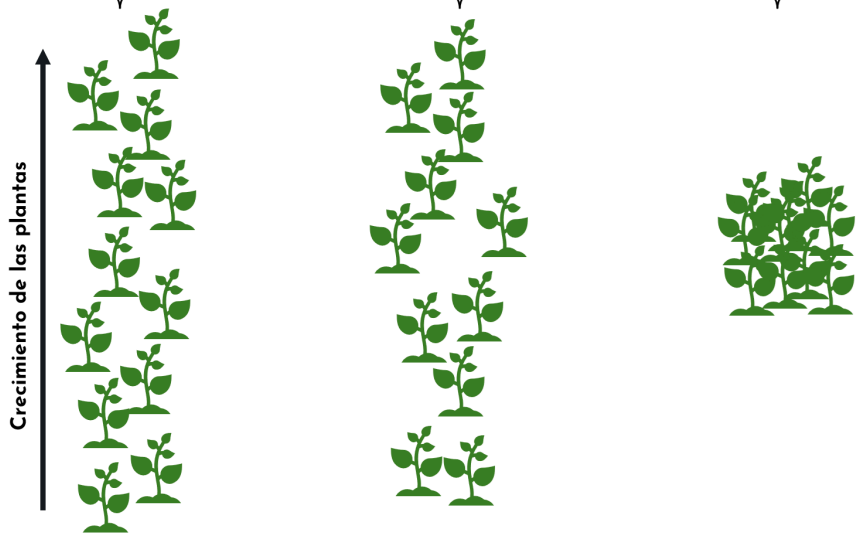
$$`SS_{total} = SS_A + SS_B + SS_{AB} + SS_{error}`$$

- SS_A: varianza explicada por el factor A
- SS_B: varianza explicada por el factor B
- SS_{AB}: varianza debida a la interacción entre A y B
- SS_{error}: varianza no explicada (residual)

> Queremos evaluar si la variabilidad en el crecimiento de las plantas puede explicarse por los factores luz, fertilizante, o por la interacción entre ambos.

¿Qué hace el análisis de varianza?

$$`SS_{total} = SS_A + SS_B + SS_{AB} + SS_{error}`$$

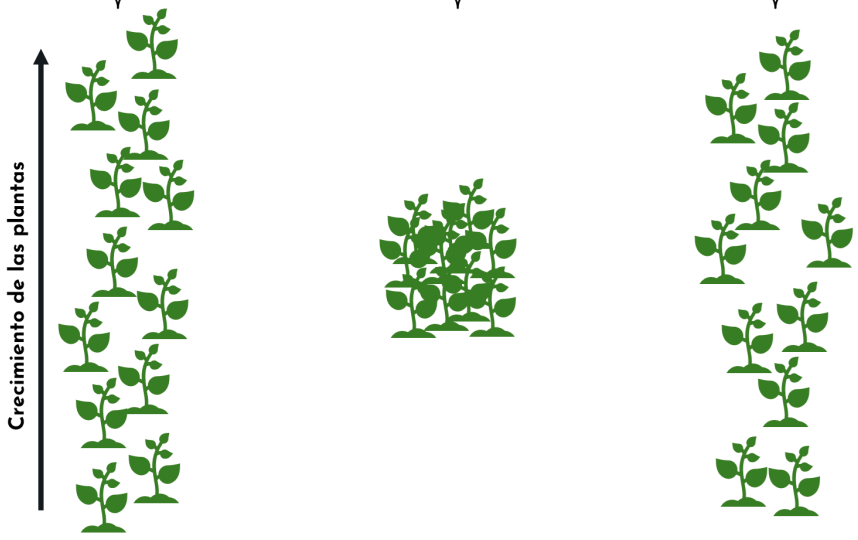


- La mayor parte de la varianza en el crecimiento se explica por los factores A y B, y su interacción.
- Solo una pequeña proporción de la variabilidad queda sin explicar (error residual).

> Podemos describir muy bien el crecimiento a partir de los factores considerados en el modelo.

¿Qué hace el análisis de varianza?

$$`SS_{total} = \underbrace{SS_A + SS_B + SS_{AB}}_{} + \underbrace{SS_{error}}_{}`$$



¿Cómo se calcula el ANOVA de dos vías?

Calcular todas las medias:

- Media global ($\bar{G}$): media de todas las observaciones.
- Medias marginales de los factores:
  - $\bar{A}_i \rightarrow$ media de cada nivel del factor A.
  - $\bar{B}_j \rightarrow$ media de cada nivel del factor B.
- Medias de celda ($\bar{AB}_{ij}$): media de cada combinación de niveles de A × B.

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados totales

$$SS_{total} = \sum\sum\sum(x_{mij} - \bar{G})^2 =$$
$$(13.37 - 10.11)^2 + (12.58 - 10.11)^2 + \ldots$$
$$\ldots + (6.74 - 10.11)^2 + (7.6 - 10.11)^2 = 106.63$$

Grados de libertad:

$$df_{total} = n \times p \times q - 1 = 5 \times 2 \times 2 - 1 = 19$$

donde:

- n: número de observaciones (réplicas) por combinación de niveles
- p: número de grupos en el factor 1 (fertilizante)
- q: número de grupos en el factor 2 (luz)

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados totales

$$SS_{total} = \sum\sum\sum(x_{mij} - \bar{G})^2 =$$
$$(13.37 - 10.11)^2 + (12.58 - 10.11)^2 + \ldots$$
$$\ldots + (6.74 - 10.11)^2 + (7.6 - 10.11)^2 = 106.63$$

Grados de libertad:

$$df_{total} = n \times p \times q - 1 = 5 \times 2 \times 2 - 1 = 19$$

donde:

- n: número de observaciones (réplicas) por combinación de niveles
- p: número de grupos en el factor 1 (fertilizante)
- q: número de grupos en el factor 2 (luz)

Varianza total:

$$\sigma^2_{total} = \frac{SS_{total}}{df_{total}} = \frac{106.63}{19} = 5.612$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados entre grupos

$$SS_{btw} = n \times \sum\sum(\bar{X}_{ij} - \bar{G})^2 =$$
$$5 \times ((12.731 - 10.11)^2 + (11.71 - 10.11)^2 +$$
$$(8.058 - 10.11)^2 + (7.925 - 10.11)^2) = 92.12$$

Grados de libertad:

$$df_{btw} = p \times q - 1 = 2 \times 2 - 1 = 3$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados entre grupos

$$SS_{btw} = n \times \sum\sum(\bar{X}_{ij} - \bar{G})^2 =$$
$$5 \times ((12.731 - 10.11)^2 + (11.71 - 10.11)^2 +$$
$$(8.058 - 10.11)^2 + (7.925 - 10.11)^2) = 92.12$$

Grados de libertad:

$$df_{btw} = p \times q - 1 = 2 \times 2 - 1 = 3$$

Varianza entre

$$\sigma^2_{btw} = \frac{SS_{btw}}{df_{btw}} = \frac{92.12}{3} = 30.71$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del factor A (fertilizante)

$$SS_A = n \times q \times \sum(\bar{A}_i - \bar{G})^2 =$$

$$5 \times 2 \times ((10.39 - 10.11)^2 + (9.82 - 10.11)^2) = 1.659$$

Grados de libertad

$$df_A = p - 1 = 2 - 1 = 1$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del factor A (fertilizante)

$$SS_A = n \times q \times \sum(\bar{A}_i - \bar{G})^2 =$$

$$5 \times 2 \times ((10.39 - 10.11)^2 + (9.82 - 10.11)^2) = 1.659$$

Grados de libertad

$$df_A = p - 1 = 2 - 1 = 1$$

Varianza del factor A (fertilizante)

$$\sigma^2_A = \frac{SS_A}{df_A} = \frac{1.659}{1} = 1.659$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del factor B (luz)

$$SS_B = n \times p \times \sum(\bar{B}_j - \bar{G})^2 =$$

$$5 \times 2 \times ((12.22 - 10.11)^2 + (7.99 - 10.11)^2) = 89.481$$

Grados de libertad

$$df_B = q - 1 = 2 - 1 = 1$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del factor B (luz)

$$SS_B = n \times p \times \sum(\bar{B}_j - \bar{G})^2 =$$

$$5 \times 2 \times ((12.22 - 10.11)^2 + (7.99 - 10.11)^2) = 89.481$$

Grados de libertad

$$df_B = q - 1 = 2 - 1 = 1$$

Varianza del factor B (luz)

$$\sigma^2_B = \frac{SS_B}{df_B} = \frac{89.481}{1} = 89.481$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados de la interacción

$$SS_{AB} = SS_{btw} - SS_A - SS_B =$$
$$= 92.123 - 1.659 - 89.481 = 0.983$$

Grados de libertad:

$$df_{AB} = (p-1) \times (q-1) =$$
$$df_{AB} = 1 \times 1 = 1$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados de la interacción

$$SS_{AB} = SS_{btw} - SS_A - SS_B =$$
$$= 92.123 - 1.659 - 89.481 = 0.983$$

Grados de libertad:

$$df_{AB} = (p-1) \times (q-1) =$$
$$df_{AB} = 1 \times 1 = 1$$

Varianza

$$\sigma^2_{AB} = \frac{SS_{AB}}{df_{AB}} = \frac{0.983}{1} = 0.983$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del error

$$SS_{error} = \sum\sum\sum(x_{mij} - \bar{AB}_{ij})^2$$
$$= (13.37 - 12.73)^2 + (11.96 - 11.71)^2 + \ldots$$
$$\ldots + (7.79 - 8.058)^2 + (7.30 - 7.925)^2 = 14.51$$

Grados de libertad:

$$df_{error} = (n-1) \times p \times q =$$
$$4 \times 2 \times 2 = 16$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

¿Cómo se calcula el ANOVA de dos vías?

Suma de cuadrados del error

$$SS_{error} = \sum\sum\sum(x_{mij} - \bar{AB}_{ij})^2$$
$$= (13.37 - 12.73)^2 + (11.96 - 11.71)^2 + \ldots$$
$$\ldots + (7.79 - 8.058)^2 + (7.30 - 7.925)^2 = 14.51$$

Grados de libertad:

$$df_{error} = (n-1) \times p \times q =$$
$$4 \times 2 \times 2 = 16$$

Varianza

$$\sigma^2_{error} = \frac{SS_{error}}{df_{error}} = 14.51/16 = 0.907$$

		FERTILIZANTE		MEDIA
		QUÍMICO	ORGÁNICO	
LUZ	ALTA	13.369	11.957	
		12.585	10.451	
		11.971	12.253	
		13.516	11.774	
		12.216	12.124	
	MEDIA	**12.731**	**11.712**	**12.222**
	BAJA	7.792	7.305	
		6.877	9.208	
		7.917	8.780	
		10.169	6.735	
		7.533	7.597	
	MEDIA	**8.058**	**7.925**	**7.991**
		10.395	**9.818**	**10.106**

Cálculo de la F

Se obtienen dividiendo cada varianza (A, B y la interacción) por la varianza del error:

Cálculo de F:

$$F_A = \frac{\sigma_A^2}{\sigma_{error}^2} = \frac{1.659}{0.907} = 1.829$$

$$F_B = \frac{\sigma_B^2}{\sigma_{error}^2} = \frac{89.481}{0.907} = 98.656$$

$$F_{AB} = \frac{\sigma_{AB}^2}{\sigma_{error}^2} = \frac{0.983}{0.907} = 1.084$$

Grados de libertad factor A:

- df_A=1
- df_{error}=16

Grados de libertad factor B:

- df_B=1
- df_{error}=16

Grados de libertad interacción:

- df_{AB}=1
- df_{error}=16

Tabla de la distribución de F

Valores críticos de la distribución F (cola superior, $\alpha = 0.05$)

	gl1 = 1	gl1 = 2	gl1 = 3	gl1 = 4	gl1 = 5	gl1 = 6	gl1 = 7	gl1 = 8	gl1 = 9	gl1 = 10	gl1 = 11	gl1 = 12	gl1 = 13	gl1 = 14	gl1 = 15
gl2 = 1	161.4476	199.5000	215.7073	224.5832	230.1619	233.9860	236.7684	238.8827	240.5433	241.8817	242.9835	243.9060	244.6898	245.3640	245.9499
gl2 = 2	18.5128	19.0000	19.1643	19.2468	19.2964	19.3295	19.3532	19.3710	19.3848	19.3959	19.4050	19.4125	19.4189	19.4244	19.4291
gl2 = 3	10.1280	9.5521	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123	8.7855	8.7633	8.7446	8.7287	8.7149	8.7029
gl2 = 4	7.7086	6.9443	6.5914	6.3882	6.2561	6.1631	6.0942	6.0410	5.9988	5.9644	5.9358	5.9117	5.8911	5.8733	5.8578
gl2 = 5	6.6079	5.7861	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725	4.7351	4.7040	4.6777	4.6552	4.6358	4.6188
gl2 = 6	5.9874	5.1433	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.0990	4.0600	4.0274	3.9999	3.9764	3.9559	3.9381
gl2 = 7	5.5914	4.7374	4.3468	4.1203	3.9715	3.8660	3.7870	3.7257	3.6767	3.6365	3.6030	3.5747	3.5503	3.5292	3.5107
gl2 = 8	5.3177	4.4590	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881	3.3472	3.3130	3.2839	3.2590	3.2374	3.2184
gl2 = 9	5.1174	4.2565	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789	3.1373	3.1025	3.0729	3.0475	3.0255	3.0061
gl2 = 10	4.9646	4.1028	3.7083	3.4780	3.3258	3.2172	3.1355	3.0717	3.0204	2.9782	2.9430	2.9130	2.8872	2.8647	2.8450
gl2 = 11	4.8443	3.9823	3.5874	3.3567	3.2039	3.0946	3.0123	2.9480	2.8962	2.8536	2.8179	2.7876	2.7614	2.7386	2.7186
gl2 = 12	4.7472	3.8853	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964	2.7534	2.7173	2.6866	2.6602	2.6371	2.6169
gl2 = 13	4.6672	3.8056	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144	2.6710	2.6347	2.6037	2.5769	2.5536	2.5331
gl2 = 14	4.6001	3.7389	3.3439	3.1122	2.9582	2.8477	2.7642	2.6987	2.6458	2.6022	2.5655	2.5342	2.5073	2.4837	2.4630
gl2 = 15	4.5431	3.6823	3.2874	3.0556	2.9013	2.7905	2.7066	2.6408	2.5876	2.5437	2.5068	2.4753	2.4481	2.4244	2.4034
gl2 = 16	4.4940	3.6337	3.2389	3.0069	2.8524	2.7413	2.6572	2.5911	2.5377	2.4935	2.4564	2.4247	2.3973	2.3733	2.3522
gl2 = 17	4.4513	3.5915	3.1968	2.9647	2.8100	2.6987	2.6143	2.5480	2.4943	2.4499	2.4126	2.3807	2.3531	2.3290	2.3077
gl2 = 18	4.4139	3.5546	3.1599	2.9277	2.7729	2.6613	2.5767	2.5102	2.4563	2.4117	2.3742	2.3421	2.3143	2.2900	2.2686
gl2 = 19	4.3807	3.5219	3.1274	2.8951	2.7401	2.6283	2.5435	2.4768	2.4227	2.3779	2.3402	2.3080	2.2800	2.2556	2.2341
gl2 = 20	4.3512	3.4928	3.0984	2.8661	2.7109	2.5990	2.5140	2.4471	2.3928	2.3479	2.3100	2.2776	2.2495	2.2250	2.2033
gl2 = 21	4.3248	3.4668	3.0725	2.8401	2.6848	2.5727	2.4876	2.4205	2.3660	2.3210	2.2829	2.2504	2.2222	2.1975	2.1757

Decisión en el ANOVA de dos vías

Para los tres efectos: gl numerador = 1, gl denominador = 16 $\rightarrow F_{crit}(1, 16) = 4.49$

Efecto	F_{obs}	F_{crit}	p-valor	Decisión
Fertilizante (A)	1.83	4.49	0.195	No rechazamos H_0
Luz (B)	98.66	4.49	3.0×10^{-8}	Rechazamos H_0
Interacción (A×B)	1.08	4.49	0.313	No rechazamos H_0

```
pf(1.829, df1 = 1, df2 = 16, lower.tail = FALSE)   # Fertilizante
```

```
[1] 0.1950519
```

```
pf(98.656, df1 = 1, df2 = 16, lower.tail = FALSE)  # Luz
```

```
[1] 3.017747e-08
```

```
pf(1.084, df1 = 1, df2 = 16, lower.tail = FALSE)   # Interacción
```

```
[1] 0.3132823
```

> Conclusión: solo la luz afecta al crecimiento de las plantas. El tipo de fertilizante no tiene efecto, y el efecto de la luz no depende del fertilizante (no hay interacción).

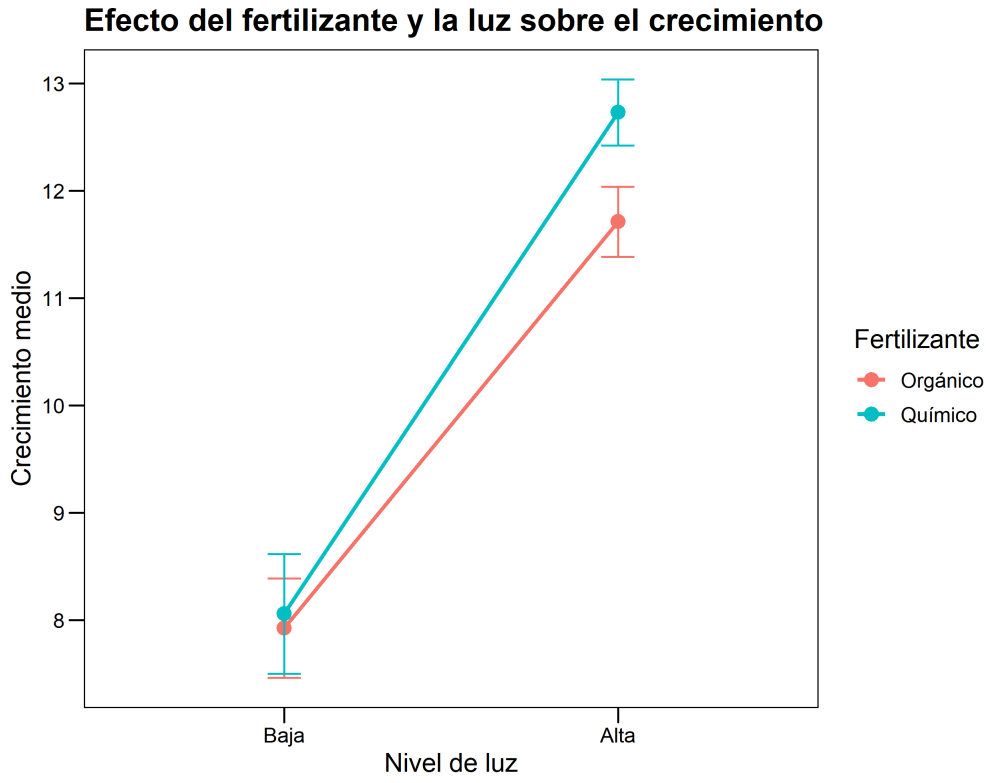
ANOVA de dos vías en R

```
modelo <- aov(Crecimiento ~ Fertilizante * Luz, data = datos_luz)
summary(modelo)
```

```
                Df Sum Sq Mean Sq F value   Pr(>F)
Fertilizante     1   1.66    1.66   1.830    0.195
Luz              1  89.48   89.48  98.698 3.01e-08 ***
Fertilizante:Luz 1   0.98    0.98   1.084    0.313
Residuals       16  14.51    0.91
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Fertilizante: efecto principal del tipo de fertilizante.
- Luz: efecto principal del nivel de luz.
- Fertilizante:Luz: interacción entre ambos factores.
- Residuals: variabilidad no explicada por el modelo, incluye diferencias individuales o ruido experimental.

ANOVA de dos vías en R



ANOVA de dos vías en R

Comprobar los supuestos

Normalidad

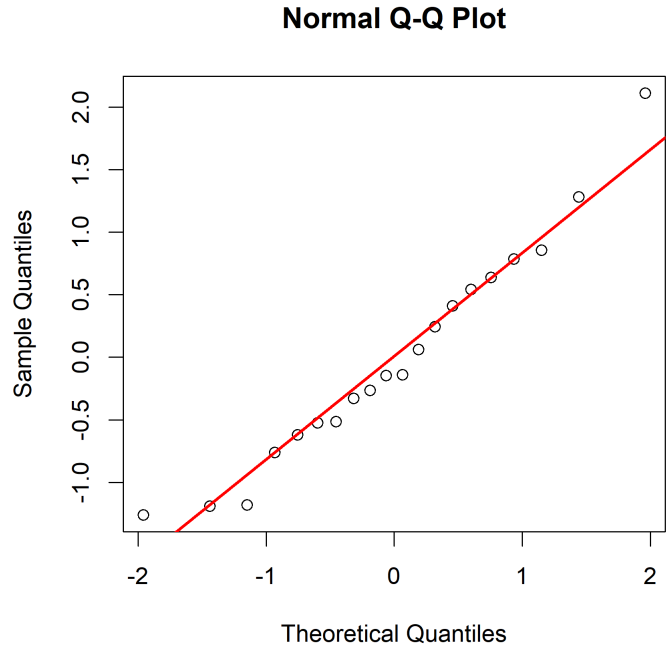
```
modelo <- aov(Crecimiento ~ Fertilizante * Luz

shapiro.test(resid(modelo))
```

```
    Shapiro-Wilk normality test

data:  resid(modelo)
W = 0.96299, p-value = 0.6051
```

```
# QQ-plot
qqnorm(resid(modelo))
qqline(resid(modelo), col = "red", lwd = 2)
```



ANOVA de dos vías en R

Comprobar los supuestos

Homogeneidad de varianzas

```
library(car)
leveneTest(Crecimiento ~ Fertilizante * Luz, data = datos_luz)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  3   0.296 0.8277
      16
```

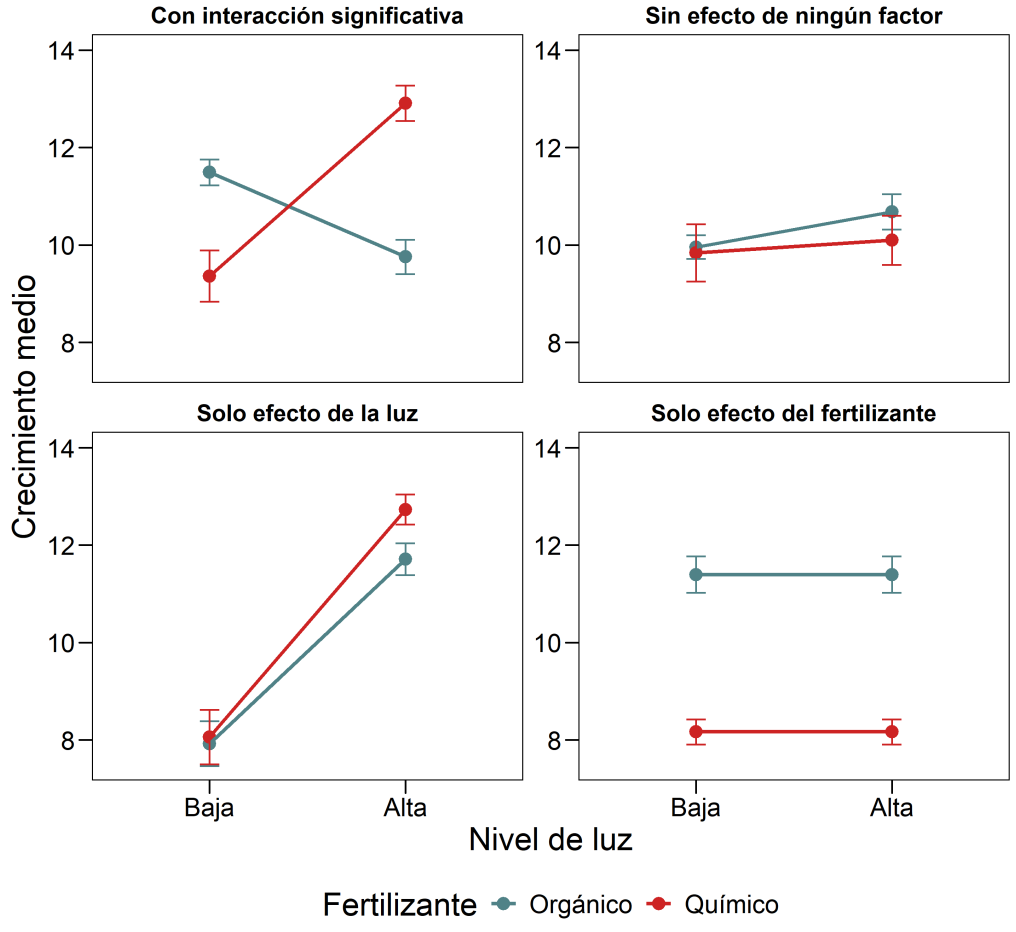
Conecta resultado de ANOVA con su tabla

```
$Caso1
               Df Sum Sq Mean Sq F value  Pr(>F)
Fertilizante    1   1.32    1.32   1.753  0.2041
Luz             1   4.12    4.12   5.469  0.0327 *
Fertilizante:Luz  1  34.93   34.93  46.365 4.2e-06 ***
Residuals      16  12.05    0.75
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$Caso2
               Df Sum Sq Mean Sq F value Pr(>F)
Fertilizante    1  0.615  0.6150   0.619  0.443
Luz             1  1.203  1.2028   1.211  0.287
Fertilizante:Luz  1  0.267  0.2674   0.269  0.611
Residuals      16 15.890  0.9931

$Caso3
               Df Sum Sq Mean Sq F value   Pr(>F)
Fertilizante    1   1.66    1.66   1.830    0.195
Luz             1  89.48   89.48  98.698 3.01e-08 ***
Fertilizante:Luz  1   0.98    0.98   1.084    0.313
Residuals      16  14.51    0.91
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$Caso4
               Df Sum Sq Mean Sq F value   Pr(>F)
Fertilizante    1  52.17   52.17   101.8 2.43e-08 ***
Luz             1   0.00    0.00     0.0        1
Fertilizante:Luz  1   0.00    0.00     0.0        1
Residuals      16   8.20    0.51
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Coeficiente de determinación de ANOVA (R^2)

- Mide qué proporción de la variabilidad total de la variable dependiente es explicada por los factores incluidos en el modelo.
- Es una medida de bondad de ajuste del modelo ANOVA.
- Va de 0 a 1 (o de 0 a 100%)

En cualquier ANOVA, la variabilidad se puede descomponer como:

$$`SS_{total} = SS_{modelo} + SS_{error}`$$

- SS_{total}: suma de cuadrados total
- SS_{modelo}: suma de cuadrados explicada por los factores (efectos principales + interacción, si la hay)
- SS_{error}: suma de cuadrados de los residuos (error)

$$R^2 = \frac{SS_{modelo}}{SS_{total}} = 1 - \frac{SS_{error}}{SS_{total}}$$

Coeficiente de determinación de ANOVA (R^2)

En ANOVA de una vía:

$$SS_{total} = SS_{entre} + SS_{dentro}$$

$$R^2 = \frac{SS_{entre}}{SS_{total}} = 1 - \frac{SS_{dentro}}{SS_{total}}$$

> ¿Qué porcentaje de la varianza total explica el factor A?

En ANOVA de dos vías:

$$SS_{total} = SS_A + SS_B + SS_{AB} + SS_{error}$$

$$R^2 = \frac{SS_A + SS_B + SS_{AB}}{SS_{total}} = 1 - \frac{SS_{error}}{SS_{total}}$$

> ¿Qué porcentaje de la varianza total explican ambos factores y su interacción?

Tipo de ANOVA	Descomposición	Componentes	R^2
Una vía	$SS_{total} = SS_{entre} + SS_{dentro}$	1 factor	$R^2 = SS_{entre}/SS_{total}$
Dos vías	$SS_{total} = SS_A + SS_B + SS_{A:B} + SS_{error}$	2 factores + interacción	$R^2 = (SS_A + SS_B + SS_{A:B})/SS_{total}$

Coeficiente de determinación de ANOVA (R^2)

Valor de (R^2)	Significado
0	El modelo **no explica nada** de la variabilidad de los datos.
1	El modelo **explica toda** la variabilidad observada.
< 0.3	El modelo explica **poca** variabilidad (orientativo).
0.3–0.7	El modelo explica **una parte moderada** de la variabilidad.
≥ 0.7	El modelo tiene **buena capacidad explicativa**.

R^2 y tamaño del efecto

En el ANOVA de una vía, el R^2 es lo que se conoce como **eta cuadrado** (η^2):

$$\eta^2 = R^2 = \frac{SS_{entre}}{SS_{total}}$$

- Es una medida del **tamaño del efecto**: igual que la *d* de Cohen en el *t*-test (Tema 10), nos dice **cuánto** importa el factor, no solo si su efecto es significativo.
- Valores orientativos (Cohen): **0.01** pequeño, **0.06** mediano, **0.14** grande.

> Estos valores son mucho más bajos que los de la tabla anterior: en biología, un factor que explica el 14% de la variabilidad ya es un efecto grande.

En el ANOVA de dos vías, el R^2 mide el efecto **conjunto** de todos los factores y su interacción. Para el tamaño del efecto de **cada factor** se usa el **eta cuadrado parcial**:

$$\eta_p^2 = \frac{SS_A}{SS_A + SS_{error}}$$

Coeficiente de determinación de ANOVA (R^2) en R

La función `lm()`: ajusta un modelo lineal que explica una variable dependiente (respuesta) en función de una o más variables independientes (factores).

> En ANOVA, `lm()` estima efectos medios de los factores y de sus interacciones

```
summary(lm(Crecimiento ~ Fertilizante * Luz, data = datos_luz))
```

> También lo podríamos calcular directamente con SS_A, SS_B, SS_{AB} y SS_{total}, que hemos calculado previamente.

```
1.659 + 89.481 + 0.983 # SS modelo (SS entre): SS_A + SS_B + SS_AB
```

```
[1] 92.123
```

```
92.123/106.63 ## SS_modelo / SS_total
```

```
[1] 0.8639501
```

Coeficiente de determinación de ANOVA (R^2) en R

```
summary(lm(Crecimiento ~ Fertilizante * Luz, data = datos_luz))
```

```
Call:
lm(formula = Crecimiento ~ Fertilizante * Luz, data = datos_luz)

Residuals:
    Min      1Q  Median      3Q     Max
-1.2607 -0.5481 -0.1439  0.5653  2.1114

Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)                  7.9250     0.4258  18.611 2.89e-12 ***
FertilizanteQuímico          0.1326     0.6022   0.220    0.829
LuzAlta                      3.7870     0.6022   6.289 1.08e-05 ***
FertilizanteQuímico:LuzAlta  0.8869     0.8516   1.041    0.313
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9522 on 16 degrees of freedom
Multiple R-squared:  0.864,    Adjusted R-squared:  0.8385
F-statistic: 33.87 on 3 and 16 DF,  p-value: 3.672e-07
```

Batch effect

- Variación sistemática no biológica entre grupos de muestras que fueron procesadas en momentos o condiciones distintas.

Por ejemplo:

- Las plantas del fertilizante orgánico se midieron en un día distinto que las del químico.
- Las muestras de RNA-seq fueron secuenciadas en distintos "batches".
- Se usaron distintos experimentadores o cámaras de luz.

Este factor no es de interés biológico, pero puede introducir ruido o confusión si no se controla.

Batch effect

	Fertilizante	Luz	Rep	Crecimiento	Escenario	Lote
1	Orgánico	Baja	1	7.305293	Solo efecto de la luz	Lote1
2	Químico	Baja	1	7.792083	Solo efecto de la luz	Lote1
3	Orgánico	Alta	1	11.957130	Solo efecto de la luz	Lote1
4	Químico	Alta	1	13.368602	Solo efecto de la luz	Lote1
5	Orgánico	Baja	2	9.207962	Solo efecto de la luz	Lote1
6	Químico	Baja	2	6.876891	Solo efecto de la luz	Lote1
7	Orgánico	Alta	2	10.451247	Solo efecto de la luz	Lote1
8	Químico	Alta	2	12.584614	Solo efecto de la luz	Lote1
9	Orgánico	Baja	3	8.779965	Solo efecto de la luz	Lote1
10	Químico	Baja	3	7.916631	Solo efecto de la luz	Lote1
11	Orgánico	Alta	3	12.253319	Solo efecto de la luz	Lote2
12	Químico	Alta	3	11.971453	Solo efecto de la luz	Lote2
13	Orgánico	Baja	4	6.734604	Solo efecto de la luz	Lote2
14	Químico	Baja	4	10.168956	Solo efecto de la luz	Lote2
15	Orgánico	Alta	4	11.774229	Solo efecto de la luz	Lote2
16	Químico	Alta	4	13.516471	Solo efecto de la luz	Lote2
17	Orgánico	Baja	5	7.597115	Solo efecto de la luz	Lote2
18	Químico	Baja	5	7.533345	Solo efecto de la luz	Lote2
19	Orgánico	Alta	5	12.123854	Solo efecto de la luz	Lote2
20	Químico	Alta	5	12.215942	Solo efecto de la luz	Lote2

Cómo controlamos por el *batch effect* en ANOVA

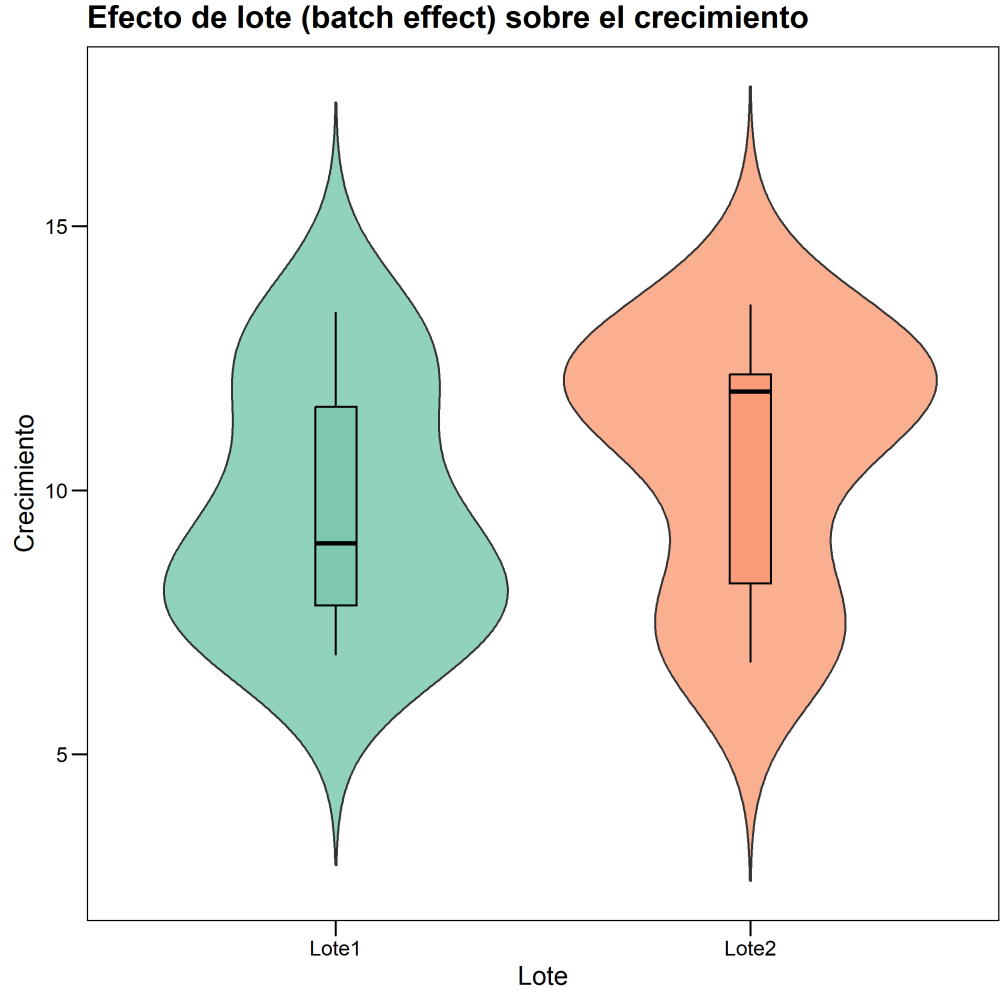
```
modelo_batch <- aov(Crecimiento ~ Fertilizante * Luz + Lote, data = datos_luz)
summary(modelo_batch)
```

```
                Df Sum Sq Mean Sq F value   Pr(>F)
Fertilizante     1   1.66    1.66   1.724    0.209
Luz              1  89.48   89.48  93.001 8.04e-08 ***
Lote             1   0.07    0.07   0.076    0.786
Fertilizante:Luz 1   0.98    0.98   1.022    0.328
Residuals       15  14.43    0.96
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- `Lote` añadido como **factor de bloqueo** (variable categórica de control)
- `aov()` usa sumas de cuadrados secuenciales (tipo I), así que **el orden importa**: con `Lote` al final, su test indica si el lote explica variación adicional **después** de tener en cuenta `Fertilizante` y `Luz`. Para ajustar los efectos de los factores por el lote, se pondría primero (`Lote + Fertilizante * Luz`).
  - Si el efecto de Lote es significativo → el batch effect está influyendo en el crecimiento
  - Si no lo es → las diferencias entre lotes no tienen un impacto relevante

Cómo controlamos por el *batch effect* en ANOVA

Verificación visual de si hay efecto:



Cómo controlamos por el *batch effect* en ANOVA

```
anova(aov(Crecimiento ~ Fertilizante * Luz, data = datos_luz),
      aov(Crecimiento ~ Fertilizante * Luz + Lote, data = datos_luz))
```

```
Analysis of Variance Table

Model 1: Crecimiento ~ Fertilizante * Luz
Model 2: Crecimiento ~ Fertilizante * Luz + Lote
  Res.Df    RSS Df Sum of Sq      F Pr(>F)
1     16 14.506
2     15 14.432  1  0.073516 0.0764  0.786
```

- ¿El modelo 2 reduce el error lo suficiente como para que valga la pena añadirle `Lote`?
- Añadir el efecto lote no mejora significativamente el modelo
- El RSS (*Residual Sum of Squares*) mide la variación no explicada por el modelo:
  - Cuanto menor sea el RSS → mejor explica el modelo la variación de los datos
  - Pero cuidado: añadir más variables nunca aumenta el RSS (casi siempre lo reduce), aunque no sean realmente relevantes
- `Pr(>F)` < 0.05 → el modelo más complejo (con más términos) mejora significativamente el ajuste
- `Pr(>F)` > 0.05 → la mejora del ajuste no es significativa → conviene quedarse con el modelo más simple (principio de parsimonia)

Alternativa no paramétrica: test de Friedman

- No existe un "Kruskal-Wallis de dos vías" estándar.
- El test de Friedman es la alternativa no paramétrica cuando tenemos un factor y un bloque (por ejemplo, el lote o el individuo en medidas repetidas).
- Compara los rangos de los tratamientos dentro de cada bloque.
- No permite estudiar la interacción entre los dos factores.

```
friedman.test(y ~ tratamiento | bloque, data = datos)
```

> Requiere una única observación por cada combinación de tratamiento y bloque.

Contacto

Marta Coronado Zamora	David Castellano
marta.coronado@uab.cat	david.castellano@uab.cat
@geneticament.bsky.social	@castellanoed.bsky.social
Universitat Autònoma de Barcelona	University of Arizona