

ANOVA

Bioestadística

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2025/26



Facultat
Bio-ciències
UAB



Outline

ANOVA

- Ejemplo
- ¿Qué es un ANOVA?
- ANOVA de una vía
- ANOVA de dos vías
- ANOVA en R

Ejemplo

It is thought that stress may increase susceptibility to illness through suppression of the immune system. In an experiment to investigate this theory, 48 rats were randomly allocated to four treatment groups: no stress, mild stress, moderate stress, and high stress. The stress conditions involved various amounts of restraint and electric shock. The concentration of lymphocytes (cells/ml $\times 10^{-6}$) in the peripheral blood was measured for each rat.

Perform an appropriate statistical analysis of this experiment.

- H_0 y H_1 ?
- Variable respuesta?
- Grupos?

Ejemplo

*It is thought that **stress may increase susceptibility to illness** through suppression of the immune system. In an experiment to investigate this theory, 48 rats were randomly allocated to **four treatment groups**: no stress, mild stress, moderate stress, and high stress. The stress conditions involved various amounts of restraint and electric shock. The **concentration of lymphocytes** (cells/ml $\times 10^{-6}$) in the peripheral blood was measured for each rat.*


Perform an appropriate statistical analysis of this experiment.

- ¿Por qué no podemos hacer t-tests a pares? (no stress vs. mild stress, no stress vs. mild stress, ...)
 - Realizar tests múltiples con los mismos datos incrementa el error tipo I

■ Análisis de la varianza (*Analysis of variance*, ANOVA), utiliza una sola prueba de hipótesis para comparar varios grupos (>2)

ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o más



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o más



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o más



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o más



T-test



ANOVA de una vía

- Prueba de hipótesis que comprueba si hay diferencias significativas entre las **medias** de **tres grupos** o más



Hipótesis en ANOVA de una vía

- **Hipótesis nula:** las medias de todos los grupos k son iguales
- **Hipótesis alternativa:** las medias de los grupos no son iguales.

$$H_0 = \mu_1 = \mu_2 = \dots = \mu_k$$

$$H_1 = \text{Al menos una } \mu_i \text{ es diferente}$$



Supuestos del ANOVA de una vía

1. Nivel de medición
2. Independencia
3. Normalidad
4. Homogeneidad

Supuestos del ANOVA de una vía

1. Nivel de medición

Variable **independiente** → Categórica

Ejemplos:

- Grupo de tratamiento
- Tipo de fertilizante
- ...

Variable **dependiente** → Continua

Ejemplos:

- Concentración en sangre
- Crecimiento planta
- ...

Supuestos del ANOVA de una vía

1. Nivel de medición

2. **Independencia**

- Los valores medidos en un grupo no deben ser influenciados por las medidas de otro grupo
- Individuos o unidades experimentales diferentes

Supuestos del ANOVA de una vía

1. Nivel de medición

2. Independencia

3. Normalidad

- Los datos han de seguir una **distribución normal** → especialmente si hay pocos
- Si no se cumple la normalidad, podemos usar el test "Kruskal-Wallis"

Supuestos del ANOVA de una vía

1. Nivel de medición

2. Independencia


3. Normalidad

4. **Homogeneidad**

- La varianza en cada grupo debería ser parecida entre grupos
- Si no se cumple la homogeneidad de varianzas, podemos usar el test "Welch-ANOVA"


Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$




Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$




Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$




Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



Cómo funciona un ANOVA de una vía

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}}$$



Cómo funciona un ANOVA de una vía


Estadístico F

$$\frac{\text{Varianza ENTRE grupos}}{\text{Varianza DENTRO de grupos}} = F$$

Cómo funciona un ANOVA de una vía

Estadístico F

$$\frac{\text{Varianza ENTRE grupos} \downarrow}{\text{Varianza DENTRO de grupos} \uparrow} = F \downarrow$$




■ Muy probable que las diferencias que veamos sean debidas al azar

Cómo funciona un ANOVA de una vía

Estadístico F

$$\frac{\text{Varianza ENTRE grupos} \uparrow}{\text{Varianza DENTRO de grupos} \downarrow} = F \uparrow$$



Poco probable que las diferencias que veamos sean debidas al azar

Para comprobar nuestra hipótesis y responder si hay o no diferencias significativas, necesitamos calcular el p-valor.

Cómo funciona un ANOVA de una vía

Estadístico F: pasos para calcularlo:

Paso 1: Calcular la media conjunta de todos los grupos

$$G = \frac{\sum x}{N}$$

Paso 2: Calcular la media de cada grupo (g) individual

$$M_i = \frac{\sum^{grupo} x}{n_g}$$

Paso 3: Suma de cuadrados de los ENTRE grupos (SSB):

$$SS_{entre} = \sum^{grupos} n_i (M_i - G)^2$$

Paso 4: Suma de cuadrados de los dentro grupos (SSW):

$$SS_{dentro} = \sum^{grupos} \sum^{grupo} (x_{mi} - M_i)^2$$

Cómo funciona un ANOVA de una vía

Media de todos los datos

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6

$$G = \frac{\sum x}{N}$$

$$G = \frac{3 + 2 + \dots + 3 + 10}{24} = 5.333$$

Cómo funciona un ANOVA de una vía

Media de cada grupo

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6


$$M_i = \frac{\sum^{grupo} x}{n_g}$$

$$M_1 = \frac{3 + 2 + \dots + 4 + 3}{8} = 2.5$$

$$M_2 = \frac{10 + 9 + \dots + 6 + 7}{8} = 8$$


$$M_3 = \frac{7 + 6 + \dots + 3 + 6}{8} = 5.5$$

Cómo funciona un ANOVA de una vía




$$SS_{entre} = \sum^{grupos} n_i (M_i - G)^2$$

Cómo funciona un ANOVA de una vía



$$SS_{entre} = 8 \times ((2.5 - 5.3)^2 + (8 - 5.3)^2 + (5.5 - 5.3)^2) = 121.3$$

Cómo funciona un ANOVA de una vía



$$SS_{dentro} = \sum_{\text{grupos}} \sum_{\text{grupo}} (x_{mi} - M_i)^2$$

Cómo funciona un ANOVA de una vía

Grupo 1	Grupo 2	Grupo 3
3	10	7
2	9	6
1	9	7
1	8	6
4	7	5
2	8	4
4	6	3
3	7	6
2.5	8	5.5

$$\begin{aligned}SS_{\text{dentro}} &= \sum_{\text{grupos}} \sum_{\text{grupo}} (x_{mi} - M_i)^2 \\&= (3 - 2.5)^2 + (2 - 2.5)^2 + \dots \\&\quad + (10 - 8)^2 + (9 - 8)^2 + \dots \\&\quad + (7 - 5.5)^2 + (6 - 5.5)^2 + \dots = 36\end{aligned}$$

Cómo funciona un ANOVA de una vía

Media total y por grupo: G , M_1 , M_2 , M_3

Suma de los cuadrados entre y dentro de grupos: SSB , SSW

Cómo funciona un ANOVA de una vía

Estadístico F: pasos para calcularlo:

Paso 1: Calcular la media conjunta de todos los grupos

$$G = \frac{\sum x}{N}$$

Paso 2: Calcular la media de cada grupo (g) individual

$$M_i = \frac{\sum^{grupo} x}{n_g}$$

Paso 3: Suma de cuadrados de los ENTRE grupos (SSB):

$$SS_{entre} = \sum^{grupos} n_i (M_i - G)^2$$

Paso 4: Suma de cuadrados de los dentro grupos (SSW):

$$SS_{dentro} = \sum^{grupos} \sum^{grupo} (x_{mi} - M_i)^2$$

Paso 5: Media de los cuadrados entre

$$MS_{entre} = \frac{SSB}{gl_e}$$

gl_{entre} : número de grupos - 1

Paso 6: Media de los cuadrados dentro

$$MS_{dentro} = \frac{SSW}{gl_d}$$

gl_{dentro} : número de observaciones - número de grupos

Cómo funciona un ANOVA de una vía

Media de los cuadrados entre:

$$MS_{entre} = \frac{SSB}{gl_e} = \frac{121.3}{2} = 60.67$$

gl_{entre} : número de grupos - 1 = 3-1 = 2

Media de los cuadrados dentro:

$$MS_{dentro} = \frac{SSW}{gl_d} = \frac{36}{21} = 1.71$$

gl_{dentro} : número de observaciones totales - número de grupos = 24 - 3 = 21


Cómo funciona un ANOVA de una vía

Cálculo del estadístico **F**:

$$F = \frac{MS_{entre}}{MS_{dentro}} = \frac{60.67}{1.71} = 35.39$$

Distribución F (ANOVA)

df1 = 2 , df2 = 21



Propiedades:

- El valor de F siempre es positivo
- Generalmente se utiliza una α de 0.05 y una hipótesis unilateral (en el ANOVA para comparar medias de grupos)

Tabla de la distribución F ($\alpha = 0.05$)

Valores críticos de la distribución F (cola superior, $\alpha = 0.05$)

	gl1 = 1	gl1 = 2	gl1 = 3	gl1 = 4	gl1 = 5	gl1 = 6	gl1 = 7	gl1 = 8	gl1 = 9	gl1 = 10	gl1 = 11	gl1 = 12	gl1 = 13	gl1 = 14	gl1 = 15
gl2 = 1	161.4476	199.5000	215.7073	224.5832	230.1619	233.9860	236.7684	238.8827	240.5433	241.8817	242.9835	243.9060	244.6898	245.3640	245.9499
gl2 = 2	18.5128	19.0000	19.1643	19.2468	19.2964	19.3295	19.3532	19.3710	19.3848	19.3959	19.4050	19.4125	19.4189	19.4244	19.4291
gl2 = 3	10.1280	9.5521	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123	8.7855	8.7633	8.7446	8.7287	8.7149	8.7029
gl2 = 4	7.7086	6.9443	6.5914	6.3882	6.2561	6.1631	6.0942	6.0410	5.9988	5.9644	5.9358	5.9117	5.8911	5.8733	5.8578
gl2 = 5	6.6079	5.7861	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725	4.7351	4.7040	4.6777	4.6552	4.6358	4.6188
gl2 = 6	5.9874	5.1433	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.0990	4.0600	4.0274	3.9999	3.9764	3.9559	3.9381
gl2 = 7	5.5914	4.7374	4.3468	4.1203	3.9715	3.8660	3.7870	3.7257	3.6767	3.6365	3.6030	3.5747	3.5503	3.5292	3.5107
gl2 = 8	5.3177	4.4590	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881	3.3472	3.3130	3.2839	3.2590	3.2374	3.2184
gl2 = 9	5.1174	4.2565	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789	3.1373	3.1025	3.0729	3.0475	3.0255	3.0061
gl2 = 10	4.9646	4.1028	3.7083	3.4780	3.3258	3.2172	3.1355	3.0717	3.0204	2.9782	2.9430	2.9130	2.8872	2.8647	2.8450
gl2 = 11	4.8443	3.9823	3.5874	3.3567	3.2039	3.0946	3.0123	2.9480	2.8962	2.8536	2.8179	2.7876	2.7614	2.7386	2.7186
gl2 = 12	4.7472	3.8853	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964	2.7534	2.7173	2.6866	2.6602	2.6371	2.6169
gl2 = 13	4.6672	3.8056	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144	2.6710	2.6347	2.6037	2.5769	2.5536	2.5331
gl2 = 14	4.6001	3.7389	3.3439	3.1122	2.9582	2.8477	2.7642	2.6987	2.6458	2.6022	2.5655	2.5342	2.5073	2.4837	2.4630
gl2 = 15	4.5431	3.6823	3.2874	3.0556	2.9013	2.7905	2.7066	2.6408	2.5876	2.5437	2.5068	2.4753	2.4481	2.4244	2.4034
gl2 = 16	4.4940	3.6337	3.2389	3.0069	2.8524	2.7413	2.6572	2.5911	2.5377	2.4935	2.4564	2.4247	2.3973	2.3733	2.3522
gl2 = 17	4.4513	3.5915	3.1968	2.9647	2.8100	2.6987	2.6143	2.5480	2.4943	2.4499	2.4126	2.3807	2.3531	2.3290	2.3077
gl2 = 18	4.4139	3.5546	3.1599	2.9277	2.7729	2.6613	2.5767	2.5102	2.4563	2.4117	2.3742	2.3421	2.3143	2.2900	2.2686
gl2 = 19	4.3807	3.5219	3.1274	2.8951	2.7401	2.6283	2.5435	2.4768	2.4227	2.3779	2.3402	2.3080	2.2800	2.2556	2.2341
gl2 = 20	4.3512	3.4928	3.0984	2.8661	2.7109	2.5990	2.5140	2.4471	2.3928	2.3479	2.3100	2.2776	2.2495	2.2250	2.2033
gl2 = 21	4.3248	3.4668	3.0725	2.8401	2.6848	2.5727	2.4876	2.4205	2.3660	2.3210	2.2829	2.2504	2.2222	2.1975	2.1757


ANOVA en R

Estamos interesados en comprobar si la abundancia de aves depende de la dieta. Total: **n** = 54 aves.

Family	MaxAbund	AvgAbund	Mass	Diet	Passerine	Aquatic
Hawks&Eagles&Kites	2.9855437	0.6740216	716.018936	Vertebrate	0	0
Long-tailed tits	37.8000000	4.0404300	5.300000	Insect	1	0
Larks	241.4000000	23.1054000	35.777088	PlantInsect	1	0
Kingfishers	4.4000000	0.5949060	119.371716	Vertebrate	0	0
Auks& Puffins	4.5325048	2.9632718	315.495519	InsectVert	0	1
Ducks& Geese	23.6936352	2.7416729	1144.290035	PlantInsect	0	1
Anhingas	24.6000000	1.8423100	1250.000000	Vertebrate	0	1

Visualizar los datos en R

```
ggplot(bird, aes(x = Diet,  
                 y = log(MaxAbund),  
                 fill=Diet)) +  
  geom_boxplot() +  
  labs(  
    x = "Tipo de dieta",  
    y = "log(Max. abundancia)",  
    title = "Distribución de abundancia máxima"  
  ) +  
  ggthemes::theme_base(base_size = 14) +  
  theme(  
    plot.title = element_text(face = "bold", hjust = 0.5),  
    axis.text.x = element_text(angle = 45, hjust = 1)  
  )
```



Verificar los supuestos del ANOVA

Primero, hacemos el ANOVA solo para poder obtener los **residuos** y verificar los supuestos

Los supuestos del ANOVA se aplican sobre los **residuos**, no sobre los datos originales!

- Los residuos representan el error que comete el modelo al predecir cada observación.
- En el ANOVA, son las diferencias entre los valores observados y las medias de los grupos

Fuente de variación	Suma de cuadrados (SS)	Grados de libertad (gl)	Media cuadrática (MS)	Estadístico F
Factor (variabilidad entre grupos)	$SS_{entre} = \sum_{i=1}^g n_i (M_i - G)^2$	$gl_{entre} = g - 1$	$MS_{entre} = \frac{SS_{entre}}{gl_{entre}}$	$F = \frac{MS_{entre}}{MS_{dentro}}$
Residuos (variabilidad dentro de los grupos)	$SS_{dentro} = \sum_{i=1}^g \sum_{j=1}^{n_i} (x_{ij} - M_i)^2$	$gl_{dentro} = N - g$	$MS_{dentro} = \frac{SS_{dentro}}{gl_{dentro}}$	
Total	$SS_{total} = \sum_{i=1}^g \sum_{j=1}^{n_i} (x_{ij} - G)^2$	$gl_{total} = N - 1$		

Verificar los supuestos del ANOVA

MS_{entre} : es una estimación de la variabilidad entre las poblaciones. Se suele conocer como "varianza explicada" por el factor que define las poblaciones.

- Nos dice cuánta diferencia hay entre los grupos, y por tanto refleja el efecto del tratamiento o del factor que estamos estudiando.

MS_{dentro} : es una estimación conjunta de la varianza residual dentro de cada población. Esta varianza se supone que es la misma para todas los grupos.

- Es una medida del “ruido” o la variabilidad natural que hay dentro de cada grupo.
- Nos dice cuánto varían los valores entre sí dentro de los grupos, sin tener en cuenta las diferencias entre grupos.

Así, cuando calculamos el estadístico F , estamos viendo si las diferencias entre grupos son mayores que el ruido interno esperado por azar.

Verificar los supuestos en R

- **Normalidad de los residuos:** los residuos del modelo deben seguir una distribución normal.
 - El **test de Shapiro-Wilk** permite contrastar si los residuos son normales.

Las hipótesis son:

H_0 : los residuos siguen una distribución normal

H_1 : los residuos no siguen una distribución normal

- **Homoscedasticidad:** debe comprobarse que las varianzas de los grupos son iguales (o al menos que no existen diferencias significativas entre ellas).
 - Aplicamos el **Test de Levene**.

Las hipótesis son:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_p^2$$

H_1 : existe al menos un par (i, j) tal que $\sigma_i^2 \neq \sigma_j^2$

ANOVA en R

La función `aov()` permite realizar el ANOVA:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
aov1
```

```
## Call:
##      aov(formula = log(MaxAbund) ~ Diet, data = bird)
##
## Terms:
##              Diet Residuals
## Sum of Squares  27.07079 116.91775
## Deg. of Freedom      4      49
##
## Residual standard error: 1.544693
## Estimated effects may be unbalanced
```

ANOVA en R

La función `aov()` permite realizar el ANOVA:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
aov1
```

- `log(MaxAbund)` → es la variable dependiente (la que queremos comparar entre grupos). Logaritmo para normalizar.
- `Diet` → es la variable independiente o factor (los grupos que queremos comparar, por ejemplo diferentes tipos de dieta).
- `data = bird` → indica que los datos se encuentran en el `dataframe bird`.

El operador `~` se lee como “en función de”, es decir: “queremos analizar la abundancia máxima en función de la dieta.”

Normalidad de residuos

Aplicamos el test de Shapiro sobre los residuos, accesibles con la función `resid()`.

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
head(resid(aov1), 20)
```

```
##           1           2           3           4
## -0.85625404  0.97537067  1.85713458 -0.46843137
##           5           6           7           8
##  0.33589637 -0.46411427  1.25271053  1.12666011
##           9          10          11          12
## -2.18693480  1.88854964 -1.17269926 -0.44893205
##          13          14          15          16
##  0.27959245 -0.39517533 -1.02983599  0.33879384
##          17          18          19          20
## -0.51210580 -1.16693290 -0.06183505 -1.22816339
```

- Cada valor es una observación de la tabla (54 en total)
- El residuo se calcula como la resta del valor observado menos el valor predicho por el modelo (es decir, la media del grupo al que pertenece dicho valor)
- Los residuos reflejan cuánto se desvía cada observación de la media de su grupo, es decir, la parte que el modelo no explica.

Normalidad de residuos

Aplicamos el test de Shapiro sobre los residuos, accesibles con la función `resid()`.

```
shapiro.test(resid(aov1))
```

```
##  
##      Shapiro-Wilk normality test  
##  
## data:  resid(aov1)  
## W = 0.97995, p-value = 0.4982
```

- Si $p\text{-valor} > 0.05$, no se rechaza H_0 : no hay evidencia suficiente para afirmar que los residuos no son normales, y la suposición de normalidad se cumple.

Homogeneidad de varianzas

Para verificar si los residuos del ANOVA tienen varianzas similares entre los grupos (supuesto de homogeneidad de varianzas), aplicamos el test de Levene:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
```

```
library(car)  
leveneTest(aov1)
```

```
## Levene's Test for Homogeneity of Variance (center = median)  
##           Df F value  Pr(>F)  
## group    4  2.3493 0.06717 .  
##           49  
## ---  
## Signif. codes:  
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Si $p\text{-valor} > 0.05 \rightarrow$ no se rechaza H_0 , las varianzas son aproximadamente iguales entre los grupos y el supuesto se cumple.

Anova en R

En R, el ANOVA se puede ejecutar directamente con la función `aov()`:

```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
summary(aov1)
```


```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Diet           4  27.07   6.768    2.836 0.0341 *
## Residuals     49 116.92   2.386
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretación del ANOVA

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Diet          4  27.07   6.768    2.836 0.0341 *
## Residuals    49 116.92   2.386
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Df** (grados de libertad): número de niveles del factor y residuales.
- **Sum Sq** (suma de cuadrados): cantidad de variación explicada por el factor y por los residuos
- **Mean Sq** (media de cuadrados): varianza estimada por cada componente.
- **F value**: estadístico F, que compara la variabilidad entre grupos con la variabilidad dentro de los grupos.
- **Pr(>F)**: valor p, que indica si las diferencias entre las medias de los grupos son estadísticamente significativas. Se proporciona el valor número y código.

Interpretación del ANOVA



Test complementario: test de Tukey

- ANOVA solo indica si existe una diferencia significativa entre grupos, no cuál es diferente.
- Para identificar qué grupos difieren entre sí, se realizan tests **post-hoc** que comparan los niveles del factor dos a dos.
- Test típico es el Tukey's HSD (*Honestly Significant Difference*):
 - Compara todas las parejas de medias de los grupos tras un ANOVA
 - Garantiza que el nivel global de significancia se mantenga, controlando el error tipo I (falsos positivos) cuando se hacen múltiples comparaciones.

Test complementario: test de Tukey

La función **TukeyHSD** aplica el test de Tukey:


```
aov1 <- aov(log(MaxAbund) ~ Diet, data = bird)
TukeyHSD(aov1)
```

Resultados del test de Tukey para el factor Diet				
	diff	lwr	upr	p adj
Vertebrate-PlantInsect	-1.6793	-3.3096	-0.0490	0.0405
PlantInsect-InsectVert	2.4539	-0.8066	5.7145	0.2236
PlantInsect-Insect	0.9724	-0.4489	2.3936	0.3118
Plant-InsectVert	2.0365	-2.3380	6.4110	0.6812
InsectVert-Insect	-1.4816	-4.7258	1.7626	0.6965
Vertebrate-Insect	-0.7069	-2.3042	0.8904	0.7204
Vertebrate-Plant	-1.2618	-4.6029	2.0792	0.8211

- Aplica el test post-hoc de Tukey (HSD), que compara todas las posibles parejas de grupos de **Diet** para determinar qué grupos son significativamente diferentes entre sí.

Test complementario: test de Tukey

- Las comparaciones con un p-valor ajustado (corregido) < 0.05 , son las significativas
- En este caso, la única diferencia significativa en la abundancia ocurre entre las dietas **PlantInsect** y **Vertebrate**.




Test complementario: test de Tukey

- El test de Tukey HSD está diseñado para comparar todas las medias entre sí sin inflar el error tipo I (el riesgo de falsos positivos): **FWER** - *family-wise error rate*
- El error familiar (FWER) es la probabilidad de cometer al menos un error tipo I en el conjunto de comparaciones.

Visualizar el resultado del test de Tukey

```
tuk <- TukeyHSD(aov1)
plot(tuk, las = 1)
```

- Las líneas horizontales son el intervalo de confianza (IC) al 95% de la diferencia de medias, ajustado por el método de Tukey.
- La línea vertical discontinua en 0 marca el punto donde no hay diferencia (diferencia = 0).
 - Si el intervalo cruza el 0, la diferencia no es significativa (no puedes descartar que sean iguales).
 - Si el intervalo no toca el 0, la diferencia sí es significativa.



Alternativas al ANOVA

Si no se cumplen los supuestos del ANOVA (normalidad o homogeneidad de varianzas), existen dos estrategias principales:

Test no paramétrico: Kruskal-Wallis

Si ninguna transformación funciona, usar un test no paramétrico:

```
kruskal.test(y ~ grupo, data = datos)
```

- No requiere normalidad ni homogeneidad de varianzas.
- Compara las medianas de los grupos en lugar de las medias.

Actividad de ANOVA

Un investigador desea conocer la efectividad de varios suplementos alimenticios (feed) sobre la tasa de crecimiento (weight) de los pollos. Carga los datos `chickwts` de `R`. Usa ANOVA para examinar la efectividad de los suplementos alimenticios. La línea de comando para cargar la tabla `chickwts` es `data("chickwts")`. Ejercicio tomado de: Biostatistics with R. Shahbaba (2012). Springer.

RETO: haz la actividad en `R`.

Pesos de pollos por tipo de alimentación					
horsebean	linseed	soybean	sunflower	meatmeal	casein
179	309	243	423	325	368
160	229	230	340	257	390
136	181	248	392	303	379
227	141	327	339	315	260
217	260	329	341	380	404
168	203	250	226	153	318
108	148	193	320	263	352
124	169	271	295	242	359
143	213	316	334	206	216
140	257	267	322	344	222
	244	199	297	258	283
	271	171	318		332
		158			
		248			

Primer paso: comprobar supuestos

```
aov1 <- aov(weight ~ feed, data = chickwts)
```

```
library(car)
```

```
leveneTest(weight ~ feed, data = chickwts)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
```

```
##           Df F value Pr(>F)
```

```
## group    5  0.7493 0.5896
```

```
##           65
```

```
shapiro.test(residuals(aov1))
```

```
##
```

```
##      Shapiro-Wilk normality test
```

```
##
```

```
## data:  residuals(aov1)
```

```
## W = 0.98616, p-value = 0.6272
```


Resultado del ANOVA:




Figura creada con el paquete **ggstatsplot**.

Calculadora de la F crítica de Fisher

- Podemos utilizar calculadoras online como: <https://www.danielsoper.com/statcalc/calculator.aspx?id=4> para obtener rápidamente la F crítica
- Mirar la tabla

Valores críticos de la distribución F (cola superior, $\alpha = 0.05$)															
	gl1 = 1	gl1 = 2	gl1 = 3	gl1 = 4	gl1 = 5	gl1 = 6	gl1 = 7	gl1 = 8	gl1 = 9	gl1 = 10	gl1 = 11	gl1 = 12	gl1 = 13	gl1 = 14	gl1 = 15
gl2 = 55	4.0162	3.1650	2.7725	2.5397	2.3828	2.2687	2.1813	2.1119	2.0552	2.0078	1.9675	1.9329	1.9026	1.8760	1.8523
gl2 = 56	4.0130	3.1619	2.7694	2.5366	2.3797	2.2656	2.1782	2.1087	2.0519	2.0045	1.9643	1.9295	1.8993	1.8726	1.8489
gl2 = 57	4.0099	3.1588	2.7664	2.5336	2.3767	2.2625	2.1751	2.1056	2.0488	2.0014	1.9611	1.9263	1.8960	1.8693	1.8456
gl2 = 58	4.0069	3.1559	2.7636	2.5307	2.3738	2.2596	2.1721	2.1026	2.0458	1.9983	1.9580	1.9233	1.8929	1.8662	1.8424
gl2 = 59	4.0040	3.1531	2.7608	2.5279	2.3710	2.2568	2.1693	2.0997	2.0429	1.9954	1.9551	1.9203	1.8899	1.8632	1.8394
gl2 = 60	4.0012	3.1504	2.7581	2.5252	2.3683	2.2541	2.1665	2.0970	2.0401	1.9926	1.9522	1.9174	1.8870	1.8602	1.8364
gl2 = 61	3.9985	3.1478	2.7555	2.5226	2.3657	2.2514	2.1639	2.0943	2.0374	1.9899	1.9495	1.9146	1.8842	1.8574	1.8336
gl2 = 62	3.9959	3.1453	2.7530	2.5201	2.3631	2.2489	2.1613	2.0917	2.0348	1.9872	1.9468	1.9119	1.8815	1.8547	1.8308
gl2 = 63	3.9934	3.1428	2.7505	2.5177	2.3607	2.2464	2.1588	2.0892	2.0322	1.9847	1.9442	1.9093	1.8789	1.8520	1.8282
gl2 = 64	3.9909	3.1404	2.7482	2.5153	2.3583	2.2440	2.1564	2.0868	2.0298	1.9822	1.9417	1.9068	1.8763	1.8495	1.8256
gl2 = 65	3.9886	3.1381	2.7459	2.5130	2.3560	2.2417	2.1541	2.0844	2.0274	1.9798	1.9393	1.9044	1.8739	1.8470	1.8231
gl2 = 66	3.9863	3.1359	2.7437	2.5108	2.3538	2.2395	2.1518	2.0821	2.0251	1.9775	1.9370	1.9020	1.8715	1.8446	1.8207
gl2 = 67	3.9840	3.1338	2.7416	2.5087	2.3517	2.2373	2.1497	2.0799	2.0229	1.9752	1.9347	1.8997	1.8692	1.8423	1.8183
gl2 = 68	3.9819	3.1317	2.7395	2.5066	2.3496	2.2352	2.1475	2.0778	2.0207	1.9730	1.9325	1.8975	1.8669	1.8400	1.8160
gl2 = 69	3.9798	3.1296	2.7375	2.5046	2.3475	2.2332	2.1455	2.0757	2.0186	1.9709	1.9304	1.8953	1.8648	1.8378	1.8138
gl2 = 70	3.9778	3.1277	2.7355	2.5027	2.3456	2.2312	2.1435	2.0737	2.0166	1.9689	1.9283	1.8932	1.8627	1.8357	1.8117

Resultado del test de Tukey

Resultados del test de Tukey para el factor Diet				
	diff	lwr	upr	p adj
linseed-horsebean	58.5500	-10.4135	127.5135	0.1413
soybean-horsebean	86.2286	19.5417	152.9155	0.0042
meatmeal-horsebean	116.7091	46.3351	187.0831	0.0001
casein-horsebean	163.3833	94.4198	232.3469	0.0000
sunflower-horsebean	168.7167	99.7531	237.6802	0.0000
soybean-linseed	27.6786	-35.6837	91.0409	0.7933
meatmeal-linseed	58.1591	-9.0729	125.3911	0.1277
casein-linseed	104.8333	39.0792	170.5875	0.0002
sunflower-linseed	110.1667	44.4125	175.9208	0.0001
linseed-sunflower	-52.4000	-84.4125	-20.3875	0.0001

La F crítica y p-valor en R

- **F crítico**: valor umbral que define si rechazamos la hipótesis nula H_0 al nivel de significancia α .

```
alpha <- 0.05      # nivel de significancia
df1 <- 5           # grados de libertad del numerador (número de grupos - 1)
df2 <- 65          # grados de libertad del denominador (total muestras - número de grupos)
```

```
F_critical <- qf(1 - alpha, df1, df2)
F_critical
```

```
## [1] 2.356028
```

La función **qf** devuelve el valor de F que corresponde al 5% de probabilidad de error tipo I (cola superior) dados esos grados de libertad.

■ Si $F_{obs} > F_{crit}$ rechazamos H_0

La F crítica y p-valor en R

```
df1 <- 5
df2 <- 65
F_obs <- 15.36

p_value <- pf(F_obs, df1, df2, lower.tail = FALSE)
p_value
```

```
## [1] 5.967948e-10
```

La función **pf** devuelve la probabilidad de obtener un F mayor o igual que F_{obs} .

Si $p - valor < \alpha \rightarrow$ el ANOVA es significativo.

▮ **lower.tail=FALSE** porque ANOVA siempre mira la cola superior.

ANOVA DE DOS VÍAS

ANOVA de dos vías

- Método estadístico para probar el efecto de **dos variables categóricas** sobre una **variable continua**
 - La **variables categóricas** son las **variables independientes**
 - las **variables continuas** son las **variables respuesta**

Contacto

Marta Coronado Zamora	David Castellano
 marta.coronado@uab.cat	 david.castellano@uab.cat
 @geneticament.bsky.social	 @castellanoed.bsky.social
 Universitat Autònoma de Barcelona	 University of Arizona