Correlación

Bioestadística

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2026/2027

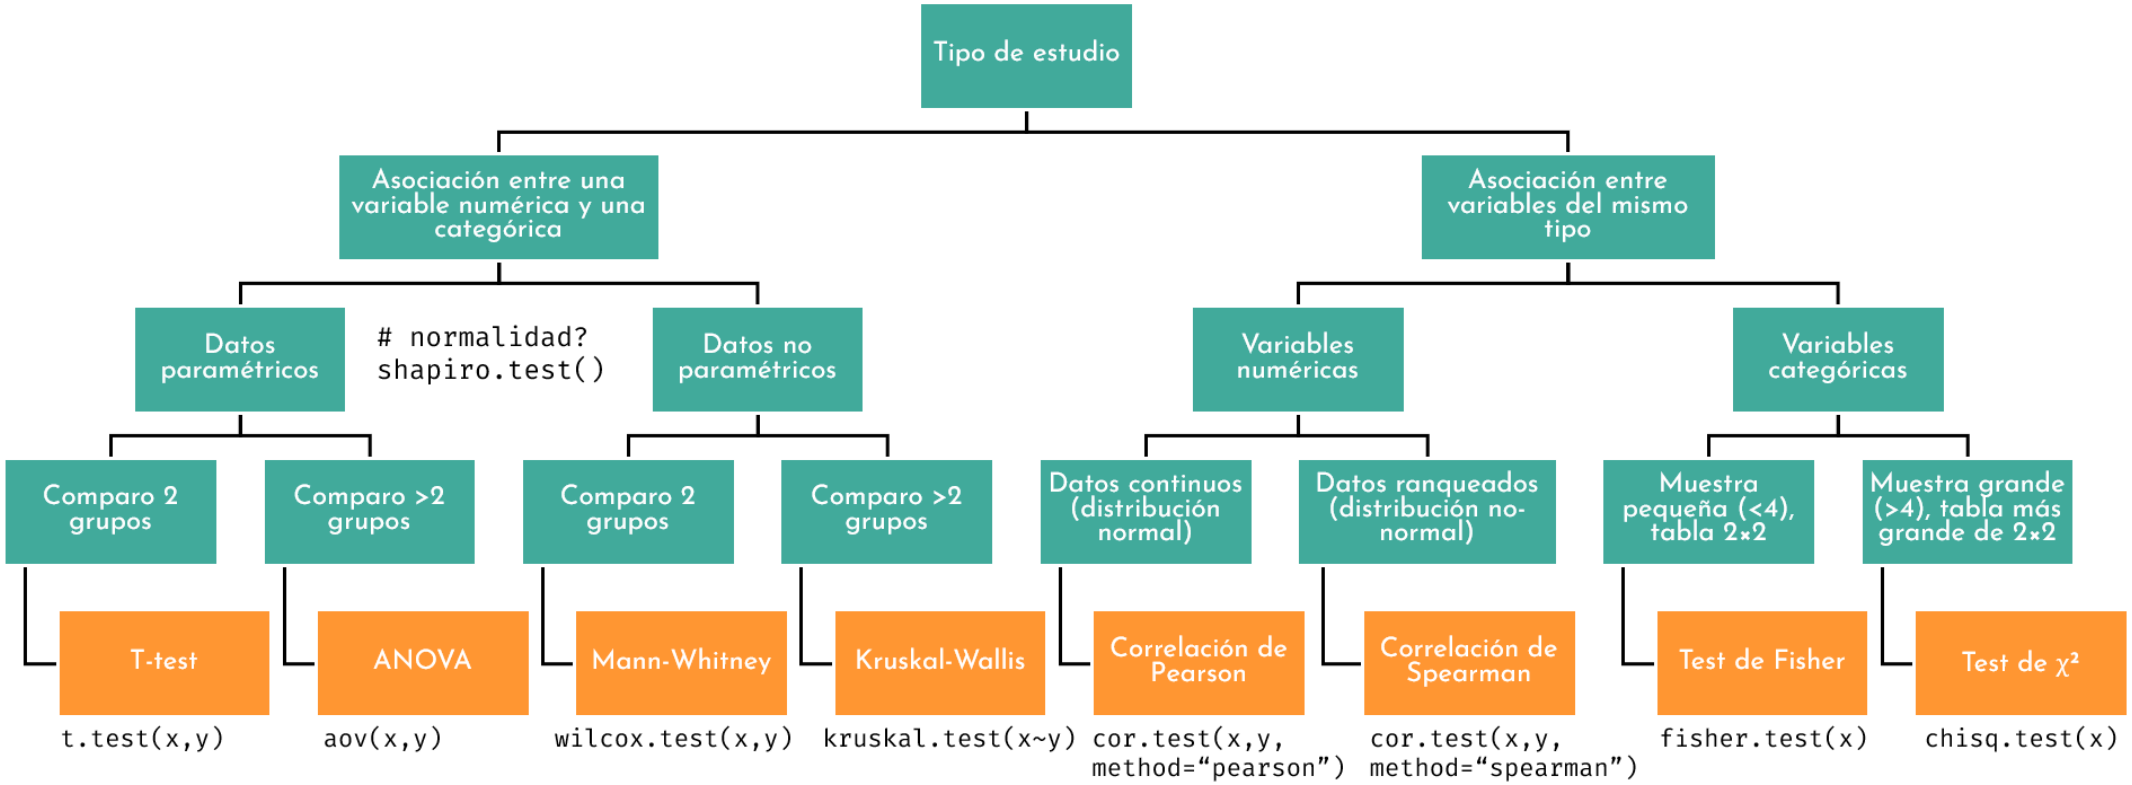


Outline

Correlación

- ¿Qué es un análisis de correlación?
- Correlación de Pearson y de Spearman
- Correlación y causalidad
- Correlación y regresión

Pruebas estadísticas



¿Qué es un análisis de correlación?

- Prueba estadística que permite medir la relación entre dos variables cuantitativas

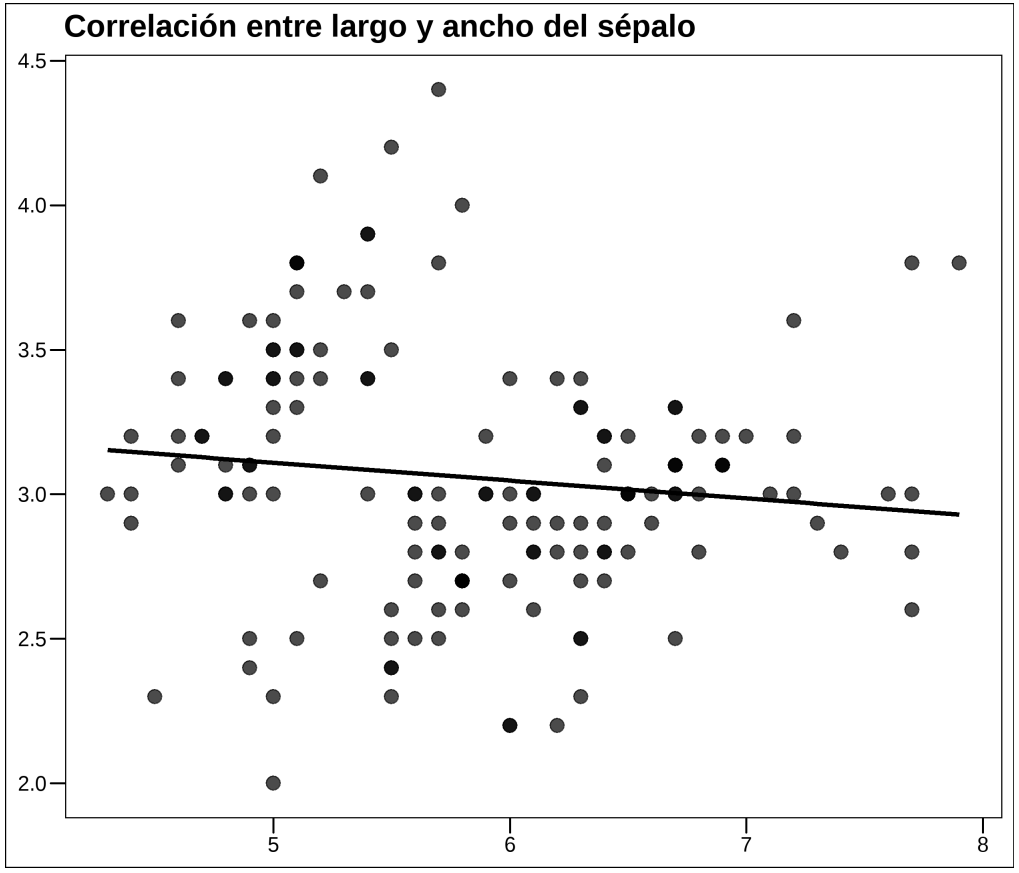
Show 10 entries Search:

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa

Showing 1 to 10 of 150 entries Previous 1 2 3 4 5 … 15 Next

¿Qué es un análisis de correlación?

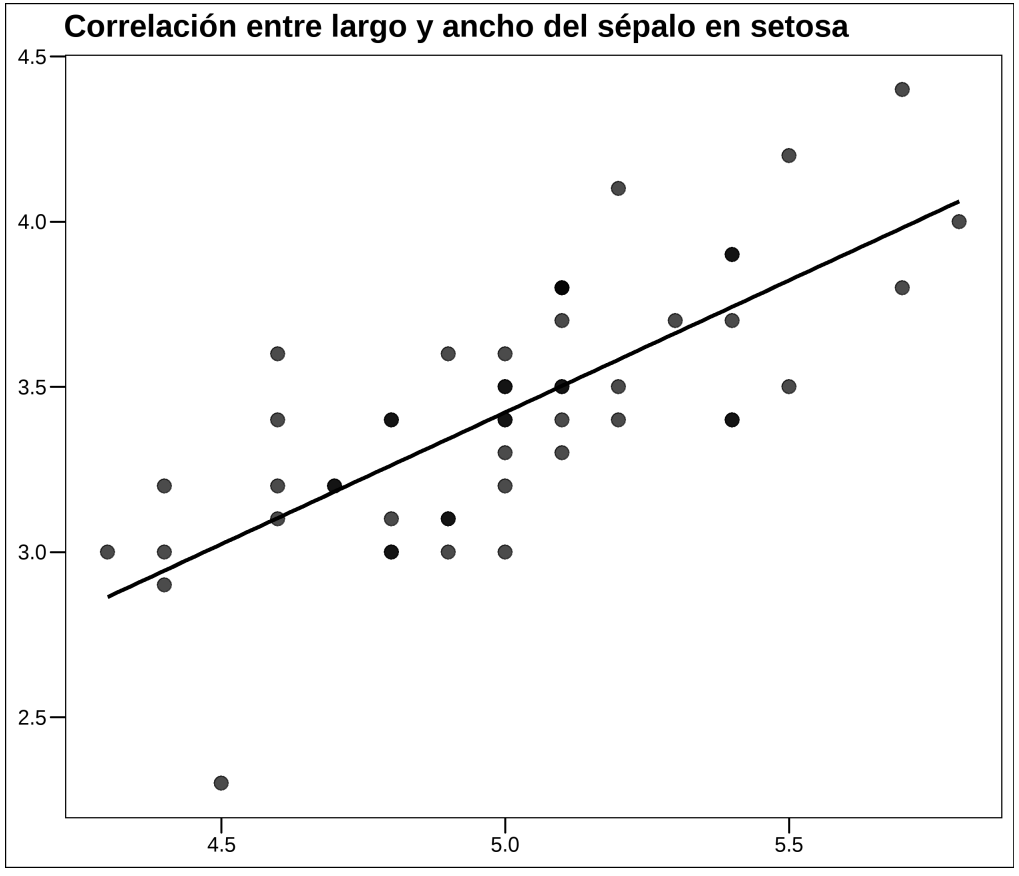
- Prueba estadística que permite medir la relación entre dos variables cuantitativas



> ¿Qué es cada punto?

¿Qué es un análisis de correlación?

- Prueba estadística que permite medir la relación entre dos variables cuantitativas



Análisis de correlación

Nos interesa conocer:

1. Lo fuerte que es la correlación
2. La dirección de la correlación

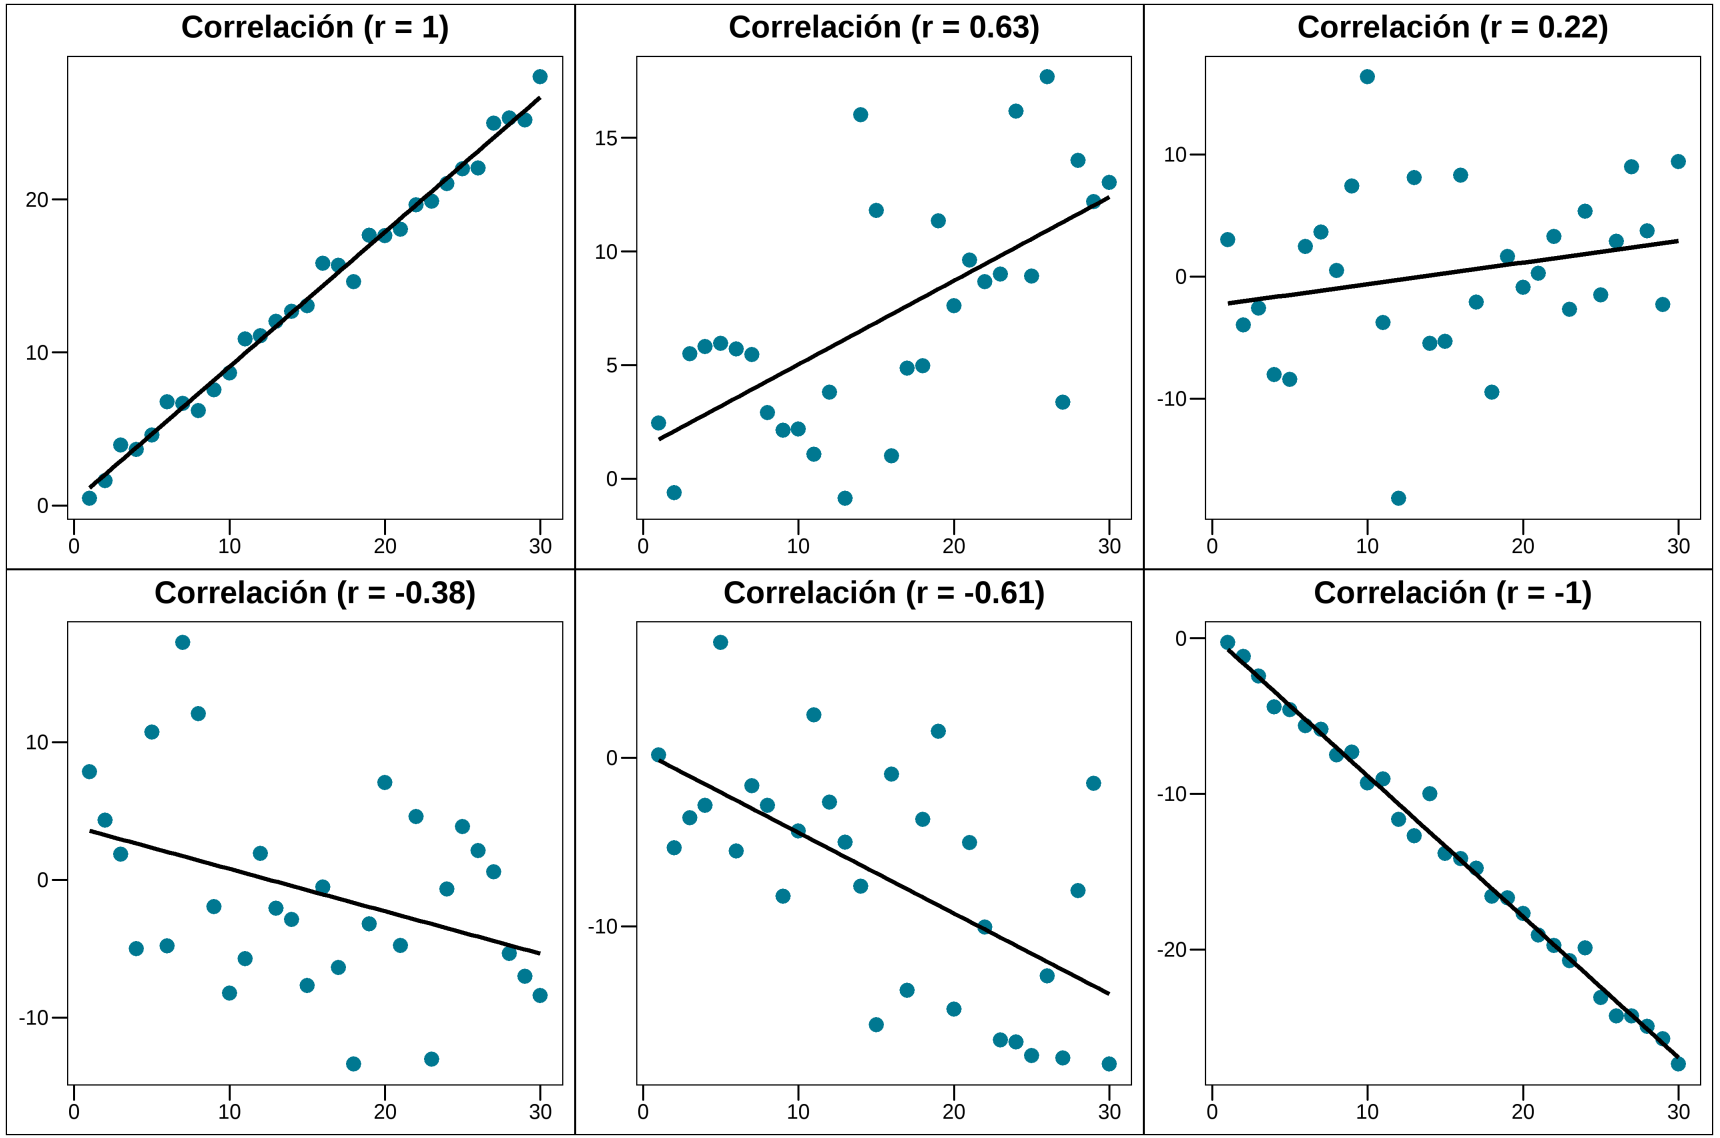
Ambas medidas se verán reflejadas en el coeficiente de correlación (r): de -1 a 1

Fuerza de la correlación según el valor de *r*

El signo indica la dirección; la fuerza depende del valor absoluto: $r = -0.8$ es una correlación tan fuerte como $r = 0.8$

Valor absoluto de *r*	Interpretación
< 0.1	No correlación
0.1 – 0.3	Correlación baja
0.3 – 0.5	Correlación media
0.5 – 0.7	Correlación alta
0.7 – 1.0	Correlación muy alta

Ejemplos

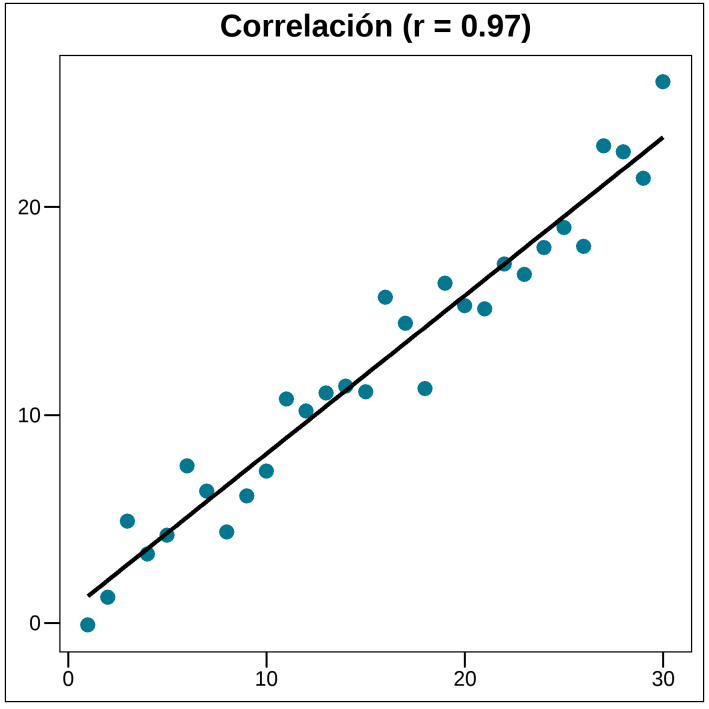

Correlación (r = 1)
Correlación (r = 0.63)
Correlación (r = 0.22)
Correlación (r = -0.38)
Correlación (r = -0.61)
Correlación (r = -1)

Tipos de coeficientes de correlación

1. *r* de Pearson: relación **lineal** entre dos variables cuantitativas con distribución normal
2. *r* de Spearman: relación **monótona**, calculada sobre los **rangos** (no paramétrica)

Correlación de Pearson

- Medida estadística que cuantifica la relación entre dos variables.
- Se mide la relación lineal entre dos variables cuantitativas.



- El coeficiente de correlación de Pearson nos informará de lo fuerte que es y la dirección de la relación lineal de dos variables

Cómo calcular el coeficiente de correlación de Pearson

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

donde:

- r: coeficiente de correlación de Pearson
- x_i: valores individuales de la variable x
- y_i: valores individuales de la variable y
- $\bar{x}$: media de la variable x
- $\bar{y}$: media de la variable y
- Los valores promedio de cada variable se restan primero de los valores individuales de ambas variables. Luego, se multiplican.
- La expresión del denominador se asegura de que el coeficiente de correlación esté escalado entre -1 y 1.

Hipótesis

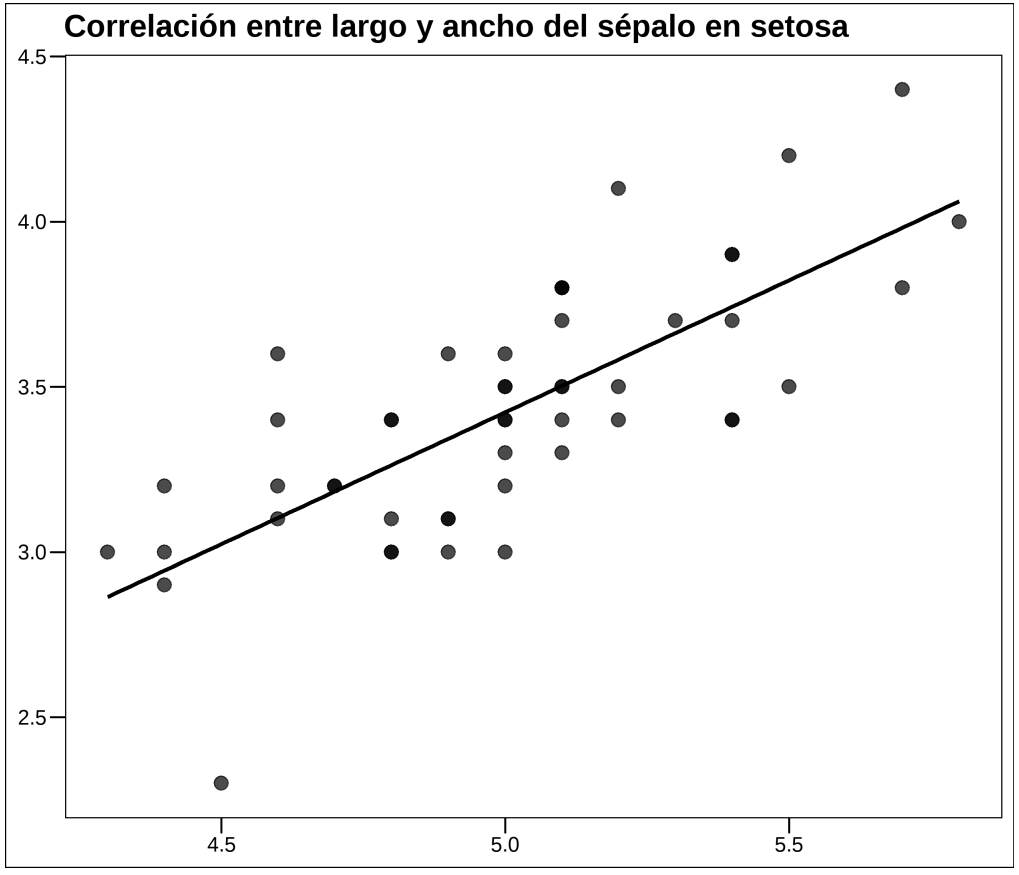
- Queremos saber si hay una correlación en la población (aunque el test lo hacemos en la muestra).
- Comprobamos si el coeficiente de correlación de la muestra es significativamente distinto de 0.

H_0: el coeficiente de correlación no difiere de 0: no hay relación lineal

H_1: el coeficiente de correlación sí difiere de 0: sí hay relación lineal

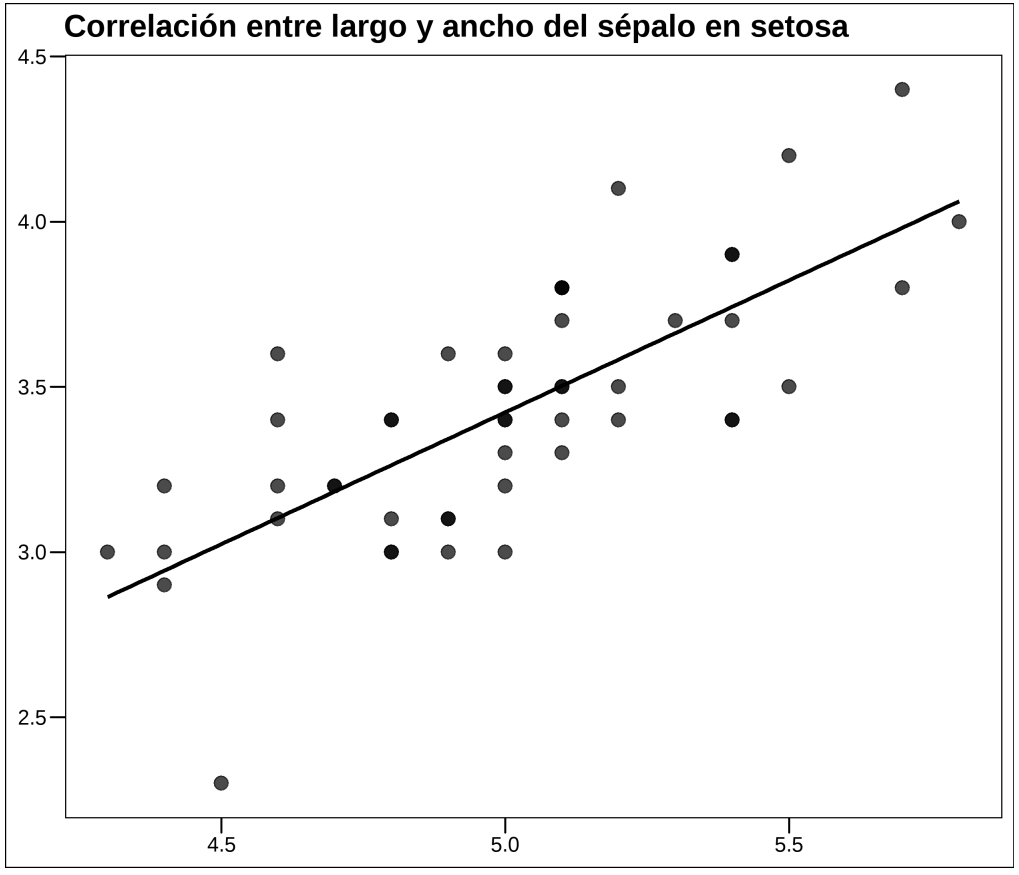
> Recuerda: en las pruebas de hipótesis, siempre comprobamos si la hipótesis nula se rechaza o no

Ejemplo: correlación entre la anchura y longitud del sépalo



- H_0: no hay una correlación entre la anchura y la longitud del sépalo: r es 0
- H_1: sí hay una correlación entre la anchura y la longitud del sépalo: r no es 0

Ejemplo: correlación entre la anchura y longitud del sépalo



- H_0: no hay una correlación entre la anchura y la longitud del sépalo: r es 0
- H_1: sí hay una correlación entre la anchura y la longitud del sépalo: r no es 0

Test del coeficiente de correlación

Para comprobar si el coeficiente de correlación es diferente de 0 utilizaremos un t-test:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

- r: coeficiente de correlación de la muestra
- n: tamaño de la muestra
- El p-valor se calculará usando la distribución t con $n-2$ grados de libertad

Supuestos de la correlación de Pearson

- Para calcular el coeficiente de correlación de Pearson necesitamos **dos variables métricas**.
- El coeficiente indica **la fuerza de la relación lineal**.
  - Si no hay relación lineal, **el coeficiente no lo refleja**.

- Para probar si el coeficiente es **significativamente distinto de 0**, ambas variables deben aproximarse a una **distribución normal**.
- Si la normalidad no se cumple:
  - La prueba de Pearson no es válida.
  - Alternativa: **correlación de Spearman** (no paramétrica).

Correlación de Pearson en R

```r
library(dplyr)

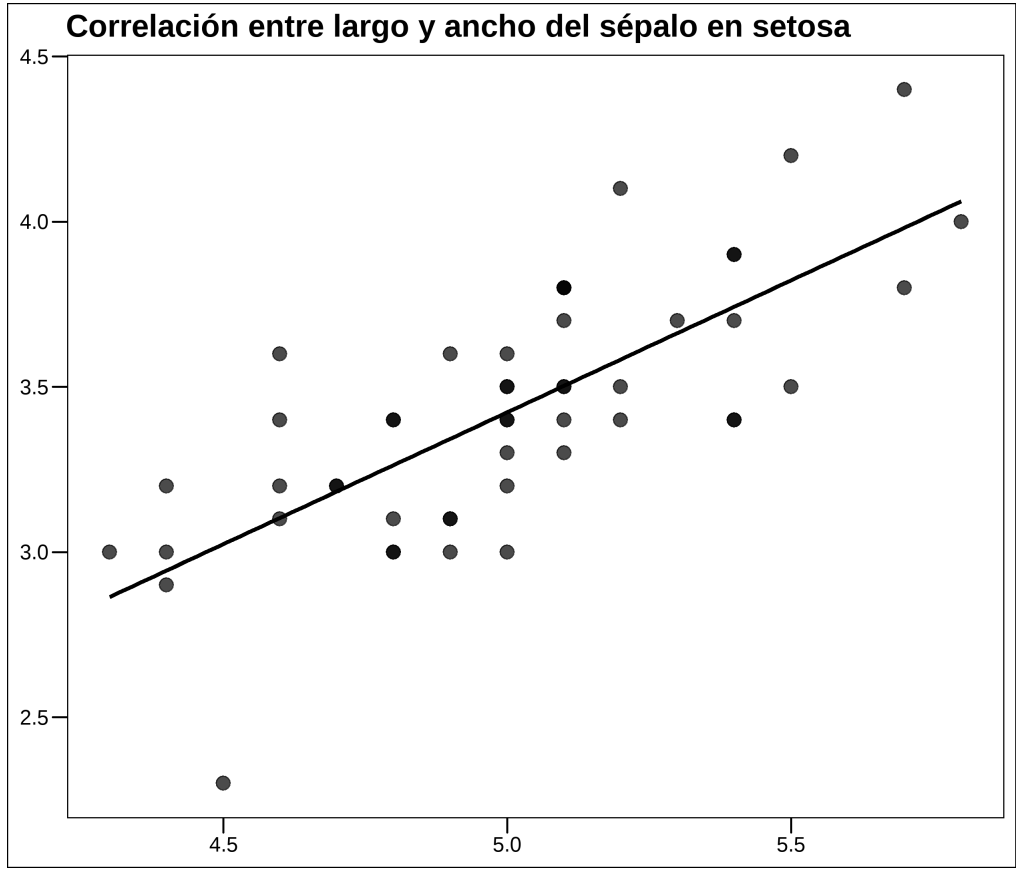
setosa <- filter(iris, Species == "setosa")

shapiro.test(setosa$Sepal.Length)
```

```
##
##     Shapiro-Wilk normality test
##
## data:  setosa$Sepal.Length
## W = 0.9777, p-value = 0.4595
```

```r
shapiro.test(setosa$Sepal.Width)
```

```
##
##     Shapiro-Wilk normality test
##
## data:  setosa$Sepal.Width
## W = 0.97172, p-value = 0.2715
```



Correlación de Pearson en R

```
cor.test(setosa$Sepal.Length,
         setosa$Sepal.Width,
         method = "pearson",
         alternative  = "two.sided")
```

```
##
##     Pearson's product-moment correlation
##
## data:  setosa$Sepal.Length and setosa$Sepal.Width
## t = 7.6807, df = 48, p-value = 6.71e-10
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.5851391 0.8460314
## sample estimates:
##       cor
## 0.7425467
```

- `t`: valor del estadístico de contraste
- `df`: grados de libertad (n − 2)
- `p-value`: significación
- `cor`: coeficiente de Pearson
- `95 percent confidence interval`: IC del coeficiente

> Con `alternative = "greater"` o `"less"` hacemos un test de una cola

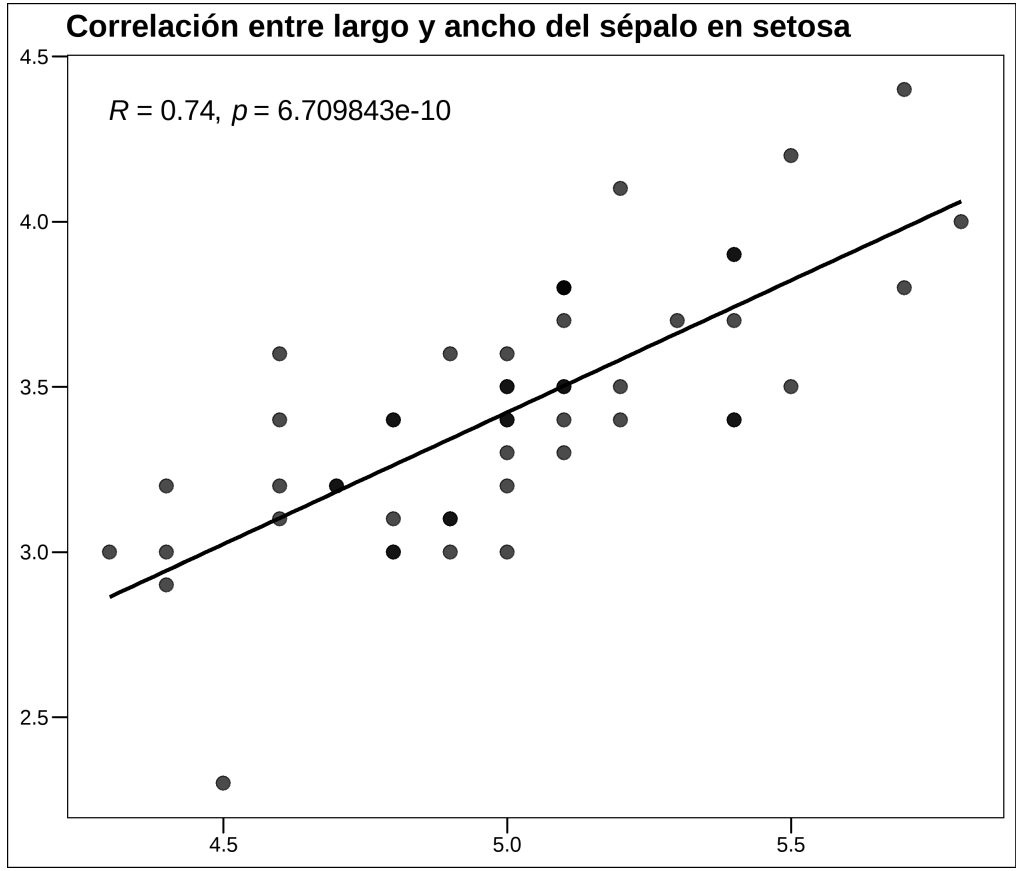
Correlación de Pearson en R

```
ggplot(setosa,
       aes(x = Sepal.Length, y = Sepal.Width))

  geom_point() +

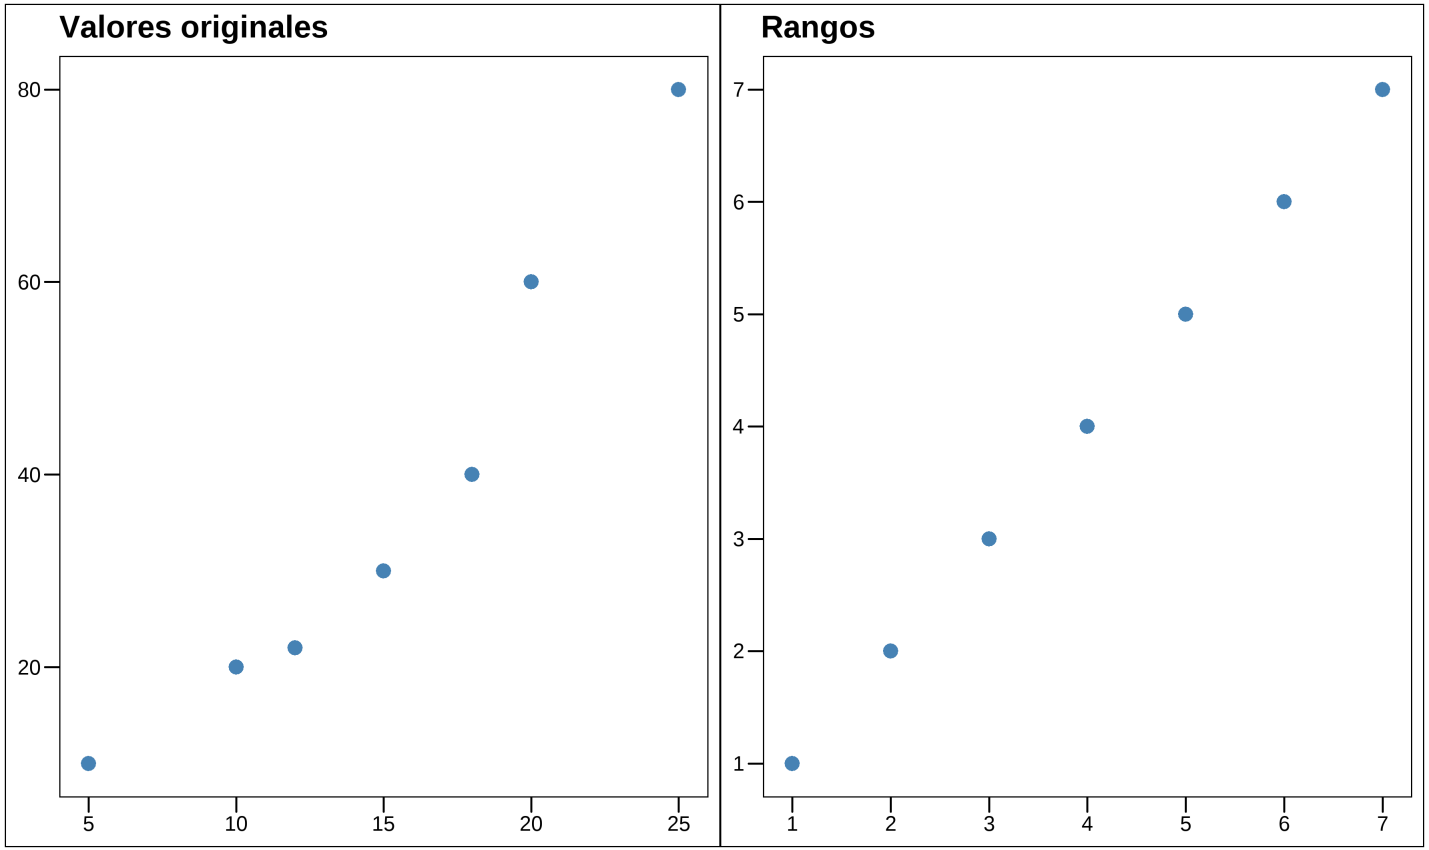
  geom_smooth(method = "lm", se = FALSE, color

  stat_cor(method = "pearson")
```

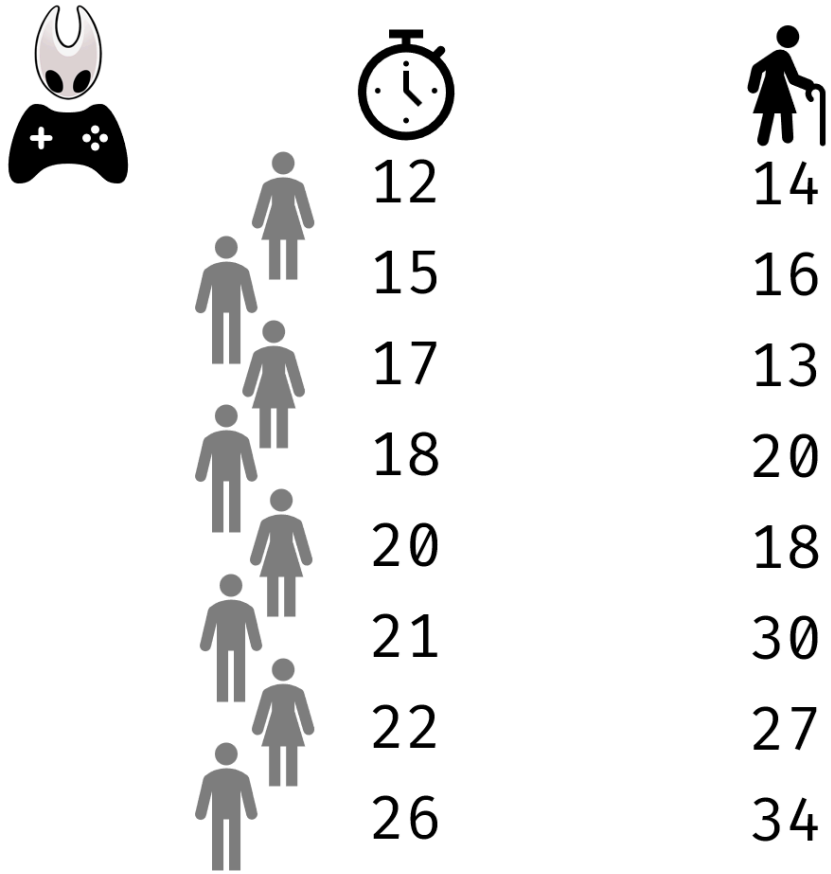


Correlación (de rangos) de Spearman

- En lugar de usar los datos originales, Spearman utiliza los rangos.



Ejemplo de correlación de Spearman



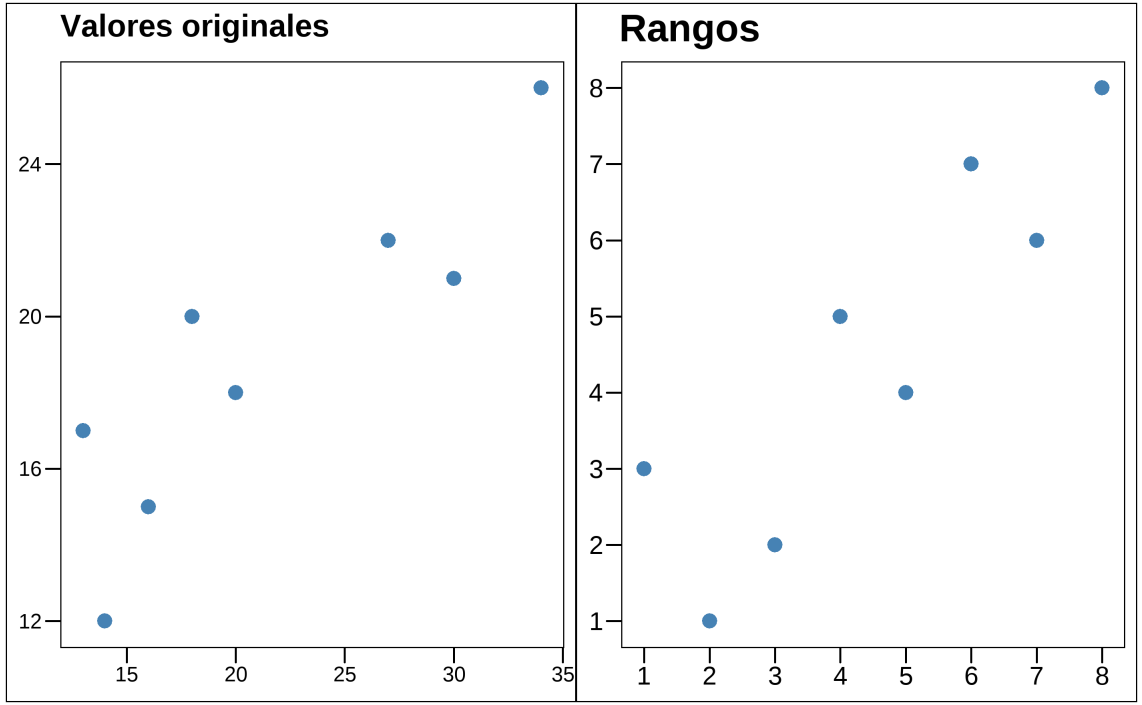
Ejemplo de correlación de Spearman





12	1	14	2
15	2	16	3
17	3	13	1
18	4	20	5
20	5	18	4
21	6	30	7
22	7	27	6
26	8	34	8

Ejemplo de correlación de Spearman



- Los datos se distribuyen de manera más uniforme

> La correlación de Spearman es como la de Pearson, pero utiliza los rangos en vez de los valores crudos

Ecuación de la correlación de Spearman

- Si no hay empates en los rangos:

$$`r_s = 1 - \frac{6 \sum d_i^2}{n(n^2-1)}`$$

donde:

- r_s es el coeficiente de correlación de Spearman
- n es el número de pares de datos
- $d_i = R(X_i) - R(Y_i)$ es la diferencia entre los rangos del i-ésimo par de valores
- $\sum_{i=1}^{n} d_i^2$ es la suma de los cuadrados de las diferencias de rangos

Ejemplo de correlación de Spearman

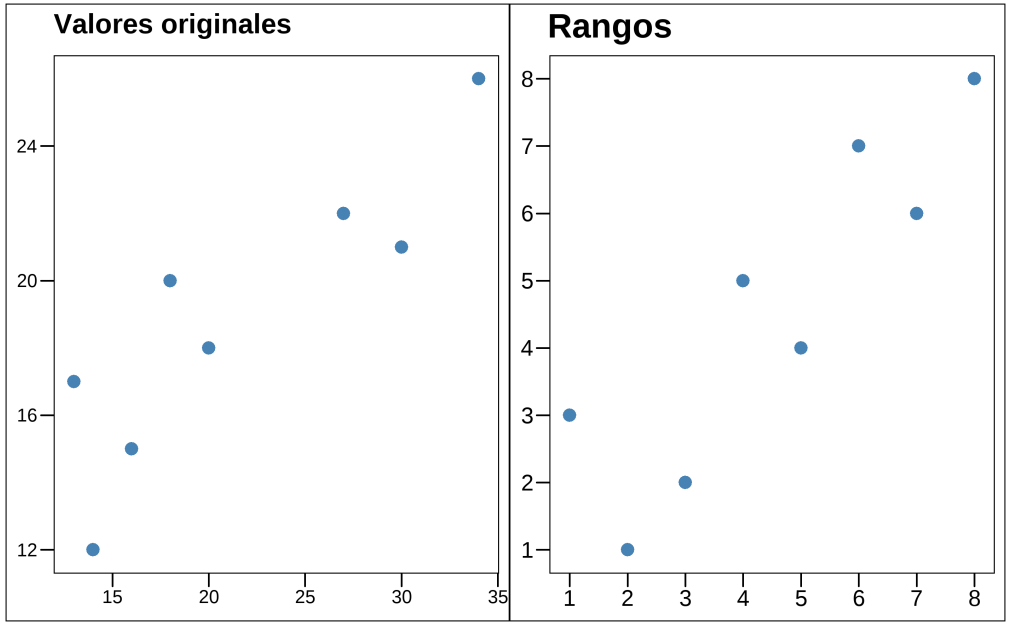




				d	**d²**
12	1	14	2	1	1
15	2	16	3	1	1
17	3	13	1	-2	4
18	4	20	5	1	1
20	5	18	4	-1	1
21	6	30	7	1	1
22	7	27	6	-1	1
26	8	34	8	0	0

Ejemplo de correlación de Spearman

$$`r_s = 1 - \frac{6\sum d_i^2}{n(n^2-1)} = 1 - \frac{6\times 10}{8(8^2-1)} = 0.88`$$



- El coeficiente de correlación de Spearman también va de −1 a 1

Coeficiente de correlación de Spearman en R

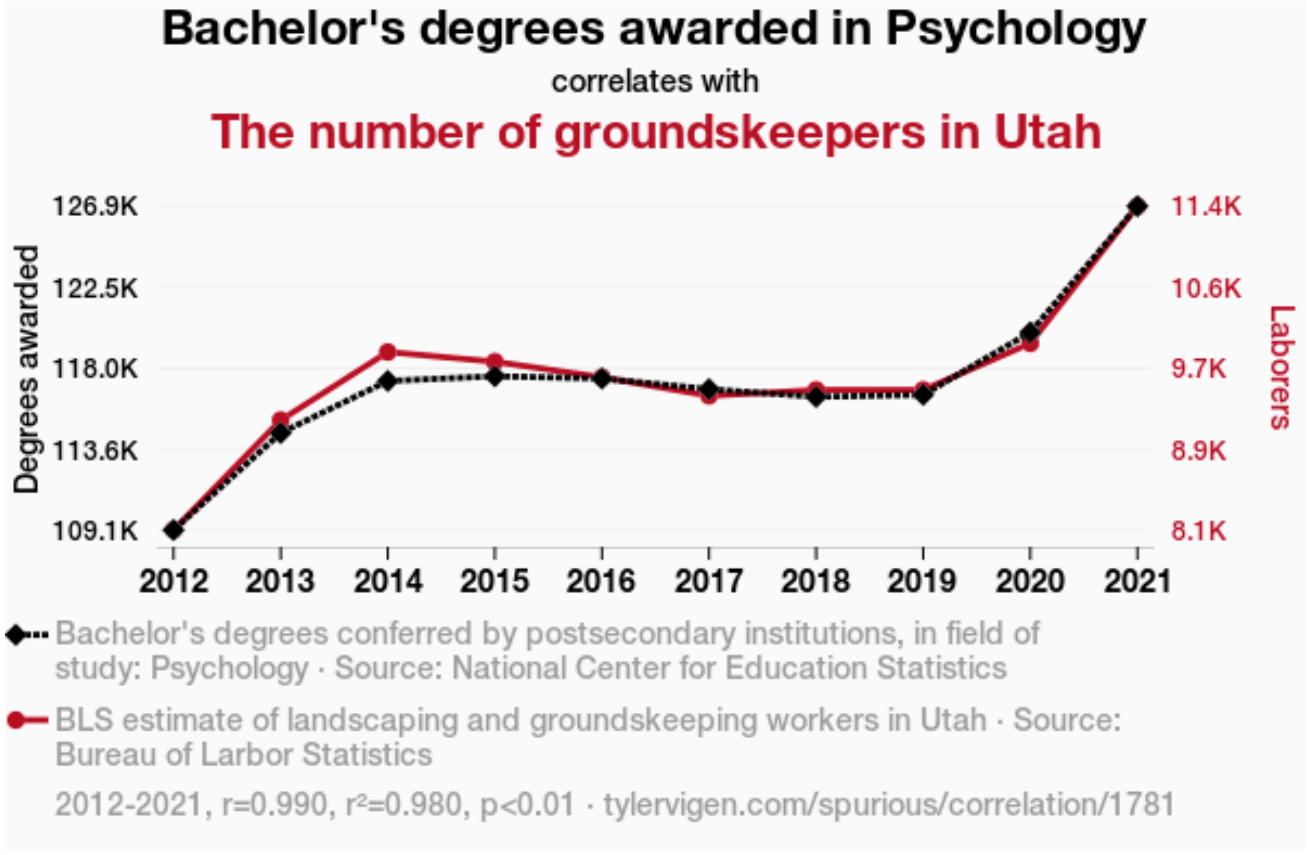
```r
edad <- c(14, 16, 13, 20, 18, 30, 27, 34)
tiempo_reaccion <- c(12, 15, 17, 18, 20, 21, 22, 26)

cor.test(edad, tiempo_reaccion, method = "spearman", alternative = "two.sided")
```

```
##
##     Spearman's rank correlation rho
##
## data:  edad and tiempo_reaccion
## S = 10, p-value = 0.007242
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##       rho
## 0.8809524
```

Causalidad vs. correlación

- Causalidad es la relación entre una causa y un efecto
- La correlación nos dice si hay una relación entre dos variables



Causalidad vs. correlación

> No podemos asumir causalidad a partir de una correlación.

La correlación solo indica que las variables se mueven juntas, no que una cause a la otra.

Se debe cumplir:

1. Correlación significativa
2. Los siguientes tres escenarios:
   a. Secuencia cronológica
   b. Experimento controlado
   c. Fundamento teórico sólido

Correlación y regresión

Correlación

- Mide la **fuerza** y la **dirección** de la relación
- Es **simétrica**: `cor(x, y)` = `cor(y, x)`
- No hay variable dependiente ni independiente

Regresión (próximo tema)

- **Predice** y a partir de x: $y = \beta_0 + \beta_1 x + \varepsilon$
- No es simétrica: y es la respuesta, x la explicativa
- Es un modelo lineal, como el ANOVA: `lm(y ~ x)`
- r = coeficiente de **correlación** (`cor()`): de -1 a 1
- R^2 = coeficiente de **determinación** (`lm()`): de 0 a 1

> En la regresión lineal simple, $R^2 = r^2$: el 55% de la variabilidad de la anchura del sépalo se explica por su longitud. Al elevar al cuadrado se **pierde el signo**: R^2 dice cuánto explica el modelo, pero **no la dirección** de la relación

```
r <- cor(setosa$Sepal.Length,
         setosa$Sepal.Width)
r^2
```

```
## [1] 0.5513756
```

```
modelo <- lm(Sepal.Width ~ Sepal.Length,
             data = setosa)
summary(modelo)$r.squared
```

```
## [1] 0.5513756
```


SOLÍA CREER QUE LA CORRELACIÓN IMPLICABA CAUSALIDAD.
LUEGO DI UNA ASIGNATURA DE ESTADÍSTICA Y DEJÉ DE CREERLO.
PARECE QUE ESA CLASE TE AYUDÓ.
BUENO, QUIZÁ.

Contacto

Marta Coronado Zamora	David Castellano
marta.coronado@uab.cat	david.castellano@uab.cat
@geneticament.bsky.social	@castellanoed.bsky.social
Universitat Autònoma de Barcelona	University of Arizona