Regresión

Bioestadística

Marta Coronado (marta.coronado@uab.cat)

Grado en Genética | Curso 2026/2027



Outline

Regresión

- ¿Qué es un análisis de regresión? Objetivos y tipos
- Regresión lineal simple: la recta, el cálculo y la predicción
- Supuestos de la regresión
- Contraste de hipótesis y R^2
- Regresión lineal múltiple: coeficientes, multicolinealidad e interpretación
- Variables *dummy*
- ANOVA y regresión: el mismo modelo

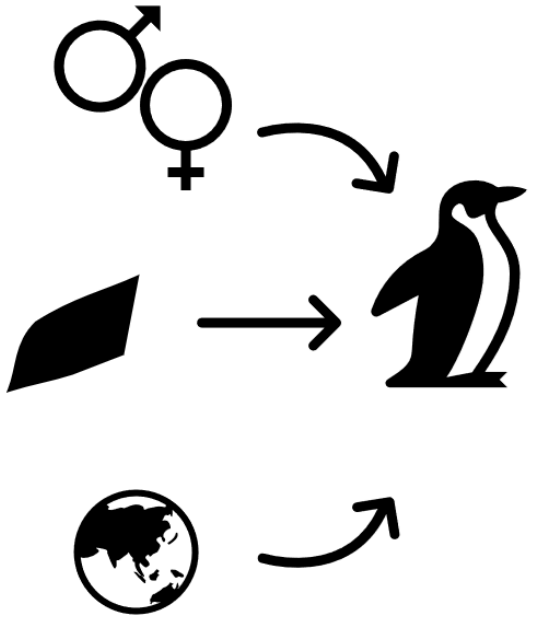
¿Qué es un análisis de regresión?

> Un método para modelar la relación entre variables. Permite inferir o predecir una variable a partir de una o más variables.

¿Qué influye en la masa corporal de un pingüino?

- La longitud de su aleta
- La especie
- El sexo

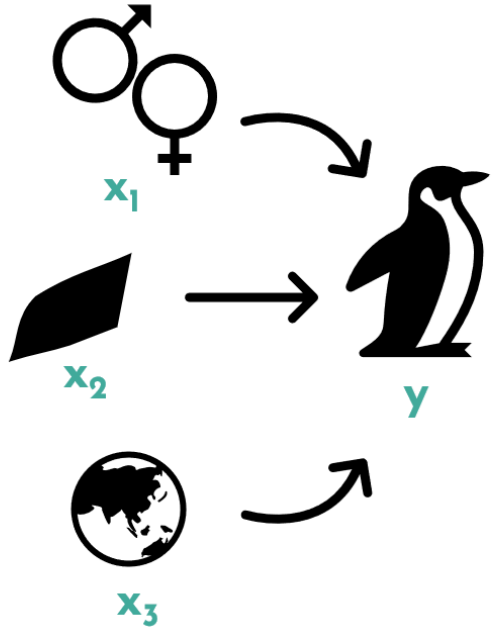
Si estas variables influyen, podemos predecir la masa de un pingüino conociendo solo esa información.



Variable dependiente e independientes

- Variable dependiente (y): la que queremos inferir o predecir
  - También: variable respuesta o *outcome*
  - Ej.: masa corporal

- Variables independientes ($x_1, x_2, \ldots$): las que usamos para predecir
  - También: variables predictoras o explicativas
  - Ej.: longitud de la aleta, especie, sexo

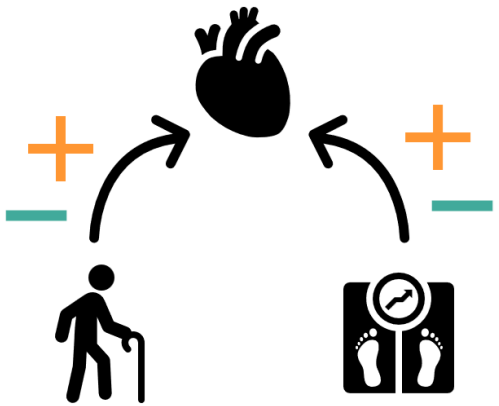


Dos objetivos de la regresión

1. Medir la influencia de una o más variables sobre otra

Orientado a la investigación

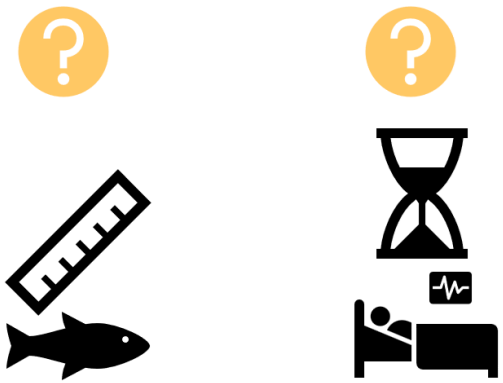
¿Qué factores influyen en la presión arterial? ¿La edad, el peso, el colesterol? ¿Su efecto es positivo o negativo?



2. Predecir una variable a partir de otras

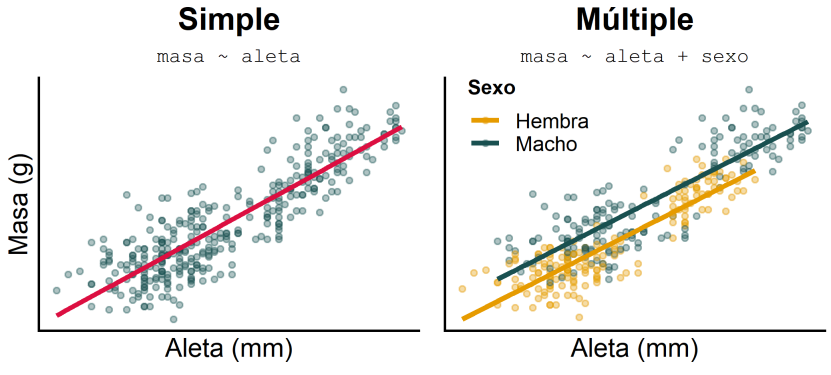
Orientado a la aplicación

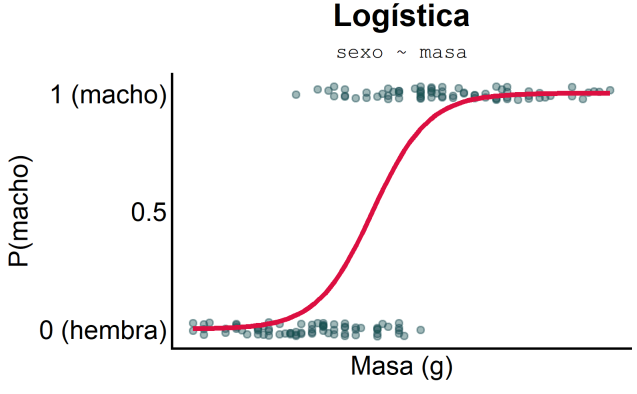
¿Qué edad tiene un pez a partir de su longitud?
¿Cuántos días estará un paciente ingresado?



Tipos de regresión

Tipo	Variable dependiente	Variables independientes	Ejemplo biológico
Lineal simple	Cuantitativa	Una	Masa corporal según la longitud de la aleta
Lineal múltiple	Cuantitativa	Dos o más	Presión arterial según edad, peso y colesterol
Logística	Categórica (p. ej. sí/no)	Una o más	Riesgo de enfermedad según la dosis de exposición





Tipos de variables en la regresión

- Variable dependiente
  - Regresión lineal (simple y múltiple): cuantitativa (masa, presión, expresión génica...)
  - Regresión logística: categórica (enfermo/sano, presencia/ausencia de una especie...). Si tiene dos categorías, hablamos de regresión logística binaria
- Variables independientes: pueden ser nominales, ordinales o cuantitativas
  - Una variable categórica entra en el modelo codificada con dos niveles: sexo → hembra = 0, macho = 1
  - ¿Y si tiene más de dos categorías (p. ej. tres especies)? → Variables *dummy* (lo veremos al final del tema)

Regresión lineal simple

Regresión lineal simple

> Método para entender la relación entre **dos variables**: permite inferir o predecir una variable a partir de la otra.

Ejemplo: ¿podemos predecir la **masa corporal** de un pingüino a partir de la **longitud de su aleta**?

Datos: `penguins` con 333 pingüinos de la Antártida.

Aleta (mm)	Masa (g)
214	4925
208	3950
185	3650
182	3150
210	4100
193	3800



La ecuación de la recta

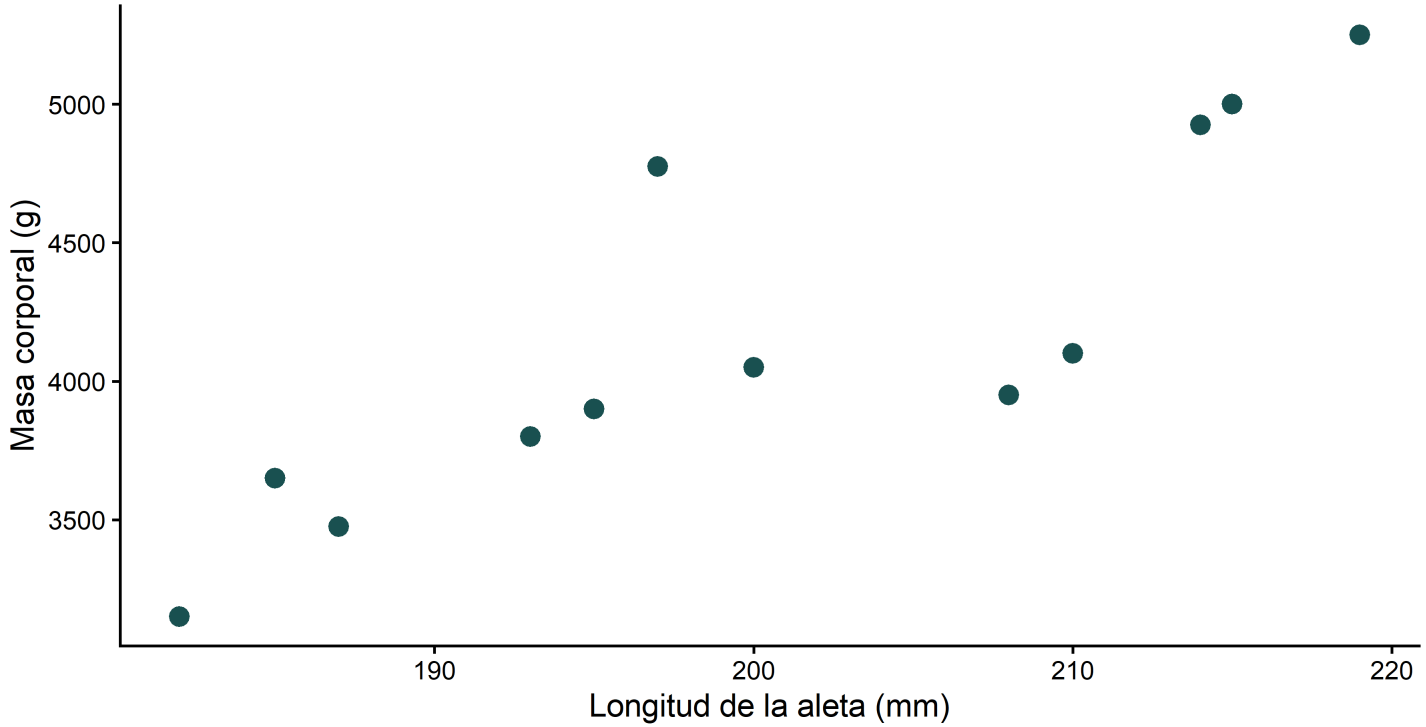
$$\hat{y} = a + b\,x$$

- $\hat{y}$: valor predicho de la variable dependiente (masa corporal)
- x: variable independiente (longitud de la aleta)
- a: ordenada en el origen (*intercept*): dónde corta la recta el eje y
- b: pendiente (*slope*): cuánto cambia y cuando x aumenta 1 unidad

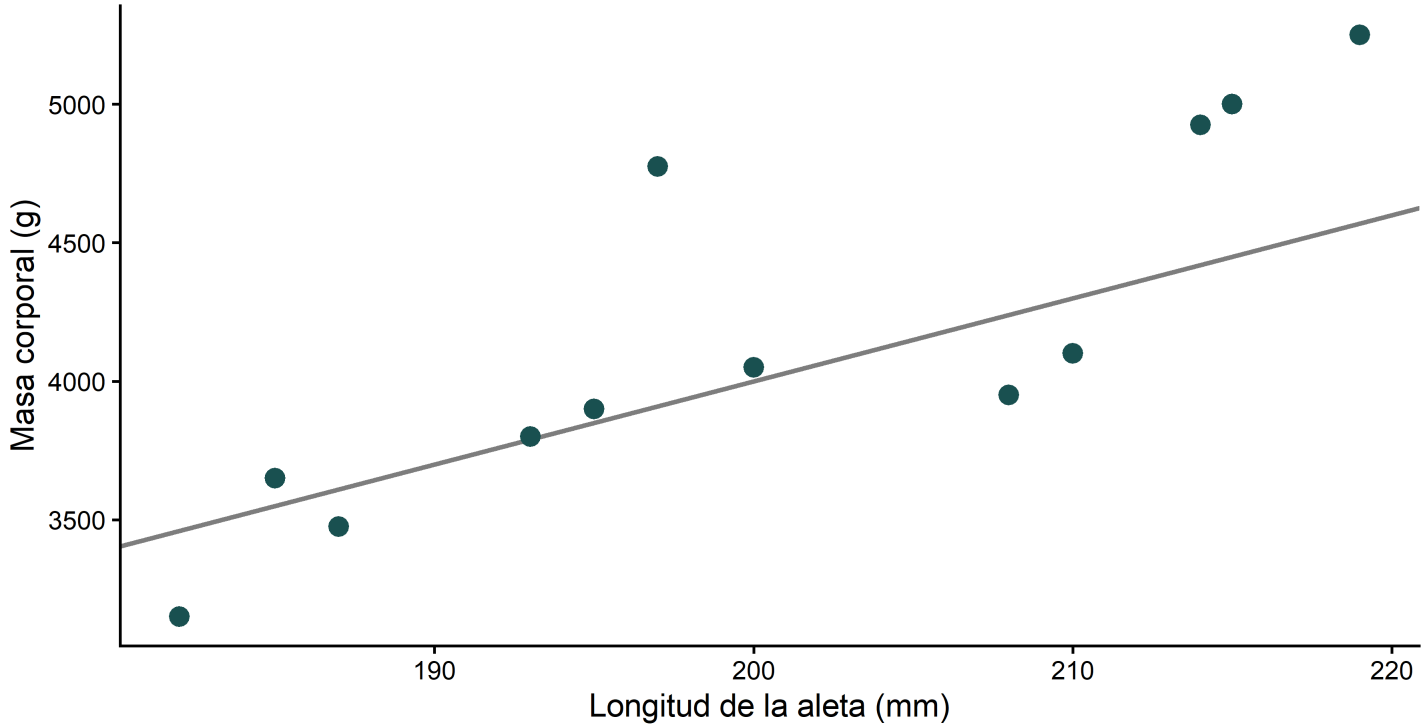
> Objetivo: usar los datos para estimar a y b

También se escribe $y = \beta_0 + \beta_1 x + \varepsilon$, como vimos en el tema de correlación.

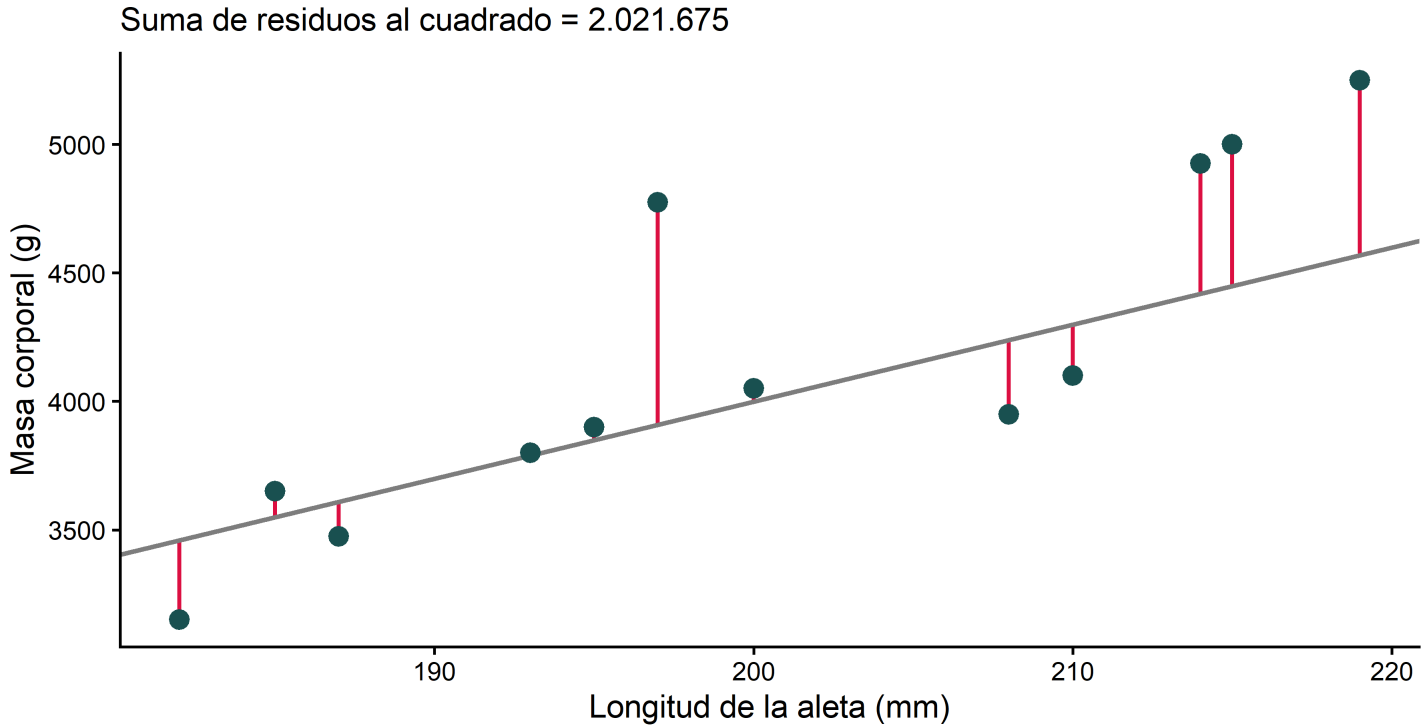
Visualizamos los datos



Trazamos una recta...

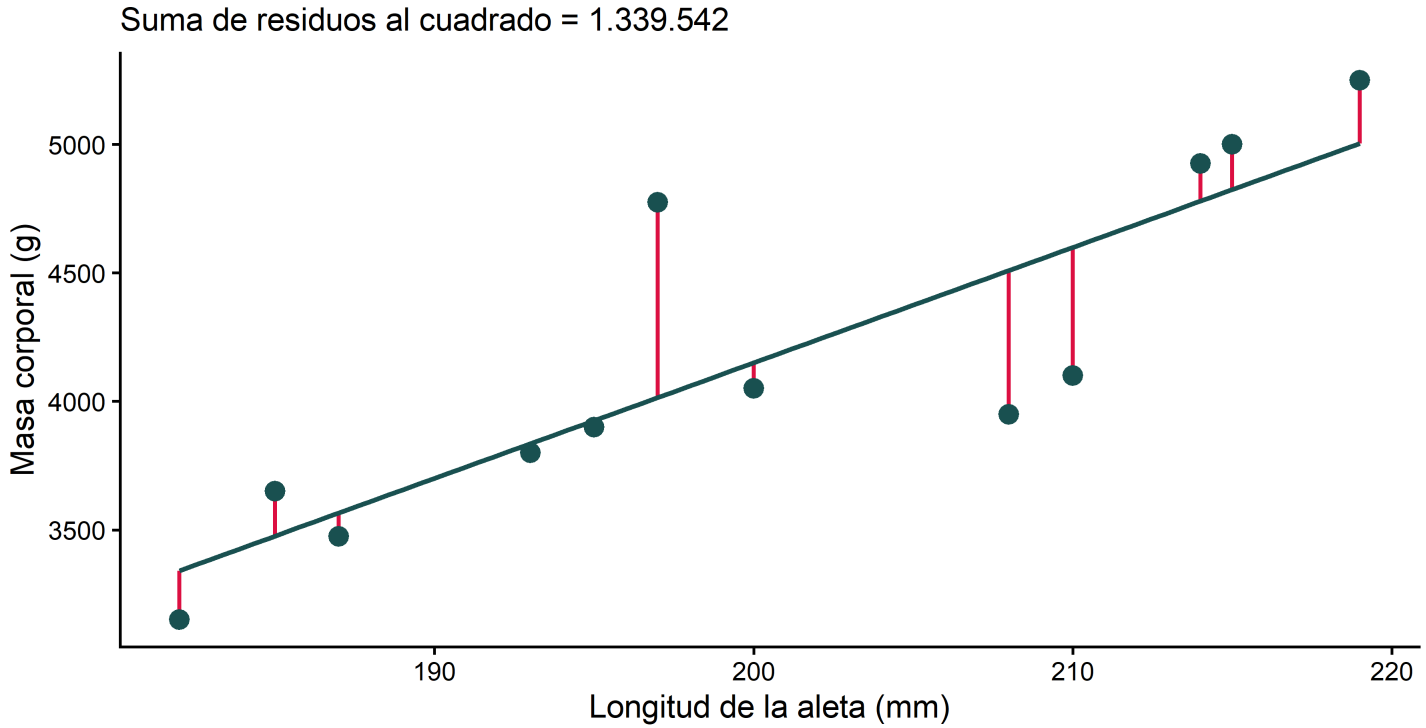


… y medimos el error de cada punto



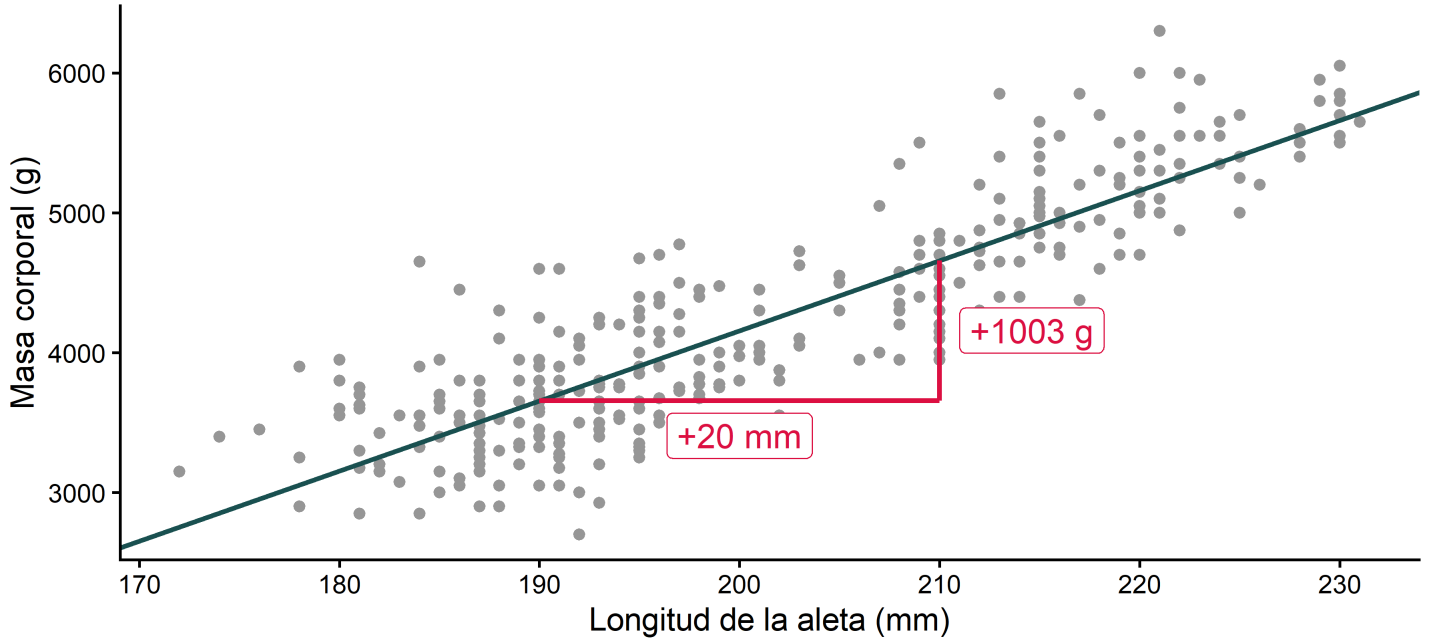
Cada línea roja es un **residuo**: la distancia entre el valor observado y y el predicho $\hat{y}$.

La mejor recta: mínimos cuadrados



La recta de regresión es la que hace **mínima** la suma de los residuos al cuadrado

Interpretar a y b

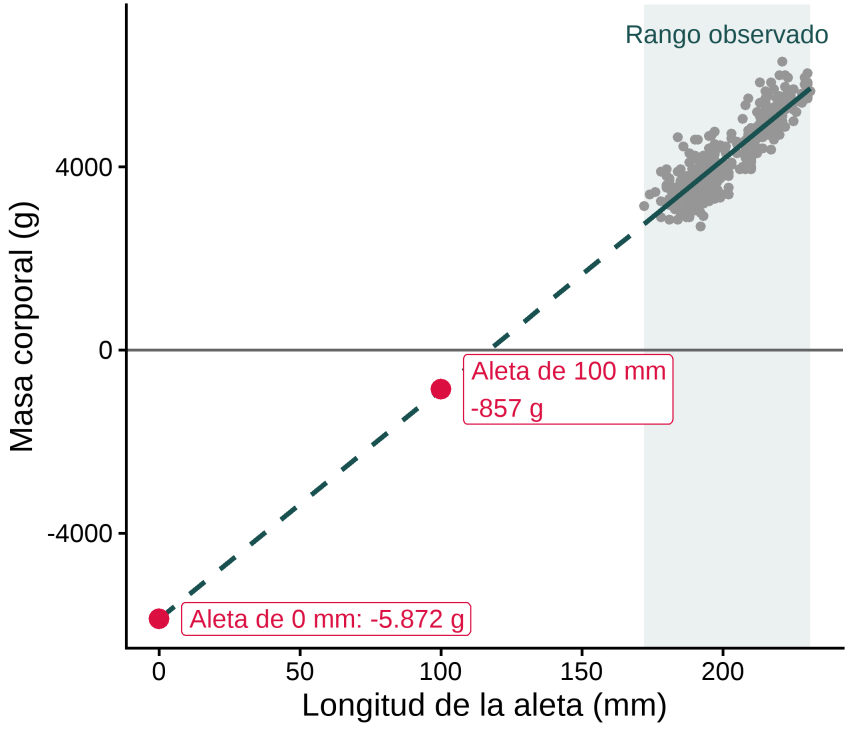


- Pendiente b = 50.2: por cada mm más de aleta, la masa aumenta en promedio 50.2 g
- Ordenada a = -5872: la masa de un pingüino con aleta de 0 mm. ¡No tiene sentido biológico!

Todo modelo es una simplificación

- La recta solo describe bien los datos **dentro del rango observado** (aletas de 172 a 231 mm)
- Fuera de ese rango, **extrapolar** puede dar resultados absurdos, como una masa negativa

> *All models are wrong, but some are useful* (George Box)



Calcular a y b

La pendiente se obtiene a partir de la correlación y las desviaciones típicas:

$$b = r \cdot \frac{s_y}{s_x}$$

Y la recta siempre pasa por el punto de medias $(\bar{x}, \bar{y})$, así que:

$$a = \bar{y} - b\,\bar{x}$$

```
r <- cor(pinguinos$flipper_len, pinguinos$body_mass)
b <- r * sd(pinguinos$body_mass) / sd(pinguinos$flipper_len)
a <- mean(pinguinos$body_mass) - b * mean(pinguinos$flipper_len)
c(a = a, b = b)
```

```
         a          b 
-5872.09268   50.15327 
```

Regresión lineal simple en R

```
modelo <- lm(body_mass ~ flipper_len, data = pinguinos)
modelo
```

```
Call:
lm(formula = body_mass ~ flipper_len, data = pinguinos)

Coefficients:
(Intercept)  flipper_len
   -5872.09        50.15
```

- `lm()` = *linear model*, la misma función que usamos en el ANOVA
- Se lee: «masa corporal en función de la longitud de la aleta»

$$\widehat{\text{masa}} = -5872.1 + 50.15 \cdot \text{aleta}$$

Predecir con el modelo

¿Cuál es la masa esperada de un pingüino con una aleta de 200 mm?
Sustituimos en la ecuación de la recta:

$$\widehat{\text{masa}} = a + b \cdot \text{aleta} = -5872.1 + 50.15 \cdot 200 = 4157.9 \text{ g}$$

```
-5872.1 + 50.15 * 200
```

```
[1] 4157.9
```

O directamente con `predict()`:

```
predict(modelo, newdata = data.frame(flipper_len = 200))
```

```
       1
4158.561
```

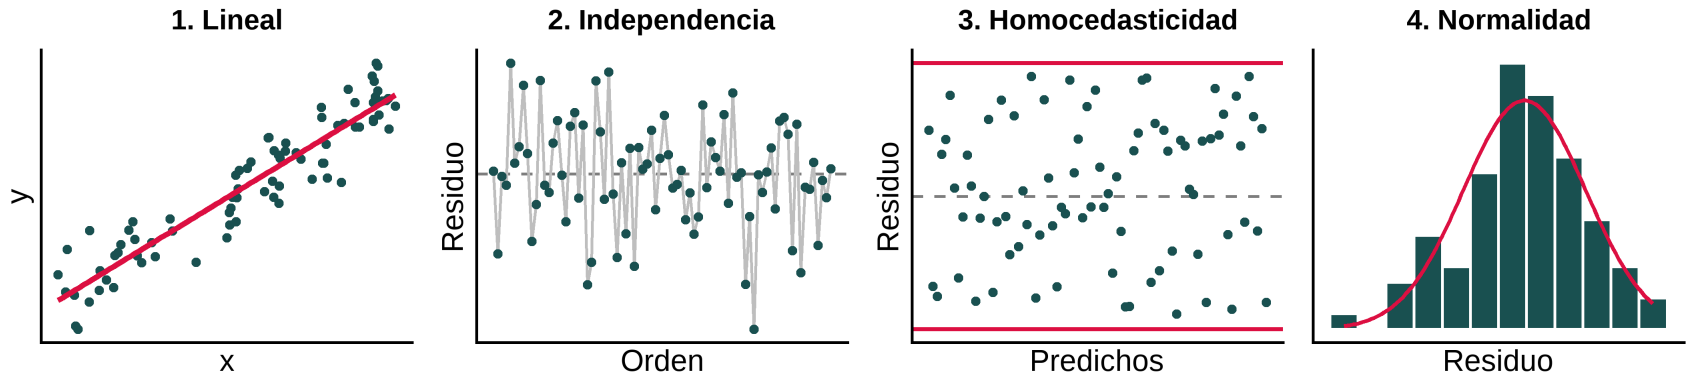
> La pequeña diferencia con el cálculo a mano se debe al **redondeo** de a y b.
>
> Con `interval = "prediction"`, `predict()` también da un intervalo de valores probables para un pingüino nuevo.

Supuestos de la regresión

Supuestos de la regresión lineal

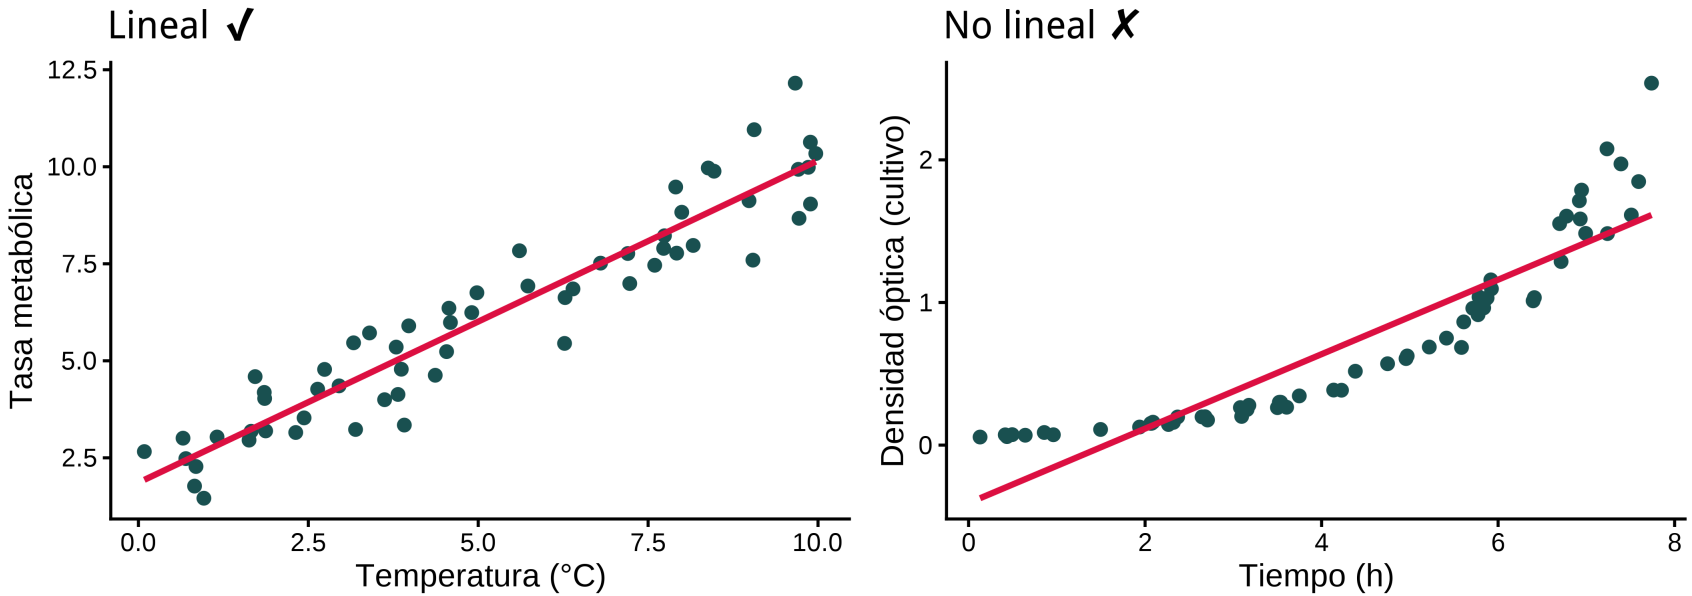
1. **Relación lineal** entre x e y
2. **Independencia** de los errores
3. **Homocedasticidad**: varianza constante de los errores
4. **Normalidad** de los errores

> Como en el ANOVA, los supuestos 2 a 4 se comprueban sobre los **residuos**



1. Relación lineal

La recta debe representar todos los puntos lo mejor posible. Si la relación no es lineal, una recta no puede hacerlo.



> El crecimiento bacteriano es exponencial: transformar con `log()` lo vuelve lineal

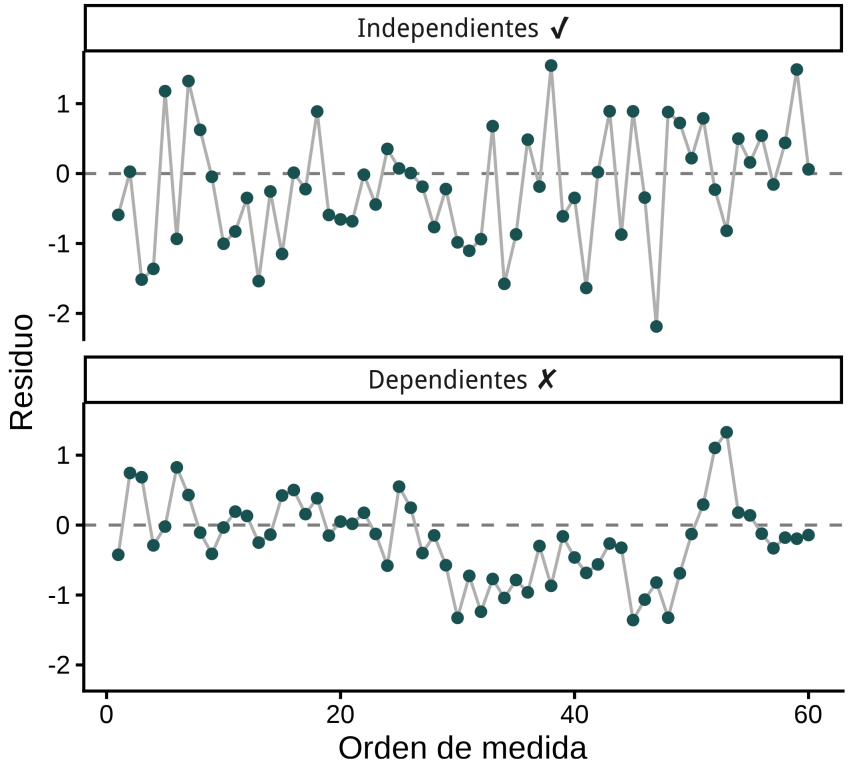
2. Independencia de los errores

El error de un punto no debe influir en el error de otro.

Se incumple, por ejemplo, con:

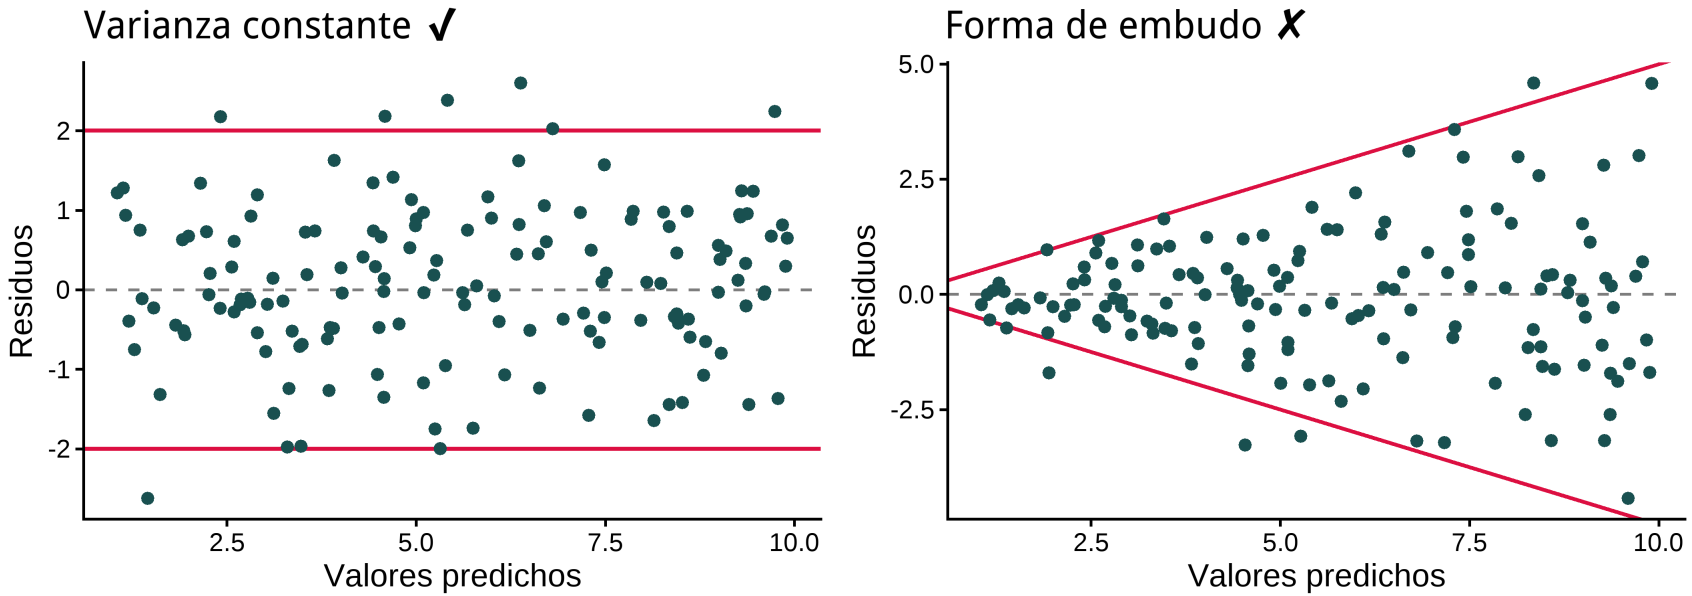
- Medidas repetidas del mismo individuo
- Series temporales (un día influye en el siguiente)
- Individuos emparentados o de la misma camada

> Se garantiza sobre todo con un buen diseño experimental (muestreo aleatorio)



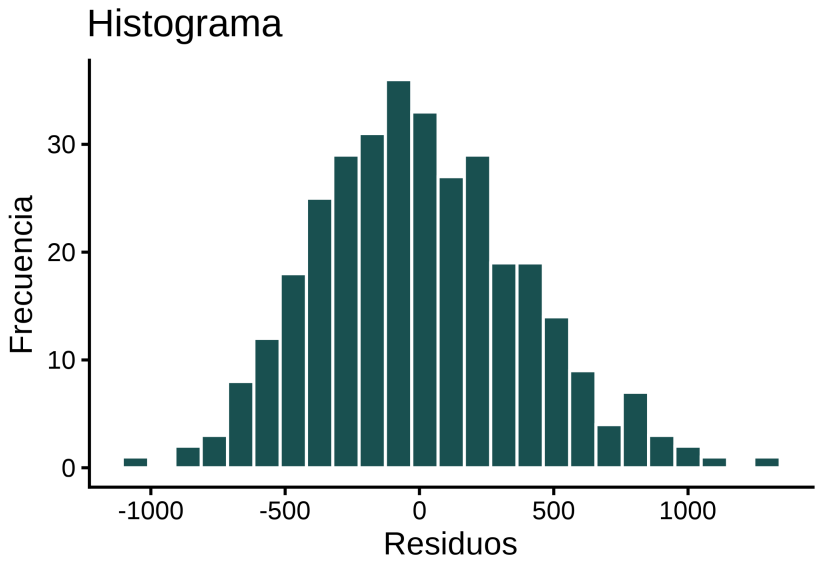
3. Homocedasticidad

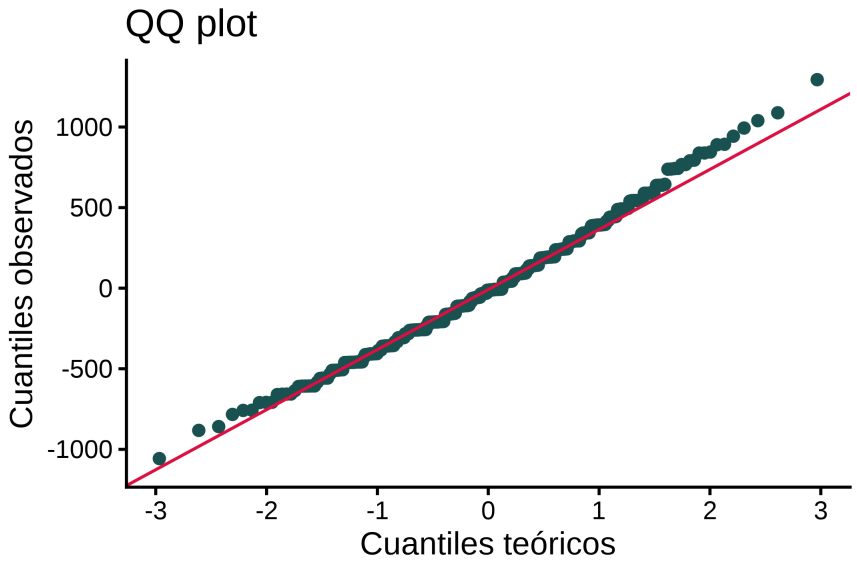
Si representamos los **residuos** frente a los **valores predichos**, su dispersión debe ser parecida en todo el rango.



> Ej.: en datos de expresión génica, la varianza suele **crecer con la media**

4. Normalidad de los errores





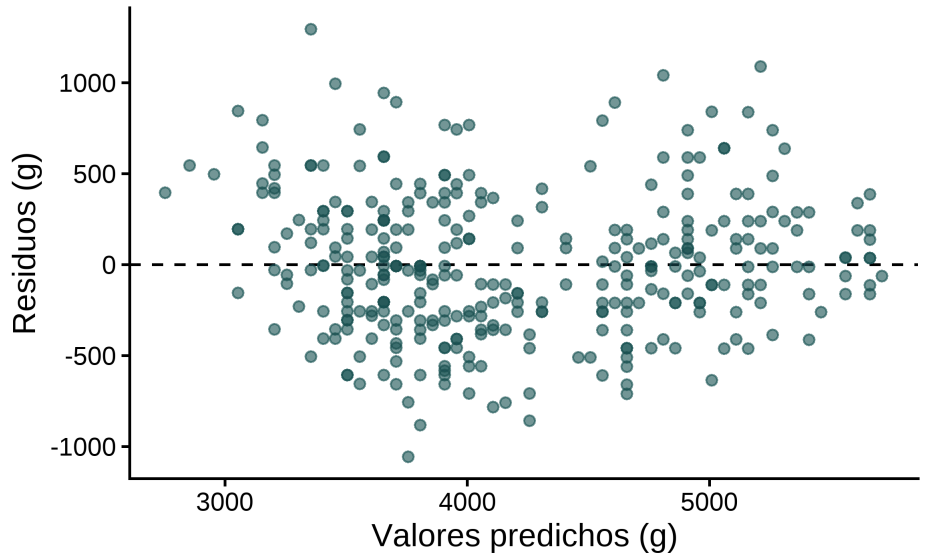
- Se puede comprobar **analíticamente** (Shapiro-Wilk) o **gráficamente** (QQ plot)
- ¡Cuidado con los tests! Con muestras **pequeñas** casi nunca rechazan la normalidad y con muestras **grandes** salen significativos enseguida → hoy se prefiere el **QQ plot**

Comprobar los supuestos con nuestros pingüinos

Representamos los **residuos** frente a los **valores predichos** del modelo `masa ~ aleta`:

```
diag <- data.frame(predichos = fitted(modelo),
                   residuos = residuals(modelo))

ggplot(diag, aes(x = predichos, y = residuos)) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_point(colour = "#1c5253", alpha = 0.6) +
  labs(x = "Valores predichos (g)", y = "Residuos (g)") +
  theme_classic(base_size = 16)
```



- Sin patrón curvo → **linealidad** ✓
- Dispersión parecida en todo el rango → **homocedasticidad** ✓
- Dos grupos de puntos: ¿falta alguna variable en el modelo? → **la especie** (lo veremos en la regresión múltiple)

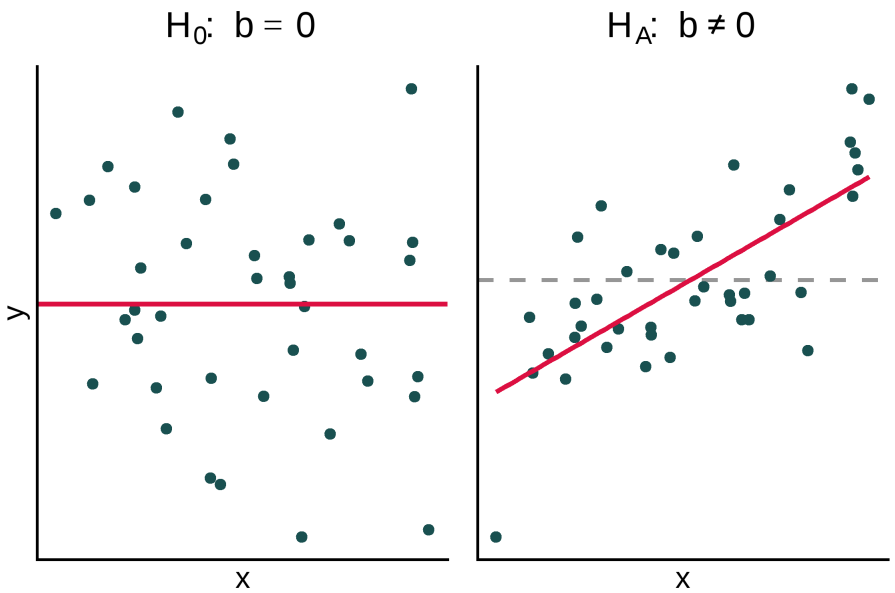
Contraste de hipótesis y R^2

¿Es significativa la relación?

El p-valor nos dice si la relación entre x e y es real o podría deberse al azar.

- H_0: no hay relación → la pendiente es $b = 0$
- H_A: hay relación → $b \neq 0$

- p-valor < 0.05: rechazamos H_0 → relación significativa
- p-valor ≥ 0.05: los datos podrían haber salido por azar; no hay evidencia de relación



`summary()` del modelo

```
modelo <- lm(body_mass ~ flipper_len, data = pinguinos)
summary(modelo)
```

```
Call:
lm(formula = body_mass ~ flipper_len, data = pinguinos)

Residuals:
     Min       1Q   Median       3Q      Max
-1057.33  -259.79   -12.24   242.97  1293.89

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -5872.09     310.29  -18.93   <2e-16 ***
flipper_len    50.15       1.54   32.56   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 393.3 on 331 degrees of freedom
Multiple R-squared:  0.7621,    Adjusted R-squared:  0.7614
F-statistic:  1060 on 1 and 331 DF,  p-value: < 2.2e-16
```

- `Estimate`: los coeficientes: a = `(Intercept)` y b = `flipper_len`
- `Pr(>|t|)` de `flipper_len`: p-valor del test $H_0 : b = 0 \rightarrow$ p < $2 \cdot 10^{-16}$, la relación es significativa
- `Multiple R-squared` = 0.762: la longitud de la aleta explica el 76% de la variabilidad de la masa corporal
- `Residual standard error` = 393 g: en promedio, las predicciones se desvían unos 393 g de la masa real

> En la regresión simple, $R^2 = r^2$: $0.873^2 = 0.762$

Regresión lineal múltiple

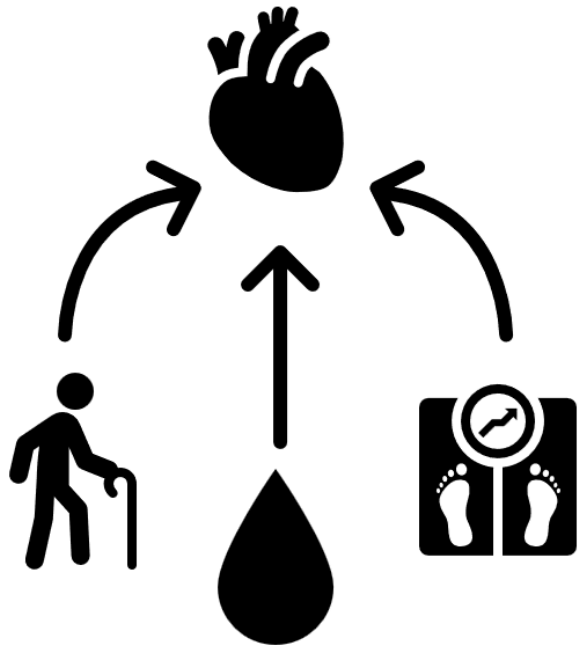
Regresión lineal múltiple

> Modela la relación entre **una** variable dependiente y **dos o más** variables independientes.

Ejemplo: ¿influyen la **edad**, el **peso** y el **colesterol** en la **presión arterial** sistólica?

- Variable dependiente: presión arterial (mmHg)
- Variables independientes: edad (años), peso (kg) y colesterol (mg/dL)

Presión	Edad	Peso	Colesterol
134	71	83	199
130	72	67	146
135	43	100	241
143	67	87	190
147	59	79	184



La ecuación de la regresión múltiple

Simple: una variable independiente

$$\hat{y} = a + b\,x$$

Múltiple: k variables independientes

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \cdots + b_k x_k$$

- a: valor de $\hat{y}$ cuando **todas** las x valen 0
- b_i: cambio en $\hat{y}$ cuando x_i aumenta 1 unidad **y las demás variables se mantienen constantes**
- $\hat{y}$ es el valor **predicho** por el modelo; y, el valor **observado**. Su diferencia es el **residuo**

Supuestos de la regresión múltiple

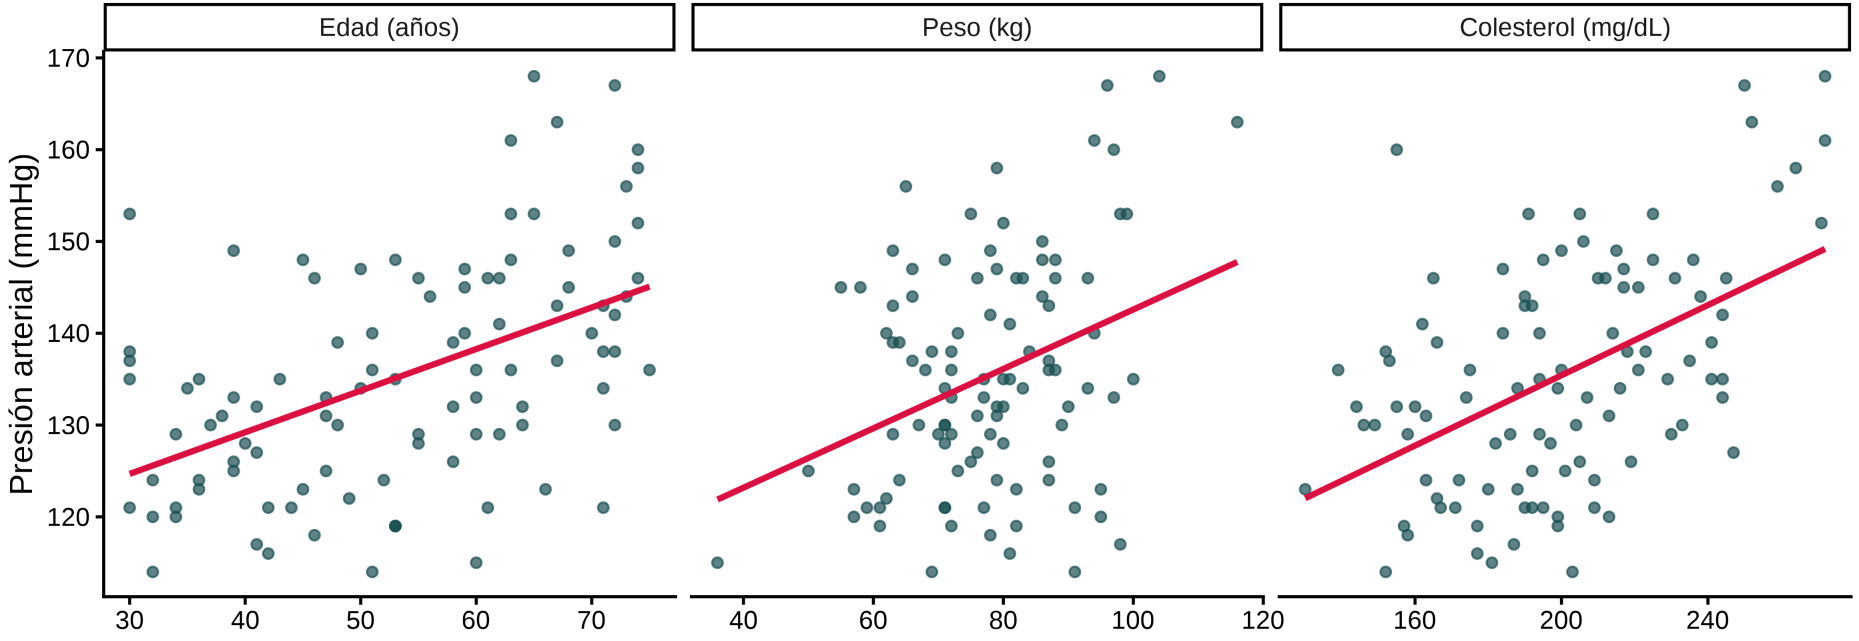
Los cuatro de la regresión simple...

1. Relación lineal → un gráfico de dispersión para cada variable
2. Independencia de los errores
3. Homocedasticidad → residuos frente a valores predichos
4. Normalidad de los errores → QQ plot

... y uno nuevo:

5. No multicolinealidad: las variables independientes no deben estar muy correlacionadas entre sí

Primero, visualizamos cada variable por separado



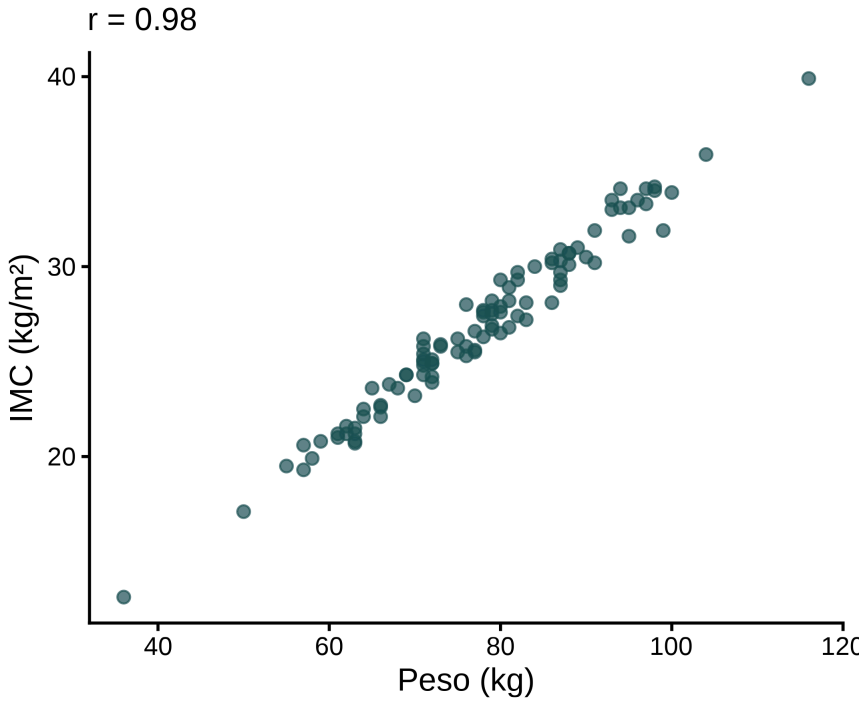
> Así comprobamos el supuesto de **linealidad** y nos hacemos una primera idea de cada relación

Multicolinealidad

Dos o más variables independientes están muy correlacionadas → aportan la misma información.

- El modelo no puede separar el efecto de cada una: no sabe cuánto deberían valer b_1 y b_2
- Los coeficientes se vuelven inestables y sus p-valores, poco fiables
- Importa cuando queremos medir la influencia de cada variable, no tanto para predecir

Ej.: peso e IMC (índice de masa corporal)



Detectar la multicolinealidad: tolerancia y VIF

Tomamos cada variable independiente, p. ej. x_1, como si fuera la dependiente y la predecimos con las demás:

$$\hat{x}_1 = a + b_2 x_2 + \cdots + b_k x_k \quad \rightarrow \quad R_1^2$$

- Si R_1^2 es alto, x_1 se puede predecir con las otras: su información ya está en el modelo

Tolerancia

$$T_i = 1 - R_i^2$$

Factor de inflación de la varianza

$$VIF_i = \frac{1}{1 - R_i^2}$$

> **Cuidado** si $T < 0.1$ o $VIF > 10$

VIF en R

```
library(car)

vif(lm(presion ~ edad + peso + colesterol, data = datos_pa))
```

```
     edad       peso colesterol
 1.021190   1.024956   1.005352
```

Si añadimos el IMC, que está muy correlacionado con el peso:

```
vif(lm(presion ~ edad + peso + colesterol + imc, data = datos_pa))
```

```
     edad       peso colesterol        imc
 1.021191  34.439014   1.038157  34.581762
```

Soluciones:

1. Eliminar una de las variables correlacionadas (la menos significativa o la menos interesante)
2. Combinar las variables correlacionadas en una sola (p. ej. su media)

Regresión múltiple en R

Las variables independientes se suman en la fórmula:

```
modelo_pa <- lm(presion ~ edad + peso + colesterol, data = datos_pa)
summary(modelo_pa)
```

```
Call:
lm(formula = presion ~ edad + peso + colesterol, data = datos_pa)

Residuals:
     Min       1Q   Median       3Q      Max
-23.9218  -5.9163   0.5223   5.0878  23.6728

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 56.46141    7.66028   7.371 5.95e-11 ***
edad         0.43316    0.06353   6.819 8.15e-10 ***
peso         0.22938    0.06626   3.462 0.000803 ***
colesterol   0.18963    0.02620   7.237 1.13e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.498 on 96 degrees of freedom
Multiple R-squared:  0.5558,    Adjusted R-squared:  0.542
F-statistic: 40.05 on 3 and 96 DF,  p-value: < 2.2e-16
```

Interpretar los coeficientes

Variable	Coeficiente b	Coeficiente estandarizado β	p-valor
Ordenada (a)	56.46		<0.001
Edad	0.43	0.47	<0.001
Peso	0.23	0.24	<0.001
Colesterol	0.19	0.49	<0.001

$$\widehat{\text{presión}} = 56.5 + 0.43 \cdot \text{edad} + 0.23 \cdot \text{peso} + 0.19 \cdot \text{colesterol}$$

- Por cada año más de edad, la presión aumenta 0.43 mmHg (con peso y colesterol constantes)
- Los tres p-valores son < 0.05: los tres coeficientes son significativamente distintos de 0

Predecir con el modelo múltiple

¿Qué presión arterial esperamos en una persona de 55 años, 95 kg y colesterol de 180 mg/dL?

```
predict(modelo_pa, newdata = data.frame(edad = 55, peso = 95, colesterol = 180))
```

```
       1
136.2105
```

Es lo mismo que sustituir en la ecuación:

$$56.5 + 0.43 \cdot 55 + 0.23 \cdot 95 + 0.19 \cdot 180 \approx 136 \text{ mmHg}$$

Coeficientes estandarizados

¿Qué variable influye **más** en la presión arterial?

- Los coeficientes b dependen de las **unidades**: 1 año, 1 kg y 1 mg/dL no son comparables
- Los coeficientes **estandarizados** (β) se calculan tras poner todas las variables en la misma escala (media 0, desviación típica 1)

```
m_std <- lm(scale(presion) ~ scale(edad) + scale(peso) + scale(colesterol),
            data = datos_pa)
round(coef(m_std), 2)
```

```
     (Intercept)       scale(edad)       scale(peso) scale(colesterol)
            0.00              0.47              0.24              0.49
```

> El **colesterol** tiene el coeficiente estandarizado más alto: es la variable con más influencia sobre la presión arterial

¿Cómo de bueno es el modelo?

```
summary(modelo_pa)
```

```
Call:
lm(formula = presion ~ edad + peso + colesterol, data = datos_pa)

Residuals:
     Min       1Q   Median       3Q      Max
-23.9218  -5.9163   0.5223   5.0878  23.6728

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 56.46141    7.66028   7.371 5.95e-11 ***
edad         0.43316    0.06353   6.819 8.15e-10 ***
peso         0.22938    0.06626   3.462 0.000803 ***
colesterol   0.18963    0.02620   7.237 1.13e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.498 on 96 degrees of freedom
Multiple R-squared:  0.5558,    Adjusted R-squared:  0.542
F-statistic: 40.05 on 3 and 96 DF,  p-value: < 2.2e-16
```

- R **múltiple**: correlación entre los valores **predichos** $\hat{y}$ y los **observados** y. No aparece en la salida, pero es $\sqrt{R^2} \rightarrow 0.746$
- R^2 (`Multiple R-squared`, **coeficiente de determinación**): proporción de la varianza de y explicada por el modelo → el modelo explica el **56%** de la variación de la presión arterial. $R^2 = 1$ sería una predicción perfecta (no pasa nunca)
- R^2 **ajustado** (`Adjusted R-squared`): corrige por el número de variables independientes. Con muchas variables, R^2 **sobreestima** lo bien que el modelo explica los datos → 0.542
- **Error estándar de la estimación** (`Residual standard error`): distancia media entre los valores observados y la predicción → al predecir la presión de una persona, nos equivocaremos en promedio unos **8.5 mmHg**

Variables *dummy*

Variables categóricas con dos niveles

¿Cómo usamos una variable nominal como variable independiente? Con dos categorías, la codificamos como 0 y 1:

- Sexo: hembra = 0 (categoría de referencia), macho = 1

$$\widehat{\text{masa}} = a + b \cdot \text{sexo}$$

- Hembra: $\widehat{\text{masa}} = a + b \cdot 0 = a$
- Macho: $\widehat{\text{masa}} = a + b \cdot 1 = a + b$

> b es la diferencia de masa entre machos y hembras

- `(Intercept)` = a = 3862.3 g: masa media de las hembras (referencia)
- `sexmale` = b = 683.4 g: los machos pesan de media 683 g más que las hembras (4545.7 − 3862.3)

```
coef(lm(body_mass ~ sex, data = pinguinos))
```

```
(Intercept)     sexmale
  3862.2727    683.4118
```

```
tapply(pinguinos$body_mass,
       pinguinos$sex, mean)
```

```
  female     male
3862.273 4545.685
```

¿Y con más de dos categorías?

La **especie** tiene tres niveles: Adelia (*Adelie*), barbijo (*Chinstrap*) y papúa (*Gentoo*). Creamos **variables *dummy***: variables artificiales que indican **presencia (1)** o **ausencia (0)** de cada categoría.

Una columna original

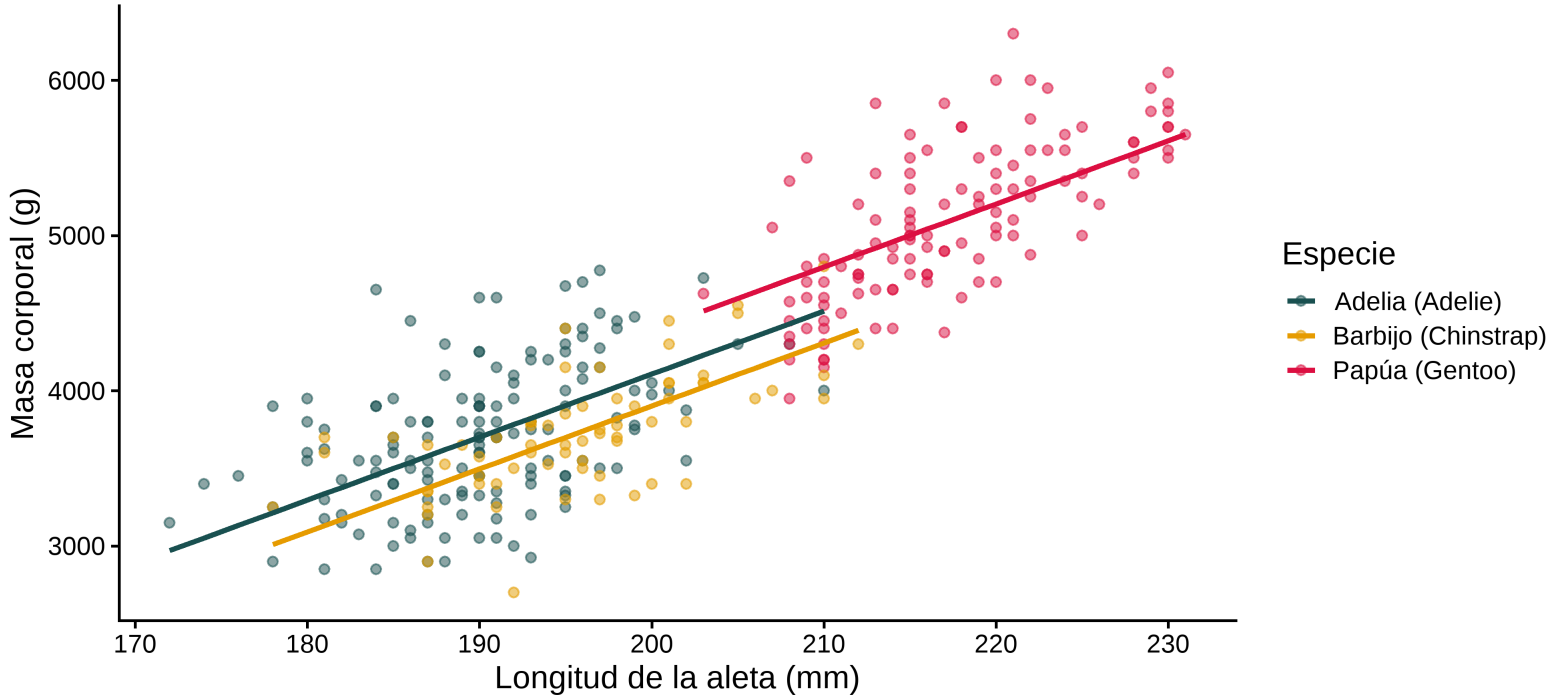
Especie
Adelia
Barbijo
Papúa
Adelia

Variables *dummy*

¿Barbijo?	¿Papúa?
0	0
1	0
0	1
0	0

> Siempre se crean **número de categorías − 1** variables *dummy*. Si no es barbijo ni papúa, ya sabemos que es Adelia (la **referencia**).

Variables *dummy*: tres rectas paralelas

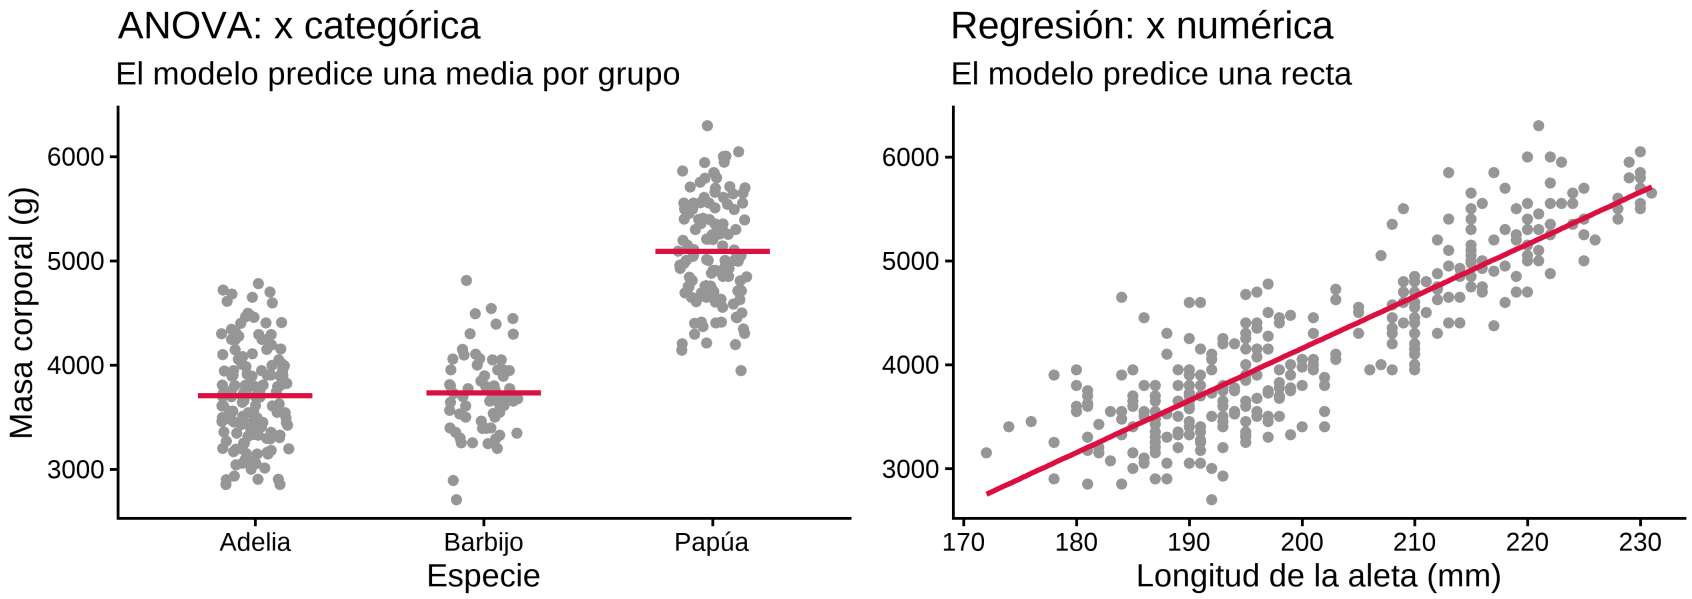


> Misma pendiente para las tres especies; cada recta se desplaza respecto a la de **Adelia** (la referencia)

ANOVA y regresión

ANOVA y regresión: el mismo modelo

Observación = predicción + residuo. Lo que cambia es la predicción: una **media por grupo** (ANOVA) o una **recta** (regresión).



El ANOVA como modelo lineal

Un ANOVA de una vía es una regresión cuya variable independiente es categórica, convertida en variables *dummy*:

$$\widehat{\text{masa}} = a + b_1 \cdot \text{Barbijo} + b_2 \cdot \text{Papúa}$$

Especie	¿Barbijo?	¿Papúa?	Predicción $\hat{y}$
Adelia	0	0	a
Barbijo	1	0	$a + b_1$
Papúa	0	1	$a + b_2$

- a es la media del grupo de referencia (Adelia)
- b_1 y b_2 son las diferencias entre la media de cada especie y la de Adelia

> El modelo predice para cada pingüino la media de su grupo. Lo que queda, $y - \hat{y}$, es el residuo, igual que en el ANOVA.

Interpretar los coeficientes de `lm()`

```
m1 <- lm(body_mass ~ species,
         data = pinguinos)
round(coef(m1), 1)
```

```
    (Intercept) speciesChinstrap    speciesGentoo
         3706.2              26.9           1386.3
```

```
# Medias de cada grupo
round(tapply(pinguinos$body_mass,
             pinguinos$species, mean), 1)
```

```
  Adelie Chinstrap    Gentoo
  3706.2    3733.1    5092.4
```

- `(Intercept)` = 3706.2 = media de Adelia
- Media de barbijo = 3706.2 + 26.9 = **3733.1**
- Media de papúa = 3706.2 + 1386.3 = **5092.4**

El test F compara dos modelos

- Modelo nulo (H_0): una sola media para todos $\rightarrow \hat{y} = a$
- Modelo completo (H_A): una media por especie $\rightarrow \hat{y} = a + b_1 \cdot \text{Barbijo} + b_2 \cdot \text{Papúa}$

¿Explica el modelo completo bastante más variabilidad que el nulo?

```
m0 <- lm(body_mass ~ 1, data = pinguinos)
anova(m0, m1)
```

```
Analysis of Variance Table

Model 1: body_mass ~ 1
Model 2: body_mass ~ species
  Res.Df       RSS Df Sum of Sq      F    Pr(>F)
1    332 215259666
2    330  70069447  2 145190219 341.89 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- RSS del modelo nulo = SS_{total}; RSS del modelo completo = SS_{dentro}. Su diferencia (`Sum of Sq`) es SS_{entre} → la misma F y el mismo p-valor que `aov()`
- $R^2 = \frac{SS_{entre}}{SS_{total}} = \frac{145190219}{215259666} = 0.674$

  La especie explica el 67% de la variabilidad de la masa (el mismo `Multiple R-squared` de `summary(m1)`)

`aov()` y `lm()`: el mismo resultado

El ANOVA del tema anterior

```
summary(aov(body_mass ~ species,
            data = pinguinos))
```

```
             Df    Sum Sq  Mean Sq F value Pr(>F)
species       2 145190219 72595110   341.9 <2e-16 ***
Residuals   330  70069447   212332
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El mismo modelo con `lm()`

```
anova(lm(body_mass ~ species,
         data = pinguinos))
```

```
Analysis of Variance Table

Response: body_mass
           Df    Sum Sq  Mean Sq F value    Pr(>F)
species     2 145190219 72595110  341.89 < 2.2e-16 ***
Residuals 330  70069447   212332
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Situación	Función
Solo factores y queremos comparar grupos (y después Tukey)	`aov()`: `TukeyHSD()` necesita un objeto `aov`
Hay alguna variable numérica, o queremos coeficientes y predicciones	`lm()`

Una sola función para todos los modelos

En R se usa siempre la misma fórmula, `lm(y ~ x)`. Lo que cambia es el tipo de variable `x`:

Variables independientes	Modelo	En R
Un factor	ANOVA de una vía	`lm(y ~ grupo)`
Dos factores	ANOVA de dos vías	`lm(y ~ A * B)`
Una variable numérica	Regresión lineal simple	`lm(y ~ x)`
Varias variables numéricas	Regresión lineal múltiple	`lm(y ~ x1 + x2 + x3)`
Numéricas y factores	Regresión con variables *dummy*	`lm(y ~ x + grupo)`

> Todos son **modelos lineales**: observación = predicción + residuo

Resumen

- La regresión modela cómo una variable dependiente y cambia en función de una o más variables independientes x, para medir influencias o predecir
- Simple: $\hat{y} = a + b\,x$, ajustada por mínimos cuadrados. En R: `lm(y ~ x)`
- Supuestos: linealidad, independencia, homocedasticidad y normalidad de los residuos (+ no multicolinealidad en la múltiple)
- p-valor de cada coeficiente: ¿es b distinto de 0? R^2: ¿cuánta variabilidad explica el modelo?
- Múltiple: $\hat{y} = a + b_1 x_1 + \cdots + b_k x_k$; los coeficientes estandarizados permiten comparar la influencia de cada variable
- Las variables categóricas entran como variables *dummy* (categorías − 1)
- El ANOVA es un caso particular de modelo lineal

Contacto

Marta Coronado Zamora	David Castellano
marta.coronado@uab.cat	david.castellano@uab.cat
@geneticament.bsky.social	@castellanoed.bsky.social
Universitat Autònoma de Barcelona	University of Arizona