# Fórmulas Bioestadística

## Estadística descriptiva

### Media aritmética

$$\bar{x} = \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

donde:

- $\bar{x} = \mu$ : media aritmética
- $n$ : número de muestras
- $i$ : índice de los valores de la variable ($i = 1, 2, \ldots, n$)
- $x_i$ : valor $i$-ésimo de la variable $x$

### Mediana

- Para un número **impar** de observaciones ($n$):

$$\text{mediana}(x) = x_{\left(\frac{n+1}{2}\right)}$$

- Para un número **par** de observaciones:

$$\text{mediana}(x) = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}$$

donde:

- $\text{mediana}(x)$: mediana de los valores disponibles de la variable $x$
- $n$: número de observaciones disponibles para $x$
- $x_{(i)}$: valor que ocupa la posición $i$ cuando los datos están ordenados de menor a mayor

### Moda

$$moda(x) = max_{k=1}(I_{i=1}(x_i = x_k))$$

donde:

- $\text{moda}(x)$: moda de los valores disponibles de la variable $x$
- $\max_{k=1}()$: argumento que maximiza sobre $k$ en $1$ a $p$
- $I_i()$: función indicadora que devuelve 1 si la condición interna es cierta para $i$ en $1$ a $n$

### Rango

Diferencia entre el valor máximo y el mínimo de una variable $x$:

$$rango = x_{\max} - x_{\min}$$

**Varianza**

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

donde:

- $s^2$: varianza
- $n$: número de observaciones de la muestra
- $i$: índice de los valores de la variable ($i = 1, 2, \ldots, n$)
- $x_i$: valor $i$-ésimo de la variable $x$
- $\bar{x}$: media aritmética

**Desviación estándar**

$$SD = s = \sqrt{s^2}$$

donde:

- $SD = s$: desviación estándar
- $s^2$: varianza

**Cuantiles**

| Nombre | Símbolo | Porcentaje de los datos | Interpretación |
|---|---|---|---|
| Primer cuartil | $Q_1$ | 25% | El 25% de los datos son menores o iguales que este valor |
| Segundo cuartil (mediana) | $Q_2$ | 50% | El 50% de los datos son menores o iguales que este valor |
| Tercer cuartil | $Q_3$ | 75% | El 75% de los datos son menores o iguales que este valor |

**Rango intercuartílico**

$$IQR = Q_3 - Q_1$$

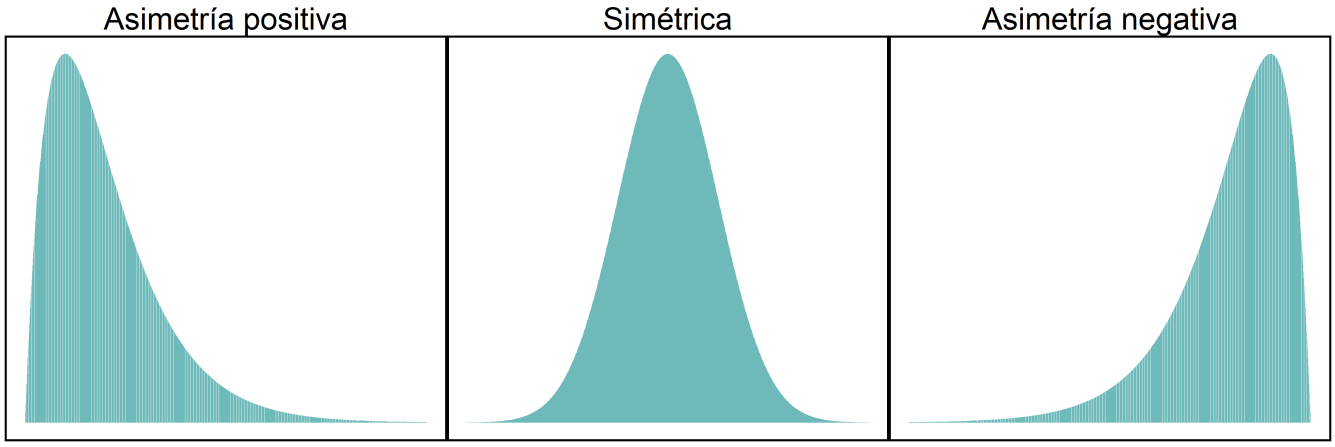
***Outliers***

$$\text{Cerca inferior} = Q_1 - 1.5 \times IQR$$

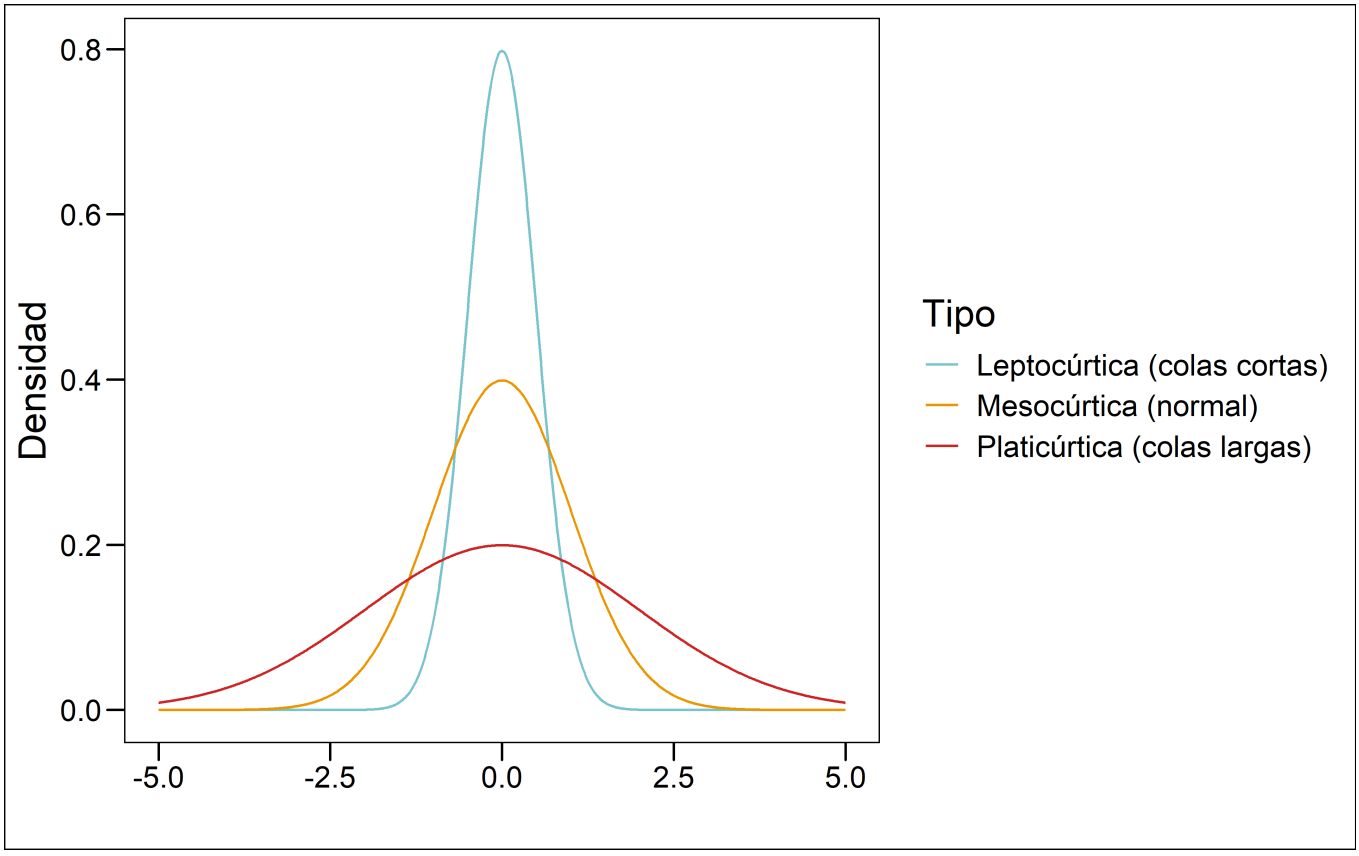
$$\text{Cerca superior} = Q_3 + 1.5 \times IQR$$

## Distribuciones

**Asimetría**




**Curtosis**




---

## Distribución binomial

**Fórmula de la distribución binomial**

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donde:

- $n$: número total de ensayos o repeticiones del experimento
- $k$: número de éxitos observados
- $p$: probabilidad de éxito en un solo ensayo

- $1 - p$: probabilidad de fracaso

#### Coeficiente binomial

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$$

donde:

- $n = 1, 2, \ldots$: número total de ensayos
- $k = 0, 1, 2, \ldots, n$: número de éxitos posibles
- Para cualquier número entero $m$, $m! = m \times (m-1) \times (m-2) \times \cdots \times 1$

#### Tabla resumen de la binomial

| Símbolo | Significado | Expresión |
|---|---|---|
| $P(X \leq k)$ | "como mucho k" | $P(X \leq k)$ |
| $P(X < k)$ | "menos de k" | $P(X \leq k-1)$ |
| $P(X \geq k)$ | "al menos k" | $1 - P(X \leq k-1)$ |
| $P(X > k)$ | "más de k" | $1 - P(X \leq k)$ |

Si la variable aleatoria sigue una distribución $X \sim \text{Binomial}(n, p)$, entonces:

- **Media**

$$\mu = n \times p$$

- **Varianza**

$$\sigma^2 = n \times p \times (1-p)$$

---

## Distribución normal

Si la variable aleatoria sigue una distribución $X \sim N(\mu, \sigma^2)$, entonces:

- $\mu$ representa la **media**
- $\sigma$ representa la **desviación estándar**

#### Estandarización

Si una variable aleatoria $X$ sigue una distribución normal con media $\mu$ y varianza $\sigma^2$, $X \sim N(\mu,\ \sigma^2)$, entonces la variable estandarizada:

$$Z = \frac{X - \mu}{\sigma}$$

sigue una distribución normal estándar: $Z \sim N(0, 1)$.

Para pasar de un valor $Z$ a la escala original:

$$X = \sigma Z + \mu$$

**Probabilidades complementarias y simetría**

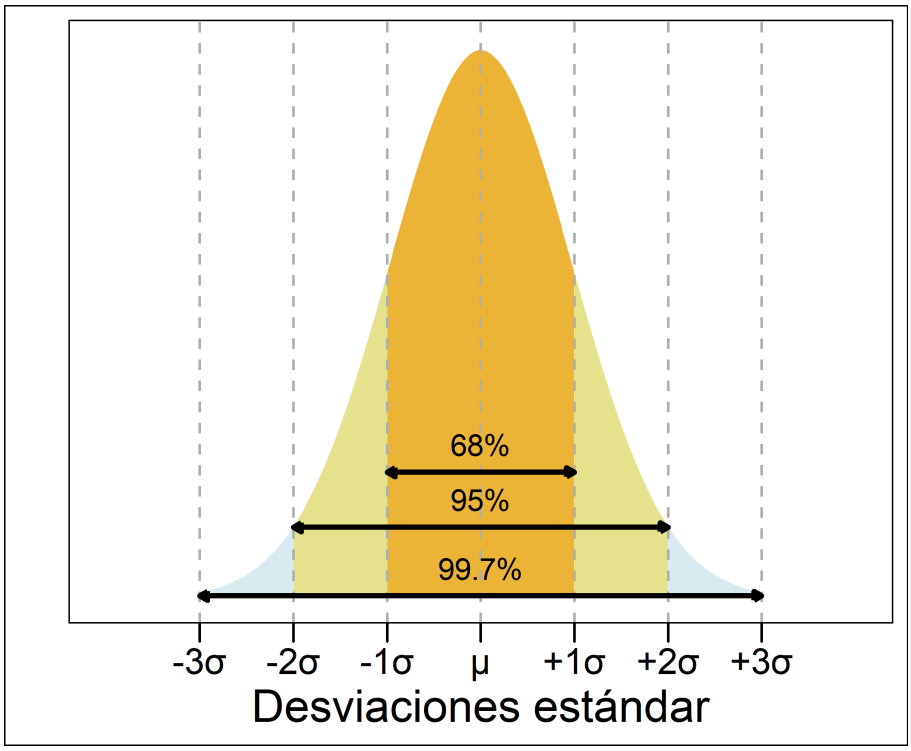
$$P(Z \leq z) = 1 - P(Z \geq z) \qquad P(Z \leq -z) = P(Z \geq z)$$

$$P(a \leq Z \leq b) = P(Z \leq b) - P(Z \leq a) = P(Z \geq a) - P(Z \geq b)$$

**Tabla resumen de la normal**

| Símbolo | Significado | Expresión |
|---|---|---|
| $P(X \leq x)$ | "como mucho x" | $P(X \leq x)$ |
| $P(X < x)$ | "menos de x" | $P(X \leq x)$ (igual, continua) |
| $P(X \geq x)$ | "al menos x" | $1 - P(X \leq x)$ |
| $P(X > x)$ | "más de x" | $1 - P(X \leq x)$ |
| $P(a \leq X \leq b)$ | "entre a y b" | $P(X \leq b) - P(X \leq a)$ |
| $P(a < X < b)$ | "entre a y b" | $P(X \leq b) - P(X \leq a)$ (igual, continua) |

**Regla empírica ("68-95-99.7")**:




- ~68% de los valores dentro de 1 desviación estándar de la media
- ~95% dentro de 2 desviaciones estándar
- ~99.7% dentro de 3 desviaciones estándar

---

## Distribución de Poisson

**Fórmula de la distribución de Poisson**

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}$$

donde:

- $X$: número de eventos en un intervalo dado
- $\lambda$: tasa esperada de eventos en ese intervalo ($n \times p$)
- $k$: número de eventos observados

Si la variable aleatoria sigue una distribución de Poisson $X \sim \text{Poisson}(\lambda)$, entonces:

- $\lambda$ representa tanto la media como el parámetro de la distribución: $\mu = \lambda$
- La desviación estándar es: $\sigma = \sqrt{\lambda}$

La probabilidad de exactamente $k$ eventos en $t$ unidades de tiempo es:

$$P(X = k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!}$$

En $t$ unidades de tiempo, la media es $\mu = \lambda t$ y desviación estándar $\sigma = \sqrt{\lambda t}$.

Si $\lambda$ es una tasa por individuo, el número esperado de eventos en una población de $N$ individuos durante $t$ unidades de tiempo es:

$$\mu = \lambda t N$$

**Tabla resumen de la distribución de Poisson**

| Símbolo | Significado | Expresión |
|---|---|---|
| $P(X \leq k)$ | "como mucho k" | $P(X \leq k)$ |
| $P(X < k)$ | "menos de k" | $P(X \leq k-1)$ |
| $P(X \geq k)$ | "al menos k" | $1 - P(X \leq k-1)$ |
| $P(X > k)$ | "más de k" | $1 - P(X \leq k)$ |

## Tabla resumen de las distribuciones

| | Binomial | Normal | Poisson |
|---|---|---|---|
| Parámetros | $n, p$ | $\mu, \sigma$ | $\lambda$ |
| Valores posibles | $0, 1, \ldots, n$ | $(-\infty, \infty)$ | $0, 1, \ldots, \infty$ |
| Media | $np$ | $\mu$ | $\lambda$ |
| Desviación estándar | $\sqrt{np(1-p)}$ | $\sigma$ | $\sqrt{\lambda}$ ($\sqrt{\lambda t}$) |

## Intervalos de confianza

### Distribución muestral de la media

Si $X \sim N(\mu, \sigma^2)$, la media muestral sigue $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, con:

$$\mu_{\bar{X}} = \mu \qquad\qquad \sigma_{\bar{X}} = SE = \frac{\sigma}{\sqrt{n}}$$

**Error estándar (SE)**: si solo tenemos la desviación estándar muestral,

$$SE \approx \frac{s}{\sqrt{n}}$$

### Estadístico z para una media muestral

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$$

donde:

- $\bar{x}$: media muestral
- $\mu$: media poblacional (bajo $H_0$, $\mu_0$)
- $\sigma$: desviación estándar poblacional
- $n$: tamaño de la muestra

### Intervalo de confianza (IC) bilateral

$$IC = (\bar{x} - m, \bar{x} + m) = \bar{x} \pm m$$

donde $m$ es el **margen de error**:

$$m = z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}} \qquad \left(\text{o } m = z_{\alpha/2} \times \frac{s}{\sqrt{n}}\right)$$

Por lo tanto, los límites del IC son:

$$x_1 = \bar{x} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \quad x_2 = \bar{x} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$

### Intervalos de confianza unilaterales (*one-sided*)

- Proporcionan **un límite inferior o un límite superior**, pero **no ambos**. Todo el $\alpha$ va en una sola cola, por eso se usa $z_\alpha$ (y no $z_{\alpha/2}$):

$$(-\infty,\ \bar{x} + z_\alpha \times SE) \quad \text{o} \quad (\bar{x} - z_\alpha \times SE,\ \infty)$$

**Valores críticos de z**

| Nivel de confianza | $\alpha$ | Bilateral: $z_{\alpha/2}$ | Unilateral: $z_{\alpha}$ |
|---|---|---|---|
| 90% | 0.10 | 1.645 | 1.28 |
| 95% | 0.05 | 1.96 | 1.645 |
| 99% | 0.01 | 2.576 | 2.33 |

**Tamaño de muestra para un error máximo $E$**

$$n \geq \left( \frac{z_{\alpha/2} \times \sigma}{E} \right)^2$$

---

## Contraste de hipótesis

**Tipos de error**

| Decisión | $H_0$ cierta | $H_A$ cierta |
|---|---|---|
| **No rechazamos $H_0$** | Correcto ($1-\alpha$) | Error tipo II ($\beta$), falso negativo |
| **Rechazamos $H_0$** | Error tipo I ($\alpha$), falso positivo | Correcto ($1-\beta$) = **potencia** |

**Regla de decisión** (con el valor crítico del estadístico)

- Si $|\text{estadístico}| \geq$ valor crítico (o p-valor $\leq \alpha$) → **rechazamos $H_0$**
- Si $|\text{estadístico}| <$ valor crítico (o p-valor $> \alpha$) → **no rechazamos $H_0$**

**p-valor de un test de permutación**

$$\text{p-valor} = \frac{\#\{|\text{dif}_{perm}| \geq |\text{dif}_{obs}|\}}{n_{perm}}$$

donde:

- $\text{dif}_{obs}$: diferencia observada entre los grupos
- $\text{dif}_{perm}$: diferencias obtenidas al permutar (barajar) las etiquetas de los grupos
- $n_{perm}$: número de permutaciones

---

## T-test

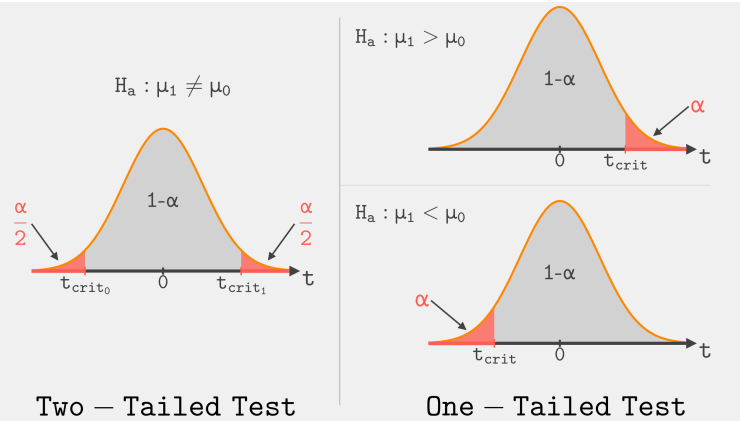
**Tablas resumen para t-test**

| Tipo de t-test | Estadístico t | Grados de libertad (df) | Intervalo de confianza (IC) |
|---|---|---|---|
| **1 muestra** | $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ | $n - 1$ | $\bar{x} \pm t_{\alpha/2,\, df} \frac{s}{\sqrt{n}}$ |
| **Pareado** | $t = \frac{\bar{x}_{dif}}{s_{dif}/\sqrt{n}}$ | $n - 1$ | $\bar{x}_{dif} \pm t_{\alpha/2,\, df} \frac{s_{dif}}{\sqrt{n}}$ |
| **2 muestras independientes*** | $t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$ | Welch-Satterthwaite | $(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2,\, df} \sqrt{s_1^2/n_1 + s_2^2/n_2}$ |

*Fórmula de Welch (por defecto en R). Si asumimos varianzas iguales (t-test de Student), $df = n_1 + n_2 - 2$ y se usa $s_p^2$ (ver abajo).

| Tipo de t-test | Hipótesis nula ($H_0$) | Hipótesis alternativa ($H_A$) |
|---|---|---|
| **1 muestra** | $\mu = \mu_0$ | $\mu \neq \mu_0$ |
| **Pareado** | $\mu_{dif} = 0$ | $\mu_{dif} \neq 0$ |
| **2 muestras independientes** | $\mu_1 = \mu_2$ | $\mu_1 \neq \mu_2$ |

| Tipo de test | Hipótesis | IC / Zona crítica | Interpretación |
|---|---|---|---|
| **Bilateral (dos colas)** | $H_0 : \mu = \mu_0$<br>$H_A : \mu \neq \mu_0$ | $IC = \bar{x} \pm \lvert t_{crit} \rvert \times SE$ | IC simétrico alrededor de $\bar{x}$. Si $\mu_0$ **no está dentro**, se rechaza $H_0$. |
| **Unilateral (cola derecha)** | $H_0 : \mu = \mu_0$<br>$H_A : \mu > \mu_0$ | $IC = (\bar{x} - \lvert t_{crit} \rvert \times SE, +\infty)$ | Si límite inferior > $\mu_0$, se rechaza $H_0$. |
| **Unilateral (cola izquierda)** | $H_0 : \mu = \mu_0$<br>$H_A : \mu < \mu_0$ | $IC = (-\infty, \bar{x} + \lvert t_{crit} \rvert \times SE)$ | Si límite superior < $\mu_0$, se rechaza $H_0$. |




**IC unilaterales con la distribución t** (una muestra, $df = n - 1$)

$$\text{Límite superior: } \mu \leq \bar{x} + t_{\alpha,\, n-1} \times \frac{s}{\sqrt{n}} \qquad \text{Límite inferior: } \mu \geq \bar{x} - t_{\alpha,\, n-1} \times \frac{s}{\sqrt{n}}$$

**Decisión** (bilateral): si $|t| > t_{crit}$ → rechazamos $H_0$; si $|t| \leq t_{crit}$ → no rechazamos $H_0$.

#### t-test de 2 muestras independientes con varianzas iguales (Student)

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \qquad s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2} \qquad df = n_1 + n_2 - 2$$

donde:

- $s_p^2$: varianza combinada (*pooled*)

#### t-test de Welch (varianzas desiguales): grados de libertad de Welch-Satterthwaite

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$$

---

## Tests no paramétricos

**Test de Mann-Whitney (Wilcoxon de suma de rangos)**: alternativa al t-test de 2 muestras independientes

1. Juntamos los valores de los dos grupos, los ordenamos y les asignamos un rango (1 al más pequeño; si hay empates, el rango medio).
2. Sumamos los rangos de cada grupo ($R_1$ y $R_2$).

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2} \qquad U_2 = R_2 - \frac{n_2(n_2 + 1)}{2} \qquad U = \min(U_1, U_2)$$

Comprobaciones: $U_1 + U_2 = n_1\, n_2$ y $R_1 + R_2 = \frac{N(N+1)}{2}$, con $N = n_1 + n_2$.

#### Aproximación normal de $U$

$$\mu_U = \frac{n_1\, n_2}{2} \qquad \sigma_U = \sqrt{\frac{n_1\, n_2\, (n_1 + n_2 + 1)}{12}} \qquad z = \frac{U - \mu_U}{\sigma_U}$$

Si $|z| \geq z_{\alpha/2}$ (1.96 para $\alpha = 0.05$ bilateral) → rechazamos $H_0$.

**Test de Wilcoxon de rangos con signo**: alternativa al t-test pareado

1. Calculamos la diferencia de cada par, $d_i = x_{2i} - x_{1i}$, y descartamos las diferencias iguales a 0.
2. Ordenamos las diferencias en **valor absoluto** $|d_i|$ y les asignamos un rango.
3. Sumamos los rangos de las diferencias positivas ($T^+$) y de las negativas ($T^-$).

$$T^+ = \sum_{d_i > 0} \text{rango}(|d_i|) \qquad T^- = \sum_{d_i < 0} \text{rango}(|d_i|) \qquad W = \min(T^+, T^-)$$

Comprobación: $T^+ + T^- = \frac{n(n+1)}{2}$ ($n$: número de pares con diferencia distinta de 0).

**Aproximación normal de $W$**

$$\mu_W = \frac{n(n+1)}{4} \qquad \sigma_W = \sqrt{\frac{n(n+1)(2n+1)}{24}} \qquad z = \frac{W - \mu_W}{\sigma_W}$$

| Diseño | Test paramétrico | Alternativa no paramétrica | *Post hoc* |
|---|---|---|---|
| 2 muestras independientes | t-test (Welch) | Mann-Whitney | — |
| 2 muestras pareadas | t-test pareado | Wilcoxon de rangos con signo | — |
| $\geq$ 3 grupos (1 factor) | ANOVA de una vía | Kruskal-Wallis | Dunn (con corrección de p-valores) |

## Tamaño del efecto y potencia

**d de Cohen**

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p} \qquad s_p = \sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}}$$

donde:

- $s_p$: desviación estándar combinada (*pooled*)

| $\lvert d \rvert$ | **Efecto (guía orientativa de Cohen)** |
|---|---|
| $< 0.2$ | trivial |
| $0.2 - 0.5$ | pequeño |
| $0.5 - 0.8$ | medio |
| $\geq 0.8$ | grande |

**Tamaño de muestra necesario (2 grupos)**

$$n = \frac{2\,(Z_{\alpha/2} + Z_{\beta})^2}{d^2} \quad \text{por grupo}$$

donde:

- $Z_{\alpha/2}$: 1.96 para $\alpha = 0.05$ (bilateral); 2.58 para $\alpha = 0.01$
- $Z_{\beta}$: 0.84 para potencia del 80%; 1.28 para potencia del 90%

**Potencia para un $n$ dado**

$$Z_{\beta} = d\sqrt{\frac{n}{2}} - Z_{\alpha/2} \qquad \text{Potencia} = 1 - \beta = P(Z \leq Z_{\beta})$$

## ANOVA

ANOVA de una vía

| Fuente de variación | Suma de cuadrados (SS) | Grados de libertad (gl) | Media cuadrática (MS) | Estadístico F |
|---|---|---|---|---|
| **Factor** (variabilidad entre grupos) | $SS_{entre} = \sum_{i=1}^{g} n_i (M_i - G)^2$ | $gl_{entre} = g - 1$ | $MS_{entre} = \frac{SS_{entre}}{gl_{entre}}$ | $F = \frac{MS_{entre}}{MS_{dentro}}$ |
| **Residuos** (variabilidad dentro de los grupos) | $SS_{dentro} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - M_i)^2$ | $gl_{dentro} = N - g$ | $MS_{dentro} = \frac{SS_{dentro}}{gl_{dentro}}$ | |
| **Total** | $SS_{total} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - G)^2$ | $gl_{total} = N - 1$ | | |

**Donde:**

- $G$ = media global (media conjunta de todos los grupos)
- $M_i$ = media del grupo *i*
- $n_i$ = tamaño del grupo *i*
- $g$ = número de grupos
- $N$ = número total de observaciones