Fórmulas Bioestadística

Estadística descriptiva

Media aritmética

$$\bar{x} = \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

donde:

- $\bar{x} = \mu$: media aritmética
- n : número de muestras
- i : índice de los valores de la variable ($i = 1, 2, \ldots, n$)
- x_i : valor i-ésimo de la variable x

Mediana

- Para un número **impar** de observaciones (n):

$$\text{mediana}(x) = x_{\left(\frac{n+1}{2}\right)}$$

- Para un número **par** de observaciones:

$$\text{mediana}(x) = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}$$

donde:

- $\text{mediana}(x)$: mediana de los valores disponibles de la variable x
- n: número de observaciones disponibles para x
- $x_{(i)}$: valor que ocupa la posición i cuando los datos están ordenados de menor a mayor

Moda

$$moda(x) = max_{k=1}(I_{i=1}(x_i = x_k))$$

donde:

- $\text{moda}(x)$: moda de los valores disponibles de la variable x
- $\max_{k=1}()$: argumento que maximiza sobre k en 1 a p
- $I_i()$: función indicadora que devuelve 1 si la condición interna es cierta para i en 1 a n

Rango

Diferencia entre el valor máximo y el mínimo de una variable x:

$$rango = x_{\max} - x_{\min}$$

Varianza

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

donde:

- s^2: varianza
- n: número de observaciones de la muestra
- i: índice de los valores de la variable ($i = 1, 2, \ldots, n$)
- x_i: valor i-ésimo de la variable x
- $\bar{x}$: media aritmética

Desviación estándar

$$SD = s = \sqrt{s^2}$$

donde:

- $SD = s$: desviación estándar
- s^2: varianza

Cuantiles

Nombre	Símbolo	Porcentaje de los datos	Interpretación
Primer cuartil	Q_1	25%	El 25% de los datos son menores o iguales que este valor
Segundo cuartil (mediana)	Q_2	50%	El 50% de los datos son menores o iguales que este valor
Tercer cuartil	Q_3	75%	El 75% de los datos son menores o iguales que este valor

Rango intercuartílico

$$IQR = Q_3 - Q_1$$

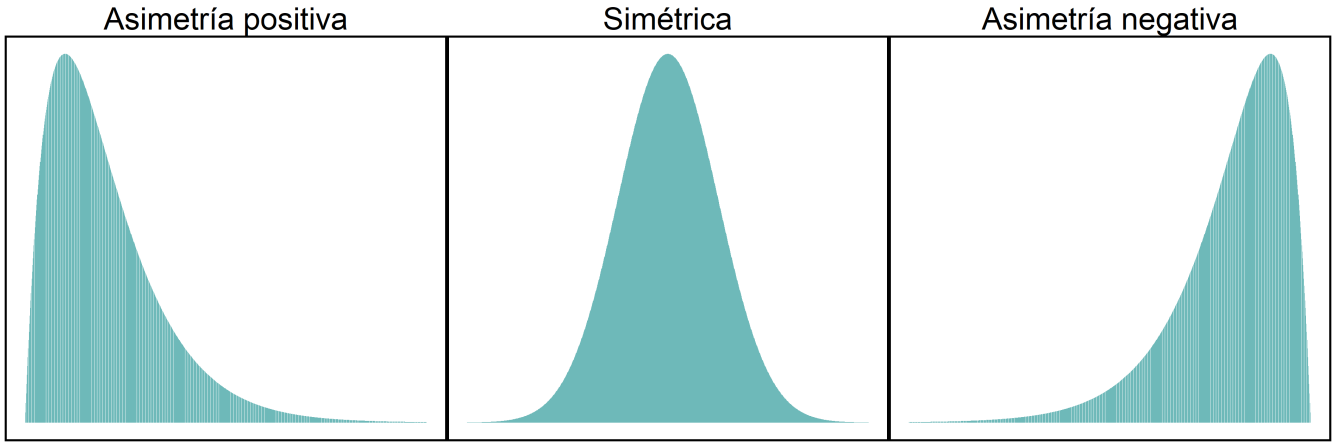
Outliers

$$\text{Cerca inferior} = Q_1 - 1.5 \times IQR$$

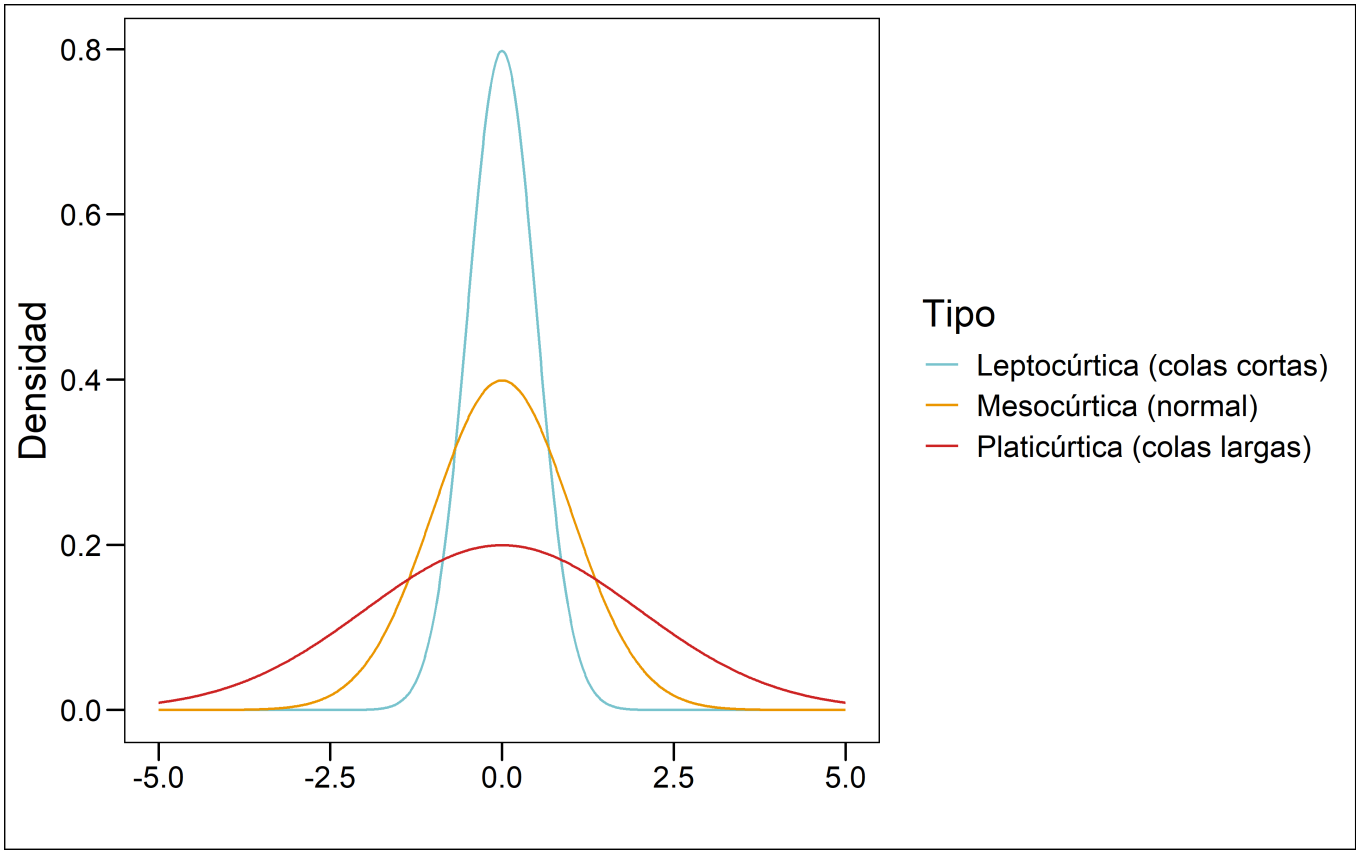
$$\text{Cerca superior} = Q_3 + 1.5 \times IQR$$

Distribuciones

Asimetría



Curtosis



Distribución binomial

Fórmula de la distribución binomial

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donde:

- n: número total de ensayos o repeticiones del experimento
- k: número de éxitos observados
- p: probabilidad de éxito en un solo ensayo

- $1 - p$: probabilidad de fracaso

Coeficiente binomial

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$$

donde:

- $n = 1, 2, \ldots$: número total de ensayos
- $k = 0, 1, 2, \ldots, n$: número de éxitos posibles
- Para cualquier número entero m, $m! = m \times (m-1) \times (m-2) \times \cdots \times 1$

Tabla resumen de la binomial

Símbolo	Significado	Expresión
$P(X \leq k)$	"como mucho k"	$P(X \leq k)$
$P(X < k)$	"menos de k"	$P(X \leq k-1)$
$P(X \geq k)$	"al menos k"	$1 - P(X \leq k-1)$
$P(X > k)$	"más de k"	$1 - P(X \leq k)$

Si la variable aleatoria sigue una distribución $X \sim \text{Binomial}(n, p)$, entonces:

- **Media**

$$\mu = n \times p$$

- **Varianza**

$$\sigma^2 = n \times p \times (1-p)$$

Distribución normal

Si la variable aleatoria sigue una distribución $X \sim N(\mu, \sigma^2)$, entonces:

- μ representa la **media**
- σ representa la **desviación estándar**

Estandarización

Si una variable aleatoria X sigue una distribución normal con media μ y varianza σ^2, $X \sim N(\mu,\ \sigma^2)$, entonces la variable estandarizada:

$$Z = \frac{X - \mu}{\sigma}$$

sigue una distribución normal estándar: $Z \sim N(0, 1)$.

Para pasar de un valor Z a la escala original:

$$X = \sigma Z + \mu$$

Probabilidades complementarias y simetría

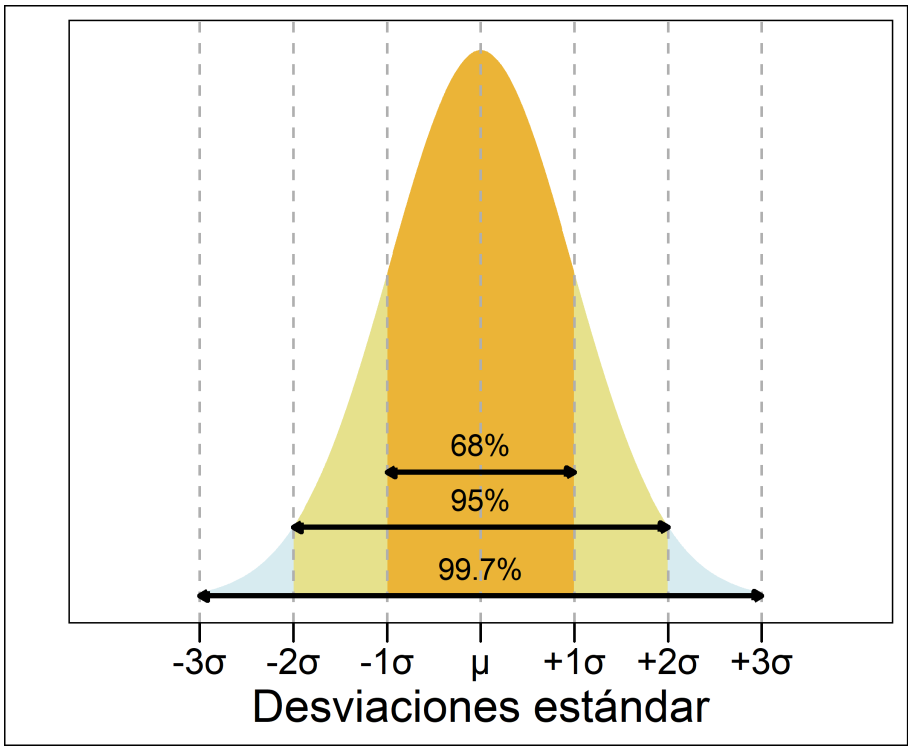
$$P(Z \leq z) = 1 - P(Z \geq z) \qquad P(Z \leq -z) = P(Z \geq z)$$

$$P(a \leq Z \leq b) = P(Z \leq b) - P(Z \leq a) = P(Z \geq a) - P(Z \geq b)$$

Tabla resumen de la normal

Símbolo	Significado	Expresión
$P(X \leq x)$	"como mucho x"	$P(X \leq x)$
$P(X < x)$	"menos de x"	$P(X \leq x)$ (igual, continua)
$P(X \geq x)$	"al menos x"	$1 - P(X \leq x)$
$P(X > x)$	"más de x"	$1 - P(X \leq x)$
$P(a \leq X \leq b)$	"entre a y b"	$P(X \leq b) - P(X \leq a)$
$P(a < X < b)$	"entre a y b"	$P(X \leq b) - P(X \leq a)$ (igual, continua)

Regla empírica ("68-95-99.7"):



- ~68% de los valores dentro de 1 desviación estándar de la media
- ~95% dentro de 2 desviaciones estándar
- ~99.7% dentro de 3 desviaciones estándar

Distribución de Poisson

Fórmula de la distribución de Poisson

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}$$

donde:

- X: número de eventos en un intervalo dado
- λ: tasa esperada de eventos en ese intervalo ($n \times p$)
- k: número de eventos observados

Si la variable aleatoria sigue una distribución de Poisson $X \sim \text{Poisson}(\lambda)$, entonces:

- λ representa tanto la media como el parámetro de la distribución: $\mu = \lambda$
- La desviación estándar es: $\sigma = \sqrt{\lambda}$

La probabilidad de exactamente k eventos en t unidades de tiempo es:

$$P(X = k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!}$$

En t unidades de tiempo, la media es $\mu = \lambda t$ y desviación estándar $\sigma = \sqrt{\lambda t}$.

Si λ es una tasa por individuo, el número esperado de eventos en una población de N individuos durante t unidades de tiempo es:

$$\mu = \lambda t N$$

Tabla resumen de la distribución de Poisson

Símbolo	Significado	Expresión
$P(X \leq k)$	"como mucho k"	$P(X \leq k)$
$P(X < k)$	"menos de k"	$P(X \leq k-1)$
$P(X \geq k)$	"al menos k"	$1 - P(X \leq k-1)$
$P(X > k)$	"más de k"	$1 - P(X \leq k)$

Tabla resumen de las distribuciones

	Binomial	Normal	Poisson
Parámetros	n, p	μ, σ	λ
Valores posibles	$0, 1, \ldots, n$	$(-\infty, \infty)$	$0, 1, \ldots, \infty$
Media	np	μ	λ
Desviación estándar	$\sqrt{np(1-p)}$	σ	$\sqrt{\lambda}$ ($\sqrt{\lambda t}$)

Intervalos de confianza

Distribución muestral de la media

Si $X \sim N(\mu, \sigma^2)$, la media muestral sigue $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, con:

$$\mu_{\bar{X}} = \mu \qquad\qquad \sigma_{\bar{X}} = SE = \frac{\sigma}{\sqrt{n}}$$

Error estándar (SE): si solo tenemos la desviación estándar muestral,

$$SE \approx \frac{s}{\sqrt{n}}$$

Estadístico z para una media muestral

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$$

donde:

- $\bar{x}$: media muestral
- μ: media poblacional (bajo H_0, μ_0)
- σ: desviación estándar poblacional
- n: tamaño de la muestra

Intervalo de confianza (IC) bilateral

$$IC = (\bar{x} - m, \bar{x} + m) = \bar{x} \pm m$$

donde m es el **margen de error**:

$$m = z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}} \qquad \left(\text{o } m = z_{\alpha/2} \times \frac{s}{\sqrt{n}}\right)$$

Por lo tanto, los límites del IC son:

$$x_1 = \bar{x} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \quad x_2 = \bar{x} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$

Intervalos de confianza unilaterales (*one-sided*)

- Proporcionan **un límite inferior o un límite superior**, pero **no ambos**. Todo el α va en una sola cola, por eso se usa z_α (y no $z_{\alpha/2}$):

$$(-\infty,\ \bar{x} + z_\alpha \times SE) \quad \text{o} \quad (\bar{x} - z_\alpha \times SE,\ \infty)$$

Valores críticos de z

Nivel de confianza	α	Bilateral: $z_{\alpha/2}$	Unilateral: z_{α}
90%	0.10	1.645	1.28
95%	0.05	1.96	1.645
99%	0.01	2.576	2.33

Tamaño de muestra para un error máximo E

$$n \geq \left(\frac{z_{\alpha/2} \times \sigma}{E} \right)^2$$

Contraste de hipótesis

Tipos de error

Decisión	H_0 cierta	H_A cierta
No rechazamos H_0	Correcto ($1-\alpha$)	Error tipo II (β), falso negativo
Rechazamos H_0	Error tipo I (α), falso positivo	Correcto ($1-\beta$) = **potencia**

Regla de decisión (con el valor crítico del estadístico)

- Si $|\text{estadístico}| \geq$ valor crítico (o p-valor $\leq \alpha$) → **rechazamos H_0**
- Si $|\text{estadístico}| <$ valor crítico (o p-valor $> \alpha$) → **no rechazamos H_0**

p-valor de un test de permutación

$$\text{p-valor} = \frac{\#\{|\text{dif}_{perm}| \geq |\text{dif}_{obs}|\}}{n_{perm}}$$

donde:

- dif_{obs}: diferencia observada entre los grupos
- dif_{perm}: diferencias obtenidas al permutar (barajar) las etiquetas de los grupos
- n_{perm}: número de permutaciones

T-test

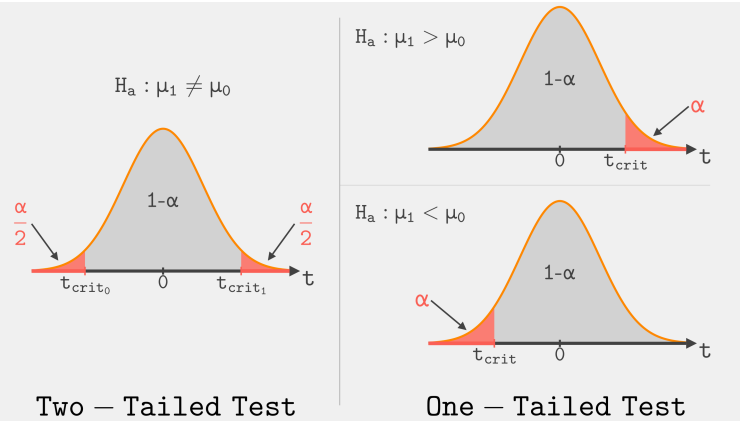
Tablas resumen para t-test

Tipo de t-test	Estadístico t	Grados de libertad (df)	Intervalo de confianza (IC)
1 muestra	$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$n - 1$	$\bar{x} \pm t_{\alpha/2,\, df} \frac{s}{\sqrt{n}}$
Pareado	$t = \frac{\bar{x}_{dif}}{s_{dif}/\sqrt{n}}$	$n - 1$	$\bar{x}_{dif} \pm t_{\alpha/2,\, df} \frac{s_{dif}}{\sqrt{n}}$
2 muestras independientes*	$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	Welch-Satterthwaite	$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2,\, df} \sqrt{s_1^2/n_1 + s_2^2/n_2}$

*Fórmula de Welch (por defecto en R). Si asumimos varianzas iguales (t-test de Student), $df = n_1 + n_2 - 2$ y se usa s_p^2 (ver abajo).

Tipo de t-test	Hipótesis nula (H_0)	Hipótesis alternativa (H_A)
1 muestra	$\mu = \mu_0$	$\mu \neq \mu_0$
Pareado	$\mu_{dif} = 0$	$\mu_{dif} \neq 0$
2 muestras independientes	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$

Tipo de test	Hipótesis	IC / Zona crítica	Interpretación
Bilateral (dos colas)	$H_0 : \mu = \mu_0$ $H_A : \mu \neq \mu_0$	$IC = \bar{x} \pm \lvert t_{crit} \rvert \times SE$	IC simétrico alrededor de $\bar{x}$. Si μ_0 **no está dentro**, se rechaza H_0.
Unilateral (cola derecha)	$H_0 : \mu = \mu_0$ $H_A : \mu > \mu_0$	$IC = (\bar{x} - \lvert t_{crit} \rvert \times SE, +\infty)$	Si límite inferior > μ_0, se rechaza H_0.
Unilateral (cola izquierda)	$H_0 : \mu = \mu_0$ $H_A : \mu < \mu_0$	$IC = (-\infty, \bar{x} + \lvert t_{crit} \rvert \times SE)$	Si límite superior < μ_0, se rechaza H_0.



IC unilaterales con la distribución t (una muestra, $df = n - 1$)

$$\text{Límite superior: } \mu \leq \bar{x} + t_{\alpha,\, n-1} \times \frac{s}{\sqrt{n}} \qquad \text{Límite inferior: } \mu \geq \bar{x} - t_{\alpha,\, n-1} \times \frac{s}{\sqrt{n}}$$

Decisión (bilateral): si $|t| > t_{crit}$ → rechazamos H_0; si $|t| \leq t_{crit}$ → no rechazamos H_0.

t-test de 2 muestras independientes con varianzas iguales (Student)

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \qquad s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2} \qquad df = n_1 + n_2 - 2$$

donde:

- s_p^2: varianza combinada (*pooled*)

t-test de Welch (varianzas desiguales): grados de libertad de Welch-Satterthwaite

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$$

Tests no paramétricos

Test de Mann-Whitney (Wilcoxon de suma de rangos): alternativa al t-test de 2 muestras independientes

1. Juntamos los valores de los dos grupos, los ordenamos y les asignamos un rango (1 al más pequeño; si hay empates, el rango medio).
2. Sumamos los rangos de cada grupo (R_1 y R_2).

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2} \qquad U_2 = R_2 - \frac{n_2(n_2 + 1)}{2} \qquad U = \min(U_1, U_2)$$

Comprobaciones: $U_1 + U_2 = n_1\, n_2$ y $R_1 + R_2 = \frac{N(N+1)}{2}$, con $N = n_1 + n_2$.

Aproximación normal de U

$$\mu_U = \frac{n_1\, n_2}{2} \qquad \sigma_U = \sqrt{\frac{n_1\, n_2\, (n_1 + n_2 + 1)}{12}} \qquad z = \frac{U - \mu_U}{\sigma_U}$$

Si $|z| \geq z_{\alpha/2}$ (1.96 para $\alpha = 0.05$ bilateral) → rechazamos H_0.

Test de Wilcoxon de rangos con signo: alternativa al t-test pareado

1. Calculamos la diferencia de cada par, $d_i = x_{2i} - x_{1i}$, y descartamos las diferencias iguales a 0.
2. Ordenamos las diferencias en **valor absoluto** $|d_i|$ y les asignamos un rango.
3. Sumamos los rangos de las diferencias positivas (T^+) y de las negativas (T^-).

$$T^+ = \sum_{d_i > 0} \text{rango}(|d_i|) \qquad T^- = \sum_{d_i < 0} \text{rango}(|d_i|) \qquad W = \min(T^+, T^-)$$

Comprobación: $T^+ + T^- = \frac{n(n+1)}{2}$ (n: número de pares con diferencia distinta de 0).

Aproximación normal de W

$$\mu_W = \frac{n(n+1)}{4} \qquad \sigma_W = \sqrt{\frac{n(n+1)(2n+1)}{24}} \qquad z = \frac{W - \mu_W}{\sigma_W}$$

Diseño	Test paramétrico	Alternativa no paramétrica	*Post hoc*
2 muestras independientes	t-test (Welch)	Mann-Whitney	—
2 muestras pareadas	t-test pareado	Wilcoxon de rangos con signo	—
$\geq$ 3 grupos (1 factor)	ANOVA de una vía	Kruskal-Wallis	Dunn (con corrección de p-valores)

Tamaño del efecto y potencia

d de Cohen

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p} \qquad s_p = \sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}}$$

donde:

- s_p: desviación estándar combinada (*pooled*)

$\lvert d \rvert$	**Efecto (guía orientativa de Cohen)**
< 0.2	trivial
$0.2 - 0.5$	pequeño
$0.5 - 0.8$	medio
≥ 0.8	grande

Tamaño de muestra necesario (2 grupos)

$$n = \frac{2\,(Z_{\alpha/2} + Z_{\beta})^2}{d^2} \quad \text{por grupo}$$

donde:

- $Z_{\alpha/2}$: 1.96 para $\alpha = 0.05$ (bilateral); 2.58 para $\alpha = 0.01$
- Z_{β}: 0.84 para potencia del 80%; 1.28 para potencia del 90%

Potencia para un n dado

$$Z_{\beta} = d\sqrt{\frac{n}{2}} - Z_{\alpha/2} \qquad \text{Potencia} = 1 - \beta = P(Z \leq Z_{\beta})$$

ANOVA

ANOVA de una vía

Fuente de variación	Suma de cuadrados (SS)	Grados de libertad (gl)	Media cuadrática (MS)	Estadístico F
Factor (variabilidad entre grupos)	$SS_{entre} = \sum_{i=1}^{g} n_i (M_i - G)^2$	$gl_{entre} = g - 1$	$MS_{entre} = \frac{SS_{entre}}{gl_{entre}}$	$F = \frac{MS_{entre}}{MS_{dentro}}$
Residuos (variabilidad dentro de los grupos)	$SS_{dentro} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - M_i)^2$	$gl_{dentro} = N - g$	$MS_{dentro} = \frac{SS_{dentro}}{gl_{dentro}}$	
Total	$SS_{total} = \sum_{i=1}^{g} \sum_{j=1}^{n_i} (x_{ij} - G)^2$	$gl_{total} = N - 1$		

Donde:

- G = media global (media conjunta de todos los grupos)
- M_i = media del grupo *i*
- n_i = tamaño del grupo *i*
- g = número de grupos
- N = número total de observaciones

Hipótesis y decisión

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_g \qquad H_A : \text{al menos una } \mu_i \text{ es diferente}$$

Si $F_{obs} > F_{crit}(gl_{entre},\ gl_{dentro})$ (tabla F, $\alpha = 0.05$) o p-valor $\leq \alpha \rightarrow$ **rechazamos** $H_0 \rightarrow$ test *post hoc* (Tukey) para saber qué grupos difieren.

Coeficiente de determinación y tamaño del efecto

$$\eta^2 = R^2 = \frac{SS_{entre}}{SS_{total}}$$

η^2	**Efecto (guía orientativa de Cohen)**
0.01	pequeño
0.06	mediano
≥ 0.14	grande

ANOVA de dos vías

Fuente de variación	Grados de libertad (gl)	Media cuadrática (MS)	Estadístico F
Factor A	$gl_A = p - 1$	$MS_A = \dfrac{SS_A}{gl_A}$	$F_A = \dfrac{MS_A}{MS_{error}}$
Factor B	$gl_B = q - 1$	$MS_B = \dfrac{SS_B}{gl_B}$	$F_B = \dfrac{MS_B}{MS_{error}}$
Interacción A×B	$gl_{AB} = (p-1)(q-1)$	$MS_{AB} = \dfrac{SS_{AB}}{gl_{AB}}$	$F_{AB} = \dfrac{MS_{AB}}{MS_{error}}$
Error (residuos)	$gl_{error} = p\,q\,(n-1)$	$MS_{error} = \dfrac{SS_{error}}{gl_{error}}$	
Total	$gl_{total} = n\,p\,q - 1$		

Donde:

- p = número de niveles del factor A; q = número de niveles del factor B
- n = número de réplicas por combinación de niveles

Cada F se compara con $F_{crit}(gl_{efecto},\ gl_{error})$. Tamaño del efecto de cada factor (eta cuadrado parcial): $\eta_p^2 = \dfrac{SS_A}{SS_A + SS_{error}}$

Correlación

Coeficiente de correlación de Pearson (relación **lineal** entre dos variables cuantitativas)

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\,\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \qquad -1 \le r \le 1$$

Valor absoluto de r	Interpretación
< 0.1	No correlación
$0.1 - 0.3$	Correlación baja
$0.3 - 0.5$	Correlación media
$0.5 - 0.7$	Correlación alta
$0.7 - 1.0$	Correlación muy alta

El **signo** de r indica la dirección (positiva o negativa); su **valor absoluto**, la fuerza.

Test de la correlación

$$H_0 : \rho = 0 \qquad H_A : \rho \neq 0 \qquad t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \qquad gl = n - 2$$

donde:

- ρ: correlación en la **población**; r: correlación en la **muestra**
- Si $|t| > t_{crit}$ (dos colas) → rechazamos H_0: la correlación es significativa
- Requiere que ambas variables sean aproximadamente **normales**; si no, se usa Spearman

Coeficiente de correlación de Spearman (relación **monótona**; usa los **rangos**, no paramétrico)

$$r_s = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \qquad d_i = R(x_i) - R(y_i)$$

donde:

- $R(x_i)$, $R(y_i)$: rangos de cada valor dentro de su variable (fórmula válida si **no hay empates**)
- $-1 \leq r_s \leq 1$; se interpreta igual que r

Regresión lineal

Regresión lineal simple

$$\hat{y} = a + b\,x \qquad b = r \cdot \frac{s_y}{s_x} \qquad a = \bar{y} - b\,\bar{x}$$

donde:

- $\hat{y}$: valor **predicho** de la variable dependiente; x: variable independiente
- b (**pendiente**): cambio en $\hat{y}$ cuando x aumenta 1 unidad
- a (**ordenada en el origen**): valor de $\hat{y}$ cuando $x = 0$ (a menudo sin sentido biológico)
- s_x, s_y: desviaciones típicas de x y de y
- Solo se puede predecir **dentro del rango observado** de x (no extrapolar)

Residuo y mínimos cuadrados

$$e_i = y_i - \hat{y}_i \qquad \text{La recta de regresión minimiza } \sum_{i=1}^{n} e_i^2$$

Contraste de la pendiente: $H_0 : b = 0$ (no hay relación) frente a $H_A : b \neq 0$. Si p-valor $\leq \alpha \rightarrow$ la relación es significativa.

Supuestos (se comprueban sobre los **residuos**): linealidad, independencia, homocedasticidad (varianza constante) y normalidad.

Bondad del ajuste

$$R^2 = \frac{SS_{explicada}}{SS_{total}} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2} \qquad \text{En la regresión simple: } R^2 = r^2$$

donde:

- R^2 (**coeficiente de determinación**, `Multiple R-squared`): proporción de la variabilidad de y explicada por el modelo ($0 \leq R^2 \leq 1$). No indica la **dirección** de la relación
- R^2 **ajustado** (`Adjusted R-squared`): corrige por el número de variables independientes; es el que se usa para comparar modelos con distinto número de variables
- **Error estándar de la estimación** (`Residual standard error`): distancia media entre los valores observados y los predichos, en las unidades de y

Regresión lineal múltiple

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \cdots + b_k x_k$$

donde:

- b_i: cambio en $\hat{y}$ cuando x_i aumenta 1 unidad **y las demás variables se mantienen constantes**
- R **múltiple**: correlación entre los valores predichos $\hat{y}$ y los observados y ($R = \sqrt{R^2}$)

Coeficientes estandarizados (para comparar la influencia de variables con unidades distintas)

$$\beta_i = b_i \cdot \frac{s_{x_i}}{s_y}$$

La variable con mayor $|\beta_i|$ es la que más influye en y.

Multicolinealidad: tolerancia y VIF

$$T_i = 1 - R_i^2 \qquad\qquad VIF_i = \frac{1}{T_i} = \frac{1}{1 - R_i^2}$$

donde:

- R_i^2: R^2 de la regresión de x_i sobre las demás variables independientes
- **Cuidado** si $T < 0.1$ o $VIF > 10$: las variables aportan la misma información

Variables *dummy* (variables independientes categóricas)

- Una variable con k categorías se convierte en $k - 1$ variables *dummy* (0/1)
- La categoría que no tiene *dummy* es la **referencia**: la ordenada a es su media
- Cada coeficiente b_i es la **diferencia** de la categoría i respecto a la referencia

Variables independientes	Modelo	En `R`
Un factor	ANOVA de una vía	`lm(y ~ grupo)`
Dos factores	ANOVA de dos vías	`lm(y ~ A * B)`
Una variable numérica	Regresión lineal simple	`lm(y ~ x)`
Varias variables numéricas	Regresión lineal múltiple	`lm(y ~ x1 + x2 + x3)`
Numéricas y factores	Regresión con variables *dummy*	`lm(y ~ x + grupo)`